

제 1 장

기초통계이론

- 1.1 기본용어
- 1.2 자료의 기초적 분석
- 1.3 확률변수와 확률표본
- 1.4 통계적 추정과 검정
- 1.5 테일러 근사법
- 1.6 다중검정

2 제 1 장 기초통계이론

본 장에서는 회귀분석에서 필요로 하는 통계학의 기초개념을 정리하여 설명한다. 대부분의 이론들은 기초통계학 과정에서 이미 소개된 내용들이며, 그 외에 확률변수들의 선형함수의 분포, 확률벡터, 다변량정규분포, 통계적 근사이론 등에 대한 내용들이 추가된다. 독자들은 이들 내용을 대략적으로 훑어 본 뒤에 본문에서 구체적으로 사용될 때 다시 복습하는 것이 좋을 것이다.

1.1 기본 용어

1.1.1 모집단과 표본

통계학에서는 어떤 분석대상이나 문제가 있을 때 그것과 관련된 가능한 정보를 모두 수집하여 분석한 후 과학적이고 객관적인 의사결정의 근거를 제공하여 준다고 할 수 있다. 통계학에서는 이 분석대상이나 문제에 대한 정보를 관측할 수 있는 집단을 모집단(population)이라 부른다. 이를테면, 어느 대학교 학생들의 적성에 관한 분석에서는 그 학교 학생전체가 모집단이 되며, 어느 생산공정에서 생산품의 특성에 관한 분석에서는 생산품 전체가 모집단을 형성한다. 정확한 분석결과를 얻기 위해서는 모집단에 대한 많은 정보가 요구되나 일반적으로 시간이나 비용의 제약을 받으므로 우리가 분석에 이용할 수 있는 정보량에는 한계가 있다. 모집단의 원소들 중에서 정보를 수집하기 위하여 추출되어 관측되는 원소들의 집합을 표본(sample)이라 한다. 예를 들어, 학생들의 적성에 관한 분석에서 전체학생 중에서 100명을 추출하여 조사하든지, 또는 생산품의 특성에 관한 분석에서 50개의 생산품을 추출하여 특성값을 관측하면 이들이 표본을 형성한다. 추출되는 표본의 크기는 분석에서 허용된 예산, 또는 요구되는 결과의 정확도 등에 의하여 결정된다.

앞의 예제들과 같이 모집단의 일부만 표본으로 추출하여 분석하는 것을 표본조사(sampling survey)라 한다. 이와는 달리 인구조사와 같은 분석에서는 모집단 전체를 관측하게 되는데(즉, 모집단과 표본이 동일) 이를 전수조사(census)라 한다. 일반적으로 잘 계획된 표본조사는 전수조사보다 더욱 정확한 분석결과를 제공하여 준다.

1.1.2 변수의 분류

모집단에서 표본을 추출하여 정보를 얻는다는 것은 모집단의 각 원소에 대해 문제와 관련된 특성들의 값을 관측하는 것이다. 이를테면, 학생들의 적성에 관한 분석에서 관측되는 값은 학생들의 성별, 학년, 전공, 적성검사의 점수 등을 관측할 수 있다. 이와 같이 분석에 이용하기 위하여 관측되는 모집단원소의 특성들을 변수(variable)라 한다. 변수는 관측되는 원소의 특성에 따라 다양한 형태의 값을 가질 수 있다. 위의 학생들의 적성에 관한 분석에서 성별을 나타내는 변수는 ‘여’, ‘남’, 또는 ‘0’, ‘1’, 또는 ‘F’, ‘M’의 값을 가질 수 있고, 학년은 ‘1’, ‘2’ 또는 ‘1’, ‘2’, ‘3’, ‘4’의 값들을, 그리고 적성검사 점수는 0에서 50까지의 값을 가진다고 할 수 있다.

변수가 갖는 값들의 종류에 따라 적용되는 통계적 분석방법이 달라질 수 있으므로 사전

4 제 1 장 기초통계이론

에 각 문제에서 관측되는 변수들의 값의 성격을 명확하게 규정짓는 것이 중요하다. 그러므로 변수의 종류를 갖는 값들에 따라 여러 가지로 분류하는 방법이 있는데 이 책에서는 크게 질적변수와 양적변수로 구분한다.

질적변수(qualitative variable)는 명목형 변수(nominal variable)와 순서형 변수(ordinal variable)로 구분한다. 명목형 변수는 성별이나 혈액형 처럼 순서의 개념이 전혀 없고 단지 구분하기 위한 것이다. 반면 순서형 변수는 좋아하는 정도나 암의 진행상태(초기, 중기, 말기)처럼 순서의 개념을 가진 변수인데 이 경우 숫자로 변환할 때 순서가 반드시 고려되어야 한다. 즉, 초기, 중기, 말기를 1, 2, 3 처럼 순서의 의미를 부여하여 변환해야지 3, 1, 2와 같이 순서의 개념을 무시하면 곤란하다.

양적변수(quantitative variable)는 관측된 값이 수의 개념을 갖는 것으로 점수, 신장, 농도 등과 같은 양을 나타내는 변수들이다. 양적변수를 더 세분화하여 고객의 수, 불량품의 수 등과 같이 모든 가능한 관측값들이 유한개 또는 셀 수 있는 형태로 주어지는 이산형 변수(discrete variable), 신장, 농도 등과 같이 모든 가능한 관측값들이 셀 수 없는 실수 형태로 주어지는 연속형 변수(continuous variable)로 구분하기도 한다. 양적변수의 값들은 수의 개념을 갖고 있으므로 수학 연산을 적용할 수 있어 평균, 분산 등을 구하여 사용할 수 있다. 회귀분석에서는 대체로 연속형 변수들 간의 관계를 규명하는데 사용되었으나 최근에는 회귀분석의 개념이 확장되어 이산형 변수에 대한 분석에도 널리 사용되고 있다.


1.2 자료의 기초적 분석

모집단에서 표본을 추출하여 분석과 관련된 변수들의 값을 관측한 후에는 이들 관측값에서 필요한 정보를 얻기 위하여 통계적 분석방법을 적용시킨다. 이 절에서는 기초적 분석방법으로 표와 그림을 이용한 방법과 기본적인 측도를 이용한 방법을 소개한다. 이들 분석방법은 간단하면서도 모집단에 대한 중요한 정보를 제공하므로 회귀분석의 경우에도 사전분석으로 반드시 실시할 필요가 있다.

1.2.1 표와 그림을 이용한 자료분석

통계분석의 궁극적인 목적은 모집단의 특성을 밝히는 것이다. 특히 분석의 대상인 변수가 있을 때 이 변수의 특성을 밝히는 것은 이 변수가 가질 수 있는 값들이 어떠한 형태를 하고 있는가 하는 것으로 이를 변수의 분포(distribution)라 한다. 이 분포는 식이나 그림으로 나타낼 수 있는데 이를테면 (그림 1.1)은 통계학에서 다루는 분포의 세 가지 대표적인

형태를 보여준다. (그림 1.1)에서 첫 번째 분포는 좌우대칭형으로 대부분의 값들이 중심 근처에 몰려 있음을 의미한다. 예를 들어, 20세 남자의 신장은 이 분포를 가진다고 할 수 있다. 두 번째 분포는 값들이 왼쪽에 많이 몰려 있는 형태로 일반적으로 소득의 분포가 여기에 해당된다. 이와는 반대로 세 번째 분포는 값들이 오른쪽에 많이 몰려 있는 형태로 예를 들면, 쉽게 출제된 수능시험 성적의 분포가 여기에 해당된다고 할 수 있다. 그러나 대부분의 경우 자료의 정확한 분포는 알 수 없으므로 우리는 경험이나 이론에 의해 변수의 분포를 가정하거나, 또는 관찰된 자료로부터 그 분포의 형태를 추정해야한다.



(그림 1.1) 분포의 세 가지 형태


표와 그림을 이용하여 분포를 추정하는 방법에서는 기본적으로 도수분포표(frequency table), 막대그래프(bar graph), 히스토그램(histogram) 등을 사용하며 그 외에도 원형 차트(pie chart), 점도표(dot diagram), 줄기-잎 그림(stem-and-leaf plot), 상자그림(box plot) 등을 사용할 수 있다. 이들 표와 그림의 작성방법 및 해석방법에 대한 자세한 설명은 참고문헌(강근석 외, 1994)을 참조하기 바라며 여기에서는 몇 가지 예제만 든다. 예를 들어, <표 1.1>에는 어느 대학교 신입생들 중에서 추출한 500명의 신장측정치에 대한 도수 분포표가 주어져 있으며, (그림 1.2)에는 이 자료에 대한 히스토그램과 상자그림이 주어져 있다. 이 표와 그림에서 표본의 분포가 대략적으로 좌우대칭이므로, 우리는 신입생 전체의 신장도 이와 비슷하게 좌우대칭인 분포형태를 가진다고 추론할 수 있다.

<표 1.1> 대학 신입생 500명 신장측정치의 도수분포표

구 간	도 수
157.5 ~ 162.5	13
162.5 ~ 167.5	75
167.5 ~ 172.5	186
172.5 ~ 177.5	168
177.5 ~ 182.5	50
182.5 ~ 187.5	7
187.5 ~ 192.5	1


만약 분석에 포함된 변수가 두 개 이상인 경우에는 분할표(contingency table)와 산점도(scatter plot)를 이용하여 정리할 수 있다. 특히 산점도는 회귀분석에서 중요하게 사용

6 제 1 장 기초통계이론



(그림 1.2) 대학 신입생 500명 신장측정치의 히스토그램과 상자그림

되는 그림으로 한 변수를 X 축, 다른 변수를 Y 축으로 하여 각각의 관찰값을 XY 평면상의 좌표값으로 하여 점으로 나타낸 것이다. 이 산점도는 두 변수의 관계에 대한 중요한 정보를 제공하여 준다. (그림 1.3)은 어느 식물의 시간에 따른 성장치를 반복관측한 자료에 대한 산점도로 우리는 두 변수들이 비선형함수 관계를 가지고 있음을 알 수 있다.



(그림 1.3) 두 변수간의 산점도

1.2.2 기본적 측도를 이용한 자료분석

모집단이나 변수의 통계적 특성은 어떤 수치로 표현될 수 있는데 이를 모수(parameter)라 한다. 모수의 예로는 모집단의 중심위치를 나타내는 평균, 중간값, 최빈값과 값들이 중심에서 퍼져있는 정도, 즉 산포도를 나타내는 범위, 편차, 표준편차, 분산 등이 있다. 이들 모수의 값은 대부분의 경우 알려져 있지 않으므로 표본을 이용하여 이들 값을 추정하게 된다. 모수에 대응하여 표본의 특성을 나타내는 수치를 통계량(statistic)이라 한다. 통계량은 표본을 이용하여 계산되므로 각 모수에다 ‘표본’을 붙여 통계량을 나타낸다. 예를 들어, 표본평균, 표본분산 등은 통계량을 나타낸다. 회귀분석에서는 평균, 표준편차와 분산을 주로 사용한다. 이들 측도에 대한 자세한 설명은 강근석 외(1994)를 참조하기 바란다.

두 개 이상 변수들의 관계에 대한 측도로는 공분산과 상관계수 등이 사용된다. 이 두 측도에 대한 설명은 뒤에서 자세히 주어진다(1.3.3절과 2.9절 참조).

1.3 확률변수와 확률표본

앞 절에서 질적변수의 경우는 관측결과가 대부분 기호로 표시되었다. 그러나 이들 변수에 대한 분석에서도 수치적인 결과가 사용되는 것이 일반적이다. 예를 들어, ‘앞면’, ‘뒷면’으로 표시되는 동전던지기의 경우에는 동전의 공정성을 알아보기 위하여 100번을 던졌을 때 나타나는 앞면의 횟수가 관심의 대상이며, 혈액형의 경우는 혈액형의 분포를 조사하기 위하여 1000명을 조사했을 때 각 혈액형을 갖는 사람 수가 분석의 대상이 된다. 양적변수의 경우는 당연히 결과가 숫자로 관측되므로 통계학에서는 대개 수치적인 결과를 갖고 분석을 하게 되는데 이를 위하여 확률변수라는 개념을 사용한다. 확률변수(random variable)는 분석대상인 변수들이 갖는 각 결과에 하나의 실수값을 대응시켜주는 함수라고 정의된다. 여기에서 확률(random)의 의미는 확률변수의 값은 실제로 관측하기 전에는 어떠한 값이 될지는 알 수 없다는 것이다. 이를테면, 공정한 동전을 100번 던질 때 앞면이 나올 횟수는 실제로 던져보기 전에는 알 수가 없다.

확률변수도 일종의 변수이므로 평균과 분산 등을 정의하여 구할 수 있다. 특히 확률변수의 평균을 기댓값(expected value)이라고 부른다. 그리고 이러한 측도 등을 계산하는 수학적 방법이 달라지므로 양적변수에서의 분류와 같이, 변수가 가지는 값들이 이산형으로 주어지면 이산확률변수(discrete random variable), 연속형으로 주어지면 연속확률변수(continuous random variable)로 나누어 구분한다.

앞에서 언급한대로 확률변수의 값은 사전에 알 수 없지만 우리는 각 가능한 값에 대한

확률을 구할 수는 있다. 공정한 동전을 100번 던지는 예제에서 앞면이 나올 횟수는 실제로 던져보기 전에는 알 수가 없지만, 예를 들어, 앞면이 30번 나올 확률이 얼마인지는 계산을 할 수 있다. 이와 같이 확률변수의 모든 가능한 값에 확률을 대응시킬 수 있는데 이것을 확률변수의 **확률분포**(probability distribution)라 한다. 확률분포는 이산확률변수의 경우 표, 그림, 수식으로 나타내어지며, 연속확률변수의 경우는 그림 또는 수식으로 주어진다.

1.3.1 확률변수의 기댓값과 분산

확률변수 Y 의 기댓값은 $E[Y]$ 라 나타내며 다음과 같이 정의된다. d 개의 가능한 값 $y_1, y_2, \dots, y_d$ 을 갖는 이산확률변수 Y 의 확률분포는 확률함수

$$f_Y(y_i) = \Pr[Y = y_i], \quad i = 1, 2, \dots, d$$

로 주어지며 기댓값은 합기호를 이용하여 다음과 같이 정의된다.

$$E[Y] = \sum_{i=1}^d y_i f_Y(y_i)$$

즉, 이산확률변수 Y 의 기댓값은 $f_Y(y_i)$ 가 가중치로 주어지는 가중평균임을 알 수 있다. 확률변수의 기댓값은 보통 기호 μ_Y 로 나타내기도 한다.

연속확률변수의 경우는 확률변수의 가능한 값이 무한개이므로 각 점에서의 확률은 무의미하다(실제로 한 점에서의 확률은 0으로 간주된다). 대신 확률변수의 값이 어느 구간에 있을 확률을 생각하게 된다. 연속확률변수의 확률분포는 **확률밀도함수**(probability density function)라는 함수로 나타내어진다. 연속확률변수 Y 의 확률밀도함수를 $f_Y(y)$ 라 하면 기댓값은

$$E[Y] = \int_{-\infty}^{\infty} y f_Y(y) dy$$

으로 정의된다. 지금부터는 모두 연속확률변수의 경우만을 생각하기로 하자. 그렇지만 모든 성질은 이산확률변수의 경우에도 똑같이 성립한다.

확률변수 Y 의 함수 $g(Y)$ 도 확률변수이며 기댓값은 다음과 같이 정의된다.

$$E[g(Y)] = \int_{-\infty}^{\infty} g(y) f_Y(y) dy$$

이 정의를 이용하면 기댓값함수의 다음과 같은 유용한 성질을 증명할 수 있다. 즉, a 와 b 를 상수라 하면

$$E[a + bY] = a + bE[Y]$$

가 성립한다.

확률변수 Y 의 분산(variance)은 σ_Y^2 또는 $Var(Y)$ 라 나타내며 함수 $(Y - E[Y])^2$ 의 기댓값으로 정의된다. 즉,

$$\sigma_Y^2 = Var(Y) = E[(Y - E[Y])^2]$$

그리고 분산의 제곱근 σ_Y 를 Y 의 표준편차(standard deviation)라 한다. 분산의 공식에서 제곱을 전개하여 정리하면 다음과 같은 유용한 관계식을 얻는다.

$$Var(Y) = E[Y^2] - (E[Y])^2$$

확률변수 Y 의 선형함수에 대하여 분산은 다음 성질을 갖는다. 상수 a 와 b 에 대해

$$Var(a + bY) = b^2 Var(Y)$$

가 성립한다. 이 식은 기댓값함수의 성질을 이용하면 쉽게 증명할 수 있다. 특히 $b = 1$ 인 경우는 Y 의 모든 값에 단순히 a 만큼 더해주는 것으로 Y 의 분포를 a 만큼 평행이동하는 것이므로 분산은 변하지 않게 된다. 기댓값과 분산의 성질을 이용하면 확률변수 Y 에서 평균을 빼고 표준편차를 나누어준 Y 의 선형함수

$$Z = \frac{Y - \mu_Y}{\sigma_Y}$$

는 평균이 0이고, 분산은 1인 확률변수임을 보일 수 있다. 이것을 표준화된 확률변수(standardized random variable)라 한다.

1.3.2 결합확률분포

두 개 이상의 확률변수들이 갖는 확률분포를 결합확률분포(joint probability distribution)라 한다. 예를 들어, 두 개의 연속확률변수 Y_1, Y_2 에 대해 결합확률밀도함수

$f(y_1, y_2)$ 가 정의되면 확률함수는

$$\Pr[Y_1 \leq y_1, Y_2 \leq y_2] = \int_{-\infty}^{y_1} \int_{-\infty}^{y_2} f(y_1, y_2) dy_2 dy_1$$

로 주어진다. 이에 대해, 각각의 확률변수가 갖는 분포를 **주변확률분포**(marginal probability distribution)라 하는데, 결합확률분포가 주어지면 주변확률분포는 쉽게 구해진다. 이를테면, 위에서 Y_1 의 주변확률분포가 갖는 확률밀도함수는 결합확률밀도함수 $f(y_1, y_2)$ 를 Y_2 의 전 구간에 대해 적분하면 얻어진다. 즉,

$$f_{Y_1}(y_1) = \int_{-\infty}^{\infty} f(y_1, y_2) dy_2$$

이와는 반대로 Y_1, Y_2 의 주변확률분포가 주어졌을 때 결합확률분포를 구하는 것은 일반적으로 쉽지 않다.

확률변수 Y_2 가 어떤 고정된 값 y_2 를 가진다는 조건 하에서 Y_1 이 갖는 확률분포를 **조건부확률분포**(conditional probability distribution)라 하며 확률밀도함수는 다음과 같이 정의된다.

$$f(y_1|Y_2 = y_2) = \frac{f(y_1, y_2)}{f_{Y_2}(y_2)}$$

즉, Y_2 의 값이 y_2 로 주어질 때 Y_1 의 조건부확률밀도함수는 Y_1, Y_2 의 결합확률밀도함수를 Y_2 의 주변확률밀도함수로 나눈 것으로 주어진다.

두 확률변수 Y_1, Y_2 의 결합확률밀도함수가 각각의 주변확률밀도함수의 곱으로 주어질 때, 즉,

$$f(y_1, y_2) = f_{Y_1}(y_1)f_{Y_2}(y_2)$$

이 성립하면 Y_1, Y_2 는 서로 **확률적으로 독립**(stochastically independent), 또는 간단히 독립(independent)이라 한다. Y_1, Y_2 가 서로 독립이면 다음 식이 성립한다.

$$E[Y_1 Y_2] = E[Y_1] \cdot E[Y_2] \quad (1.1)$$

즉, 두 확률변수들의 곱의 기댓값은 각 확률변수의 기댓값의 곱과 같다. 그리고 독립인 확률변수들의 함수들도 서로 독립이 된다. 즉, 서로 독립인 Y_1, Y_2 의 함수 $g(Y_1)$ 과 $h(Y_2)$ 도

서로 독립이다. 즉,

$$E[g(Y_1)h(Y_2)] = E[g(Y_1)]E[h(Y_2)]$$

이 성립한다.

확률변수들의 독립성은 주변확률분포가 주어졌을 때 결합확률분포를 쉽게 구할 수 있는 조건이다. 이를테면, 확률변수 Y_i ($i = 1, 2, \dots, n$)들이 서로 독립이고 각각 확률밀도함수 $f_{Y_i}(y_i)$ 를 갖는 확률분포를 따를 때 Y_i 들의 결합확률밀도함수는 다음과 같이 각 주변확률밀도함수들의 곱으로 주어진다.

$$\begin{aligned} f(y_1, y_2, \dots, y_n) &= f_{Y_1}(y_1)f_{Y_2}(y_2)\cdots f_{Y_n}(y_n) \\ &= \prod_{i=1}^n f_{Y_i}(y_i) \end{aligned}$$

특히, 확률변수 $Y_1, Y_2, \dots, Y_n$ 들이 서로 독립이고 같은 확률분포를 따를 때 이를 확률표본(random sample)이라 한다.

1.3.3 공분산과 상관계수

공분산(covariance)은 두 변수간의 선형관계를 나타내는 척도로 다음과 같이 정의된다. 즉, 두 확률변수 Y_1, Y_2 간의 공분산 $Cov(Y_1, Y_2)$ 는

$$Cov(Y_1, Y_2) = E[(Y_1 - \mu_{Y_1})(Y_2 - \mu_{Y_2})]$$

로 정의된다. 공분산의 의미를 파악하기 위해 Y_1 이 증가할 때 Y_2 도 증가하는 경우를 생각해 보자. 이 경우 μ_{Y_1} 보다 큰 Y_1 값에 대응하는 Y_2 값 역시 μ_{Y_2} 보다 크고, μ_{Y_1} 보다 작은 Y_1 값에 대응하는 Y_2 값 역시 μ_{Y_2} 보다 작다. 그래서, $(Y_1 - \mu_{Y_1})(Y_2 - \mu_{Y_2})$ 는 항상 양수값을 가지며 이들의 평균인 공분산 역시 양수값을 가진다. 이와는 반대로 한 변수의 값이 증가할 때 다른 변수의 값이 감소하면 공분산의 값은 음수가 된다는 것을 쉽게 알 수 있다. 그러므로 공분산은 양의 상관(즉, 한 변수의 값이 증가하면 다른 변수의 값도 증가)이나 음의 상관(즉, 한 변수의 값이 증가하면 다른 변수의 값은 감소)의 두 변수간의 상호관계를 알려주는 척도가 된다.

공분산의 공식에서 곱을 전개하여 정리하면 다음과 같은 유용한 관계식을 얻는다.

$$Cov(Y_1, Y_2) = E[Y_1 Y_2] - \mu_{Y_1} \mu_{Y_2}$$

12 제 1 장 기초통계이론

이 식에서 두 확률변수 Y_1, Y_2 가 서로 독립이면 식 (1.1)에 의하여 두 확률변수의 공분산은 0이 됨을 알 수 있다. 그러나 역은 일반적으로 성립하지 않는다. 다만, 나중에 소개되는 정규분포에서는 두 확률변수의 공분산이 0이면 독립이 성립한다.

공분산 자체도 좋은 척도이나 공분산은 Y_1 과 Y_2 의 단위에 의존하여 다른 자료와 비교할 때 불편하다는 단점이 있다. 변수의 종류나 특정단위에 관계없는 척도를 구하기 위해 공분산을 Y_1 과 Y_2 의 표준편차인 σ_{Y_1} 과 σ_{Y_2} 의 곱으로 나누어 표준화시키는데 이를 모집단 상관계수(population correlation coefficient)라 부르고 ρ 라고 표시한다.

모집단 상관계수 :

$$\rho = \frac{Cov(Y_1, Y_2)}{\sigma_{Y_1} \sigma_{Y_2}}$$

상관계수 ρ 는 다음과 같이 해석된다.

- (1) ρ 는 변수의 종류나 특정단위에 관계없는 척도로 -1 과 $+1$ 사이의 값을 가지며, ρ 의 값이 $+1$ 에 가까울수록 강한 양의 상관관계를, -1 에 가까울수록 강한 음의 상관관계를 나타내며, ρ 의 값이 0에 가까울수록 선형관계는 약해진다.
- (2) Y_1 과 Y_2 의 대응되는 모든 값들이 한 직선 상에 위치하면 ρ 의 값은 -1 (직선의 기울기가 음인 경우)이나 $+1$ (직선의 기울기가 양인 경우)의 값을 가진다.
- (3) 상관계수 ρ 는 단지 두 변수간의 선형관계만을 나타내는 척도이다. 그러므로 $\rho = 0$ 인 경우에 두 변수의 선형상관관계는 없지만 다른 관계는 가질 수 있다.

상관계수 ρ 의 추정과 가설검정의 문제는 뒤에서 다루도록 한다(2.9절 참조).

1.3.4 확률변수들의 선형결합

통계학에서 사용되는 척도들 중의 대부분은 확률변수 $Y_1, Y_2, \dots, Y_n$ 들의 선형함수

$$\sum_{i=1}^n a_i Y_i = a_1 Y_1 + a_2 Y_2 + \dots + a_n Y_n$$

로 나타내어진다. 이 선형함수도 하나의 확률변수이며 기댓값과 분산은 다음과 같다.

$$E\left[\sum_{i=1}^n a_i Y_i\right] = \sum_{i=1}^n a_i E[Y_i] \quad (1.2)$$

$$\text{Var}\left(\sum_{i=1}^n a_i Y_i\right) = \sum_{i=1}^n \sum_{j=1}^n a_i a_j \text{Cov}(Y_i, Y_j) \quad (1.3)$$

만약 Y_i 들이 서로 독립이면 $\text{Cov}(Y_i, Y_j) = 0$ ($i \neq j$) 이므로 다음 식이 성립한다.

$$\text{Var}\left(\sum_{i=1}^n a_i Y_i\right) = \sum_{i=1}^n a_i^2 \text{Var}(Y_i) \quad (1.4)$$

더욱 일반적인 경우로 확률변수 $Y_1, Y_2, \dots, Y_n$ 들의 두 선형함수 $\sum_{i=1}^n a_i Y_i$ 와 $\sum_{i=1}^n b_i Y_i$ 간의 공분산은 다음과 같이 주어지며

$$\text{Cov}\left(\sum_{i=1}^n a_i Y_i, \sum_{i=1}^n b_i Y_i\right) = \sum_{i=1}^n \sum_{j=1}^n a_i b_j \text{Cov}(Y_i, Y_j) \quad (1.5)$$

Y_i 들이 서로 독립이면 다음 식이 성립한다.

$$\text{Cov}\left(\sum_{i=1}^n a_i Y_i, \sum_{i=1}^n b_i Y_i\right) = \sum_{i=1}^n a_i b_i \text{Var}(Y_i) \quad (1.6)$$

1.3.5 이산확률분포

여러 가지 이산확률분포들 중에서 회귀분석과 관련이 있는 분포는 이항분포(binomial distribution)와 포아송분포(Poisson distribution)이다. 먼저 이항분포는 베르누이 시행(Bernoulli trial)에 의해 정의되는데, 어느 실험이 (i) 오직 두 가지의 가능한 결과만을 가지고, (ii) 매 번 시행에서 성공의 확률이 같아야 하며, (iii) 각 시행은 서로 독립이라는 세 가지 조건을 만족하면 이를 베르누이 시행이라 한다. 예를 들어, 동전던지기(앞면과 뒷면), 품질검사(양품과 불량품), 합격과 불합격을 나타내는 시험 등을 들 수 있다. 일반적으로 베르누이 시행의 결과를 성공과 실패로 나타낸다.

확률변수 U 를 한번의 베르누이 시행에서 나타나는 성공의 개수라 정의하자. 그러면, U 는 0또는 1의 값을 가지며, 성공이 나타날 확률을 p 라 할 때 U 의 확률분포는 다음과 같이 주어진다.

$$f(u) = \Pr[U = u] = p^u (1-p)^{1-u}, \quad u = 0, 1$$

그러므로 U 의 기댓값은

$$E[U] = p$$

이며, 또한, $E[U^2] = p$ 이므로, 분산은

$$\text{Var}(U) = p(1 - p)$$

로 주어진다.

이항분포는 위와 같은 베르누이 시행을 독립적으로 n 번 반복할 때 나타나는 성공의 개수가 갖는 확률분포로 정의된다. 즉, U_i ($i = 1, 2, \dots, n$)를 i 번째 베르누이 시행에서의 성공의 개수라 정의하면 n 번 시행에서 나타나는 성공의 개수 Y 는 이들의 합으로 주어진다. 즉,

$$Y = \sum_{i=1}^n U_i$$

확률변수 Y 는 0에서 n 까지의 정수값을 가지며, 확률분포는 다음과 같이 주어진다.

$$f(y) = \binom{n}{y} p^y (1-p)^{n-y}, \quad y = 0, 1, \dots, n$$

확률변수들의 선형합수에 대한 기댓값과 분산의 공식(식 (1.2)와 (1.4))을 사용하면 U_i 들은 서로 독립이므로 Y 의 기댓값과 분산이 다음과 같이 주어짐을 쉽게 보일 수 있다.

$$E[Y] = np, \quad \text{Var}(Y) = np(1 - p)$$

이항분포는 각 시행의 결과가 두 가지인 경우에 해당되는 분포인데 일반적으로 각 시행의 결과가 k ($k \geq 2$) 가지인 경우를 다항분포(multinomial distribution)라 한다. 각 시행에서 i 번째 결과가 나올 확률을 p_i , $i = 1, \dots, k$ 라 하고 n 번 시행에서 i 번째 결과가 나올 횟수를 y_i , $i = 1, \dots, k$ 라 하면 $\sum_{i=1}^k p_i = 1$ 와 $\sum_{i=1}^k y_i = n$ 을 만족해야 한다. 시행의 결과가 k 가지인 다항분포를 정의하기 위해서 $k-1$ 개의 확률변수 $Y_1, \dots, Y_{k-1}$ 가 필요하며 확률분포는

$$f(y_1, \dots, y_{k-1}) = \frac{n!}{y_1! \cdots y_k!} p_1^{y_1} \cdots p_k^{y_k}$$

으로 주어지는데 여기서 $p_k = 1 - \sum_{i=1}^{k-1} p_i$, $y_k = n - \sum_{i=1}^{k-1} y_i$ 이며, $k = 2$ 인 경우가 바로 이항 분포임을 쉽게 알 수 있다.

포아송분포는 단위 시간당 또는 단위 영역당 발생하는 사건의 횟수를 나타내기 위한 분포이다. 이를테면, 어느 시간대에 가게에 찾아오는 고객의 수, 어느 도시에서 하루동안 발생하는 교통사고의 수 등은 포아송분포를 따른다. 사건발생 평균횟수가 λ 인 포아송분포를 따르는 확률변수 Y 의 확률분포는 다음과 같이 주어진다.

$$f(y) = \frac{e^{-\lambda} \lambda^y}{y!}, \quad y = 0, 1, 2, \dots$$

포아송분포의 한 특성은 평균과 분산이 모두 λ 로 같게 주어진다는 것이다. 즉,

$$E[Y] = \lambda, \quad Var(Y) = \lambda.$$

1.3.6 정규분포

확률변수 Y 의 확률밀도함수가 다음과 같이 주어질 때

$$f(y) = \frac{1}{\sqrt{2\pi}\sigma^2} \exp\left(-\frac{(y-\mu)^2}{2\sigma^2}\right), \quad -\infty < y < \infty$$

Y 는 평균이 μ 이고 분산이 σ^2 인 정규분포(normal distribution)를 따른다고 하며

$$Y \sim N(\mu, \sigma^2)$$

와 같이 나타낸다. 위의 식에 주어진 것처럼 Y 는 $(-\infty, \infty)$ 에서 정의되며, 확률밀도함수 $f(y)$ 는 평균 μ 에 대해 좌우대칭인 종 모양의 연속함수이다.

특히, 평균 μ 가 0이고, 분산 σ^2 이 1인 정규분포를 표준정규분포(standard normal distribution)라 하며, 관습적으로 이 분포를 갖는 확률변수를 Z 로 나타내고, 이 분포의 누적확률을 다음과 같이 나타낸다.

$$\Phi(z) = \Pr[Z \leq z] = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z^2} dz$$

위의 누적확률값은 부록 B의 <표 1>에 주어져 있다. 예를 들면, $\Phi(-1) = 0.1587$, $\Phi(1) =$

0.8413, $\Phi(1.96) = 0.975$, $\Phi(0) = 0.5$ 등의 값을 찾을 수 있다. 이 누적확률을 이용하면 확률변수 Z 에 대한 모든 확률값을 구할 수 있다. 예를 들어, 다음은 일반적으로 많이 사용하는 확률식이다.

$$\Pr[-1.645 < Z < 1.645] = 0.90, \Pr[-1.96 < Z < 1.96] = 0.95$$

그리고 확률식

$$\Pr[Z > z_\alpha] = \alpha$$

를 만족하는 값 z_α 를 표준정규분포의 상위 100 α % 백분위수(upper 100 α % percentile)라 부른다. 예를 들어, 상위 5% 백분위수와 상위 2.5% 백분위수는 각각 $z_{0.05} = 1.645$, $z_{0.025} = 1.96$ 으로 역시 부록 B의 <표 1>에서 구할 수 있다.

정규분포의 대표적 성질 중 하나는 정규분포를 따르는 확률변수의 선형함수 역시 정규분포를 따른다는 것이다. 확률변수 Y 가 평균이 μ 이고 분산이 σ^2 인 정규분포를 따를 때 선형함수 $a + bY$ 는 평균이 $a + b\mu$ 이고 분산이 $b^2\sigma^2$ 인 정규분포를 따른다. 즉,

$$a + bY \sim N(a + b\mu, b^2\sigma^2)$$

예를 들어, 임의의 정규분포 $N(\mu, \sigma^2)$ 을 따르는 확률변수 Y 를 표준화하면 표준정규분포를 따르게 된다. 즉,

$$Z = \frac{Y - \mu}{\sigma} \sim N(0, 1)$$

이 사실을 이용하면 Y 에 대한 모든 확률식의 값을 다음과 같이 구할 수 있다.

$$\begin{aligned} \Pr[a < Y < b] &= \Pr\left[\frac{a - \mu}{\sigma} < \frac{Y - \mu}{\sigma} < \frac{b - \mu}{\sigma}\right] \\ &= \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right) \end{aligned}$$

예를 들면,

$$\Pr[\mu - 2\sigma < Y < \mu + 2\sigma] = \Phi(2) - \Phi(-2) = 0.9772 - 0.0228 = 0.9544$$

$$\Pr[\mu - 3\sigma < Y < \mu + 3\sigma] = \Phi(3) - \Phi(-3) = 0.9987 - 0.0013 = 0.9974$$

등을 구할 수 있다.

정규분포를 따르는 확률변수의 선형함수에 대한 성질은 더욱 일반화될 수 있다. n 개의 확률변수 $Y_1, Y_2, \dots, Y_n$ 들이 정규분포를 따르면 이들의 선형함수 $\sum_{i=1}^n a_i Y_i$ 도 정규분포를 따르고, Y_i 들이 서로 독립이고 각각 정규분포 $N(\mu_i, \sigma_i^2)$ 를 따르면 식 (1.2)와 (1.4)에 의해 선형함수의 분포는 다음과 같이 주어진다.

$$\sum_{i=1}^n a_i Y_i \sim N\left(\sum_{i=1}^n a_i \mu_i, \sum_{i=1}^n a_i^2 \sigma_i^2\right)$$

만약 Y_i 들이 전부 같은 정규분포 $N(\mu, \sigma^2)$ 을 따르면 평균과 분산의 식은 다음과 같이 간단해진다.

$$\sum_{i=1}^n a_i Y_i \sim N\left(\mu \sum_{i=1}^n a_i, \sigma^2 \sum_{i=1}^n a_i^2\right) \quad (1.7)$$

정규분포는 통계학에서 가장 많이 사용되는 확률분포이다. 그러나 모순적인 것은 정규분포를 정확하게 따르는 변수는 현실적으로 없다는 것이다. 왜냐하면 정규분포는 우선 $(-\infty, \infty)$ 에서 정의되어야하고, 모든 구간에서의 확률이 0보다 커야 한다는 조건이 주어지기 때문이다. 그러므로 이를테면 항상 양수값만을 갖는 학생들의 신장이 정규분포를 따른다고 가정하는 것은 엄격하게 보면 잘못된 것일 수 있다. 그렇지만 이 가정이 타당성을 갖는 이유는 정규분포에서는 위에서 주어졌듯이 $(\mu - 3\sigma, \mu + 3\sigma)$ 정도의 구간에 99.74%라는 거의 모든 확률이 포함되어 있기 때문이다. 신장의 경우 표준편차 σ 가 아주 크지 않는 경우에는 음수부분은 거의 확률이 존재하지 않는 것으로 보아도 무방하게 된다.

통계학에서 정규분포는 많은 통계량들이 근사적으로 따르는 확률분포로도 중요하게 사용된다. 특히 다음의 중심극한정리(central limit theorem)는 많은 응용문제들에서 확률의 계산을 간단하게 하여준다.

중심극한정리 : 확률변수 $Y_1, Y_2, \dots, Y_n$ 들이 평균이 μ 이고 분산이 $\sigma^2 < \infty$ 인 확률분포를 따르며 서로 독립일 때, 표본의 크기 n 이 적당히 크면 표본평균의 분포는 근사적으로 정규분포에 가까워진다. 즉,

$$\sqrt{n}(\bar{Y} - \mu) \rightarrow N(0, \sigma^2)$$

이 성립한다.

1.3.7 정규분포와 관련된 연속확률분포

기초통계학에서 중요하게 사용되었던 t , F , χ^2 (카이제곱)분포들은 모두 정규분포에서 유도되어 정의된다.

먼저 카이제곱분포를 정의하자. 확률변수 $Z_1, Z_2, \dots, Z_n$ 들이 서로 독립이고 표준정규분포를 따를 때 이들의 제곱합

$$V = Z_1^2 + Z_2^2 + \dots + Z_n^2$$

은 자유도가 n 인 카이제곱(χ^2)분포를 따른다고 정의한다. 이 χ^2 분포는 자유도 n 에 의해 결정되는 분포로 평균과 분산은 각각 n 과 $2n$ 으로 주어진다. 즉,

$$E[V] = n, \quad \text{Var}(V) = 2n$$

부록 B의 <표 2>에는 χ^2 분포의 백분위수가 주어져 있다.

만약 위에서 확률변수 Z_i 들이 서로 독립이면서 정규분포 $N(\mu_i, 1)$ 를 따르는 경우에는 제곱합

$$V = \sum_{i=1}^n Z_i^2$$

은 비중심모수(noncentrality parameter)가 $\lambda = \sum_{i=1}^n \mu_i^2$ 이고 자유도가 n 인 비중심카이제곱(χ^2)분포(noncentral χ^2 distribution)를 따른다고 정의하며 이것을 $V \sim \chi^2(n, \lambda)$ 로 나타낸다. 그리고 비중심모수 λ 가 0인 경우를 중심카이제곱분포(central χ^2 distribution)라 하는데 이것은 정의에서 알 수 있듯이 위의 카이제곱분포와 동일한 것이다.

확률변수 Z 가 표준정규분포를, V 가 자유도가 n 인 χ^2 분포를 따르고 두 확률변수가 서로 독립일 때 다음의 통계량

$$t = \frac{Z}{\sqrt{V/n}}$$

는 자유도가 n 인 t 분포를 따른다고 정의한다. 이 t 분포는 0에 대해 대칭으로 표준정규분포와 비슷한 모양을 가지나, 표준정규분포보다 꼬리부분에 더 많은 확률을 갖는다. 자유도 n 이 커질수록 t 분포는 표준정규분포에 가깝게 된다. 자유도가 n 인 t 분포의 상위 $100\alpha\%$ 백분위수를 $t_\alpha(n)$ 이라 나타내며, 부록 B의 <표 3>에 주어져 있다. 예를 들어, 자유도가

8인 t 분포의 상위 5% 백분위수는 $t_{0.05}(8) = 1.860$ 이다.

확률변수 V_1 과 V_2 가 각각 자유도가 n_1, n_2 인 χ^2 분포를 따르고 두 확률변수가 서로 독립일 때 다음의 통계량

$$F = \frac{V_1/n_1}{V_2/n_2}$$

은 분자의 자유도가 n_1 이고 분모의 자유도가 n_2 인 F 분포를 따른다고 정의한다. 이 F 분포의 상위 $100\alpha\%$ 백분위수를 $F_\alpha(n_1, n_2)$ 라 나타내며, 부록 B의 <표 4>에 주어져 있다. 예를 들어, 자유도가 (3, 8)인 F 분포의 상위 5% 백분위수는 $F_{0.05}(3, 8) = 4.07$ 이다. 그리고 만약 분자의 V_1 이 비중심모수가 λ 인 비중심 χ^2 분포를 따르는 경우에는 통계량 F 는 분자의 자유도가 n_1 이고 분모의 자유도가 n_2 이면서, 비중심모수가 λ 인 비중심 F 분포를 따른다고 정의한다.

1.3.8 확률벡터와 다변량정규분포

이 장의 3.2절에서는 두 개 이상의 확률변수들이 갖는 결합확률분포가 설명되었다. 회귀 분석에서는 식의 표현과 계산작업을 쉽게 하기 위하여 행렬과 벡터를 많이 이용하게 된다. 여기서는 벡터들의 각 원소가 확률변수로 주어지는 확률벡터를 정의하여 그 사용에 대해서 알아보자.

n 개의 확률변수 $Y_1, Y_2, \dots, Y_n$ 이 있을 때 이들을 원소로 하는 n 차원 벡터

$$\mathbf{y} = (Y_1, Y_2, \dots, Y_n)'$$

을 n 차원 확률벡터(random vector)라 한다(이 책에서는 행렬과의 혼동을 피하기 위하여, 확률벡터에 대해 굵은 소문자를 사용한다). 확률변수의 기댓값과 분산에 대응하는 것으로 확률벡터에 대해 기댓값 벡터와 분산-공분산 행렬이 정의될 수 있다. 확률벡터 $\mathbf{y}$ 의 기댓값 벡터는 $\mathbf{y}$ 의 각 원소에 기댓값함수를 취한 것으로 정의되며 $\boldsymbol{\mu}$ 로 나타낸다. 즉,

$$\boldsymbol{\mu} = E[\mathbf{y}] = (E[Y_1], E[Y_2], \dots, E[Y_n])'$$

확률벡터의 경우에도 기댓값함수의 일반적인 성질들도 모두 성립함을 보일 수 있다. 예를 들어, $m \times n$ 행렬 A 와 m 차원 벡터 b 의 모든 원소가 상수일 때 선형변환 $A\mathbf{y} + b$ 의 기댓

값벡터는

$$E[\mathbf{A}\mathbf{y} + \mathbf{b}] = \mathbf{A}E[\mathbf{y}] + \mathbf{b}$$

로 주어진다.

그리고 $\mathbf{y}$ 의 분산-공분산행렬(variance-covariance matrix)은 각 원소의 분산을 대각원소, 원소들 간의 공분산을 비대각원소로 하는 $n \times n$ 대칭행렬로 주어진다. 이 분산-공분산행렬은 $Cov(\mathbf{y})$ 라 나타내며 다음과 같이 정의된다.

$$Cov(\mathbf{y}) = E[(\mathbf{y} - \boldsymbol{\mu})(\mathbf{y} - \boldsymbol{\mu})'] \quad (1.8)$$

구체적으로 각 원소는 다음과 같이 주어진다.

$$\begin{aligned} Cov(\mathbf{y}) \text{의 } i\text{번째 대각원소} &= Var(Y_i) \\ Cov(\mathbf{y}) \text{의 } (i, j)(i \neq j)\text{번째 원소} &= Cov(Y_i, Y_j) \end{aligned}$$

예를 들어, $n = 3$ 인 경우 다음과 같다.

$$Cov(\mathbf{y}) = \begin{bmatrix} Var(Y_1) & Cov(Y_1, Y_2) & Cov(Y_1, Y_3) \\ Cov(Y_1, Y_2) & Var(Y_2) & Cov(Y_2, Y_3) \\ Cov(Y_1, Y_3) & Cov(Y_2, Y_3) & Var(Y_3) \end{bmatrix}$$

식 (1.8)에서 우측을 전개하여 정리하면 일차원의 경우와 비슷하게 다음과 같은 관계식을 얻을 수 있다.

$$Cov(\mathbf{y}) = E[\mathbf{y}\mathbf{y}'] - \boldsymbol{\mu}\boldsymbol{\mu}' \quad (1.9)$$

그리고 선형변환에 대한 분산-공분산행렬은

$$Cov(\mathbf{A}\mathbf{y} + \mathbf{b}) = \mathbf{A}Cov(\mathbf{y})\mathbf{A}'$$

와 같이 주어진다.

이 책에서는 여러 가지 다변량 확률분포들 중 다항분포와 다변량정규분포가 사용되는데 이 절에서는 다변량정규분포(multivariate normal distribution)를 설명한다. 확률벡터

$\mathbf{y} = (Y_1, Y_2, \dots, Y_n)'$ 의 기댓값이

$$E[\mathbf{y}] = \boldsymbol{\mu} = (\mu_1, \mu_2, \dots, \mu_n)'$$

이고 분산-공분산행렬이

$$\text{Cov}(\mathbf{y}) = \boldsymbol{\Sigma}$$

이며, 확률밀도함수가

$$f(\mathbf{y}|\boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{(2\pi)^{n/2}|\boldsymbol{\Sigma}|^{1/2}} \exp \left[-\frac{1}{2}(\mathbf{y} - \boldsymbol{\mu})' \boldsymbol{\Sigma}^{-1}(\mathbf{y} - \boldsymbol{\mu}) \right]$$

로 주어질 때, 확률벡터 $\mathbf{y}$ 는 평균벡터가 $\boldsymbol{\mu}$ 이고, 분산-공분산행렬이 $\boldsymbol{\Sigma}$ 인 n 차원 정규분포를 따른다고 하고,

$$\mathbf{y} \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$$

로 나타낸다.

다변량정규분포의 여러 특성들 중 중요한 것은 주변확률분포와 조건부확률분포가 역시 정규분포로 주어진다는 것이다. 예를 들어, 위의 경우 i 번째 원소인 확률변수 Y_i 는 평균이 μ_i 이고 분산이 σ_i^2 인 정규분포를 따르게 된다. 즉,

$$Y_i \sim N(\mu_i, \sigma_i^2)$$

(단, σ_i^2 는 $\boldsymbol{\Sigma}$ 의 i 번째 대각원소임).

n 차원 벡터 $\mathbf{y}$ 가 $N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 를 따를 때 $\mathbf{y}$ 를 분할하여 $\mathbf{y}' = (\mathbf{y}'_1, \mathbf{y}'_2)$ 으로 나타내고 $\mathbf{y}_1$ 를 r 차원 벡터 ($r < n$)라 가정하자. 또한, $\boldsymbol{\mu}$ 와 $\boldsymbol{\Sigma}$ 도 같은 차원으로 분할되었다고 하자. 즉,

$$\boldsymbol{\mu} = \begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \quad \boldsymbol{\Sigma} = \begin{pmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{12} & \Sigma_{22} \end{pmatrix}$$

라고 하면 $\mathbf{y}_2$ 가 주어졌을 때 $\mathbf{y}_1$ 에 대한 조건부분포는

$$\mathbf{y}_1|\mathbf{y}_2 \sim N_r(\boldsymbol{\mu}_1 + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{y}_2 - \boldsymbol{\mu}_2), \quad \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21})$$

22 제 1 장 기초통계이론

으로 주어짐을 보일 수 있다.

$n = 2$ 인 간단한 경우에 조건부 확률분포를 구체적으로 살펴보자. 확률변수 Y_1, Y_2 의 분포가 다음과 같은 이변량 정규분포를 따른다고 하자.

$$\begin{pmatrix} Y_1 \\ Y_2 \end{pmatrix} \sim N \left(\begin{pmatrix} \mu_1 \\ \mu_2 \end{pmatrix}, \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix} \right)$$

(위에서 σ_{12} 는 Y_1, Y_2 의 공분산으로 Y_1, Y_2 의 상관계수를 ρ 라고 하면 $\sigma_{12} = \rho\sigma_1\sigma_2$ 의 관계식이 성립한다). 예를 들어, Y_1 의 $Y_2 = y_2$ 에 대한 조건부확률분포는 평균이

$$\mu_{1.2} = \mu_1 + \rho \frac{\sigma_1}{\sigma_2} (y_2 - \mu_2)$$

이고, 분산이

$$\sigma_{1.2}^2 = \sigma_1^2 (1 - \rho^2)$$

인 정규분포로 주어진다. 즉,

$$Y_1 | Y_2 = y_2 \sim N(\mu_{1.2}, \sigma_{1.2}^2)$$

위에서 주목할 내용은 Y_1 의 조건부평균 $\mu_{1.2}$ 가 y_2 의 선형함수로 주어진다는 것과 조건부 분산 $\sigma_{1.2}^2$ 은 Y_2 의 값에 관계없이 상수로 주어지며, Y_1 의 분산 σ_1^2 보다 작다는 것이다. 이와 같은 사실은 회귀모형의 해석과 밀접한 관계를 가지고 있다.

1.4 통계적 추정과 검정

1.4.1 추정량의 종류와 성질

확률변수 $Y_1, Y_2, \dots, Y_n$ 들의 함수가 미지의 모수 θ 를 추정하는 공식으로 사용되는 경우 이를 추정량(estimator)이라 부르고, $\hat{\theta}(Y_1, Y_2, \dots, Y_n)$ 또는 간단하게 $\hat{\theta}$ 으로 나타낸다. 통계분석에서 미지의 모수를 추정하는 방법은 항상 두 가지 이상 존재한다. 그러므로 해결하고자 하는 문제에 적합한 추정방법을 선택하는 것이 중요하고, 또한, 각 추정방법에서 유도되는 추정량이 어떠한 성질을 갖고 있는지를 조사할 필요가 있다. 추정량의 바람직

한 성질로는 불편성, 일치성, 최소분산성 등이 있다.

추정량 $\hat{\theta}$ 의 기댓값이 모수 θ 와 같아지면, 즉,

$$E[\hat{\theta}] = \theta$$

이면 $\hat{\theta}$ 을 불편추정량(unbiased estimator)이라 부른다. 즉, 추정량의 값은 항상 추정오차 ($\hat{\theta} - \theta$)를 가지나, 표본을 반복 추출하여 추정을 계속하면 이 추정오차의 값은 평균적으로 0이 된다는 뜻이다. 한편, 추정량 $\hat{\theta}$ 의 기댓값과 모수 θ 의 차이 즉,

$$E[\hat{\theta}] - \theta$$

를 추정량 $\hat{\theta}$ 의 편의(bias)라 부른다.

추정량 $\hat{\theta}$ 이 확률적으로 모수 θ 와 가까질 때 $\hat{\theta}$ 을 일치추정량(consistent estimator)이라 한다. 즉, 모든 양수 ε 에 대해

$$\lim_{n \rightarrow \infty} \Pr[|\hat{\theta} - \theta| \leq \varepsilon] = 1$$

이 됨을 의미한다. 이는 표본의 크기가 커지면 추정치가 모수에 확률적으로 수렴한다는 뜻이다.

추정량 $\hat{\theta}$ 이 θ 의 다른 추정량들보다 작은 분산을 가질 때 $\hat{\theta}$ 을 최소분산추정량(minimum variance estimator)이라 한다. 즉, 다른 모든 추정량 $\hat{\theta}^*$ 에 대해

$$\text{Var}(\hat{\theta}) \leq \text{Var}(\hat{\theta}^*)$$

을 만족한다. 추정량의 분산이 작다는 것은 모수를 더욱 정확하게 추정할 수 있다는 것을 의미한다. 그러나 통계학에서는 모든 추정량보다 작은 분산을 갖는 유일한 추정량은 존재하지 않는다. 일반적인 접근방식은 추정량의 집합을 한정시켜 그 중에서 제일 작은 분산을 갖는 추정량을 찾는 것이다. 예를 들어, 추정량이 확률변수 $Y_1, Y_2, \dots, Y_n$ 들의 선형함수로 주어지고 불편성을 만족하는 집합 중에서는 최소분산을 갖는 유일한 추정량이 존재하는데 이를 최소분산불편선형추정량(best linear unbiased estimator)이라 한다.

기초통계학에서 많이 사용되는 표본평균 $\bar{Y}$ 는 위의 바람직한 성질들을 모두 만족한다.

1.4.2 최소제곱 추정치

회귀분석에서 사용하는 추정방법에는 최소제곱법(least squares method)과 최우추정법(maximum likelihood estimation method)이 있다. 모평균을 추정하는 문제에서 이 두 방법을 각각 살펴보자. 확률변수 $Y_1, Y_2, \dots, Y_n$ 들이 모평균이 μ 이고 분산이 σ^2 인 모집단에서 추출된 표본이라 하자. 최소제곱법은 확률변수 Y_i 와 모평균 μ 사이에 다음과 같은 관계를 가정한다.

$$Y_i = \mu + \varepsilon_i, \quad i = 1, 2, \dots, n$$

위의 식에서 ε_i 는 Y_i 가 모수 μ 에서 벗어나는 정도를 나타내는 확률변수로 평균이 0이고 분산이 σ^2 인 확률변수라 정의된다. 이제 위의 식에서 모평균 μ 대신에 추정량 $\hat{\theta}$ 을 대입하면 이 차이는

$$Y_i - \hat{\theta}, \quad i = 1, 2, \dots, n$$

로 주어지고 최소제곱법은 이 차이들의 제곱의 합

$$S = \sum_{i=1}^n (Y_i - \hat{\theta})^2$$

을 최소화하는 추정량 $\hat{\theta}$ 을 구하게된다. 위의 제곱합은 다음과 나타낼 수 있으므로

$$\sum_{i=1}^n (Y_i - \hat{\theta})^2 = \sum_{i=1}^n (Y_i - \bar{Y} + \bar{Y} - \hat{\theta})^2 = \sum_{i=1}^n (Y_i - \bar{Y})^2 + n(\bar{Y} - \hat{\theta})^2$$

우리는 제곱합 S 를 최소화하는 $\hat{\theta}$ 은 표본평균 $\bar{Y}$ 임을 쉽게 알 수 있다.

한편, 오차의 제곱의 합을 최소화하는 대신 오차의 절대값의 합을 최소로 하는 추정치도 있다. 즉,

$$S = \sum_{i=1}^n |Y_i - \theta|$$

을 최소화하는 추정치인데 이 경우 θ 에 대한 추정치는 $Y_1, \dots, Y_n$ 의 중간값으로 주어진다. 이 처럼 오차의 절대값의 합을 최소로 하는 추정치를 최소절대편차 추정치(LAD : Least Absolute Deviation estimator)라 부른다.

1.4.3 최우 추정치

최소제곱법에서는 확률변수 Y_i 가 갖는 확률분포는 가정되지 않았다. 이와는 다르게 최우추정법은 특정한 확률분포의 가정 하에서 정의되는 방법이다. 확률변수 $Y_1, Y_2, \dots, Y_n$ 가 확률밀도함수 $f(y_i|\theta)$ 를 갖는 모집단에서 추출되고 서로 독립이라 가정하자. 그러면 독립성에 의하여 이들의 결합확률밀도함수는

$$\prod_{i=1}^n f(y_i|\theta)$$

로 주어지는데 이는 모수 θ 가 주어져 있을 때 확률변수 $Y_1, Y_2, \dots, Y_n$ 들의 함수로 간주하는 것이다. 이와는 반대로 확률변수 $Y_1, Y_2, \dots, Y_n$ 이 주어져 있을 때 모수 θ 의 함수로 간주하는 것을 우도함수(likelihood function)라 한다. 즉, 우도함수는

$$L(\theta|\mathbf{y}) = \prod_{i=1}^n f(y_i|\theta)$$

으로 정의되며, 편의상 $L(\theta) \equiv L(\theta|\mathbf{y})$ 으로 나타내기도 한다. 최우추정법은 이 우도함수를 최대화하는 θ 의 값을 구하는 방법이다. 로그함수는 단순증가함수이므로 우도함수를 최대화하는 것은 $\log L(\theta)$ 를 최대화하는 것과 같은데 흔히 이를 $l(\theta) \equiv \log L(\theta)$ 로 표현하며 이를 로그우도함수(log-likelihood function)라 한다.

예를 들어, Y_i 들이 평균이 λ 인 포아송분포에서 추출되었다고 가정하자. 그러면, λ 의 우도함수는

$$L(\lambda) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{y_i}}{y_i!} = \frac{e^{-n\lambda} \lambda^{\sum_{i=1}^n y_i}}{y_1! y_2! \cdots y_n!}$$

로 주어진다. 이 우도함수 $L(\lambda)$ 를 최대화하는 것은 이것의 로그함수를 최대화하는 것과 같으며, 이는 또한, λ 의 연속함수이므로 λ 에 대하여 미분하여 최대값을 구할 수 있다. 즉,

$$\log L(\lambda) = -n\lambda + \left(\sum_{i=1}^n y_i\right) \log \lambda - \log(y_1! y_2! \cdots y_n!)$$

이므로

$$\frac{\partial \log L(\lambda)}{\partial \lambda} = -n + \frac{1}{\lambda} \sum_{i=1}^n y_i = 0$$

에서 λ 의 최우추정량 $\hat{\lambda} = \bar{Y}$ 를 구할 수 있다.

일반적으로 모수 θ 의 차원을 p -벡터라 할 때 로그우도함수 $l(\theta)$ 를 θ 에 대해 한번 미분한 것을 $\nabla l(\theta) = \partial l(\theta)/\partial \theta$ 라고 표시하면 최우추정치는 $0 = \nabla l(\theta)$ 을 만족한다. 그러나, 로그우도함수 $l(\theta)$ 가 θ 에 대해 미분가능하지 않을 경우도 있으므로 일반적으로 최우추정치는 다음과 같이 정의한다.

$$\hat{\theta} = \arg \max_{\theta} L(\theta)$$

최우추정치는 여러 가지 바람직한 성질을 가지는데 그 중에서도 근사적 정규성을 갖는다. 즉, $\hat{\theta}$ 이 θ 의 최우추정치일 때

$$\hat{\theta} \rightarrow N_p(\theta, I^{-1}(\theta))$$

인데 여기서 $I(\theta) = -E[\partial^2 l(\theta)/\partial \theta \partial \theta']$ 는 피셔 정보행렬(Fisher information matrix)이라 부른다. 최우추정량은 항상 불편성을 만족하지는 않는다. 그러나 가정된 분포에 관계없이 표본의 크기가 어느 정도 이상이면 바람직한 성질(근사적 불편성, 일치성 등)을 갖게 되므로 최우추정법은 통계학에서 가장 널리 사용되는 추정방법이다. 그리고 최우추정량의 또 다른 특징은 함수적무관성(functional invariance property)을 갖는다는 것이다. 즉, 모수 θ 의 최우추정량이 $\hat{\theta}$ 일 때 θ 의 함수 $g(\theta)$ 의 최우추정량은 $g(\hat{\theta})$ 로 주어지게 된다. 예를 들어 앞의 포아송 분포에서 λ 에 대한 최우추정치는 $\bar{Y}$ 이므로 함수적 무관성에 의해 λ^2 에 대한 최우추정치는 $\bar{Y}^2$ 이 된다.

1.4.4 정규모집단에 대한 추론

이 절에서는 기초통계학에서 다루어진 추정과 검정의 문제를 정규모집단에 적용하여 복습한다. 이 절의 내용은 회귀분석에서도 중요하게 사용된다.

확률변수 $Y_1, Y_2, \dots, Y_n$ 들이 정규분포 $N(\mu, \sigma^2)$ 를 따르는 모집단에서 추출된 확률표본이라 하자. 이 경우 최소제곱법과 최우추정법에서 모두 평균 μ 의 추정량으로 표본평균

$$\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$$

를 구할 수 있으며 이 추정량은 μ 에 대해 불편성, 일치성, 최소분산성을 모두 만족한다. 분산 σ^2 의 추정량으로는 표본분산

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (Y_i - \bar{Y})^2 \quad (1.10)$$

이 사용된다. 분산 σ^2 의 최우추정량은 실제

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (Y_i - \bar{Y})^2$$

으로 주어지나 불편성을 만족하는 추정량을 사용하기 위하여 분모에 n 대신에 $(n-1)$ 을 사용한 식 (1.10)의 공식을 이용한다. 이 $(n-1)$ 을 편차들의 제곱합 $\sum_{i=1}^n (Y_i - \bar{Y})^2$ 가 갖는 자유도(degrees of freedom)라 한다. 자유도란 통계학에서 관습적으로 사용하는 용어로 일반적으로 관측값들의 개수에서 관측값들 간에 존재하는 제약관계의 개수를 뺀 것으로 정의된다. 이를테면, s^2 의 식에서는 n 개의 편차 $(Y_i - \bar{Y})$ 가 사용되지만, 편차들 간에는

$$\sum_{i=1}^n (Y_i - \bar{Y}) = 0$$

이라는 제약식이 하나 존재하기 때문에 제곱합 $\sum_{i=1}^n (Y_i - \bar{Y})^2$ 은 $(n-1)$ 개의 자유도를 가진다고 할 수 있다. 또는 자유도를 제곱합을 계산하기 전에 추정해야 할 모수의 개수와 연관시켜 생각할 수 있다. 즉, 편차의 제곱합을 계산하기 위해서는 먼저 한 개의 모수 μ 를 추정하여야 하므로, 이 모수의 추정에 한 개의 자유도가 사용되어 $(n-1)$ 개의 자유도가 남았다고 해석할 수 있다. 그리고 추정량 $\bar{Y}$ 는 한 개의 자유도를 가진다.

평균 μ 에 대한 구간추정과 가설검정을 하기 위해서는 점추정량 $\bar{Y}$ 가 갖는 확률분포를 유도할 필요가 있는데, 이는 $\bar{Y}$ 의 선형성에 의하여 쉽게 주어진다. 즉, $\bar{Y}$ 는 서로 독립이면서 정규분포를 따르는 확률변수 $Y_1, Y_2, \dots, Y_n$ 들의 선형함수이므로 식 (1.7)을 이용하면 $\bar{Y}$ 의 분포는 다음과 같이 주어진다.

$$\bar{Y} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \quad (1.11)$$

그리고 다음의 표준화된 확률변수는 표준정규분포를 따른다.

$$\frac{\bar{Y} - \mu}{\sigma/\sqrt{n}} \sim N(0, 1)$$

이외에도 정규모집단에 대한 중요한 결과는 다음과 같다.

정규모집단 결과(1): $(n-1)s^2/\sigma^2 \sim \chi^2(n-1)$

정규모집단 결과(2): $\bar{Y}$ 와 s^2 은 서로 독립이다.

분산 σ^2 은 일반적으로 알려져 있지 않기 때문에 표본분산 s^2 을 대신 사용하면 $\bar{Y}$ 의 표준편차의 추정량, 즉, 표준오차(standard error)는

$$SE(\bar{Y}) = s/\sqrt{n}$$

로 주어지고, 이것을 이용한 t -통계량

$$t = \frac{\bar{Y} - \mu}{s/\sqrt{n}} \quad (1.12)$$

은 자유도가 $(n-1)$ 인 t 분포를 따르게 된다. 위의 t -통계량은 실제로는 다음 식을 간단히 하여 유도된 것이다.

$$\frac{\frac{\bar{Y} - \mu}{\sigma / \sqrt{n}}}{\sqrt{\frac{1}{\sigma^2} \sum_{i=1}^n (Y_i - \bar{Y})^2 / (n-1)}}$$

위의 식에서 분자는 표준정규분포를 가지며 분모의

$$\frac{1}{\sigma^2} \sum_{i=1}^n (Y_i - \bar{Y})^2$$

은 정규모집단 결과(1)에 의해 자유도가 $(n-1)$ 인 χ^2 를 따르고, 또한, 정규모집단 결과(2)에 의해 분자와 분모는 서로 독립이므로 1.3.7절의 t 분포의 정의에 의해 식 (1.12)는 자유도가 $(n-1)$ 인 t 분포를 따르게 된다. 이 사실들에 대한 증명은 3장의 연습문제(3.5와 3.6)에 주어져 있다.

자유도 $(n-1)$ 인 t 분포의 상위 $100\alpha\%$ 백분위수를 $t_{\alpha}(n-1)$ 라 나타내면 위의 사실을 이용하여 t 분포의 대칭성에 의하여 다음 식이 성립한다.

$$\begin{aligned} 1 - \alpha &= \Pr[-t_{\alpha/2}(n-1) < \frac{\bar{Y} - \mu}{SE(\bar{Y})} < t_{\alpha/2}(n-1)] \\ &= \Pr[\bar{Y} - t_{\alpha/2}(n-1)SE(\bar{Y}) < \mu < \bar{Y} + t_{\alpha/2}(n-1)SE(\bar{Y})] \end{aligned}$$

따라서, 정규분포에서 평균 μ 에 대한 $100(1-\alpha)\%$ 신뢰구간은

$$\bar{Y} - t_{\alpha/2}(n-1)SE(\bar{Y}) < \mu < \bar{Y} + t_{\alpha/2}(n-1)SE(\bar{Y}) \quad (1.13)$$

으로 주어지며 이 구간을 다음과 같은 신뢰한계(confidence limits)로 나타내기도 한다.

$$\mu = \bar{Y} \pm t_{\alpha/2}(n-1)SE(\bar{Y})$$

표본의 값이 관측되기 전에는 위의 구간은 μ 를 포함할 확률이 $(1 - \alpha)$ 인 일종의 확률구간(random interval)이다. 그러나 Y_i 들의 관측값을 대입하여 계산된 구간은 모수 μ 를 포함할 확률이 0 아니면 1이 된다. 이 때 신뢰구간의 의미는 크기 n 의 표본들을 반복 추출하여 위의 신뢰구간을 계산하면 이들 중에서 최소한 $100(1 - \alpha)\%$ 의 구간들은 모수 μ 의 참값을 포함하고 있다는 것이다. 일반적으로 신뢰한계의 공식은 다음과 같은 형식을 가진다.

$$\text{모수} = \text{점추정량} \pm C \cdot (\text{점추정량의 표준오차})$$

위 식에서 상수 C 는 점추정량이 갖는 확률분포의 상위백분위수로 $(1 - \alpha)$ 의 신뢰수준이 만족되도록 선택된다.

평균 μ 에 대한 가설검정도 식 (1.12)의 t -통계량을 이용하여 할 수 있다. 귀무가설 $H_0 : \mu = \mu_0$ 하에서 검정통계량

$$t = \frac{\bar{Y} - \mu_0}{SE(\bar{Y})}$$

은 자유도가 $(n - 1)$ 인 t 분포를 따르므로 대립가설의 형태에 따라 유의수준 α 하에서 다음의 세 가지 기각역이 주어진다.

귀무가설	검정통계량	대립가설	H_0 기각역
$H_0 : \mu = \mu_0$	$t = \frac{\bar{Y} - \mu_0}{SE(\bar{Y})}$	$H_1 : \mu < \mu_0$	$t < -t_{\alpha}(n-1)$
		$H_1 : \mu > \mu_0$	$t > t_{\alpha}(n-1)$
		$H_1 : \mu \neq \mu_0$	$ t > t_{\alpha/2}(n-1)$

위의 검정에서 특히 양측검정의 경우 기각역의 반대 영역은

$$|t| = \left| \frac{\bar{Y} - \mu_0}{SE(\bar{Y})} \right| < t_{\alpha/2}(n-1)$$

로 주어지며 이 부등식을 μ_0 에 대해 정리하면

$$\bar{Y} - t_{\alpha/2}(n-1)SE(\bar{Y}) < \mu_0 < \bar{Y} + t_{\alpha/2}(n-1)SE(\bar{Y})$$

와 같은 구간을 얻을 수 있다. 이 구간은 식 (1.13)의 신뢰구간과 동일한 것으로, 이 것에서 우리는 신뢰구간과 양측검정의 유사성을 찾을 수 있다. 일반적으로 어느 모수의 가설에 대한 양측검정에서 귀무가설에 주어진 모수의 값(위의 경우는 μ_0)이 $100(1 - \alpha)\%$ 신뢰구간 밖에 있으면 귀무가설을 유의수준 α 하에서 기각할 수 있다.

1.5 테일러 근사법

확률변수의 분포나 추정치의 분산 등을 정확하게 표현할 수 없는 경우가 흔히 있다. 이 경우 차선택으로 근사적 분포나 분산의 근사치를 사용하게 되는데 이를 도출하는 수학적 도구로서 테일러 근사식(Taylor approximation)이 많이 사용된다. 예를 들어, 1.3.6절에 소개한 중심극한정리도 테일러 근사식을 이용하여 유도할 수 있다.

1.5.1 테일러 급수전개

(1) $f : R \rightarrow R$ 인 경우

함수 $f : R \rightarrow R$ 가 x_0 에서 k 번 미분가능하고 $|x - x_0| \rightarrow 0$ 이면

$$f(x) = \sum_{j=0}^k \frac{1}{j!} f^{(j)}(x_0)(x - x_0)^j + o(|x - x_0|^k)$$

으로 표현된다. 단, $f^{(j)}(x) = d^j f(x)/dx^j$ 이다. 만약, f 가 모든 범위에서 $k + 1$ 번 미분가능하고 $|f^{(k+1)}(x)| \leq M < \infty$ 이면 잔류항(remainder term)을 다음과 같이 더 정확하게 표현할 수 있다.

$$f(x) = \sum_{j=0}^k \frac{1}{j!} f^{(j)}(x_0)(x - x_0)^j + \frac{1}{(k+1)!} f^{(k+1)}(\xi)(x - x_0)^{k+1}$$

단, ξ 는 x 와 x_0 사이의 어떤 값이다.

(2) $f : R^d \rightarrow R$ 인 경우

함수 $f : R^d \rightarrow R$ 가 $\mathbf{x}_0 \in R^d$ 에서 k 번 미분가능하고 $\|\mathbf{x} - \mathbf{x}_0\| \rightarrow 0$ 이면

$$f(\mathbf{x}) = f(\mathbf{x}_0) + \nabla f(\mathbf{x}_0)'(\mathbf{x} - \mathbf{x}_0) + \frac{1}{2}(\mathbf{x} - \mathbf{x}_0)'H(\mathbf{x}_0)(\mathbf{x} - \mathbf{x}_0) + \cdots + o(\|\mathbf{x} - \mathbf{x}_0\|^k)$$

단, 여기서 $\nabla f(\mathbf{x}) = \partial f(\mathbf{x})/\partial \mathbf{x}$ 이고 $H(\mathbf{x})$ 는 두 번 미분한 헤시안(Hessian) 행렬이다.

(3) $f: R^d \rightarrow R^p$ 인 경우

함수 $f: R^d \rightarrow R^p$ 가 $\mathbf{x}_0 \in R^d$ 에서 1번 미분가능하고 $\|\mathbf{x} - \mathbf{x}_0\| \rightarrow 0$ 이면

$$f(\mathbf{x}) = f(\mathbf{x}_0) + Df(\mathbf{x}_0)(\mathbf{x} - \mathbf{x}_0) + o(\|\mathbf{x} - \mathbf{x}_0\|)$$

단, 여기서 $f(\mathbf{x}) = (f_1(\mathbf{x}), \dots, f_p(\mathbf{x}))'$ 이고 $Df(\mathbf{x})$ 는 $p \times d$ 행렬로서 $\partial f_i(\mathbf{x})/\partial x_j$ 를 (i, j) 번째 원소로 가지고 있다.

1.5.2 델타법

확률변수 X 가 평균 μ , 분산 σ^2 을 가질 때 $f(X)$ 에 대한 평균과 분산을 계산하고 싶다. 단, 여기서 함수 f 는 미분가능한 함수라고 가정한다. 물론 f 의 형태에 따라 $f(X)$ 의 평균과 분산을 정확하게 계산할 수 있는 경우도 있지만 대부분의 경우 정확하게 계산할 수 없다. 이런 경우 테일러 급수전개를 이용하면 $f(X)$ 의 평균과 분산을 다음과 같이 근사적으로 구할 수 있다. X 를 μ 에 대해 1차 테일러 급수 전개하면

$$f(X) \simeq f(\mu) + (X - \mu)f'(\mu)$$

이므로 $E[f(X)] \simeq f(\mu)$ 이고 $Var[f(X)] \simeq \sigma^2 f'(\mu)^2$ 임을 쉽게 알 수 있다. 이러한 결과를 흔히 델타법(delta method) 또는 유용한 극한 정리(useful limit theorem)라 부른다. 확률변수에 대한 델타법은 확률벡터로 확장시킬 수 있다. 차원이 d 인 확률벡터 $\mathbf{X}$ 가 평균벡터 μ , 분산-공분산 행렬 Σ 를 갖고 함수 $f: R^d \rightarrow R^p$ 가 μ 에서 미분가능하다고 하자. 이때 $E[f(\mathbf{X})] \simeq f(\mu)$ 이고 $Cov[f(\mathbf{X})] \simeq Df(\mu)' \Sigma Df(\mu)$ 가 성립된다.

예를 들어, 확률변수 $Y_1, Y_2, \dots, Y_n$ 들이 서로 독립이고 평균 μ , 분산 σ^2 인 분포를 따를 때 표본의 크기 n 이 충분히 크면 중심극한정리에 의해 $\sqrt{n}(\bar{Y} - \mu) \rightarrow N(0, \sigma^2)$ 이 성립된다. 그렇다면, 표본평균의 제곱인 $\bar{Y}^2$ 의 분포는 델타법에 의해

$$\sqrt{n}(\bar{Y}^2 - \mu^2) \rightarrow N(0, 4\mu^2\sigma^2)$$

임을 쉽게 보일 수 있다.

1.5.3 뉴턴-랩슨 반복

1.4.1절에서 언급한 것 처럼 모수 θ 에 대한 최우추정치 $\hat{\theta}$ 은 우도함수 $L(\theta)$ 를 최대화하는 값인데 이는 흔히 우도함수 또는 로그우도함수 $l(\theta) = \log L(\theta)$ 를 한번 미분하여 0으로 놓은 식의 해로 주어진다. 그러나 이 해가 존재하지만 음함수(implicit function) 형태로 주어져서 식으로 표현할 수 없는 경우(does not have closed form solution 또는 does not have analytic solution)가 가끔 발생한다. 이 경우 로그우도함수의 이차미분이 존재한다면 뉴턴-랩슨 반복법(Newton-Raphson iteration)을 이용하여 해를 계산할 수 있다. 이 역시 테일러 근사법을 이용한 것으로 다음과 같이 설명할 수 있다.

일반적으로 모수 θ 의 차원을 p -벡터라 하고, $\nabla l(\theta) = \partial l(\theta)/\partial \theta$ 를 로그우도함수를 θ 에 대해 한번 미분한 p -벡터라 하자. 흔히, 이 벡터를 스코어 벡터(score vector)라고도 한다. 또한, $H(\theta) = \partial^2 l(\theta)/\partial \theta \partial \theta'$ 를 로그우도함수를 θ 에 대해 두번 미분한 $p \times p$ 행렬(즉, 헤시안 행렬)이라 하자. 최우추정치는 $0 = \nabla l(\theta)$ 을 만족하는데 이 식의 해가 식으로 표현안 될 경우 이 식을 초기치 $\hat{\theta}^{(0)}$ 에 대해 1차 테일러 급수 전개하면

$$\begin{aligned} 0 &= \nabla l(\theta) \\ &\simeq \nabla l(\hat{\theta}^{(0)}) + H(\hat{\theta}^{(0)})(\theta - \hat{\theta}^{(0)}) \end{aligned}$$

으로 표현할 수 있는데 위의 근사식을 만족하는 θ 를 $\hat{\theta}^{(1)}$ 라 두면

$$\hat{\theta}^{(1)} = \hat{\theta}^{(0)} - H(\hat{\theta}^{(0)})^{-1} \nabla l(\hat{\theta}^{(0)})$$


이 되고 이를 수렴할 때까지 반복하며 뉴턴-랩슨 반복법은

$$\hat{\theta}^{(t+1)} = \hat{\theta}^{(t)} - H(\hat{\theta}^{(t)})^{-1} \nabla l(\hat{\theta}^{(t)}), \quad t = 0, 1, 2, \dots$$

으로 표현할 수 있다. $-H(\theta)$ 대신 피셔정보행렬 $-E[H(\theta)]$ 을 사용하면 피셔의 스코어링 방법(Fisher's scoring method)이라 부른다. θ 가 스칼라인 경우 뉴턴-랩슨 반복법의 수렴성이 (그림 1.4)에 잘 나타나 있다. 즉,

$$H(\hat{\theta}^{(t)}) = -\frac{\nabla l(\hat{\theta}^{(t)})}{\hat{\theta}^{(t+1)} - \hat{\theta}^{(t)}}$$

로 부터 알 수 있듯이 반복될수록 구하고자 하는 해 $\hat{\theta}$ 에 가까워짐을 알 수 있다.



(그림 1.4) 뉴턴-랩슨 반복법에서 반복될수록 초기치가 해(최우추정치)에 가까워짐을 알 수 있다.

1.6 다중검정

지금까지는 하나의 가설에 대한 검정을 하였는데 많은 경우 두 개 이상의 귀무가설에 대하여 동시에 검정을 해야 할 필요가 있으며 여러 개의 귀무가설을 동시에 검정하는 것을 다중검정(multiple testing)이라 부른다. 우선 다중검정이 필요한 예를 살펴보기로 하자.

1.6.1 다중검정의 예

(1) 일원배치법

3가지 처리(treatment)를 하고 각 처리에서 n 번 반복하는 일원배치법을 고려한다.

$$Y_{ij} = \mu_i + \varepsilon_{ij}, \quad i = 1, 2, 3, \quad j = 1, 2, \dots, n$$

이제 각 처리효과가 같은지 검정하기 위해 다음과 같은 귀무가설과 대립가설을 고려한다.

$$H_0 : \mu_1 = \mu_2 = \mu_3 \quad \text{vs} \quad H_1 : \text{not } H_0$$

주어진 유의수준(level of significance)에서 귀무가설이 기각되지 않으면 처리효과 간에 차이가 없다고 결론을 내리고, 귀무가설이 기각되면 다음 단계는 어떤 처리간에 차이가 있는

지 밝혀야 한다. 즉, 다음과 같은 3개의 귀무가설을 동시에 고려해야 한다.

$$H_{01} : \mu_1 = \mu_2, \quad H_{02} : \mu_1 = \mu_3, \quad H_{03} : \mu_2 = \mu_3$$

이처럼 두 개 이상의 귀무가설을 동시에 고려해야하는 검정을 다중검정이라 부르고 이는 결국 모든 처리효과 간의 차이인 $\mu_1 - \mu_2$, $\mu_2 - \mu_3$, $\mu_1 - \mu_3$ 에 대한 신뢰구간을 구하는 문제와 같다. 이것을 다중비교(multiple comparison) 또는 동시신뢰구간(simultaneous confidence interval)이라 한다.

(2) 마이크로어레이 자료

인간의 유전자는 약 30,000개로 알려져 있는데 어떤 특정 질병과 관련된 유전자를 탐색하는 일은 매우 중요하다. 이를 위해 최근 마이크로어레이 자료(microarray data)가 많이 이용되고 있다. 목적에 따라 여러 형태의 디자인으로 마이크로어레이 자료를 구성할 수 있는데 예를 들어 폐암과 관련된 유전자를 찾기 위해 n_1 명의 폐암환자로 부터 유전자 발현정보를 얻고 n_2 명의 정상인으로 부터 유전자 발현정보를 얻었다고 하자. 이때 마이크로어레이 자료는 $p \times n$ 행렬로 주어지는데 $n = n_1 + n_2$ 이고 p 는 유전자의 개수이다. 흔히 n 은 100 이하의 수이고 p 는 1000 이상의 수이다. 암환자의 발현량인 μ_{1i} 가 정상인의 발현량인 μ_{2i} 와 같은지 모든 p 개의 유전자에 대해 검정해야 한다. 즉, 우리의 관심은 다음에 주어진 것 처럼 p 개의 귀무가설을 동시에 검정하는 것이다.

$$H_{0i} : \mu_{1i} = \mu_{2i}, \quad i = 1, 2, \dots, p$$

일반적으로 마이크로어레이 자료에서 유전자의 수인 p 는 수천 개이므로 우리는 수천 개의 귀무가설을 동시에 검정해야 하는 다중검정의 문제에 접하게 된다.

1.6.2 제1종 오류

m 개의 다중검정

$$H_{0i} : \mu_{1i} = \mu_{2i}, \quad i = 1, 2, \dots, m$$

에서 E_i 를 H_{0i} 가 참일 때 H_{0i} 를 기각하는 사건이라 하자. 유의수준 α 가 주어져 있을 때 만약 어떤 검정이 $P(E_i) \leq \alpha$ 를 만족한다면 이러한 검정을 “ α 에서 제어된 검정”(controlled

at α)이라 부른다. 여기서 $P(E_i)$ 는 i 번째 가설에서 제1종 오류를 범할 확률이고, 다중검정에서 제1종 오류를 범할 확률은 모든 귀무가설 H_{0i} , $i = 1, 2, \dots, m$ 가 참일 때 적어도 하나 이상의 H_{0i} 를 기각할 확률이다. 즉, m 개의 다중검정에서 발생하는 제1종 오류는

$$P(\bigcup E_i) = 1 - P(\bigcap E_i^c) = 1 - \prod_{i=1}^m P(E_i^c) \leq 1 - (1 - \alpha)^m$$

이 되는데(각 검정을 독립적으로 수행하는 경우) 이를 $\alpha = .05$ 인 경우 몇 가지 m 에 대해 살펴보면

$$m = 2 : 1 - (1 - 0.05)^2 = 0.0975$$

$$m = 3 : 1 - (1 - 0.05)^3 = 0.1426$$

$$m = 100 : 1 - (1 - 0.05)^{100} = 0.9941$$

이 된다. 만약 두 개의 귀무가설을 검정하여 기각했을 때 제1종 오류를 범할 확률이 0.0975가 되며 100개의 귀무가설인 경우 제1종 오류는 거의 1에 가깝게 된다. 제1종 오류를 범할 확률이 1에 가깝다는 것은 기각된 귀무가설이 잘못 기각되었을 가능성이 거의 100%라는 얘기다. 따라서, 다중검정에서는 m 의 크기에 따라 유의수준을 조정하여 제1종 오류를 충분히 줄여주는 방법이 필요하다.

1.6.3 군 단위 오류율

다중검정에서 유의수준을 조정하여 제1종 오류를 줄여주기 위해 오래 전 부터 사용해 왔던 방법으로 군 단위 오류율(FWER : Family-Wise Error Rate)을 조정하는 것이 있다. <표 1.2>에 나타나 있듯이 m 개의 가설중에서 R 개를 기각하였으며 그 중에서도 귀무가설이 참인데도 불구하고 V 개를 기각했다고 하자(여기서 R 은 관측가능한 변수지만 V 는 관측불가임). FWER은

$$P(V \geq 1 | m_0 > 0) \leq \alpha$$

를 만족하도록 α 를 조절하는 것이다. 즉, FWER은 귀무가설이 참일 때 적어도 하나 이상의 귀무가설을 기각하는 잘못을 저지를 확률을 α 이하로 조절하겠다는 것이다. 이를 위해 여러 가지 방법이 제안되었는데 여기서는 본페로니(Bonferroni)방법과 시닥(Sidak)방법 등을 소개한다.

<표 1.2> m개의 다중검정결과

참 사실 \ 검정 결과	H_0 채택 H_0 기각		합계
	H_0 참	H_0 기각	
H_0 참	U	V	m_0
H_1 참	T	S	m_1
합계	$m - R$	R	m

(1) 본페로니 방법

이 방법은 다음의 부등식 (이를 흔히 본페로니 부등식이라 부른다)에 근거하고 있다.

$$P(V \geq 1) = P(\bigcup E_i) \leq \sum P(E_i) \leq \alpha.$$

따라서, $P(V \geq 1)$ 을 α 이하로 조절하기 위해 $P(E_i) \leq \alpha^* \equiv \alpha/m$ 로 조절하면 된다. 예를 들어, 유의수준이 .05로 주어졌을 때 10개의 귀무가설을 동시에 검정하기 위해서는 각 귀무가설의 유의수준을 $.05/10 = .005$ 로 조절해야 된다는 것이다. p_i 를 i 번째 귀무가설을 검정하기 위한 검정통계량의 p -값이라 하자. 귀무가설의 기각여부는 주어진 검정통계량의 p -값과 일대일로 대응되므로 본페로니 방법을 사용한다는 것은 p -값을 $p_i^* = mp_i$ 로 변환하는 것과 같다. 즉, 본페로니 방법은 $P(E_i) \leq \alpha/m$ 또는 $mp_i \leq \alpha$ 이면 H_{0i} 를 기각한다. 일반적으로 본페로니 방법은 매우 보수적(conservative)이고 검정력이 약한 것으로 알려져 있다. 여기서 보수적이란 좀처럼 귀무가설을 기각할 수 없다는 뜻인데 이는 위에 주어진 본페로니 부등식의 상한값이 날카롭지 못하기(not sharp) 때문이다. 예를 들어, 유의수준 $\alpha = .05$ 에서 두 그룹을 비교하기 위해 t -검정을 할 경우 하나의 귀무가설일 경우 $p < .05$ 이면 귀무가설을 기각하지만 $m = 10$ 인 다중검정에서는 어떤 귀무가설을 기각하기 위해서는 $p^* < .005$ 가 되어야만 하므로 좀처럼 기각하기 어렵다.

(2) 시닥 방법

본페로니 부등식이 날카롭지 못해서 본페로니 방법은 보수적이고 약한 검정력을 가진다고 했으므로 이를 보완하기 위해 시닥(Sidak)은 $P(\bigcup E_i) = 1 - (1 - \alpha)^m$ 을 이용하였다. 즉, $1 - (1 - \alpha^*)^m \leq \alpha$ 이면 $\alpha^* \leq 1 - (1 - \alpha)^{1/m}$ 이므로 주어진 α 대신 $\alpha^* = 1 - (1 - \alpha)^{1/m}$ 을 이용한다. p -값을 이용할 경우 변환된 값은 $p_i^* = 1 - (1 - p_i)^m$ 로 주어진다. 일반적으로 시닥 방법은 본페로니 방법보다 검정력이 더 강하지만 m 이 크면 두 방법은 매우 보수적인 것으로 알려져 있다.

1.6.4 위발견율

지난 100여년 간 통계학 분야에서 지속적으로 사용되어 온 가설검정의 기본 개념은 피셔-네이만-피어슨(Fisher-Neyman-Pearson)에 의해 정립되었으며 이는 제1종 오류가 일정한 값 이하라는 조건 하에 검정력을 최대화하는 것이 초점이었다. 이런 기존의 개념은 여러 가지 좋은 성질들을 가지고 있으며 많은 분야에 성공적으로 사용되어 왔음은 누구도 부인할 수 없다. 그간 가설검정의 대상은 표본 수가 비교적 작고 다중검정의 경우도 m 이 비교적 작은 수가 대부분이었다. 그러나 최근 마이크로어레이 자료처럼 표본 수도 크고 귀무가설도 수천개를 동시에 검정해야하는 상황이 생겼으며 앞에서 언급한 것처럼 기존의 검정법은 FWER등의 방법을 동원하더라도 한계에 부딪히고 말았다. 약 100년간 지속되어 온 통계학의 검정법에 획기적인 변화가 생겼는데 이는 바로 벤자미니와 호허버그(Benjamini & Hochberg, 1995)에 의해 정립된 위발견율(FDR : False Discovery Rate)이다. 에프론(Efron, 2008)이 언급했듯이 FDR은 지난 100년간 통계학 분야에서 가장 뛰어난 업적 중의 하나로 꼽힌다.

위발견율 방법은 주어진 상수 q , $0 < q < 1$ 에 대해

$$E(V/R) \leq q$$

를 만족하는 검정법이다. FWER이 제1종 오류를 일으킬 확률을 제어하는 방법이라면 FDR은 기각한 귀무가설 중에서 잘못 기각된 가설의 비율(이를 위발견율이라 부른다)의 기댓값을 제어하는 방법이다. 확률과 기댓값은 엄연히 다른 것이다. $q = .05$ 가 주어졌다고 가정했을 때 1000개의 귀무가설에서 우리가 기각한 가설의 수가 20개라면 이 중에서 잘못 기각된 가설이 평균적으로 1개 이하라는 것이 FDR에 의한 해석이다. 한편, $\alpha = .05$ 가 주어졌다고 가정했을 때 1000개의 귀무가설에서 우리가 기각한 가설의 수가 20개라면 이 중에서 잘못 기각된 가설이 1개 이상일 확률이 .05이하라는 것이 FWER에 의한 해석이다. 어떤 방법이 더 이해하기 쉽고 현실적인 결론인지 독자 스스로 생각해 보기 바란다. 이제 FDR에 대한 중요한 성질을 살펴보고 실제로 FDR에 의한 다중검정법을 계산하는 알고리즘을 소개한다.

[정리 1.1] FWER이 제어되면 FDR도 제어된다.

[증명] $FDR \leq FWER$ 임을 보이면 된다.

(1) 먼저, $m_1 = 0$ 인 경우를 고려하자. $m_1 = 0$ 이면 $S = 0$ 이므로 $V = R$ 이다. 이 때 $V = 0$ 이면 $V/R = 0$ 이다. 즉, $FDR = E(V/R) \leq P(V \geq 1) = 0 = FWER$ 이 성립된다. 만약 $V > 0$ 이면 $V/R = 1$ 이다. 따라서,

38 제 1 장 기초통계이론

$FDR = E(V/R) = 1 = P(V \geq 1) = FWER$ 이 역시 성립된다.

(2) 이번에는, $m_1 > 0$ 인 경우를 고려하자. 만약 $V = 0$ 이면 $FDR = 0 \leq P(V \geq 1) = 0 = FWER$ 이 되고, 만약 $V > 0$ 이면 $V/R = 1$ 이다. 따라서, $FDR = E(V/R) \leq 1 = P(V \geq 1) = FWER$ 이 성립된다. $\square$

다음에 소개하는 정리는 FDR을 이용한 다중검정 알고리즘이다. 증명은 꽤 수준이 높으므로 벤자미니와 호허버그(Benjamini & Hochberg, 1995) 논문을 참고하기 바란다.

[정리 1.2] $p_1 \leq p_2 \leq \dots \leq p_m$ 을 m 개의 귀무가설들에 대한 p -값이라 하고, q 는 주어진 상수라고 할 때


$$j = \max_{1 \leq i \leq m} \left\{ i \mid p_i \leq \frac{i}{m} q \right\}$$

이면 FDR은 $p_1 \leq p_2 \leq \dots \leq p_j$ 에 해당되는 귀무가설을 기각한다.

FDR을 이용한 다중검정을 위해 예를 들어 보자. $m = 15$ 이고 $p_1 \leq p_2 \leq \dots \leq p_{15}$ 는 다음과 같다고 하자.

0.0030	0.0050	0.0060	0.0095	0.0201	0.0278	0.0298	0.0344
0.0459	0.3240	0.4262	0.5719	0.6528	0.7590	1.0000	

또한, $\alpha = q = 0.05$ 라 하자. 본페로니 방법은 $0.05/15 = 0.0033$ 이므로 1개의 가설만을 기각하지만 FDR은 4개의 가설을 기각한다(그림 1.5 참조).



(그림 1.5) FDR에 의한 검정 결과, q/m 직선과 p -값들을 나타낸 것으로 q/m 직선 아래 쪽의 p -값에 해당되는 가설을 기각한다.