

제 4 장

회귀진단

- 4.1 서론
- 4.2 잔차
- 4.3 지렛값
- 4.4 영향력 관측치
- 4.5 영향력 측도
- 4.6 이상치의 검정
- 4.7 다중공선성의 탐색
- 4.8 자기상관과 더빈-왓슨 검정

4.2.2 외 표준화 잔차

앞에서 정의한 내 표준화 잔차의 단점은 관측치 Y_i 가 분자의 e_i 와 분모의 s 의 계산에 동시에 사용된다는 것이다. 만일 특정한 Y_i 가 이상점일 경우 잔차 e_i 가 커지게 되지만, 동시에 Y_i 가 s 의 값에도 영향을 미쳐 s 의 값이 크게 된다. 그러므로 이 경우 내 표준화 잔차의 값으로 이상점 Y_i 를 찾아내지 못할 가능성이 있다. 이를 해결하기 위해서는 e_i 와 독립적으로 계산되는 σ^2 의 추정치가 필요하게 된다. 이를테면, 현재 분석에 포함된 관측치와 독립적인 다른 자료가 있는 경우에는 이를 이용하여 s^2 의 값을 구할 수 있을 것이다. 그러나 보통의 경우에는 분석에 포함된 자료가 전부이므로 다른 대안을 생각하여야 한다.

이 경우 합리적인 방법중의 하나는 i 번째 관측치 Y_i 를 제외시킨 후 $(n-1)$ 개의 관측치로 회귀모형을 적합시켰을 때 얻어지는 σ^2 의 불편추정치를 e_i 의 표준화에 사용하는 것이다. 즉, 이 추정치를 $s_{(i)}^2$ 이라 나타내면 e_i 의 표준화로

$$r_i^* = \frac{e_i}{s_{(i)}\sqrt{1-h_{ii}}}$$

를 정의할 수 있으며 이 표준화 잔차를 외 표준화 잔차(externally studentized residual), 교차확인 잔차(cross-validated residual), 또는 잭나이프 잔차(jackknife residual)라 부른다. r_i^* 의 장점은 r_i^* 의 분포가 우리가 잘 알고 있는 자유도 $(n-p-1)$ 인 t 분포를 따른다는 것이다.

외 표준화 잔차의 계산에서 $s_{(i)}^2$ 을 얻기 위해 $(n-1)$ 개의 관측치로 회귀모형을 다시 적합할 필요는 없다. 왜냐하면, 4.7절에서 증명되듯이 $s_{(i)}^2$ 은 n 개의 관측치를 모두 사용하여 계산한 s^2 으로부터

$$s_{(i)}^2 = s^2 \cdot \frac{n-p-r_i^2}{n-p-1} \quad (4.3)$$

의 관계식을 이용하여 계산되기 때문이다. 식 (4.3)에 대한 증명은 연습문제 4.9에 주어져 있다. 그리고 식 (4.3)을 이용하면 r_i^* 와 r_i 의 관계는

$$r_i^* = r_i \sqrt{\frac{n-p-1}{n-p-r_i^2}}$$

으로 주어짐을 쉽게 알 수 있다.

4.3 지렛값


모자행렬 H 의 i 번째 대각원소 h_{ii} 를 디자인 행렬 X 의 i 번째 지렛값(leverage value)이라고 한다. 지렛값은 h_{ii} 의 정의에서 알 수 있듯이 반응변수 y 와는 무관하고 오직 설명변수들에 의해서만 결정된다. 우선, $h_{ii} = \mathbf{x}_i'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_i$ 가 지렛값이라고 불리는 이유에 대해 살펴보자. 쉽게 표현하자면 h_{ii} 는 i 번째 관측치 $\mathbf{x}_i$ 가 중심 $\bar{\mathbf{x}} = \frac{1}{n} \sum_{i=1}^n \mathbf{x}_i$ 에서 떨어져 있는 정도를 나타낸다. 즉, $\bar{\mathbf{x}}$ 근처의 관측치는 작은 지렛값을 가지고, $\bar{\mathbf{x}}$ 에서 멀리 떨어져 있는 관측치는 큰 지렛값을 갖는다((그림 4.1) 참조). 이는 시이소오(seesaw)의 원리와 같다. 시이소오의 무게중심을 $\bar{\mathbf{x}}$ 라 할 때, 시이소오를 타는 사람들의 몸무게가 전부 같다고 가정하면 $\bar{\mathbf{x}}$ 에서 멀리 앉을수록 그 쪽으로 더 기울어진다. 이것이 바로 지렛의 원리이고, 시이소오를 타는 사람들의 위치는 $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ 으로 비유될 수 있다. 설명변수가 한 개인 단순선형회귀에서는

$$h_{ij} = (1 \ x_i) \frac{1}{S_{XX}} \begin{pmatrix} \sum x_i^2/n & -\bar{x} \\ -\bar{x} & 1 \end{pmatrix} \begin{pmatrix} 1 \\ x_j \end{pmatrix} = \frac{1}{n} + \frac{(x_i - \bar{x})(x_j - \bar{x})}{S_{XX}}$$

이고, 따라서

$$h_{ii} = \frac{1}{n} + \frac{(x_i - \bar{x})^2}{S_{XX}} \quad (4.4)$$

이므로 x_i 가 $\bar{x}$ 에서 멀어질수록 h_{ii} 값이 커짐은 명백하다.



(그림 4.1) 평균에 가까이 위치한 관측치는 지렛값이 작고, 멀리 떨어진 관측치들의 지렛값은 크다.

이제, 설명변수가 $p - 1$ 개인 중선형회귀모형에서 h_{ii} 의 여러 가지 성질을 살펴보자.

$$(1) \sum_{i=1}^n h_{ii} = p$$

즉, 모든 지렛값의 합은 설명변수의 개수에 1을 더한 것이다. 이는

$$\sum_{i=1}^n h_{ii} = \text{tr}(\mathbf{H}) = \text{tr}[\mathbf{X}(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'] = \text{tr}[(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{X}] = \text{tr}(\mathbf{I}_p) = p$$

으로 쉽게 증명된다.

$$(2) \frac{1}{n} \leq h_{ii} \leq 1$$

우선 $h_{ii} \leq 1$ 이라는 사실은 쉽게 증명된다. 왜냐하면 $\mathbf{H}$ 가 멱등행렬이므로

$$h_{ii} = \sum_{j=1}^n h_{ij}^2 = h_{ii}^2 + \sum_{j \neq i} h_{ij}^2$$

따라서 $h_{ii} \geq h_{ii}^2$ 이고, 이는 $h_{ii} \leq 1$ 임을 의미한다. 그런데 $h_{ii} \geq \frac{1}{n}$ 은 쉽게 증명되지 않는다. 행렬 $\tilde{\mathbf{X}}$ 를 디자인 행렬 $\mathbf{X}$ 에서 각 관측치들의 평균을 뺀 행렬(이를 흔히 중심화된 행렬이라 부른다)이라 하면

$$h_{ii} = \frac{1}{n} + (\mathbf{x}_i - \bar{\mathbf{x}})'(\tilde{\mathbf{X}}'\tilde{\mathbf{X}})^{-1}(\mathbf{x}_i - \bar{\mathbf{x}})$$

임을 보일 수 있고, 따라서 $h_{ii} \geq \frac{1}{n}$ 이 된다. 단순선형회귀일때는 이미 식 (4.4)에서 이 사실을 알 수 있다.

$$(3) h_{ij}^2 \leq h_{ii}h_{jj}$$

즉, 비 대각원소의 제곱은 언제나 해당되는 대각원소들의 곱보다 작거나 같다. 이것은 코오시-슈바르츠부등식(즉, 두 벡터 $\mathbf{a}$ 와 $\mathbf{b}$ 에 대해 $(\mathbf{a}'\mathbf{b})^2 \leq (\mathbf{a}'\mathbf{a})(\mathbf{b}'\mathbf{b})$ 이 성립한다)에 의해 증명될 수 있다. $\mathbf{X}'\mathbf{X}$ 는 대칭인 양정치행렬이므로 $\mathbf{X}'\mathbf{X} = \mathbf{R}'\mathbf{R}$ 이 되는 상삼각행렬(upper triangular matrix) $\mathbf{R}$ 이 존재한다(출레스키 분할법). 따라서

$$h_{ij} = \mathbf{x}_i'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_j = \mathbf{x}_i'(\mathbf{R}'\mathbf{R})^{-1}\mathbf{x}_j = \mathbf{a}'\mathbf{b}$$

인데, 여기서 $\mathbf{a} = (\mathbf{R}^{-1})' \mathbf{x}_i$, $\mathbf{b} = (\mathbf{R}^{-1})' \mathbf{x}_j$ 이다. 이제 코오시-슈바르쯔부등식에 의하여

$$\begin{aligned} h_{ij}^2 &\leq [((\mathbf{R}^{-1})' \mathbf{x}_i)' (\mathbf{R}^{-1})' \mathbf{x}_i] [((\mathbf{R}^{-1})' \mathbf{x}_j)' (\mathbf{R}^{-1})' \mathbf{x}_j] \\ &= \mathbf{x}_i' (\mathbf{R}' \mathbf{R})^{-1} \mathbf{x}_i \mathbf{x}_j' (\mathbf{R}' \mathbf{R})^{-1} \mathbf{x}_j = h_{ii} h_{jj} \end{aligned}$$

가 됨을 알 수 있다.

지금까지 지렛값의 몇 가지 성질을 살펴보았다. 우리는 h_{ii} 가 큰 값을 갖는 관측치를 높은 지렛점(high-leverage point)이라 부른다. 이미 시이소오의 원리로 h_{ii} 의 역할을 얘기했는데 좀 더 구체적으로 살펴보자. 먼저 i 번째 적합치 $\hat{y}_i$ 에 대해 다음과 같은 관계식이 성립함을 보일 수 있다.

$$\begin{aligned} \hat{y}_i &= \mathbf{x}_i' (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{y} \\ &= \sum_{j=1}^n \mathbf{x}_i' (\mathbf{X}' \mathbf{X})^{-1} \mathbf{x}_j y_j \\ &= h_{ii} y_i + \sum_{j \neq i} h_{ij} y_j \end{aligned}$$

일반적으로 $\mathbf{H}$ 의 대각원소인 h_{ii} 가 비대각원소인 h_{ij} 보다 크기 때문에 $\hat{y}_i$ 에 가장 큰 영향을 미치는 반응변수 값은 y_i 이고, 만약 h_{ii} 가 매우 큰 값이라면 $\hat{y}_i$ 은 주로 h_{ii} 에 의해 결정되어 진다. 따라서 h_{ii} 값이 $\hat{y}_i$ 에 중요한 영향을 미치고 우리가 지렛값에 관심을 갖는 이유가 바로 이것 때문이다. 그렇다면 h_{ii} 가 어느 정도로 큰 값을 가져야 높은 지렛점으로 판단되는가? 앞에서 언급했듯이 h_{ii} 는 완전히 디자인 행렬 $\mathbf{X}$ 에 의해 결정되므로, 디자인 행렬이 어떻게 주어지느냐에 따라 h_{ii} 값들의 크기가 달라지며, h_{ii} 값들에 대한 정확한 분포나 근사적 분포는 구할 수 없다. 따라서 현재 통용되는 개략적인(rule of thumb) 기준치는 h_{ii} 들의 평균이 p/n 이므로 이것의 두배인 $2p/n$ 이 널리 사용되고 있다.

4.4 영향력 관측치


한 개 또는 소수개의 관측치가 회귀분석에서의 추정량 $\hat{\beta}$, s^2 등에 큰 영향을 미칠 때 이들 관측치를 영향력 관측치(influential observation)라 부른다. 어떤 관측치가 이상치거나 높은 지렛점이라고 해서 반드시 영향력 관측치가 될 필요는 없으며 이러한 영향력 관측치를 탐색하는데 있어서 두 가지 중요한 점이 반드시 고려되어야 한다.

첫째는 “어떤 추정량에 영향을 미치는가?(influential on what?)”를 고려해야 한다. 회

귀계수 추정량 $\hat{\beta}$ 에 영향을 많이 미치는 관측치가 s^2 에는 영향을 많이 미칠 수도 있고 그렇지 않을 수도 있다. 그러므로 영향력 관측치는 반드시 어떤 추정치에 관한 것인지가 명시되어야 한다.

둘째는 관측치 하나 하나의 영향력과 관측치 군(set of observations)의 영향력이 구별되어야 한다. 예를 들어, i 번째 관측치가 $\hat{\beta}$ 에 대한 영향력 관측치이고 j 번째 관측치도 $\hat{\beta}$ 에 대한 영향력 관측치라 하더라도, 두 관측치를 동시에 고려한 (i, j) 두 관측치의 $\hat{\beta}$ 에 대한 영향력은 작을 수가 있다. 반대로, (i, j) 두 관측치의 $\hat{\beta}$ 에 대한 영향력은 매우 큰데 i 와 j 각각의 $\hat{\beta}$ 에 대한 영향력은 작을 수가 있다((그림 4.2) 참조). 관측치 하나 하나의 영향력을 조사하여 영향력이 크다고 판단되는 관측치를 특히 개인적 영향력 관측치(singly influential observation) 또는 간단히 영향력 관측치(influential observation)라 부르고, 두 개 이상의 관측치들에 대한 영향력을 조사하여 영향력이 크다고 판단되는 관측치들은 영향력 관측치군(influential set) 또는 (set of influential observations)이라 부른다. 편의상, 개인적 영향력 관측치와 영향력 관측치군을 모두 영향력 관측치라 부르지만 반드시 구별해서 이해해야 한다.

또한, 영향력 관측치군은 두 가지 효과로 구별된다. (i, j) 가 영향력 관측치군이라 하자. 이 때 i 와 j 각각은 영향력 관측치가 아닌 경우를 가면효과(masking effect)라 부르고, i 또는 j 가 영향력 관측치인 경우를 늪현상(swamping phenomenon) 또는 늪효과(swamping effect)라 부른다. 영향력 관측치군은 항상 두 효과 중의 하나에 의해 발생되며, 어떤 효과에 의해 발생되었는지 밝힐 필요가 있다.



(그림 4.2) A, B 각각은 영향력 관측치들이지만 A와 B를 동시에 고려하면 영향력 관측치군은 아니다. C와 D 각각은 영향력 관측치가 아니지만 C와 D는 가면효과에 의한 영향력 관측치군이다.

4.5 영향력 측도

관측치의 영향력을 판단하기 위해서는 영향력 측도(influence measure)가 필요하다. 지금까지 제안된 영향력 측도는 매우 많은 종류가 있으나 이들은 크게 네가지로 분류된다.

- (1) 소거법(deletion method)
- (2) 무한소 교란법(infinitesimal perturbation method)
- (3) 국소 영향력(local influence)
- (4) 대체법(replacement method)

첫째, 소거법이란 i 번째 관측치의 영향력을 측정하기 위해 i 번째 관측치를 제거한 후 $n-1$ 개의 관측치로 추정한 추정치와 원래의 추정치의 차이를 구하는 방법이다. 예를 들어, i 번째 관측치의 $\hat{\beta}$ 에 대한 영향력을 측정하기 위해 $\hat{\beta} - \hat{\beta}_{(i)}$ 를 계산한다. 단, 여기서 $\hat{\beta}_{(i)}$ 란 i 번째 관측치를 제외한 $n-1$ 개의 관측치로 구한 β 의 최소제곱추정치이다. 즉, $X_{(i)}$ 를 i 번째 관측치를 제거시킨 $(n-1) \times p$ 행렬, $y_{(i)}$ 를 i 번째를 제거시킨 $(n-1)$ 차원 관측치벡터를 나타내면 $\hat{\beta}_{(i)} = (X'_{(i)}X_{(i)})^{-1}X'_{(i)}y_{(i)}$ 이다.

둘째, 소거법이 i 번째 관측치를 완전히 제거시키는 방법임에 비해 무한소 교란법은 i 번째 관측치의 영향을 여러 각도에서 살펴보는 방법이다. 좀 더 구체적으로 설명하기 위해, $y_j \sim N(x'_j\beta, \sigma^2/w_j)$, $j = 1, \dots, n$ 이라 하고

$$w_j = \begin{cases} 1, & j = 1, \dots, i-1, i+1, \dots, n \\ w, & j = i \end{cases}$$

이라 하자. 단, 여기서 $0 \leq w \leq 1$ 이다. 이 가정하에서 구한 β 의 최소제곱 추정치를 $\hat{\beta}_w$ 라 하면 $\hat{\beta}_1$ 은 $\hat{\beta}$ 와 같아진다. 또한, w 가 0에 무한히 가까워지면 i 번째 관측치를 제거시키는 효과와 같아지고, 궁극적으로 $\hat{\beta}_0 = \hat{\beta}_{(i)}$ 가 된다. 즉, w 를 1에서 0으로 변화시켜 가면 i 번째 관측치가 $\hat{\beta}$ 에 미치는 영향을 점점 줄여가는 효과를 얻게 된다. 이와 같이 $\hat{\beta}_w$ 의 값을 여러 가지 w 값에 대해 살펴보는 것이 무한소 교란법이다. 따라서 소거법은 무한소 교란법의 특수한 경우 ($w = 0$)라 할 수 있다.

셋째, 국소영향력을 설명하기 위해 잔차를 대각원소로 갖는 $n \times n$ 대각행렬을 $D = \text{diag}(e_1, \dots, e_n)$ 이라 하고, 벡터 l 을 크기가 1인 n 차원 벡터라 하자. 또한,

$$C_l = l' K l \quad (4.5)$$

이라 정의하고, 여기서 $K = D H D$ 라고 하자. 이제, $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$ 을 K 의 고

유치라 하고 $l_1, l_2, \dots, l_n$ 을 이들의 고유벡터라고 하면 l_1 (가장 큰 고유치 λ_1 에 해당하는 고유벡터)이 국소영향력이 된다. 또한, l_1 의 구성원소 n 개 중에서 절대값이 큰 원소에 해당하는 것을 영향력 관측치로 판단한다.

넷째, 대치법이란 i 번째 관측치를 소거시키는 것이 아니라 y_i 대신 $\hat{y}_i$ 을 대치시켜 i 번째 관측치의 영향력을 보는 것으로 다른 측도들과 매우 밀접한 관계가 있음을 보일 수 있다.

이상으로 영향력 측도를 정의하는 네 가지 방법을 소개하였는데 이 중에서 소거법이 가장 널리 사용되며 많은 측도들이 이 방법에 의해 유도되었다.

4.5.1 소거법에 의한 측도

(1) 쿡 통계량

여러 측도들 중에서 쿡 통계량(Cook's distance, Cook 1977)이 가장 널리 사용되고 있으며 MINITAB, SAS, SPSS 등의 통계패키지에서 간단한 명령어에 의해 쉽게 구해진다.

먼저, i 번째 관측치의 쿡 통계량을 정의해보자. i 번째 관측치의 $\hat{\beta}$ 에 대한 영향력은 $\hat{\beta} - \hat{\beta}_{(i)}$ 로 생각할 수 있으며, 밀러(Miller, 1974)는

$$\hat{\beta} - \hat{\beta}_{(i)} = (X'X)^{-1}x_i e_i / (1 - h_{ii}) \quad (4.6)$$

임을 보였다(증명 : 연습문제 참조). 그런데 식 (4.6)은 p 차원벡터로 척도 무관하지 않으므로 이에 대한 표준화가 필요한데, 쿡(Cook, 1977)은

$$C_i = \frac{1}{p}(\hat{\beta} - \hat{\beta}_{(i)})'Cov(\hat{\beta})^{-1}(\hat{\beta} - \hat{\beta}_{(i)}) \quad (4.7)$$

를 제안하였고, 이를 i 번째 관측치의 쿡 통계량이라 부른다. 식 (4.6)을 이용하면

$$C_i = \frac{1}{p\sigma^2} \cdot \frac{e_i^2 h_{ii}}{(1 - h_{ii})^2} \quad (4.8)$$

임을 쉽게 보일 수 있고, 일반적으로 σ^2 이 알려져 있지 않으므로 s^2 으로 대체하여 사용한다. 또한, 내 표준화 잔차 r_i (식 (4.1)참조)를 사용하면

$$C_i = \frac{1}{p} \cdot \frac{r_i^2 h_{ii}}{(1 - h_{ii})} \quad (4.9)$$

로 표현된다. 따라서 C_i 는 잔차와 지렛값의 증가함수로 표현되고 C_i 의 값이 클 경우 i 번째 관측치가 영향력 관측치로 판단된다. 그렇다면 C_i 에 대한 기준치는 어떤 값일까?

쿡(Cook, 1977)은 β 의 공동신뢰영역이

$$\frac{1}{p}(\hat{\beta} - \beta)'Cov(\hat{\beta})^{-1}(\hat{\beta} - \beta) \leq F_{\alpha}(p, n-p) \quad (4.10)$$

임에 착안하여, 식 (4.7)에 정의된 C_i 가 식 (4.10)에서 β 대신 $\hat{\beta}_{(i)}$ 를 대체한 형태이므로

$$C_i \geq F_{0.05}(p, n-p) \quad (4.11)$$

이면 영향력 관측치로 판단하자고 하였다. 그러나 김과 스토러(Kim & Storer, 1996)는 모의실험을 통해 여러 형태의 선형회귀모형에서 쿡 통계량의 95% 백분위수에 해당되는

$$C_i \geq 3.67/(n-p) \quad (4.12)$$

가 더 적절한 쿡 통계량의 기준치임을 밝혔다. 한편 $r_i^2/(n-p)$ 가 베타분포를 따르므로 식 (4.9)에 의해 베타분포의 95% 백분위수가 식 (4.12)의 기준치와 거의 같음을 알 수 있다.

다음으로, 영향력 관측치군을 위한 쿡 통계량을 살펴보자. k 개의 원소를 갖는 집합 $K = \{i_1, \dots, i_k\}$ 를 생각하면, 집합 K 에 속하는 관측치들의 $\hat{\beta}$ 에 대한 영향력은 $\hat{\beta} - \hat{\beta}_{(K)}$ 로 계산할 수 있다. 여기서, $\hat{\beta}_{(K)}$ 는 k 개의 관측치를 제거시킨 후 $n-k$ 개로 추정한 β 의 추정치이다. 즉, $\mathbf{X}_{(K)}$ 는 $\mathbf{X}$ 행렬에서 K 에 속하는 k 개의 행을 없앤 $(n-k) \times p$ 행렬을, $\mathbf{y}_{(K)}$ 는 $\mathbf{y}$ 벡터에서 $y_{i1}, \dots, y_{ik}$ 를 제거시킨 $(n-k)$ 벡터를 나타낸다면 $\hat{\beta}_{(K)} = (\mathbf{X}_{(K)}' \mathbf{X}_{(K)})^{-1} \mathbf{X}_{(K)}' \mathbf{y}_{(K)}$ 이다. 따라서, 집합 K 에 속하는 k 개 관측치들의 $\hat{\beta}$ 에 대한 쿡 통계량은

$$C_K = \frac{1}{p}(\hat{\beta} - \hat{\beta}_{(K)})'Cov(\hat{\beta})^{-1}(\hat{\beta} - \hat{\beta}_{(K)}) \quad (4.13)$$

으로 정의될 수 있다. 그리고 $\mathbf{X}_K$ 를 $\mathbf{X}$ 행렬에서 집합 K 에 속하는 관측치들로 이루어진 $k \times p$ 행렬이라 하고, $\mathbf{H}_K = \mathbf{X}_K(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}_K'$ 라 하면 다음 식이 성립함을 보일 수 있다.

$$\hat{\beta} - \hat{\beta}_{(K)} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}_K'(\mathbf{I} - \mathbf{H}_K)^{-1}\mathbf{e}_K \quad (4.14)$$

따라서 집합 K 에 속하는 관측치들의 영향력을 나타내는 쿡 통계량은 다음과 같다.

$$C_K = \frac{1}{p\sigma^2}\mathbf{e}_K'(\mathbf{I} - \mathbf{H}_K)^{-1}\mathbf{H}_K(\mathbf{I} - \mathbf{H}_K)^{-1}\mathbf{e}_K \quad (4.15)$$

(2) 앤드류-프레기본 통계량

국 통계량이 $\hat{\beta} - \hat{\beta}_{(i)}$ 에 근간을 둔 반면 앤드류-프레기본(Andrews & Pregibon, 1978) 통계량은 신뢰영역의 차에 기초한 것이다. $X^* = (X, y)$ 를 X 행렬에 y 벡터를 덧붙인 행렬이라 하면 i 번째 관측치의 앤드류-프레기본 통계량은

$$AP_i = \det[X_{(i)}^{*'} X_{(i)}^*] / \det[X^{*'} X^*] \quad (4.16)$$

로 정의되는데, 여기서 $\det[\cdot]$ 는 행렬식을 나타내는 기호이다. 그리고

$$\det[X^{*'} X^*] = e'e \det[X' X]$$

를 이용하면

$$AP_i = (1 - h_{ii}) \{1 - e_i^2 / (1 - h_{ii}) e'e\} = 1 - h_{ii}^* \quad (4.17)$$

임을 보일 수 있다. 단, 여기서 $h_{ii}^* = x_i^{*'} (X^{*'} X^*)^{-1} x_i^*$, 즉 X^* 행렬의 지렛값에 해당된다. AP_i 의 값이 작을수록 i 번째 관측치는 영향력 관측치로 판단되는데 이에 대한 기준치는 아직 제시된 바 없다.

집합 K 에 속하는 k 개의 영향력 관측치군을 위한 앤드류-프레기본 통계량은

$$\begin{aligned} AP_K &= \det[X_{(K)}^{*'} X_{(K)}^*] / \det[X^{*'} X^*] \\ &= \det[I - H_K] \{1 - e_K'(I - H_K)^{-1} e_K / e'e\} \\ &= \det[I - H_K^*] \end{aligned} \quad (4.18)$$

이며 $H_K^* = X_K^* (X^{*'} X^*)^{-1} X_K^{*'}$ 이다.

(3) DFBETAS

국 통계량과 앤드류-프레기본 통계량은 관측치의 p 차원 벡터 $\hat{\beta}$ 에 대한 영향력이다. 따라서, 관측치가 어떤 $\hat{\beta}_j$, $j = 0, 1, \dots, p-1$ 에 영향을 미치는지 알 수 없다. 이를 위해 벨슬리, 쿠와 웰쉬(Belsley, Kuh & Welsch, 1980)는 i 번째 관측치가 $\hat{\beta}_j$ 에 미치는 영향력을 고려하였다. 우선 $p \times n$ 행렬

$$C = (X' X)^{-1} X'$$

라 두고 이 행렬의 ji 번째 원소를 C_{ji} 라 놓으면 식 (4.6)으로부터

$$\hat{\beta}_j - \hat{\beta}_{j(i)} = \frac{c_{ji}e_i}{1 - h_{ii}} \quad (4.19)$$

임을 쉽게 알 수 있다. 단, 여기서 $\hat{\beta}_{j(i)}$ 는 i 번째 관측치가 제거되었을 때 β_j 의 추정치를 나타낸다. 또한,

$$\text{Cov}(\hat{\beta}) = (\mathbf{X}'\mathbf{X})^{-1}\sigma^2, \quad \mathbf{C}\mathbf{C}' = (\mathbf{X}'\mathbf{X})^{-1}$$

이므로

$$\text{Var}(\hat{\beta}_j) = \sigma^2 \sum_{l=1}^n c_{jl}^2$$

임을 쉽게 알 수 있다. 따라서 i 번째 관측치의 $\hat{\beta}_j$ 에 대한 영향력은

$$\frac{\hat{\beta}_j - \hat{\beta}_{j(i)}}{\sqrt{\text{Var}(\hat{\beta}_j)}} = \frac{\hat{\beta}_j - \hat{\beta}_{j(i)}}{\sigma \sqrt{(\mathbf{X}'\mathbf{X})_{jj}^{-1}}}$$

으로 표현될 수 있으며, 벨슬리, 쿠와 웰쉬(Belsley, Kuh & Welsch, 1980)는 σ 에 대한 추정치로 $s_{(i)}$ 를 사용한 것을 DFBETAS(Difference in betas)라 정의하였다. 즉,

$$\text{DFBETAS}_{j,i} = \frac{\hat{\beta}_j - \hat{\beta}_{j(i)}}{s_{(i)} \sqrt{(\mathbf{X}'\mathbf{X})_{jj}^{-1}}} = \frac{c_{ji}}{\sqrt{\sum_{l=1}^n c_{jl}^2}} \cdot \frac{e_i}{s_{(i)}(1 - h_{ii})}. \quad (4.20)$$

이제 집합 $K = \{i_1, \dots, i_k\}$ 에 속하는 k 개의 관측치가 $\hat{\beta}_j$ 에 미치는 영향을 고려해 보자. $\mathbf{c}_{jk} = (c_{ji_1}, \dots, c_{ji_k})'$ 라 두면 식 (4.14)로부터

$$\hat{\beta}_j - \hat{\beta}_{j(K)} = \mathbf{c}'_{jk}(\mathbf{I} - \mathbf{H}_K)^{-1}\mathbf{e}_K$$

이므로

$$\text{DFBETAS}_{j,K} = \frac{\hat{\beta}_j - \hat{\beta}_{j(K)}}{s_{(K)} \sqrt{(\mathbf{X}'\mathbf{X})_{jj}^{-1}}} = \frac{\mathbf{c}'_{jk}(\mathbf{I} - \mathbf{H}_K)^{-1}\mathbf{e}_K}{s_{(K)} \sqrt{\sum_{l=1}^n c_{jl}^2}}$$

이 된다. 단, 여기서 $s_{(K)}^2$ 은 k 개의 관측치를 제거하고 $n - k$ 개에 근거한 σ^2 의 추정치인데 이는 $s_{(i)}^2$ 을 유도할 때와 같은 방법을 사용하면 된다(Kim & Hwang, 2000 참조).

(4) DFFITS

i 번째 관측치의 i 번째 추정치 $\hat{y}_i$ 에 대한 영향력은 $\hat{y}_i - \hat{y}_{i(i)}$ 에 의해 계산될 수 있다. 여기서 $\hat{y}_{i(i)}$ 란 i 번째 관측치를 제거시킨 후 추정된 회귀모형에 의한 y_i 의 적합치를 뜻하는 것으로 $\hat{y}_{i(i)} = \mathbf{x}_i' \hat{\boldsymbol{\beta}}_{(i)}$ 임을 의미한다. 이에 대한 표준화된 값으로

$$\frac{|\hat{y}_i - \hat{y}_{i(i)}|}{\text{SE}(\hat{y}_i)} = \frac{|\mathbf{x}_i'(\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}_{(i)})|}{\sigma \sqrt{h_{ii}}} \quad (4.21)$$

을 생각할 수 있다. 벨슬리, 쿠와 웰쉬(Belsley, Kuh & Welsch, 1980)는 σ 에 대한 추정치로 $s_{(i)}$ 를 사용한 것을 DFFITS(Difference in Standardized Fits)라 정의하였다. 즉,

$$\text{DFFITS}_i = \frac{|\mathbf{x}_i'(\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}_{(i)})|}{s_{(i)} \sqrt{h_{ii}}} = \frac{1}{s_{(i)}} \cdot \frac{|e_i| \sqrt{h_{ii}}}{1 - h_{ii}} = \frac{|r_i^*| \sqrt{h_{ii}}}{\sqrt{1 - h_{ii}}} \quad (4.22)$$

이 되는데 이는 쿡 통계량 C_i 와 매우 흡사한 형태임을 알 수 있다.

이제 k 개의 관측치가 $\hat{y}_i$ 에 미치는 영향을 생각해 보자. 식 (4.19)를 확장해 보면

$$\frac{|\hat{y}_i - \hat{y}_{i(K)}|}{\sigma \sqrt{h_{ii}}} = \frac{|\mathbf{x}_i'(\hat{\boldsymbol{\beta}} - \hat{\boldsymbol{\beta}}_{(K)})|}{\sigma \sqrt{h_{ii}}}$$

으로 표현되고 식 (4.14)에 의해

$$\text{DFFITS}_K = \frac{1}{s_{(K)}} \cdot \frac{\mathbf{x}_i'(\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'_K(\mathbf{I} - \mathbf{H}_K)^{-1}\mathbf{e}_K}{\sqrt{h_{ii}}}$$

으로 정의할 수 있다.

(5) COVRATIO

i 번째 관측치의 $\text{Cov}(\hat{\boldsymbol{\beta}})$ 의 추정치에 대한 영향력을 고려하기 위해 $\text{Cov}(\hat{\boldsymbol{\beta}}_{(i)}) = \sigma^2(\mathbf{X}'_{(i)}\mathbf{X}_{(i)})^{-1}$ 와 $\text{Cov}(\hat{\boldsymbol{\beta}}) = \sigma^2(\mathbf{X}'\mathbf{X})^{-1}$ 을 비교하는 것이 바람직하다. 그런데 이들은 모두 행렬이므로 스칼라로 바꾸어 주는 작업이 필요하다. 벨슬리, 쿠와 웰쉬(Belsley, Kuh & Welsch, 1980)는 행렬식의 비를 제안하였고, $\text{Cov}(\hat{\boldsymbol{\beta}}_{(i)})$ 에 필요한 σ^2 의 추정치로 $s_{(i)}^2$ 을 사

용하고 $Cov(\hat{\beta})$ 에 필요한 σ^2 의 추정치로 s^2 을 사용하였다. 즉,

$$COVRATIO_i = \det[s_{(i)}^2(\mathbf{X}'_{(i)}\mathbf{X}_{(i)})^{-1}] / \det[s^2(\mathbf{X}'\mathbf{X})^{-1}] \quad (4.23)$$

을 i 번째 관측치의 $Cov(\hat{\beta})$ 의 추정치에 대한 영향력 측도로 제안하였다. 식 (4.23)을 좀 더 계산하기 쉬운 형태로 바꾸기 위해 식 (4.2), (4.3)과

$$\det[\mathbf{X}'_{(i)}\mathbf{X}_{(i)}] = (1 - h_{ii})\det[\mathbf{X}'\mathbf{X}]$$

를 이용하면

$$COVRATIO_i = 1 / \left\{ \frac{n-p-1}{n-p} + \frac{r_i^{*2}}{n-p} \right\}^p (1 - h_{ii})$$

임을 쉽게 보일 수 있다. $COVRATIO_i$ 의 기준으로 벨슬리, 쿠와 웰쉬(Belsley, Kuh & Welsch, 1980)는 $|COVRATIO_i - 1| \geq 3p/n$ 을 제시한 바 있다.

집합 K 에 속하는 k 개 관측치들의 $Cov(\hat{\beta})$ 의 추정치에 미치는 영향력 측도는

$$COVRATIO_K = \det[s_{(K)}^2(\mathbf{X}'_{(K)}\mathbf{X}_{(K)})^{-1}] / \det[s^2(\mathbf{X}'\mathbf{X})^{-1}]$$

이며 $\det[\mathbf{X}'_{(K)}\mathbf{X}_{(K)}] = \det[\mathbf{I} - \mathbf{H}_K]\det[\mathbf{X}'\mathbf{X}]$ 을 이용하면 계산이 좀 더 간편해 진다.

4.5.2 다른 방법에 의한 측도

(1) 영향력 곡선

무한소 교란법에 의한 $\hat{\beta}_w$ 는

$$\hat{\beta} - \hat{\beta}_w = \frac{(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_i(1-w)e_i}{\{1 - (1-w)h_{ii}\}} \quad (4.24)$$

임을 보일 수 있다. w 를 1에서 0으로 움직여 나갈 때 $w = 1$ 에서의 기울기를 살펴보자. 이를 위해 $\hat{\beta}_w$ 를 w 에 대해 미분해야 한다. 즉,

$$\Delta\hat{\beta}_w = \frac{\partial\hat{\beta}_w}{\partial w} = \frac{-(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_ie_i}{\{1 - (1-w)h_{ii}\}^2}$$

이 된다. 그런데 특히 $w = 1$ 에서의 기울기, 즉 $\Delta\hat{\beta}_1$ 을 영향력 곡선(influence curve)이라 부르고

$$\Delta\hat{\beta}_1 = -(X'X)^{-1}x_ie_i$$

임을 쉽게 알 수 있다. 따라서, $\Delta\hat{\beta}_1$ 이 작으면 w 값에 민감하지 않고 $\Delta\hat{\beta}_1$ 이 크면 w 의 변화에 민감하여 이러한 관측치가 영향력 관측치로 판단될 수 있다.

(2) 대치측도

대치법이란 i 번째 관측치의 영향력을 파악하기 위해 y_i 대신 $\hat{y}_i$ 을 사용하는 것이라 하였는데 좀 더 구체적으로 살펴보자. 반응벡터 y 의 i 번째 원소인 y_i 대신 $\hat{y}_i$ 을 대치시킨 벡터를 $y_{r(i)}$, 즉 $y_{r(i)} = (y_1, \dots, y_{i-1}, \hat{y}_i, y_{i+1}, \dots, y_n)'$ 이라 할 때, $y_{r(i)}$ 을 X 에 회귀시켰을 때의 회귀계수는 $\hat{\beta}_{r(i)} = (X'X)^{-1}X'y_{r(i)}$ 가 된다. 김(Kim, 1996)은 i 번째 관측치의 $\hat{\beta}$ 에 대한 영향력으로

$$R_i = \frac{1}{p}(\hat{\beta} - \hat{\beta}_{r(i)})'Cov(\hat{\beta})^{-1}(\hat{\beta} - \hat{\beta}_{r(i)})$$

를 제안하였고, 이를 대치측도(replacement measure)라 부른다. R_i 를 좀 더 계산하기 쉬운 식으로 바꾸기 위해 다음과 같은 계산이 필요하다. 우선 $n \times n$ 행렬 E_i 를 i 번째 대각원소만 1이고 나머지는 모두 0인 행렬, 즉

$$E_i = \text{diag}(0, \dots, 0, 1, 0, \dots, 0)$$

이라 두면

$$y_{r(i)} = (I - E_i)y + E_i\hat{y}$$

이므로

$$\begin{aligned}\hat{\beta}_{r(i)} &= (X'X)^{-1}X'[(I - E_i)y + E_i\hat{y}] \\ &= (X'X)^{-1}X'[y - E_i(y - \hat{y})] \\ &= \hat{\beta} - (X'X)^{-1}X'E_ie\end{aligned}$$

이다. 따라서

$$\begin{aligned}
 R_i &= \frac{1}{p\sigma^2} \mathbf{e}' \mathbf{E}_i \mathbf{X} (\mathbf{X}' \mathbf{X})^{-1} (\mathbf{X}' \mathbf{X}) (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{E}_i \mathbf{e} \\
 &= \frac{1}{p\sigma^2} \mathbf{e}' \mathbf{E}_i \mathbf{H} \mathbf{E}_i \mathbf{e} \\
 &= \frac{1}{p\sigma^2} e_i^2 h_{ii}
 \end{aligned} \tag{4.25}$$

으로 표현되고 만약 σ^2 을 모를 경우 s^2 으로 대체시키면 된다. 식 (4.25)에서 알 수 있듯이 R_i 역시 잔차와 지렛값의 증가함수로 표현된다. 그러나 쿡 통계량 C_i 에 비해 지렛값보다 잔차에 더 비중을 둔 측도임을 알 수 있다. 또한, R_i 는 영향력 곡선 $\Delta \hat{\beta}_1$ 과 매우 밀접한 관계를 가진다. 왜냐하면

$$R_i = \Delta \hat{\beta}_1' \text{Cov}(\hat{\beta})^{-1} \Delta \hat{\beta}_1 / p$$

임을 쉽게 알 수 있기 때문이다.

R_i 의 기준치에 대해서는 뚜렷이 연구된 바 없으나

$$R_i = r_i^2 (1 - h_{ii}) h_{ii} / p$$

으로 표현할 수 있으므로 r_i 의 분포가 $N(0, 1)$ 에 가까우며 h_{ii} 의 평균값이 p/n 이란 점을 고려하면 대치측도에 대한 적절한 기준치를 계산할 수 있다. 즉, 위의 식에서 r_i 에 2(정규 분포의 95% 값에 해당)를 대입하고 h_{ii} 에 p/n 을 대입하면 $4(n-p)/n^2$ 이 R_i 에 대한 적당한 기준치라 할 수 있다.

이제 집합 K 에 속하는 k 개 관측치들의 대치측도를 알아보자. $\mathbf{y}_{r(i)}$, $\hat{\beta}_{r(i)}$, $\mathbf{E}_i$ 를 각각 $\mathbf{y}_{r(K)}$, $\hat{\beta}_{r(K)}$, $\mathbf{E}_K$ 로 확장시키면

$$\mathbf{y}_{r(K)} = (\mathbf{I} - \mathbf{E}_K) \mathbf{y} + \mathbf{E}_K \hat{\mathbf{y}}$$

이 되고

$$\begin{aligned}
 \hat{\beta}_{r(K)} &= (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' [(\mathbf{I} - \mathbf{E}_K) \mathbf{y} + \mathbf{E}_K \hat{\mathbf{y}}] \\
 &= (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' [\mathbf{y} - \mathbf{E}_K (\mathbf{y} - \hat{\mathbf{y}})] \\
 &= \hat{\beta} - (\mathbf{X}' \mathbf{X})^{-1} \mathbf{X}' \mathbf{E}_K \mathbf{e}
 \end{aligned}$$

이므로

$$\begin{aligned}
 R_K &= \frac{1}{p}(\hat{\beta} - \hat{\beta}_{r(K)})' Cov(\hat{\beta})^{-1}(\hat{\beta} - \hat{\beta}_{r(K)}) \\
 &= \frac{1}{p\sigma^2} e' E_K X (X' X)^{-1} (X' X) (X' X)^{-1} X' E_K e \\
 &= \frac{1}{p\sigma^2} e' E_K H E_K e \\
 &= \frac{1}{p\sigma^2} \left\{ \sum_{i \in K} e_i^2 h_{ii} + 2 \sum_{\substack{i \neq j \\ i, j \in K}} e_i e_j h_{ij} \right\}
 \end{aligned} \tag{4.26}$$

으로 표현된다.

예제 4.1 지금까지 설명된 잔차, 지렛값, 그리고 여러 가지 영향력 측도들을 구체적으로 적용하기 위해 암모니아의 산화(oxidation of amonia)자료를 이용한다. 이 자료는

y : 암모니아의 산화비율(%)

X_1 : 공기 주입량

X_2 : 온도

X_3 : 질소 농도

으로 구성되고 21개의 관측치가 있다. 다니엘과 우드(Daniel & Wood, 1971)는 여러 과정을 거쳐 4개의 관측치 (1, 3, 4, 21)을 제거하고 나머지 17개의 관측치로

$$y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1^2 + \varepsilon$$

이란 모형이 최적이라고 제안하였는데 여기에서는 21개의 관측치에 근거하여 이 모형을 사용한다. 왜냐하면, 진단측도 C_i , R_i 등이 이러한 영향력 관측치를 잘 찾아줄 수 있는지 확인하고 싶기 때문이다. 관측자료, e_i , r_i , r_i^* , h_{ii} , C_i , R_i 가 <표 4.1>에 정리되어 있다. 먼저 r_i 또는 r_i^* 로부터 4번째와 21번째의 잔차가 매우 크다는 사실을 알 수 있고, 다음으로 h_{ii} 의 값을 보면 $2p/n = 0.38$ 이므로 첫 번째와 두 번째가 높은 지렛값을 가진다는 것을 알 수 있다. 실제로, 이 두 관측치는 같은 설명변수의 값을 가지므로 같은 지렛값을 갖는다. 쿡 통계량은 기준치 $3.67/(n-p)$ 를 사용하면 0.22이므로 4번째와 21번째가 영향력 관측치이고, 대치측도는 기준치 $4(n-p)/n^2$ 을 사용하면 0.15 이므로 역시 4번째와 21번째가 영향력 관측치로 판단된다. 4번째 관측치의 경우 잔차는 크지만 지렛값은 그렇게 크지 않고, 21번째의 경우는 잔차와 지렛값 모두 큰 상황이다.

<표 4.1> 암모니아의 산화 자료

번호	X_1	X_2	X_3	y	e_i	r_i	r_i^*	h_{ii}	C_i	R_i
1	80	27	89	42	2.39	0.97	0.97	0.41	0.16	0.06
2	80	27	88	37	-2.61	-1.06	-1.06	0.41	0.19	0.07
3	75	25	90	37	4.48	1.54	1.60	0.18	0.13	0.09
4	62	24	87	28	6.57	2.27	2.64	0.19	0.30	0.20
5	62	22	87	18	-0.93	-0.31	-0.30	0.10	0.00	0.00
6	62	23	87	18	-2.18	-0.73	-0.72	0.13	0.02	0.02
7	62	24	93	19	-2.43	-0.84	-0.83	0.19	0.04	0.03
8	62	24	93	20	-1.43	-0.50	-0.49	0.19	0.02	0.01
9	58	23	87	15	-2.76	-0.94	-0.93	0.16	0.04	0.03
10	58	18	80	14	2.50	0.84	0.83	0.14	0.03	0.02
11	58	18	89	14	2.59	0.84	0.83	0.14	0.03	0.02
12	58	17	88	13	2.75	0.96	0.96	0.21	0.06	0.04
13	58	18	82	11	-0.50	-0.17	-0.16	0.14	0.00	0.00
14	58	19	93	12	-0.76	-0.25	-0.24	0.09	0.00	0.00
15	50	18	89	8	0.50	0.17	0.17	0.19	0.00	0.00
16	50	18	86	7	-0.51	-0.17	-0.17	0.19	0.00	0.00
17	50	19	72	8	-0.76	-0.26	-0.25	0.19	0.00	0.00
18	50	19	79	8	-0.76	-0.26	-0.25	0.19	0.00	0.00
19	50	20	80	8	-0.01	-0.35	-0.34	0.21	0.01	0.01
20	56	20	82	15	2.10	0.68	0.66	0.06	0.01	0.01
21	70	20	91	15	-7.13	-2.63	-3.31	0.29	0.70	0.35

이제, 영향력 관측치군을 살펴보자. <표 4.2>는 C_K 와 R_K 를 $k = 1, 2, 3, 4$ 에 대해 가장 큰 집합 3개씩 조사하였다. $k = 2$ 일 때, (2, 21)은 가장 큰 쿼 통계량을 갖는 영향력 관측치군인데 21번째가 $k = 1$ 인 경우에도 영향력 관측치로 판명되었으므로 집합 (2, 21)은 21번째 관측치로 인해 늑효과로 발생한 영향력 관측치군이다. 한편, (1, 3)은 첫 번째와 세 번째 모두 개별적으로는 영향력 관측치가 아님에도 불구하고 두 관측치를 동시에 고려한 쿼 통계량은 매우 큰 값을 가지므로 가면효과에 의한 영향력 관측치군이다. k 가 3, 4로 증가함에 따라 가면효과에 의한 영향력 관측치군은 없고 전부 늑효과에 의한 영향력 관측치군들이다. 즉, (2, 21) 또는 (1, 3)에 의해 늑효과가 발생하였다. k 가 2 이상일 때는 C_K 와 R_K 에 대한 적당한 기준치가 없으므로 영향력 관측치군을 찾아내는 것이 쉬운 일은 아니지만 통계량의 상대적인 크기를 보면 쿼 통계량의 경우 $k = 3$ 일 때 (1, 2, 3)이 (1, 2, 21)이나 (2, 4, 21)에 비해 상대적으로 매우 큰 값을 가진다. 결론적으로, 쿼 통계량에 의하면 1, 2, 3, 4, 21 등이 영향력이 큰 관측치이고, 대치측도에 의하면 4, 21 등이 그러하다. 이런 관측치들은 반드시 제거되거나 나쁜 영향을 미치는 관측치로 판단해서는 안되고 이 자료를 수집한 전문가에게 상의하는 것이 가장 바람직하다. □

<표 4.2> 암모니아의 산화자료에서 $k = 1, 2, 3, 4$ 에 대해 가장 영향력이 큰 세가지의 쿼 통계량 (C_K)과 대치측도 (R_K)

k	집합 K	C_K	집합 K	R_K
1	21	0.70	21	0.36
	4	0.30	4	0.20
	2	0.19	3	0.09
2	2, 21	1.46	4, 21	0.63
	1, 3	1.30	2, 21	0.50
	4, 21	1.24	14, 21	0.39
3	1, 2, 3	33.42	2, 4, 21	0.78
	1, 2, 21	3.20	4, 20, 21	0.66
	2, 4, 21	2.06	4, 13, 21	0.66
4	1, 2, 3, 4	39.85	2, 4, 20, 21	0.82
	1, 2, 3, 13	37.63	2, 4, 13, 21	0.81
	1, 2, 3, 14	37.08	2, 4, 14, 21	0.80

4.6 이상치의 검정

n 개의 관측치 중에서 의심이 가는 k 개의 관측치가 이상치인지를 검정하는 문제를 생각해 보자. 편의상 $n - k$ 개의 관측치는 행렬 X 의 윗쪽에 있고 이상치로 의심이 가는 관측치 k 개는 아래쪽에 있다고 가정하자. k 개의 관측치가 이상치인지를 검정하기 위해 다음과 같은 이상치 전이 모형(outlier shift model)

$$y = X\beta + Z\gamma + \varepsilon$$

을 고려하는데 여기서 $n \times k$ 행렬 Z 는

$$Z = \begin{pmatrix} 0 \\ I_k \end{pmatrix} \begin{matrix} (n-k) \times k \\ k \times k \end{matrix}$$

으로 주어지며 0 는 $(n - k) \times k$ 행렬이고 γ 는 k -벡터이다. 이는 3.6.3절에 주어진 설명 변수 추가 모형의 특별한 경우이다. k 개의 관측치가 이상치인가에 대한 검정은 귀무가설 $H_0 : \gamma = 0$ 으로 표현할 수 있으며 이 결과 또한, 3.6.3절에 자세히 주어져 있다. 귀무가설 하에서의 모형 (즉, 축소모형)은

$$y = X\beta + \varepsilon$$

인데 이 모형하에서의 모자행렬 (hat matrix) H 를 다음과 같이 분할행렬로 만든다.

$$H = \begin{pmatrix} H_{11} & H_{12} \\ H_{21} & H_{22} \end{pmatrix}$$

여기서, H_{11} 는 $(n-k) \times (n-k)$, H_{12} 는 $(n-k) \times k$, H_{21} 는 $k \times (n-k)$, H_{22} 는 $k \times k$ 행렬이다. 또한, $e = (I_n - H)y$ 를 축소모형하에서의 잔차벡터라 하고 이를 $e = (e'_1, e'_2)'$ 으로 분할한다. $H_0 : \gamma = 0$ 를 검정하기 위한 F -통계량 (3.6.3절 참조)은

$$F = \frac{\hat{\gamma}' Z' R y / k}{(y' R y - \hat{\gamma}' Z' R y) / (n - p - k)}$$

인데 여기서 $R = I - H$ 이다. 이를 계산하기 위해 우선

$$\begin{aligned} \hat{\gamma} &= [Z'(I_n - H)Z]^{-1} Z'(I_n - H)y \\ &= \left[(0, I_k)(I_n - H) \begin{pmatrix} 0 \\ I_k \end{pmatrix} \right]^{-1} (0, I_k) \begin{pmatrix} e_1 \\ e_2 \end{pmatrix} \\ &= (I_k - H_{22})^{-1} e_2 \end{aligned}$$

임을 알 수 있고,

$$\hat{\gamma}' Z' (I_n - H) y = \hat{\gamma}' (0, I_k) e = \hat{\gamma}' e_2 = e_2' (I_k - H_{22})^{-1} e_2$$

이 된다. 따라서,

$$F = \frac{e_2' (I_k - H_{22})^{-1} e_2 / k}{[RSS - e_2' (I_k - H_{22})^{-1} e_2] / (n - p - k)}$$

으로 주어진다.

이제 특별한 경우로 $k = 1$, 즉, i 번째 관측치가 이상치인지 검정해 보기로 하자.

$$e_2' (I_k - H_{22})^{-1} e_2 = \frac{e_i^2}{1 - h_{ii}}$$

으로 나타나므로 위의 F -검정통계량은

$$\frac{(n - p - 1)e_i^2}{(1 - h_{ii})SSE - e_i^2}$$

이고 이는 귀무가설하에서 $F(1, n - p - 1)$ 을 따르는데 내표준화잔차 (4.2.2절 참조)가

$$r_i^2 = \frac{e_i^2}{s^2(1 - h_{ii})}$$

으로 표현되므로 F -검정통계량은

$$t_i^2 = \frac{(n - p - 1)r_i^2}{n - p - r_i^2}$$

으로 나타난다. 이는 다름아닌 외표준화잔차 (4.2.1절 참조)의 제곱이다. 결론적으로 이상치 전이모형에서 유도한 검정통계량은 외표준화잔차와 같음을 알 수 있다.

4.7 다중공선성의 탐색

다중공선성(multicollinearity)은 설명변수들이 높은 선형종속관계에 있는 경우에 발생하고, 이것은 회귀계수의 추정과 추론에 심각한 문제를 초래한다. 이 절에서는 다중공선성의 존재 여부를 판정하는 방법에 대하여 알아보자.

설명변수들 간의 선형종속관계는 설명변수들간의 상관계수값을 계산하여보면 쉽게 판별할 수 있다. 그러나 일반적으로 상관계수를 이용하여 다중공선성을 찾는 것은 한계가 있으므로 참고적으로만 사용하여야 한다. 특히 세 개 이상의 변수들간에 선형종속관계가 있는 경우에는 상관계수의 값들이 높게 나오지 않을 수도 있다.

앞에서 다중공선성이 존재하는 경우에는 회귀계수추정치의 분산이 커진다는 것을 설명하였다. 이 사실을 이용하면 다중공선성의 정도를 나타내는 측도를 정의할 수 있다. 예를 들어, 두 개의 표준화된 설명변수가 있고 서로 직교한다고 가정하면

$$W'W = (W'W)^{-1} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

로 주어지게 되어 표준화 회귀계수 추정치의 분산은 각각 1로 주어진다(오차항의 분산은 무시). 이와는 반대로 두 설명변수의 상관계수가 0.975로 높다고 가정하면

$$W'W = \begin{bmatrix} 1 & 0.975 \\ 0.975 & 1 \end{bmatrix}, \quad (W'W)^{-1} = \begin{bmatrix} 20.253 & -19.747 \\ -19.747 & 20.253 \end{bmatrix}$$

로 주어지게 되어 표준화 회귀계수 추정치의 분산은 각각 20.253으로 앞의 경우보다 무려

20배나 증가하게 된다.

이와 같이 표준화회귀모형에서 계산되는 행렬 $(W'W)^{-1}$ 의 대각원소는 회귀계수 추정치의 분산이 이상적인 경우(즉, 서로 직교하는 경우)에 비하여 얼마만큼 팽창하는지를 알려주게 된다. 이런 의미에서 행렬 $(W'W)^{-1}$ 의 k 번째 대각원소를 k 번째 설명변수의 분산 팽창인수(variance inflation factor)라 부르고 VIF_k 라 나타낸다. 또한,

$$VIF_k = \frac{1}{1 - R_k^2}, \quad k = 1, 2, \dots, p-1$$

으로 정의될 수 있는데 여기서 R_k^2 은 k 번째 설명변수를 반응변수로 하여 나머지 설명변수에 대하여 회귀분석을 하였을 때 얻어지는 결정계수의 값이다. k 번째 설명변수가 다른 설명변수들과 밀접한 관계에 있으면 R_k^2 은 1에 가깝게 되고 따라서 VIF_k 의 값은 커지게 된다. VIF_k 값들 중 제일 큰 값이 다중공선성의 존재여부를 알려주는데 일반적인 기준으로 VIF_k 의 값중 가장 큰 값이 10보다 크면 다중공선성의 가능성이 있다고 판단한다.

세 번째 방법은 행렬 $X'X$ 또는 $W'W$ 의 고유값을 조사하는 것이다. 설명변수들 간에 선형종속관계가 있는 경우 디자인 행렬 X 의 계수(rank)가 줄어들게 되고, 따라서 행렬 $X'X$ 의 계수도 p 보다 작아지게 된다. $X'X$ 또는 $W'W$ 의 계수는 0보다 큰 고유값의 개수와 같으므로 만일 0에 가까운 고유값이 있으면 다중공선성을 의심할 필요가 있다.

고유값을 이용하는 방법의 장점은 VIF_k 의 경우와는 달리 고유벡터에서 선형종속관계의 형태를 대략적으로 알 수 있다는 것이다. 구체적으로 행렬 $W'W$ 의 고유값을 $\lambda_1, \lambda_2, \dots, \lambda_{p-1}$ 이라 하고, 대응되는 고유벡터를 $v_1, v_2, \dots, v_{p-1}$ 이라 나타내면 행렬 $V = [v_1, v_2, \dots, v_{p-1}]$ 에 대하여

$$V'(W'W)V = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_{p-1})$$

의 관계식이 성립한다. 만일 다중공선성이 있는 경우 고유값들 중의 하나, 예를 들어, λ_k 가 0이거나 0에 가까운 작은 값을 갖게 되고, 이것에서

$$v_k'(W'W)v_k = (Wv_k)'(Wv_k) \approx 0$$

이 됨을 알 수 있으며, 또한, 이 식은

$$\sum_{i=1}^{p-1} v_{ik} W_i = 0 \quad (4.27)$$

이 성립함을 의미한다(벡터 W_i 는 행렬 W 의 i 번째 열벡터를 나타낸다). 식 (4.27)는 설명변수들간에 성립하는 선형종속관계를 구체적으로 보여주는 것으로, 고유벡터의 각 원소 v_{ik} 가 선형관계식에서 i 번째 설명변수의 계수가 된다고 해석할 수 있다.

고유치를 이용한 다중공선성의 존재여부는 다음과 같은 식으로 판별할 수 있다. 임의의 $n \times p$ ($p < n$) 행렬 X 를 비정칙치분해(SVD)하여 만들어진 비정칙치(singular values)를 $d_1 \geq d_2 \geq \dots \geq d_p \geq 0$ 라 할 때

$$\kappa(X) = d_1/d_p$$

를 행렬 X 의 조건수(condition number)라고 정의한다. 단, 여기서 $d_p = 0$ 이면 조건수는 무한대가 된다. 만약 X 의 계수가 p 이면 조건수는 $\kappa(X) = (\lambda_1/\lambda_p)^{1/2}$ 으로 표현할 수 있는데 여기서 λ_1 과 λ_p 는 각각 $X'X$ 의 가장 큰 고유치와 가장 작은 고유치를 나타낸다. 따라서, 조건수가 커지면 다중공선성이 심해짐을 알 수 있는데 많은 경우 다중공선성의 정도를 조건수로 나타낸다.

예제 4.2 이 예제에서는 7장의 [예제 7.1]에서 설명되는 체내지방자료에 대하여 분석을 하고자 한다. 여기에는 3개의 설명변수, 삼두근 두께(X_1), 허벅지 둘레(X_2), 팔의 중간부위 둘레(X_3)가 있고, 체내 지방량(body fat)이 반응변수이다. 각 설명변수에 대한 VIF_k 값을 구하고, 표준화된 값을 이용하여 행렬 $W'W$ 의 고유값을 계산하여 분석하라.

<풀이> 3장에 주어진 표준화 공식

$$W_{ij} = \frac{X_{ij} - \bar{X}_j}{\sqrt{S_{jj}}}, \quad S_{jj} = \sum_{i=1}^{20} (X_{ij} - \bar{X}_j)^2, \quad i = 1, 2, \dots, 20; j = 1, 2, 3$$

을 이용하여 먼저 행렬 $W'W$ 를 계산하면 다음과 같이 주어진다.

$$W'W = \begin{bmatrix} 1.00000 & 0.92384 & 0.45778 \\ 0.92384 & 1.00000 & 0.08467 \\ 0.45778 & 0.08467 & 1.00000 \end{bmatrix}$$

위의 행렬은 곧 세 설명변수간의 상관계수행렬이므로 우리는 X_1 과 X_2 의 상관계수가 0.92384로 두 변수간에 높은 상관관계가 존재한다는 것을 알 수 있다. 그러나 그 외 변수간의 상관관계는 높다고 할 수 없다. 이제 역행렬을 계산하면

$$(W'W)^{-1} = \begin{bmatrix} 708.856 & -631.927 & -270.995 \\ -631.927 & 564.354 & 241.499 \\ -270.995 & 241.499 & 104.608 \end{bmatrix}$$

으로 주어진다. 그러므로, 각 설명변수에 대한 VIF_k 값은 다음과 같이 주어진다.

$$VIF_1 = 708.856, \quad VIF_2 = 564.354, \quad VIF_3 = 104.608$$

위의 VIF_k 세 값 모두 10보다 아주 크므로 우리는 명백한 다중공선성이 존재한다는 것을 알 수 있다. 더욱 확실한 분석을 위하여 행렬 $W'W$ 에 대한 고유값과 고유벡터를 구해보자.

먼저 고유값은

$$\lambda_1 = 2.06647, \quad \lambda_2 = 0.93280, \quad \lambda_3 = 0.00073$$

로 0에 가까운 값(λ_3)이 하나 존재하므로 우리는 설명변수들간에 하나의 선형종속관계가 존재한다고 판단할 수 있다. 그리고 고유벡터들은 다음과 같이 주어진다.

$$v_1 = \begin{bmatrix} 0.694696 \\ 0.629428 \\ 0.348164 \end{bmatrix}, \quad v_2 = \begin{bmatrix} -0.050106 \\ -0.440509 \\ 0.896349 \end{bmatrix}, \quad v_3 = \begin{bmatrix} 0.717556 \\ -0.640135 \\ -0.274482 \end{bmatrix}$$

위에서 고유값 λ_3 에 대응되는 고유벡터 v_3 의 각 원소를 보면 대략적으로 이 선형종속관계가 표준화된 세 설명변수간에 존재하고 있다는 것을 알 수 있다. 이 사실은 상관계수를 이용한 분석에서는 나타나지 않았다.

다음으로 조건수를 계산해 보자. 조건수의 정의로부터

$$\kappa(X) = (\lambda_1/\lambda_3)^{1/2} = (2.06647/0.00073)^{1/2} = 53.2$$

로 매우 큰 값을 알 수 있다. □

다중공선성이 있다고 판단되는 경우, 관련된 변수들 중에서 적당한 변수를 회귀모형에서 제거할 수도 있지만 이 방법은 매우 주관적이고 위험하다. 다중공선성이 존재할 경우 이를 해결하기 위한 여러 방법들이 6장과 7장에 소개되어 있다.

4.8 자기상관과 더빈-왓슨 검정

시간에 따라 관측되는 자료들, 특히, 경제나 기상 관련 자료들은 기본적으로 인접한 값들간에 밀접한 관계를 가지게 되고, 또한, 모형의 구축단계에서 시간과 관련된 중요한 변수가 생략되면 설정된 회귀모형에서 오차항들이 서로 독립이 아니면서 상관관계를 가지게 된다. 이 경우 여러 가지 문제가 발생하게 되는데, 예를 들어, 회귀계수의 추정치가 불편성은 만족하나 최소분산성은 만족하지 못하게 되며, 독립성 가정 하에 수행되는 신뢰구간의 계산, 가설검정 등 여러 가지 추론의 결과가 정확하지 않게 된다. 특히, 오차항들이 양의 상관관계를 갖는 경우에는 오차항의 분산 σ^2 또는 각 회귀계수 추정치의 표준오차를 과소추정(underestimation)하는 경향이 있다.

그러므로 오차항의 독립성 여부를 판정하는 것은 매우 중요한 문제로, 일차적으로 잔차 분석에서 잔차의 산점도를 이용하여 할 수 있다. 즉, 잔차 대 관측순서의 산점도를 작성하

$$y_i = x_i' \beta + \varepsilon_i$$

여 특정한 경향(예를 들어, 사인(sine)함수 모양)이 나타나는지를 조사하여 판정한다. 그러나, 이 방법은 그림으로 판단하는 주관성이 강하므로 독립성에 대한 검정을 객관적으로 실행할 필요가 있다. 이를 위해 여기서 설명할 더빈-왓슨 검정(Durbin-Watson test)은 오차항들간에 일차자기상관관계가 있는지를 조사하는 방법이다. 만약 오차항들간에 상관관계가 있다고 판정되면 오차항의 독립성에 대한 가정이 만족된다고 할 수 없다.

인접한 두 오차들간에 모형

$$\varepsilon_t = \rho\varepsilon_{t-1} + \delta_t, \quad |\rho| < 1$$

(δ_t 는 서로 독립이면서 평균이 0이고 분산이 σ_δ^2 인 확률변수)이 성립할 때 이를 일차자기회귀모형(first-order autoregressive model)이라 하고, ρ 를 $\varepsilon_1, \dots, \varepsilon_n$ 의 일차자기상관계수(first-order autocorrelation coefficient)라 한다. 이 모형 하에서 성립하는 오차항의 몇 가지 성질들을 살펴보자. 먼저 오차항들간의 관계를 축차적으로 대입하면 ε_t 를 ρ 와 δ_t 들의 무한급수로 나타낼 수 있다. 즉,

$$\begin{aligned} \varepsilon_t &= \rho(\rho\varepsilon_{t-2} + \delta_{t-1}) + \delta_t \\ &= \rho^2(\rho\varepsilon_{t-3} + \delta_{t-2}) + \rho\delta_{t-1} + \delta_t \\ &= \delta_t + \rho\delta_{t-1} + \rho^2\delta_{t-2} + \dots \\ &= \sum_{j=0}^{\infty} \rho^j \delta_{t-j} \end{aligned} \tag{4.28}$$

위의 식을 이용하면 ε_t 의 기댓값은

$$E(\varepsilon_t) = \sum_{j=0}^{\infty} \rho^j E(\delta_{t-j}) = 0$$

임을 보일 수 있고, 시간 l 만큼 떨어져 있는 두 오차항간의 공분산은

$$\text{Cov}(\varepsilon_t, \varepsilon_{t-l}) = \frac{\rho^l \sigma_\delta^2}{1 - \rho^2}$$

로 주어지게 된다. 그러므로, ε_t 의 분산은 $l=0$ 인 경우로

$$\text{Var}(\varepsilon_t) = \frac{\sigma_\delta^2}{1 - \rho^2}$$

이 됨을 알 수 있다. 이 결과는 오차항간에 자기상관이 있는 경우에도 등분산성은 여전히 만족됨을 보여주고 있다. 한편, 시간 l 만큼 떨어져 있는 두 오차항간의 상관계수는

$$\text{Corr}(\varepsilon_t, \varepsilon_{t-l}) = \frac{\text{Cov}(\varepsilon_t, \varepsilon_{t-l})}{\sqrt{\text{Var}(\varepsilon_t)\text{Var}(\varepsilon_{t-l})}} = \rho^l, \quad l \neq 0$$

임을 보일 수 있다.

이제 오차항간에 일차자기상관이 존재하는지에 대한 더빈-왓슨 검정통계량을 구하기 위하여 다음의 관계식을 생각하자.

$$\begin{aligned} E(\varepsilon_t - \varepsilon_{t-1})^2 &= E(\varepsilon_t^2 + \varepsilon_{t-1}^2 - 2\varepsilon_t\varepsilon_{t-1}) \\ &= E(\varepsilon_t^2) + E(\varepsilon_{t-1}^2) - 2E(\varepsilon_t\varepsilon_{t-1}) \\ &= 2\sigma_\varepsilon^2 - 2\frac{\rho\sigma_\varepsilon^2}{1-\rho^2} \end{aligned}$$

위의 식에서 일차자기상관계수 ρ 의 값에 따라 다음의 관계식들이 성립함을 알 수 있다.

$$\begin{aligned} \rho = 0 \text{ 이면 } E(\varepsilon_t - \varepsilon_{t-1})^2 &= 2\sigma_\varepsilon^2 \\ \rho > 0 \text{ 이면 } E(\varepsilon_t - \varepsilon_{t-1})^2 &< 2\sigma_\varepsilon^2 \\ \rho < 0 \text{ 이면 } E(\varepsilon_t - \varepsilon_{t-1})^2 &> 2\sigma_\varepsilon^2 \end{aligned} \quad (4.29)$$

식 (4.29)은 모수들을 포함하므로 추정값을 사용하여 우변 부등식의 대소 관계를 파악하면 우리는 역으로 일차자기상관계수 ρ 에 대한 정보를 알 수 있을 것이다. 구체적으로 오차항 ε_t 대신에 잔차 e_t 를 사용하고, 기댓값 대신에 합기호를 사용하면 다음의 더빈-왓슨 검정통계량을 얻게 된다.

더빈-왓슨 검정통계량 :

$$D = \frac{\sum_{t=2}^n (e_t - e_{t-1})^2}{\sum_{t=1}^n e_t^2}$$

식 (4.29)의 관계식에서 짐작할 수 있듯이 만약 D 의 값이 2 근처이면 자기상관이 없고, 2보다 작으면 양의 자기상관관계, 2보다 크면 음의 자기상관관계가 있음을 알 수 있다. 실제로 표본의 크기 n 이 어느 정도 크면

$$D \approx 2(1 - \hat{\rho})$$

이 성립함을 보일 수 있다. 위 식에서 $\hat{\rho}$ 은 ρ 의 점추정치로 다음과 같이 주어진다.

$$\hat{\rho} = \frac{\sum_{t=2}^n e_t e_{t-1}}{\sum_{t=2}^n e_{t-1}^2} \quad (4.30)$$

그러므로 D 의 값이 2 근처이면 $\rho = 0$ 이고, 0에 가까우면 양의 자기상관관계, 4에 가까우면 음의 자기상관관계가 있음을 알 수 있다.

더빈-왓슨 검정은 보다 정확한 D 의 기각역을 사용한다. 부록 B의 <표 7>은 D 값의 상한값(d_U)과 하한값(d_L)을 제공하여 주는데 이를 사용하여 다음과 같이 검정한다.

귀무가설 $H_0 : \rho = 0$ 와 대립가설 $H_1 : \rho > 0$ 에 대하여

$D < d_L$ 이면 귀무가설을 기각하여 양의 자기상관이 있다고 판정

$D > d_U$ 이면 귀무가설을 기각하지 못하여 자기상관이 없다고 판정

$d_L \leq D \leq d_U$ 이면 판정을 보류

위에서 알 수 있듯이 이 검정의 특징은 결정을 유보하는 구간이 있다는 것이다. 음의 자기상관관계에 대한 검정은 D 대신에 $D^* = 4 - D$ 를 계산하여 위에서와 똑같이 하면 된다. 그러나 대부분의 실제 문제에서는 양의 자기상관관계가 나타난다.

예제 4.3 기계장비용 강판을 생산하는 회사에서는 납품하는 강판의 가격이 그 강판을 사용하는 기계의 가격에 어떠한 영향을 받는지를 조사하기 위하여 과거 16개월 동안의 자료를 수집하였다. 자료는 <표 4.3>에 정리되어 있으며, (그림 4.3(a))는 산점도를 보여준다. 단순선형회귀분석을 실시하고 자기상관이 있는지를 조사하라.


<표 4.3> 기계의 가격(단위:백만원)과 강판의 가격(단위:십만원) 자료

월	1	2	3	4	5	6	7	8
기계가격(X)	82.3	81.4	79.3	79.0	76.8	80.7	83.4	85.4
강판가격(Y)	66.7	66.0	64.0	64.0	61.3	64.0	66.7	68.7
월	9	10	11	12	13	14	15	16
기계가격(X)	85.8	83.6	83.7	82.7	84.5	85.4	87.3	81.2
강판가격(Y)	70.0	68.7	68.0	67.3	68.7	68.7	70.0	64.7

<풀이> 더빈-왓슨 검정통계량은 단순선형회귀모형 $Y_i = \beta_0 + \beta_1 X_i + \varepsilon_i$ 을 가정하여 회귀계수의 최소제곱추정치를 구한 다음 계산된 잔차를 통계량 식에 대입하여 구해진다. 적합된 회귀식은

$$\hat{Y}_i = -5.00 + 0.868X_i$$

이며, (그림 4.3(a))의 산점도 위에 그려졌다. 적합된 회귀직선은 두 변수간의 관계를 잘 나타내고 있으나, (그림 4.3(b))의 잔차의 산점도를 보면 독립성에 문제가 있다는 것이 확연히 나타난다. 이 잔차들로 계산된 더빈-왓슨 검정통계량의 값은 $D = 0.71$ 로 상대적으로 0에 가까우므로 양의 자기상관관계가 있다는 것을 알 수 있다. 부록의 표에 주어진 하한과 상한은 1개의 설명변수와 $n = 16$ 에 대하여 각각 $d_L = 1.10$, $d_U = 1.37$ 이므로, D 의 값 0.71은 하한값 1.10보다 작아 위의 사실을 뒷받침하고 있다. □



(그림 4.3) 기계장비용 강판 자료의 산점도(a)와 잔차의 산점도(b)

오차항들간에 자기상관이 존재하는 경우에는 이에 대한 적절한 조치가 필요하다. 간단한 방법은 자기상관을 유발하는 변수를 설명변수로 모형에 포함시키는 것이다. 예를 들어, 어느 회사에서 과거 몇 년간에 걸친 판매액과 광고비와의 관계를 분석하는 문제에서는 만일 그 회사의 외형적 크기(자본금의 크기, 종업원의 수 등)를 회귀모형에 포함시키지 않으면 양의 자기상관관계가 있을 수 있다. 그리고 경제 관련 문제에서는 시간과 관련된 변수나 시간변수 자체를 추가할 수 있다.

다른 방법으로는 독립성이 만족되도록 변수변환을 하는 것이다. 이 방법을 단순선형회귀모형을 이용하여 설명한다. 오차항간에 일차자기상관관계가 있는 다음의 회귀모형을 생각하자(아래에서 δ_t 는 서로 독립이며 정규분포 $N(0, \sigma_\delta^2)$ 를 따르는 확률변수이다).

$$Y_t = \beta_0 + \beta_1 X_t + \varepsilon_t, \quad \varepsilon_t = \rho \varepsilon_{t-1} + \delta_t$$

이 모형에서 반응변수를 $Y'_t = Y_t - \rho Y_{t-1}$ 로 변환하면

$$\begin{aligned} Y'_t &= Y_t - \rho Y_{t-1} \\ &= (\beta_0 + \beta_1 X_t + \varepsilon_t) - \rho (\beta_0 + \beta_1 X_{t-1} + \varepsilon_{t-1}) \\ &= \beta_0(1 - \rho) + \beta_1(X_t - \rho X_{t-1}) + (\varepsilon_t - \rho \varepsilon_{t-1}) \\ &= \beta'_0 + \beta_1 X'_t + \delta_t \end{aligned}$$

로 되어 서로 독립인 오차항 δ_t 를 갖는 회귀모형을 얻을 수 있다. 그러나 자기상관계수 ρ 는 알려져 있지 않는 모수이므로 대신에 적당한 추정치 $\hat{\rho}$ 를 사용할 필요가 있다. 이와 같은 방법으로 구한 β'_0 과 β_1 의 최소제곱추정치들을 각각 $\hat{\beta}'_0$ 과 $\hat{\beta}_1$ 이라 하면 β_0 의 추정치는 $\hat{\beta}'_0 = \hat{\beta}_0(1 - \hat{\rho})$ 에서

$$\hat{\beta}_0 = \frac{\hat{\beta}'_0}{(1 - \hat{\rho})}$$

로 주어지고, 그리고 $\hat{\beta}_0$ 의 표준오차는

$$SE(\hat{\beta}_0) = \frac{SE(\hat{\beta}'_0)}{1 - \hat{\rho}}$$

으로 주어진다.

위의 변수변환법에서 적당한 ρ 의 추정치 $\hat{\rho}$ 를 구하는 방법에는 일반적으로 세 가지가 있다. 먼저 코크레인-오커트(Cochrane-Orcutt)방법에서는 ρ 의 값을 반복 추정하여 사용한다. 초기 단계에서는 자기상관을 무시하고 모형

$$Y_t = \beta_0 + \beta_1 X_t + \varepsilon_t$$

을 적합하여 잔차 e_t 를 구한다. 그리고 식 (4.28)를 이용하여 추정치 $\hat{\rho}$ 를 계산하여 변수변환하면 된다. 그리고 변환된 회귀모형을 적합한 다음 이 모형에서 구한 잔차를 이용하여 자기상관에 대한 더빈-왓슨 검정을 실시한다. 만약 자기상관이 없다고 판정되면 이 단계에서 끝나고, 아니면 다시 추정치 $\hat{\rho}$ 를 계산하여 변수변환을 계속적으로 수행하게 된다.

두 번째 방법인 힐드리스-루(Hildreth-Lu) 방법에서는 ρ 의 값을 추정하는 대신에 타당한 여러 개의 ρ 값을 사용하여 분석한 후 그 중에서 오차제곱합 SSE의 값이 제일 적은 경우를 선택하는 방법이다.

마지막으로 차분(difference)법은 시계열분석에서 흔히 사용하는 방법으로 ρ 의 값을 1로

가정하여 변수변환하는 방법이다. 즉, 각 변수에 대하여

$$Y'_t = Y_t - Y_{t-1}, \quad X'_t = X_t - X_{t-1}$$

로 변환한 모형

$$Y'_t = \beta_1 X'_t + \delta_t$$

을 적합하는 것이다. 이 경우 β_1 의 추정치 $\hat{\beta}_1$ 은 원점을 지나는 회귀직선의 기울기의 최소 제곱추정치로 주어지며 β_0 의 추정치는 $\hat{\beta}_0 = \bar{Y} - \hat{\beta}_1 \bar{X}$ 로 주어지게 된다.

예제 4.4 기계장비용 강판 자료에 대하여 코크레인-오커트방법을 적용하여 회귀계수를 추정하라.

<풀이> 앞의 예제에서 계산된 잔차를 이용하여 자기상관계수 ρ 의 추정치를 구하면(식 (4.28))

$$\hat{\rho} = 0.651$$

의 값을 얻을 수 있다. 그러므로 변환공식은

$$Y'_t = Y_t - 0.651Y_{t-1}, \quad X'_t = X_t - 0.651X_{t-1}$$

로 주어지고, 이 변환된 변수에 대한 추정선형회귀식은

$$\hat{Y}'_t = -1.370 + 0.853X'_t$$

(1.743) (0.0603)

으로 얻을 수 있다. 이 변환된 모형에 대한 더빈-왓슨 검정통계량의 값은 $D = 1.41$ 로 상대적으로 2에 가까우므로 변환된 모형에는 자기상관관계가 없다는 것을 알 수 있다. 실제로 부록의 표에 주어진 하한과 상한은 1개의 설명변수와 $n = 15$ 에 대하여 각각

$$d_L = 1.08, \quad d_U = 1.36$$

이므로, D 의 값 1.41은 상한값 1.36을 초과하여 위의 사실을 뒷받침하고 있다. 그러므로 반복추정 작업은 이 단계에서 끝나게 되고, 원래 변수를 사용한 회귀모형에서의 절편의 추정치와 표준오차는 각각

$$\hat{\beta}_0 = \frac{-1.370}{1 - 0.651} = 3.926, \quad SE(\hat{\beta}_0) = \frac{1.743}{1 - 0.651} = 4.994$$

로 주어진다. 기울기에 대한 값은 변환된 모형의 추정치와 동일하다. (예제 4.3)의 결과와 비교하여 보면, 특히 추정치들의 표준오차가 커졌다는 것을 알 수 있다. 이 사실은 이 절의 처음에서 언급한대로 양의 자기상관이 있는 경우 추정치의 표준오차를 과소추정한다는 사실을 보여주고 있다. $\square$

연습문제 (4)

[이론 문제]

4.1 식 (4.15), (4.17), (4.20)를 증명하라.

4.2 다음을 증명하라.

$$(1) \mathbf{X}'_{(i)}\mathbf{X}_{(i)} = \mathbf{X}'\mathbf{X} - \mathbf{x}_i\mathbf{x}'_i$$

$$(2) \det(\mathbf{X}'_{(i)}\mathbf{X}_{(i)}) = (1 - h_{ii})\det(\mathbf{X}'\mathbf{X}) \quad (\text{참고 : } \det(\mathbf{I} - \mathbf{u}\mathbf{v}') = 1 - \mathbf{v}'\mathbf{u})$$

4.3 $\hat{y}_i = w_i y_i + (1 - w_i)\hat{y}_{i(i)}$ 로 표현할 때 w_i 를 구하라.4.4 $\text{Var}(\hat{y}_{i(i)})$ 을 계산하라(참고 : 연습문제 4.3의 결과를 이용).4.5 $K = \{i, j\}$ 일 때 $C_K = C_i + C_j$ 가 되기 위한 조건을 구하라. 또한, $R_K = R_i + R_j$ 가 되기 위한 조건을 구하라.4.6 $C_i = (\hat{\mathbf{y}} - \hat{\mathbf{y}}_{(i)})'(\hat{\mathbf{y}} - \hat{\mathbf{y}}_{(i)})/ps^2$ 임을 보여라.4.7 $\mathbf{A}$ 는 $p \times p$ 행렬, $\mathbf{u}, \mathbf{v}$ 는 p 차원벡터라 할 때 다음의 식(updating formula)

$$(\mathbf{A} - \mathbf{u}\mathbf{v}')^{-1} = \mathbf{A}^{-1} + \frac{\mathbf{A}^{-1}\mathbf{u}\mathbf{v}'\mathbf{A}^{-1}}{1 - \mathbf{v}'\mathbf{A}^{-1}\mathbf{u}}$$

와 연습문제 4.2 (1)의 결과를 이용하여

$$(\mathbf{X}'_{(i)}\mathbf{X}_{(i)})^{-1} = (\mathbf{X}'\mathbf{X})^{-1} + \frac{(\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_i\mathbf{x}'_i(\mathbf{X}'\mathbf{X})^{-1}}{1 - h_{ii}}$$

임을 보여라.

4.8 식 (4.6) $\hat{\beta} - \hat{\beta}_{(i)} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{x}_i e_i / (1 - h_{ii})$ 를 증명하라(참고 : 연습문제 4.2(1)과 4.7의 결과를 이용할 것).

4.9 식 (4.3)에 대한 증명을 다음과 같이 할 수 있음을 직접 확인해 보라. 4.5절의 식

(4.6)을 이용하면

$$\begin{aligned}
 (n-p-1)s_{(i)}^2 &= \sum_{j \neq i} \{y_j - \mathbf{x}'_j \hat{\boldsymbol{\beta}}_{(i)}\}^2 \\
 &= \sum_{j=1}^n \{y_j - \mathbf{x}'_j \hat{\boldsymbol{\beta}}_{(i)}\}^2 - \{y_i - \mathbf{x}'_i \hat{\boldsymbol{\beta}}_{(i)}\}^2 \\
 &= \sum_{j=1}^n \{y_j - \mathbf{x}'_j \hat{\boldsymbol{\beta}} + \mathbf{x}'_j \hat{\boldsymbol{\beta}} - \mathbf{x}'_j \hat{\boldsymbol{\beta}}_{(i)}\}^2 \\
 &\quad - \left\{ y_i - \mathbf{x}'_i \left(\hat{\boldsymbol{\beta}} - \frac{(\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i e_i}{1 - h_{ii}} \right) \right\}^2 \\
 &= \sum_{j=1}^n \left\{ e_j + \mathbf{x}'_j \frac{(\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i e_i}{1 - h_{ii}} \right\}^2 - \left\{ e_i + \frac{h_{ii} e_i}{1 - h_{ii}} \right\}^2 \\
 &= \sum_{j=1}^n \left\{ e_j + \frac{h_{ij} e_i}{1 - h_{ii}} \right\}^2 - \left\{ \frac{e_i}{1 - h_{ii}} \right\}^2 \\
 &= \sum_{j=1}^n \left\{ e_j^2 + 2h_{ij} e_i e_j / (1 - h_{ii}) + \left(\frac{h_{ij} e_i}{1 - h_{ii}} \right)^2 \right\} - \left\{ \frac{e_i}{1 - h_{ii}} \right\}^2
 \end{aligned}$$

여기서

$$\sum_{j=1}^n h_{ij} e_j = 0, \quad \sum_{j=1}^n h_{ij}^2 = h_{ii}$$

을 이용하면

$$\begin{aligned}
 (n-p-1)s_{(i)}^2 &= \sum_{j=1}^n e_j^2 + \frac{e_i^2 h_{ii}}{(1 - h_{ii})^2} - \frac{e_i^2}{(1 - h_{ii})^2} \\
 &= (n-p)s^2 - \frac{e_i^2}{(1 - h_{ii})} \\
 &= (n-p)s^2 - s^2 \frac{e_i^2}{s^2(1 - h_{ii})} \\
 &= s^2(n-p-r_i^2)
 \end{aligned}$$

이 된다.

4.10 식 (4.28)의 오차항에 대한 무한급수식을 이용하여 시간 i 만큼 떨어져 있는 두 오차항간의 공분산은

$$Cov(\varepsilon_t, \varepsilon_{t-1}) = \frac{\rho^l \sigma_\delta^2}{1 - \rho}$$

로 주어짐을 보여라.

[응용 문제]

4.1 다음 자료는 미국 프로야구의 아메리칸 리그 소속 타자 124명에 대한 1985과 1986년 타율을 나타낸 것이다.


- (1) 산점도를 그리고 1985년 타율을 설명변수, 1986년 타율을 반응변수로 하여 단순선형회귀모형을 적합시켜라.
- (2) 표준화잔차 r_i , 지렛값 h_{ii} , 쿡 통계량 C_i , 대치측도값 R_i 를 계산하고 가장 영향력 있는 관측치를 구하라.
- (3) 산점도에서 표본상관계수에 영향을 미치는 관측치가 있는지 조사하라.

No	1985	1986	No	1985	1986	No	1985	1986	No	1985	1986
1	0.265	0.264	32	0.248	0.241	63	0.230	0.218	94	0.286	0.252
2	0.309	0.296	33	0.263	0.259	64	0.293	0.287	95	0.282	0.282
3	0.268	0.240	34	0.289	0.310	65	0.277	0.284	96	0.251	0.210
4	0.243	0.229	35	0.238	0.221	66	0.259	0.261	97	0.300	0.233
5	0.289	0.289	36	0.256	0.300	67	0.265	0.251	98	0.219	0.249
6	0.266	0.286	37	0.288	0.306	68	0.263	0.287	99	0.262	0.272
7	0.231	0.238	38	0.246	0.287	69	0.264	0.227	100	0.283	0.228
8	0.275	0.309	39	0.225	0.250	70	0.218	0.254	101	0.228	0.237
9	0.304	0.300	40	0.254	0.274	71	0.324	0.352	102	0.280	0.264
10	0.274	0.301	41	0.282	0.281	72	0.239	0.266	103	0.258	0.246
11	0.295	0.256	42	0.295	0.258	73	0.259	0.252	104	0.257	0.287
12	0.368	0.357	43	0.287	0.268	74	0.297	0.281	105	0.245	0.212
13	0.248	0.222	44	0.242	0.268	75	0.232	0.260	106	0.275	0.326
14	0.300	0.310	45	0.270	0.285	76	0.259	0.253	107	0.251	0.204
15	0.335	0.290	46	0.273	0.250	77	0.222	0.203	108	0.215	0.187
16	0.237	0.270	47	0.270	0.218	78	0.295	0.259	109	0.236	0.229
17	0.242	0.256	48	0.296	0.323	79	0.233	0.252	110	0.313	0.265
18	0.299	0.267	49	0.282	0.278	80	0.297	0.305	111	0.258	0.277
19	0.219	0.243	50	0.241	0.265	81	0.267	0.290	112	0.275	0.251
20	0.239	0.269	51	0.314	0.263	82	0.290	0.283	113	0.258	0.277
21	0.311	0.278	52	0.244	0.247	83	0.267	0.277	114	0.287	0.316
22	0.262	0.302	53	0.285	0.283	84	0.259	0.231	115	0.280	0.269
23	0.251	0.270	54	0.278	0.267	85	0.239	0.238	116	0.249	0.272
24	0.293	0.258	55	0.268	0.231	86	0.273	0.257	117	0.245	0.268
25	0.197	0.215	56	0.313	0.260	87	0.249	0.276	118	0.285	0.251
26	0.287	0.271	57	0.252	0.241	88	0.257	0.258	119	0.189	0.219
27	0.287	0.268	58	0.274	0.288	89	0.275	0.265	120	0.244	0.237
28	0.244	0.256	59	0.260	0.250	90	0.288	0.328	121	0.278	0.269
29	0.254	0.208	60	0.231	0.229	91	0.276	0.276	122	0.275	0.262
30	0.263	0.267	61	0.243	0.240	92	0.306	0.176	123	0.273	0.252
31	0.262	0.302	62	0.238	0.210	93	0.291	0.324	124	0.277	0.312

4.2 다음 자료는 20편의 영화에 대한 관객과 영화 평론가의 평가를 나타낸 것이다.

영화	1	2	3	4	5	6	7	8	9	10
관객	3.9	3.8	3.8	3.6	3.6	3.7	3.6	3.5	3.4	3.5
평론가	3.4	2.5	3.0	3.0	2.8	3.1	2.0	3.2	2.3	2.7
영화	11	12	13	14	15	16	17	18	19	20
관객	3.4	3.2	3.1	3.3	3.3	3.1	2.8	3.1	2.7	2.0
평론가	1.5	2.2	2.3	1.2	2.3	3.3	1.7	3.0	3.2	1.7

이 자료에 대한 산점도(그림(4.4))로 부터 알 수 있듯이 관객 및 영화 평론가의 평가는 양의 상관관계를 가진다($r = .3606$). 이제 어떤 관측치들이 표본상관계수 r 에 큰 영향을 미치는지 알기 위해 $k = 1, 2, 3, 4$ 에 대한 $r_{(K)} - r$ 의 값이 가장 큰 5개의 관측치를 <표 4.5>에 수록하였다. 여기서 $K = \{i_1, \dots, i_k\}$ 이고 $r_{(K)}$ 는 k 개의 관측치를 제거했을 때의 표본상관계수를 나타낸다. 이 표로부터 알 수 있듯이 19번째 관측치가 매우 영향력이 크고 k 가 증가함에 따라 가면효과는 없고 늘 현상이 뚜렷함을 알 수 있다. 관객보다 평론가가 더 높은 점수를 준 경우는 16, 19번째 밖에 없으며 이러한 현상이 19번째 관측치가 영향력 관측치로 나타났다. 또한, $r_{(K)}$ 는 r 보다 일반적으로 커짐을 알 수 있다. <표 4.5>을 직접 계산해 보라.



(그림 4.4) 영화평가점수에 대한 산점도

<표 4.5> $k = 1, 2, 3, 4$ 에 대한 $r_{(K)} - r$ 의 값이 가장 큰 5개의 관측치군

k	관측치	$r_{(K)} - r$	k	관측치	$r_{(K)} - r$
1	19	.1200	3	14, 16, 19	.2535
	16	.0518		16, 18, 19	.2488
	11	.0442		11, 14, 19	.2467
	14	.0438		11, 16, 19	.2435
	7	.0390		7, 16, 19	.2306
2	16, 19	.1942	4	11, 14, 16, 19	.3371
	14, 19	.1709		7, 11, 17, 19	.3239
	11, 19	.1665		14, 16, 18, 19	.3110
	18, 19	.1618		7, 14, 16, 19	.3065
	7, 19	.1582		11, 16, 18, 19	.2978

19 $\frac{1}{2}$ ms

제 5 장

회귀모형의 선택

- 5.1 모형선택
- 5.2 변수선택의 기준
- 5.3 변수선택의 방법
- 5.4 모형의 확인
- 5.5 변수선택의 진단
- 5.6 모형선택의 기타논제

4장에서는 주어진 회귀모형을 여러 측면에서 검토하였는데 5장에서는 반응변수를 가장 잘 설명해 주는 설명변수를 선택하는 방법을 소개한다. 이러한 과정을 모형의 구축(model building)또는 모형선택(model selection)이라 하며 선택된 모형이 회귀진단을 통해 어떻게 변화해 가는지를 소개한다. 또한, 모형선택에 대한 여러 가지 측도를 소개하고 이들의 관계를 설명한다.

5.1 모형선택

5.1.1 모형선택의 필요성

회귀분석은 주어진 설명변수들과 반응변수간의 관계를 구하는 것이다. 회귀분석의 목적은 크게 두 가지로 요약된다. 첫째 목적은 적합한 회귀모형으로부터 설명변수와 반응변수간의 관계를 파악하는 것이다. 예를 들어, 광고비를 1단위 증가시키면 매출액이 1.2단위 증가한다는 사실등을 파악하는 것이다. 회귀분석의 두 번째 목적은 적합한 회귀모형에 새롭게 주어진 설명변수 값을 대입하여 반응변수값을 예측(prediction)하는 것이다. 일반적으로 예측에 사용되는 자료는 회귀모형의 적합에 사용된 자료와는 별개의 것 (즉, 독립)이다. 예를 들어 폐암발병율(반응변수)을 나이, 흡연기간, 성별 이라는 세 가지 설명변수로 미국인의 자료를 이용하여 만들어진 것이 있을 경우 이를 한국인에 적용하여 예측할 수 있다.

이러한 회귀분석의 목적을 달성하기 위해 이용가능한 모든 설명변수들을 전부 다 사용하면 가장 정확한 회귀모형을 얻을 수 있을 것으로 생각되지만 실제로는 사용가능한 설명변수들중 일부만 사용하여 구축한 회귀모형이 오히려 더 좋은 경우가 흔히 있다. 이러한 현상을 회귀분석의 역설(paradox)이라고도 부른다. 만약 작은 개수의 설명변수를 사용한 모형이 많은 개수의 설명변수를 사용한 모형보다 더 좋다면 모형이 간단해지므로 모형의 해석이 더 쉽다는 점도 큰 수확이다. 여기서 한 가지 명확하게 짚고 넘어가야 할 부분은 “어떤 모형이 다른 모형보다 더 좋다”라고 할 때 “더 좋다”라는 개념을 계량적으로 정의해야 하는데 이는 흔히 예측오차(prediction error)라는 값으로 나타낸다.

5.1.2 예측오차

회귀모형을 구축하기 위해 주어진 자료를 모두 사용하여 모형을 적합할 수도 있지만 자료의 일부만 적합에 사용하고 나머지 자료는 적합한 회귀모형이 제대로 되었는지 시험하는데 사용될 수 있다. 이처럼 모형의 구축에 사용된 자료를 훈련자료(training data), 구축된 모형을 여러 측면에서 시험하는데 사용되는 자료를 시험자료(test data)라 부른다.

먼저 일반적인 상황에서 예측오차를 정의한다. 설명변수 $\mathbf{X} = (X_1, \dots, X_p)$ 를 이용하여 반응변수 Y 를 예측하기 위한 함수를 f 라 하자. 주어진 손실함수(loss function) L 에 대

해서 예측함수는

$$f = \underset{g}{\operatorname{argmin}} E[L(Y, g(\mathbf{X}))]$$

으로 주어진다. 만약 제곱오차손실함수(squared error loss) $L(Y, g(\mathbf{X})) = (y - g(\mathbf{X}))^2$ 를 사용하게 되면 예측함수는

$$f(\mathbf{x}) = E(Y|\mathbf{X} = \mathbf{x})$$

으로 주어짐을 쉽게 알 수 있다. 이제 훈련자료 $\chi_n = \{(\mathbf{X}_i, Y_i), i = 1, \dots, n\}$ 을 이용하여 추정된 f 를 $\hat{f}$ 이라 하고 시험자료인 $\mathbf{T} = (\mathbf{Z}, W)$ 가 주어졌을 때 예측오차는 다음과 같이 정의된다.

test data.의 반응변수

$$PE = E_{\chi_n} E_{\mathbf{Z}, W} L(W, \hat{f}(\mathbf{Z}))$$

popⁿ prediction error

test의 설명변수

즉, 예측오차란 훈련자료를 이용하여 만들어진 추정치에 시험자료를 대입했을 때 발생하는 손실의 기댓값이라 할 수 있다.

다음으로 예측오차를 선형회귀모형에 적용해 보자. 주어진 모형을

$$Y = \mu + \varepsilon$$

이라 하고 여기서 $E(\varepsilon) = 0$, $\operatorname{Var}(\varepsilon) = \sigma^2$ 으로 가정한다. 이때 $\hat{f}(\mathbf{x}) = \mathbf{x}'\hat{\beta}$ 라 두자. 단, $\hat{\beta} = (\mathbf{X}'\mathbf{X})^{-1}\mathbf{X}'\mathbf{y}$ 으로 이는 n 개의 훈련자료 $\chi_n = \{(\mathbf{X}_i, Y_i), i = 1, \dots, n\}$ 로 부터 만들어진 것이다. 제곱손실함수하에서 1개의 시험자료 $\mathbf{T} = (\mathbf{Z}, W)$ 에 대한 예측오차는

based on training

$$\begin{aligned} PE &= E_{\mathbf{Z}, W} E_{\chi_n} (W - \mathbf{z}'\hat{\beta})^2 \\ &= E_{\mathbf{Z}, W} E_{\chi_n} (W - \mu + \mu - \mathbf{z}'\hat{\beta})^2 \\ &= E_{\mathbf{Z}, W} E_{\chi_n} \{ (W - \mu)^2 + (\mu - \mathbf{z}'\hat{\beta})^2 + 2(W - \mu)(\mu - \mathbf{z}'\hat{\beta}) \} \\ &= \sigma^2 + E_{\mathbf{Z}, W} E_{\chi_n} (\mu - \mathbf{z}'\hat{\beta})^2 \end{aligned}$$

= 0 $E(W) = \mu$

으로 표현되는데 여기서 σ^2 을 축소불가오차(irreducible error)라 하고 뒷 부분을 모형오차(ME : Model Error)라 부른다. 즉, 예측오차는 축소불가오차와 모형오차의 합으로 주어지는데 축소불가오차는 원래의 모형 $Y = \mu + \varepsilon$ 에서 관측치 Y 가 참값인 μ 로부터 발생