

되는 오차 ε 의 분산으로 말 그대로 더 이상 축소할 수 없는 불가항력적인 오차이다. 반면 모형오차는 참값 μ 를 $f(x) = x'\beta$ 라는 모형으로 놓음으로써 발생하는 오차이므로 이를 말 그대로 모형오차라 부른다. 우리는 앞으로 어떤 모형의 좋고 나쁨을 예측오차의 값으로 판단하는 경우가 많은데 이런 관점에서 가장 좋은 모형이란 예측오차를 최소로 하는 모형이고 아울러 이는 모형오차를 최소로 하는 모형이 된다. 왜냐하면 축소불가오차는 더 이상 줄일수 없는 오차이므로 모형오차를 최소로 하는 모형이 결국 예측오차를 최소로 하는 모형이 되기 때문이다. 모형오차를 구체적으로 계산해 보기 위해 n 개의 시험자료를 (X, w) 라 두면 (즉, 시험자료의 설명변수를 훈련자료의 설명변수와 같게 두었음)

$$\begin{aligned}
 \text{모형오차 } ME &= E[(\mu - X'\hat{\beta})'(\mu - X'\hat{\beta})] \\
 &= E[(\mu - Hy)'(\mu - Hy)] \\
 &= E[(\mu - H\mu - H\varepsilon)'(\mu - H\mu - H\varepsilon)] \leftarrow y = \mu + \varepsilon \\
 &= E[\{(I - H)\mu - H\varepsilon\}'\{(I - H)\mu - H\varepsilon\}] \\
 &= E[\mu'(I - H)\mu + \varepsilon'H\varepsilon] \\
 &= \mu'(I - H)\mu + p\sigma^2
 \end{aligned}$$

으로 표현할 수 있는데 여기서 $H = X(X'X)^{-1}X'$ 이다. 즉, 모형오차 ME 는 $\mu'(I - H)\mu$ 와 $p\sigma^2$ 의 합으로 이루어져 있는데 이는 다음과 같이 해석될 수 있다. 우선, 적합된 모형의 편의(bias)는

$$\text{Bias}(X'\hat{\beta}) = E(X'\hat{\beta}) - \mu = H\mu - \mu = -(I - H)\mu$$

으로 표현되므로

$$\mu'(I - H)\mu = \text{Bias}(X'\hat{\beta})' \text{Bias}(X'\hat{\beta})$$

임을 알 수 있고, 또한,

$$\begin{aligned}
 p\sigma^2 &= \text{tr}[Cov(X'\hat{\beta})] \\
 &= \text{tr}[X(X'X)^{-1}X'\sigma^2] \\
 &= \text{tr}[(X'X)^{-1}X'X'\sigma^2] = p\sigma^2
 \end{aligned}$$

임을 알 수 있다. 즉, 모형오차는 편의의 제곱과 분산의 합으로 표현됨을 알 수 있으며 편의의 제곱과 분산의 합은 다름아닌 평균오차제곱(MSE : Mean Squared Error)이다. 결론적으로 제곱손실함수인 경우 모형오차는 평균오차제곱이 된다.

5.1.3 모형선택의 예

변수선택이 예측오차에 어떤 영향을 미치는지 살펴보기 위해 다음과 같은 예를 들어보자. 이 예는 린하트와 주키니(Linhart & Zucchini, 1986)의 6장 3절에 수록되어 있는 것으로 본 교재의 용어에 맞게 각색한 것임을 밝혀둔다.

참모형을 $\mu \equiv \mu(x) = \exp(0.1 + 0.02x^2)$ 이라 하고 이 모형으로 부터 $n = 100$ 개의 관측치 $(x_i, y_i), i = 1, \dots, 100$ 를 $x = 1(0.09)10$ 와 $\varepsilon_i \sim N(0, 1.5^2)$ 에 대하여

$$Y_i = \exp(0.1 + 0.02x_i^2) + \varepsilon_i$$

을 생성한다. 참모형과 이 자료에 대한 그림은 (그림 5.1)(a)에 나타나 있다. 주어진 100개의 자료로 부터 참모형은 결코 알 수 없다. 이 자료의 형태로 보아 우리가 설정할 수 있는 모형은 수 없이 많이 있지만 여기서는 6차 다항식으로 설정하자. 즉, 우리가 설정한 모형은


$$f_6(x) = \sum_{j=0}^6 \beta_j x^j$$

$$\begin{aligned} f_0(x) &= \beta_0 \\ f_1(x) &= \beta_0 + \beta_1 x \\ f_2(x) &= \beta_0 + \beta_1 x + \beta_2 x^2 \end{aligned}$$

이다. 설정한 6차 다항식 모형을 주어진 자료에 적합시킨 곡선이 (그림 5.1)(a)에 참모형과 같이 주어져 있는데 두 곡선이 매우 유사함을 알 수 있다. 그렇다면 우리가 선택한 6차 다항식이 여러 형태의 다항식중 최선의 선택인지 알아 보기 위해 상수 모형부터 6차 다항식까지 7개의 모형에 대한 예측오차를 계산해 보기로 하자. 예를 들어 $x = 5$ 에서의 예측오차를 계산하는데 참값은 $\mu(5) = \exp(0.1 + 0.02 \times 5^2) = 1.822$ 가 된다. 이제 100개의 자료를 각 설정된 모형에 적합시킨후 $x = 5$ 에서의 적합치 $\hat{f}_j(5)$ 를 계산한다. 이렇게 계산된 적합치와 참값인 1.822와의 차이가 바로 예측오차가 되는 것이다. 이러한 작업을 매번 새롭게 생성된 자료에 대해 100번 반복하면 각 설정된 모형에서 $x = 5$ 에서의 적합치가 100개 생성되며 이렇게 생성된 자료의 상자그림이(그림 5.1)(b)에 나타나 있다. 이 상자그림에서 상자의 폭이 예측오차의 분산에 대응되는 값이고 상자의 중심(중간값)과 참값의 차이가 예측오차 편향(bias)에 해당된다. 이 그림에서 알 수 있듯이 설정된 다항식의 차수가 낮으면 편향은 크지만 분산은 작고, 반면 다항식의 차수가 높아지면 편향은 줄어들지만 분산은 오히려 커진다는 것이다. 위에서 보인 것처럼 예측오차는 편향의 제곱과 분산의 합으로 나타나므로 차수가 높은 다항식이 낮은 다항식보다 예측오차가 작다고 할 수 없다. 오히려 편향과 분산 모두 작은 모형은 4차모형으로 나타났으며 이는 바로 설명변수를 무조건 많이 사용하는 것이 반드시 좋은 모형이 된다고 할 수 없다는 사실을 뒷받침하고 있다. 결론적

으로 바람직한 회귀모형이란 사용가능한 설명변수들 중에서 일부만 선택하여 구축된 모형 일 가능성이 높고 이러한 변수를 선택하기 위한 기준들이 다음 절에 제시되어 있다.

필요한 것
가 3개 정도



(그림 5.1) 참모형과 6차 다항식 (a), 상자그림(b)

5.2 변수선택의 기준

예비모형의 구축 단계에서는 고려된 설명변수 전부가 사용된다. 이때 설명변수의 총 개수를 $k - 1$ 개라 하고, 이들 변수들을 모두 사용하여 만든 예비 모형을 최대모형(maximal model, full model) 또는 포화모형(saturated model)이라 부른다. 그러나 가능한 설명변수를 모두 사용하는 것은 바람직하지 못하다. 회귀모형에서는 되도록 설명변수의 개수를 줄여서 최소한의 설명변수를 사용하는 것이 바람직하며, 이를 위해서는 반응변수를 잘 설명해주는 변수들만 선택하는 것이 중요하다. $k - 1$ 개의 설명변수 중에서 $p - 1$ 개의 설명변수로 구성된 모형을 현재모형(current model)이라고 하며, 설명변수가 전혀 사용되지 않고 반응변수 자체의 변동만을 고려한 모형을 최소모형(minimal model) 또는 영모형(null model)이라 한다.

변수선택의 원리는 되도록 작은 개수의 설명변수를 사용하여 반응변수의 많은 부분을 설명해 줄 수 있는 현재모형을 택하는 것이다(3.3절의 간결함의 원칙 참조). 또한, 모형의 구축에 사용되는 설명변수가 많아지면 관측치의 수가 기하급수적으로 많이 필요하게 된다. 따라서, 되도록이면 작은 개수의 설명변수를 사용하는 것이 바람직하는데 이를 위해 설명력이 뛰어난 변수들을 잘 선택해 주는 변수선택의 기준이 꼭 필요하다.

현재모형이 $p - 1$ 개의 설명변수로 구성되어 있는데 절편을 나타내는 모수 β_0 가 포함되어 있다고 가정하면, 현재모형에 사용된 회귀계수는 $\beta_0, \beta_1, \dots, \beta_{p-1}$ 으로 p 개가 된다. 즉, 디자인 행렬 X 는 $n \times p$ 행렬이고 X 의 첫 번째 열은 전부 1로 이루어져 있다.

변수선택의 기준을 제시하기 전에 다음의 예제를 통해 변수선택의 필요성을 제시하고 변수선택의 기준에 따라 어떤 변수들이 선택되는지 살펴보기로 한다. 또한, 최대모형에 비해 선택된 모형이 어떤 장점을 가지는지 살펴보자.

예제 5.1 (주택 판매 가격)

다음 자료는 주택 판매 가격(Y : 천만원)과 이에 영향을 줄 것으로 판단되는 4가지 설명변수 세금(X_1 : 만원), 대지평수(X_2 : 평), 건물 평수 (X_3 : 평), 주택 연령(X_4 : 년)를 27가구에 대해 조사한 것이다.

<표 5.1> 27가구에 대한 주택 판매 가격

번호	X_1	X_2	X_3	X_4	Y
1	98.352	34.720	19.96	4.2	12.95
2	100.416	35.310	30.00	6.2	14.75
3	90.858	22.750	23.50	4.0	13.95
4	91.146	40.500	24.64	5.4	12.95
5	101.194	44.550	22.42	4.2	14.95
6	77.820	44.550	19.76	5.6	14.95
7	117.960	58.500	24.80	5.1	15.45
8	112.186	95.200	30.02	3.2	14.45
9	308.404	98.000	68.40	4.2	42.45
10	289.196	128.000	60.00	1.4	41.45
11	116.564	64.350	24.50	3.2	17.95
12	106.006	49.883	31.04	3.0	15.75
13	125.424	55.200	19.50	3.0	15.50
14	119.184	66.660	22.42	3.2	15.45
15	101.000	50.000	20.40	4.6	15.00
16	164.928	51.500	33.28	5.0	18.45
17	133.938	69.020	29.76	2.2	20.95
18	155.682	71.020	27.52	1.7	20.25
19	180.768	78.000	30.00	2.3	21.95
20	119.788	55.200	25.12	4.0	18.75
21	150.844	40.000	33.80	2.2	18.95
22	175.902	98.900	36.40	5.0	22.25
23	121.862	67.265	33.04	4.4	18.95
24	167.214	91.500	35.54	4.8	19.45
25	162.800	80.000	30.08	0.3	18.45
26	182.832	73.262	36.62	3.1	22.90
27	240.000	50.000	24.00	3.0	20.50

<표 5.2> 변수들간의 상관계수행렬

	X_2	X_3	X_4	Y
X_1	.6860	.8324	-.3712	.9152
X_2		.7003	-.3803	.7263
X_3			-.1781	.9288
X_4				-.3103

이제 이 자료를 바탕으로 네가지 설명변수를 모두 사용한 중선형회귀모형

$$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_4 X_4 + \varepsilon$$

에 적합시키기 전에 몇 가지 예비분석을 해 보자. 우선 Y 와 각 설명변수간의 산점도((그림 5.2) 참조)를 보면 선형성이 나타나고 있다.

또한, 변수들 간의 상관계수 행렬(<표 5.2>)은 X_4 를 제외한 나머지 변수들 간에 비교적 높은 상관계수를 나타내고 있다. 우선 중선형회귀모형에 적합시켜 보면

$$\hat{Y} = 1.22 + 0.0519X_1 + 0.0116X_2 + 0.349X_3 - 0.219X_4$$


(2.047) (0.014) (0.025) (0.037) (0.332)

결정계수가 $R^2 = 0.93$ 으로 매우 높고 F 값에 대한 유의확률도 0.0001로 매우 잘 적합되었음을 알 수 있다.


한편, 잔차에 관한 그림을 살펴보면 별다른 형태를 보이지 않고 정규성 검토도 비교적 만족스러운 결과를 보이고 있으나, 단지 각 산점도에서 2개의 이상점이 나타나고 있어 이 점들에 대한 영향력 조사가 필요할 것으로 판단된다.

네 개의 설명변수를 모두 사용한 중선형회귀분석이 여러 가지 측면에서 적합이 잘 되었지만 보다 더 작은 개수의 설명변수로도 이에 근접하는 적합을 이룰 수 있다면 더욱 좋을 것이다. 회귀모형의 원래 목적인 자료축약이란 점과 해석의 편리함 때문이다. 그렇다면, 반응변수 Y 를 잘 설명해 줄 수 있는 설명변수를 어떻게 선택할 것인가 하는 문제를 생각해 보자. □


한편 바람직한 현재모형을 선택하기 위해서는 어떤 기준이 필요하다. 이러한 기준은 현재모형을 최소모형 또는 최대모형과 비교할 수 있어야 하며, 적절한 기준치가 제시되어야 하고, 또한, 선택된 현재모형이 통계적으로 해석되어야 한다. 변수선택의 기준에는 여러 가지가 있으나 여기서는 네가지 기준을 소개한다.




(a)




(b)




(c)



(d)



(e)



(f)

(그림 5.2) 주택판매가격 자료에서 Y 와 X_i 간의 산점도 및 잔차에 관한 그림

5.2.1 R_p^2


current model의
개수
←
모수

회귀분석의 결과 총변동(SST) 중에서 회귀직선에 의해 설명되는 변동(SSR)이 차지하는 비율, 즉 SSR/SST 를 결정계수라 하였다. 결정계수는 0과 1 사이의 값으로 1에 가까울수록 회귀의 적합, 즉, 설명변수가 반응변수를 잘 설명해 주는 것인데, 현재모형의 적합정도를 총변동에서 현재모형의 회귀에 의한 변동(SSR_p)이 차지하는 비율로 정의한다. 즉,

$$R_p^2 = \frac{SSR_p}{SST} = 1 - \frac{SSE_p}{SST} \quad (5.1)$$

으로 정의한다. 그렇다면 R_p^2 의 값이 얼마일 때 모형을 선택할 것인가? 현재모형에서 새로운 변수가 추가되면 R_p^2 은 증가함을 쉽게 증명할 수 있다. 또한, 현재모형에서 변수가 제거되면 R_p^2 은 감소한다. 즉, R_p^2 은 최소모형일 때는 0이고 최대모형일 때 최대값을 갖는다. R_p^2 을 사용하여 최적의 모형을 찾을 때는 모든 가능한 모형에서 R_p^2 의 값을 전부 계산한 다음 p 가 증가해도 R_p^2 의 증가폭이 그다지 크지 않는 시점을 선택하는 것이 바람직하다.

(그림 5.3)은 주택판매가격자료에 대해 R_p^2 을 $p = 1, 2, \dots, 5$ 에 해당하는 값을 그린 것이다. 설명변수가 한 개($p = 2$)일 때는 X_3 를 포함하는 모형의 R_p^2 이 가장 크고, 두 개일 때는 (X_1, X_3) 로 이루어진 현재모형의 R_p^2 이 가장 크다. $p = 4$ 일 때는 (X_1, X_2, X_3) 로 이루어진 현재모형의 R_p^2 이 가장 크지만 X_2 가 첨가됨으로써 증가된 R_p^2 의 증가폭이 거의 없으므로 R_p^2 에 근거한 최적모형은 (X_1, X_3) 로 이루어진 모형이라 할 수 있다.



3을 포함할 경우
무슨 것
nested model
3 → $\begin{pmatrix} 1 & 3 \\ 2 & 3 \\ 3 & 4 \end{pmatrix}$

(그림 5.3) 주택판매가격자료에 대한 R_p^2


5.2.2 R_{ap}^2 와 s_p^2

결정계수는 현재의 모형에서 새로운 변수가 추가되면 언제나 증가한다. 즉, R_p^2 은 설명 변수의 개수를 반영하지 못한다는 단점이 있으며, 변수가 추가됨에 따라 증가되는 결정계수의 값이 어느 정도 이상이어야 추가된 변수의 유의성이 존재하는지 가늠하기 어렵다. 이러한 단점을 보완하기 위해 수정된 결정계수(adjusted R^2)가 제시되었다. 이것은 결정계수의 분자와 분모에 주어진 제곱합을 각각의 자유도로 나눈 것으로 정의된다. 즉,

$$\begin{aligned} R_{ap}^2 &= 1 - \frac{SSE_p / (n - p)}{SST / (n - 1)} \\ &= 1 - \frac{s_p^2}{SST / (n - 1)} \end{aligned} \quad (5.2)$$

따라서 R_{ap}^2 을 변수선택의 기준으로 사용하는 것은 s_p^2 을 사용하는 것과 동일한 결과를 준다. 또한, R_{ap}^2 은 설명변수가 추가되더라도 항상 증가하는 것은 아니고 사용된 설명변수의 개수가 반영되므로 최대값을 갖게 되는 적절한 p 가 존재하게 된다. 즉, 설명변수가 추가되면 그 만큼의 벌칙(penalty)이 부과된다. 한편, s_p^2 을 사용하면 최소가 되는 모형을 찾으면 된다.

(그림 5.4)는 주택판매가격자료에 대해 s_p^2 을 적용한 것인데 (X_1, X_3) 을 선택하는 것이 바람직하다.



(그림 5.4) 주택판매가격자료에 대한 s_p^2

5.2.3 C_p

이 기준은 맬로우즈(Mallows, 1973)에 의해 제안된 것으로 적합치의 총 평균 오차제곱(total mean squared error)을 최소화 하기 위한 것이다. 반응변수 Y 에 대한 참 회귀함수(true regression function)는 알 수 없으며 이를

$$y = \mu + \varepsilon \quad (5.3)$$

으로 표현하자. 즉, 반응변수의 참 평균값은 $E(y) = \mu \equiv (\mu_1, \dots, \mu_n)'$ 이 된다. 한편, 우리가 고려하는 현재모형은 $y = X\beta + \varepsilon$ 인데 이를 흔히 설정된 모형(postulated model)이라 부른다. $\hat{y}$ 을 현재모형 하에서의 적합치라 하면 i 번째 적합치의 평균오차제곱은

$$E(\hat{y}_i - \mu_i)^2 \quad \hat{y}_i - \mu_i \quad (5.4)$$

으로 정의되며, 이는

$$\begin{aligned} E(\hat{y}_i - \mu_i)^2 &= E\{(\hat{y}_i - E(\hat{y}_i)) + (E(\hat{y}_i) - \mu_i)\}^2 \\ &= \text{Var}(\hat{y}_i) + \{E(\hat{y}_i) - \mu_i\}^2 \end{aligned}$$

으로 표현할 수 있다. 즉, 평균오차제곱은 언제나 분산과 편의(bias)의 제곱의 합으로 표현할 수 있다. 적합치들의 총평균오차제곱을 σ^2 으로 나눈 것을 Γ_p 라 하자. 즉,

$$\begin{aligned} \Gamma_p &= \sum_{i=1}^n \{ \text{Var}(\hat{y}_i) + (E(\hat{y}_i) - \mu_i)^2 \} / \sigma^2 \\ &= \frac{1}{\sigma^2} \{ \text{tr}[\text{Cov}(\hat{y})] + (E(\hat{y}) - \mu)'(E(\hat{y}) - \mu) \} \end{aligned}$$

그런데

$$\begin{aligned} \text{tr}[\text{Cov}(\hat{y})] &= \text{tr}[\text{Cov}(Hy)] = \text{tr}[X(X'X)^{-1}X'\sigma^2] = p\sigma^2 \\ E(\hat{y}) - \mu &= E(Hy) - \mu = -(I - H)\mu \end{aligned}$$

이므로 $(I - H)$ 가 대칭이고, 멱등행렬임을 이용하면

$$\Gamma_p = p + \frac{1}{\sigma^2} \mu'(I - H)\mu \quad (5.5)$$

으로 표현할 수 있다. Γ_p 를 최소화하면 적합치의 분산과 편의를 동시에 작게 해주는 것이므로 Γ_p 를 최적모형을 찾는 기준으로 사용하면 좋을 것이다. 그러나 Γ_p 는 미지의 모수 σ^2 , μ 등을 포함하고 있으므로 직접 사용할 수 없다. 따라서, Γ_p 에 대한 적절한 추정치가 필요하다.

Γ_p 의 추정치를 구하기 위해 먼저 현재모형 하에서 오차제곱합 SSE_p 의 기댓값을 구해보자. 이것은

$$E(SSE_p) = E(e'e) = E[y'(I - H)y] = \mu'(I - H)\mu + (n - p)\sigma^2$$

와 같이 주어짐을 알 수 있다. 따라서

$$\frac{E(SSE_p)}{\sigma^2} - (n - 2p) = \Gamma_p$$

이 성립한다. 여기서 $E(SSE_p)$ 와 σ^2 대신에 SSE_p 와 s^2 의 값을 사용하여 Γ_p 의 추정치로


$$C_p = \frac{SSE_p}{s^2} - (n - 2p) \quad \text{sample version of } MSE/\sigma^2 \quad (5.6)$$

를 변수선택의 기준으로 사용하며 이를 맬로우즈의 C_p 라 한다. 단, 여기서 s^2 은 현재모형이 아닌 최대모형에서 구한 σ^2 의 추정치다.

맬로우즈의 C_p 에 대해 다음 몇 가지 성질을 살펴보자. 첫째 C_p 의 첫번째 구성요소인 SSE_p/s^2 은 모형의 적합도(goodness-of-fit)를 나타낸 것으로 이는 설명변수가 많이 사용될수록 작아진다. 반면에 두번째 구성요소인 $-(n - 2p) = 2p - n$ 는 현재모형에서 사용된 설명변수의 개수가 많아지면 커지는 값이다. 이를 벌칙항(penalty term)이라 부른다. 즉, C_p 는 설명변수 개수가 많아지면 적합도를 나타내는 첫번째 항은 작아지지만 벌칙항을 나타내는 두번째 항은 커진다. 즉, C_p 는 적합도와 사용된 설명변수의 개수(벌칙항)에 대한 적절한 타협(compromise)이라 볼 수 있다.

다음으로, 현재모형이 좋은 것이라면 $SSE_p \simeq (n - p)s^2$ 일 것이다. 따라서 $C_p \simeq (n - p) - (n - 2p) = p$ 가 되지만 C_p 를 변수선택의 기준으로 사용할 때는 $C_p \neq p$ 를 최소화하는 모형을 최적모형으로 한다. 실제로 최대모형에서는 $SSE_p = (n - p)s^2$ 이므로 언제나 $C_p = p$ 가 된다.

(그림 5.5)는 주택판매가격자료에 대해 C_p 를 적용한 것인데 (X_1, X_3) 이 가장 좋은 변수들로 나타났다.



$C_p = p$ 가 되는 직선

X_1, X_3
이 Best!

(그림 5.5) 주택판매가격자료에 대한 C_p (점선은 $C_p = p$ 를 나타낸다)

5.2.4 $PRESS_p$

지금까지 제시된 모형선택의 기준인 R_p^2 , s_p^2 , C_p 등은 관측된 자료들에 대한 현재모형의 적합도(quality of fit)가 얼마나 좋은 지를 나타내는 측도들이다. 그러나 회귀분석에서 중요한 목적 중의 하나는 예측인데, 실제 문제들에 있어서 적합도가 높은 모형이더라도 낮은 예측도(quality of prediction)를 갖는 경우가 있다. 그러므로 정확도가 높은 예측이 중요한 분석 목적인 경우에는 적합도보다 예측도가 높은 모형을 선택할 필요가 있다.

이 예측도를 나타내는 측도로는 $PRESS_p$ 가 있다. 예측오차제곱합(prediction error sum of squares)을 나타내는 $PRESS_p$ 는 알렌(Allen, 1971)에 의해 제안되었고

$$PRESS_p = \sum_{i=1}^n (y_i - \hat{y}_{i(i)})^2$$

$$y_i - \hat{y}_{i(i)} = y_i - x_i^T \hat{\beta}_{(i)} \quad (5.7)$$

으로 정의된다. 여기서 $\hat{y}_{i(i)}$ 은 i 번째 관측치를 제외시킨 후 $(n-1)$ 개의 관측치로 회귀모형을 구한 다음, x_i 에서 예측한 y 값을 나타낸다. 즉, $PRESS_p$ 는 n 개의 자료를 나누어서 $(n-1)$ 개는 추정에 이용하고 나머지 한 개는 예측의 정확도 계산에 사용한 것이다. 이는 교차확인(cross validation)(5.4.1절 참조)의 개념과 같은 것이다. 이 $PRESS_p$ 의 값을 최소화하는 모형을 최적모형으로 선택하면 된다.

$$\hat{\beta} - \hat{\beta}_{(i)} = \frac{(X^T X)^{-1} x_i e_i}{1 - h_{ii}}$$

이 기준치의 장점은 계산이 매우 간편하다는 것이다. 식 (4.6)에 의하여


$$\hat{y}_{i(i)} = \mathbf{x}'_i \hat{\beta}_{(i)} = \mathbf{x}'_i \left(\hat{\beta} - \frac{(\mathbf{X}'\mathbf{X})^{-1} \mathbf{x}_i e_i}{1 - h_{ii}} \right) = \hat{y}_i - \frac{h_{ii} e_i}{1 - h_{ii}}$$

이므로

$$PRESS_p = \sum_{i=1}^n \underbrace{\left(y_i - \hat{y}_i + \frac{h_{ii} e_i}{1 - h_{ii}} \right)}_{e_i}^2 = \sum_{i=1}^n \left(\frac{e_i}{1 - h_{ii}} \right)^2 \quad (5.8)$$

으로 표현된다. 따라서 $PRESS_p$ 를 계산하기 위해서는 식 (5.7)보다 식 (5.8)을 이용하면 계산량을 훨씬 줄일 수 있다.

(그림 5.6)은 주택판매가격자료에 대해 $PRESS_p$ 를 적용해 본 것으로 (X_1, X_3) 이 가장 바람직한 변수로 채택되었다.



(그림 5.6) 주택판매가격자료에 대한 $PRESS_p$

이상으로 변수선택의 기준으로서 R_p^2 , R_{ap}^2 , s_p^2 , C_p , $PRESS_p$ 등을 소개하였다. 이외에도 변수선택의 기준으로 5.6절에 소개되어 있는 AIC(Akaike Information Criterion), BIC(Bayesian Information Criterion) 등이 있다. 이런 기준들을 주택판매가격자료에 적용시킨 모든 결과가 <표 5.3>에 요약되어 있다. 이 표에서 알 수 있듯이 모든 경우에 (X_1, X_3) 이 가장 바람직한 변수로 채택되었다.

<표 5.3> 주택판매가격자료에서 각 모형에 대한 변수선택 기준

	p	df	SSE_p	R_p^2	MSE_p	C_p	$PRESS_p$
None	1	26	1330.58	0.000	51.18	295.04	1434.900
X_1	2	25	216.00	0.838	8.60	28.95	316.087
X_2	2	25	628.62	0.528	25.14	128.20	838.812
X_3	2	25	182.70	0.863	7.30	20.94	220.885
X_4	2	25	1202.47	0.096	48.10	266.23	1430.610
X_1, X_2	3	24	191.94	0.856	8.00	25.17	358.215
X_1, X_3	3	24	95.20	0.928	3.97	1.90	144.399
X_1, X_4	3	24	214.64	0.839	8.94	30.63	341.429
X_2, X_3	3	24	168.59	0.873	7.02	19.55	233.762
X_2, X_4	3	24	626.81	0.529	26.12	129.77	911.355
X_3, X_4	3	24	153.81	0.884	6.41	16.00	207.659
X_1, X_2, X_3	4	23	93.26	0.930	4.05	3.43	159.175
X_1, X_2, X_4	4	23	187.51	0.859	8.15	26.10	380.174
X_1, X_3, X_4	4	23	92.32	0.931	4.01	3.21	153.594
X_2, X_3, X_4	4	23	150.10	0.887	6.53	17.10	233.224
X_1, X_2, X_3, X_4	5	22	91.45	0.931	4.16	5.00	170.481

5.3 변수선택의 방법 (알고리즘)

앞 절에서는 변수선택의 기준에 대해 소개하였다. 실제로 변수선택의 과정에서 어떤 방법으로 계산할 것인가도 중요한 문제다. 변수선택의 방법에는 크게 네 가지로 분류될 수 있다.

- (1) 모든 가능한 회귀(all possible regression)
- (2) 앞으로부터의 단계적 회귀(forward stepwise regression)
- (3) 앞으로부터의 선택(forward selection)
- (4) 뒤로부터의 제거(backward elimination)

5.3.1 모든 가능한 회귀

최대모형이 $k - 1$ 개의 변수로 구성되어 있을 때 가능한 현재모형의 가짓수를 살펴보자. 우선 설명변수를 전혀 포함하지 않는 영모형이 한 개 있고, 한 개의 설명변수만 가지는 모형이 $k - 1$ 개 있을 수 있다. 이렇게 두 개, 세 개 등으로 확장시켜 나가면 $k - 1$ 개의 변수로 구성할 수 있는 모든 가능한 가짓수는

$$\binom{k-1}{0} + \binom{k-1}{1} + \cdots + \binom{k-1}{k-1} = 2^{k-1}$$

이 된다. 모든 가능한 회귀(all possible regression)란 2^{k-1} 개의 모든 현재모형에 대해 어떤 변수선택의 기준을 적용시켜 최적모형을 구하는 것으로, 5.2절에서 주택판매가격자료에 대한 변수선택은 이 방법으로 구한 것이다. 이 방법은 모든 가능한 경우에 대해 확인절차를 거치므로 가장 확실한 방법이 될 수 있지만 계산량이 매우 많은 것이 단점이다.

5.3.2 앞으로부터의 단계적 회귀

만약 최대모형의 설명변수의 개수가 매우 크다면(예를 들어 40개), 모든 가능한 회귀방법은 적용이 거의 불가능하다. 이에 대한 대안 중의 하나인 앞으로부터의 단계적 회귀를 부분 F 검정에 사용되는 F^* 통계량을 이용해서 설명한다. 기본적인 알고리즘을 소개하면 다음과 같다.

단계 1. 먼저 현재모형이 한 개의 설명변수를 가지고 있다면 이는 단순선형회귀가 된다. 이때 기울기가 0인지에 대한 부분 F 검정은

$$F_i^* = \frac{MSR_i}{s_i^2}, \quad i = 1, \dots, k-1$$

이 되고, 이 중에서 가장 큰 F^* 값이 $F_\alpha(1, n-2)$ 보다 크면 그 변수는 첨가되고 그렇지 않으면 영모형을 채택하게 된다.

단계 2. 만약 단계 1에서 X_7 이 첨가되었다고 하자. 이제 X_7 에 또 다른 설명변수가 추가된, 두 개의 설명변수에 대한 현재모형을 부분 F 검정한다. 즉,

$$R(X_i | X_7) \rightarrow F_i^* = \frac{MSR(X_i | X_7)}{s^2(X_7, X_i)} = \left(\frac{\hat{\beta}_i}{SE(\hat{\beta}_i)} \right)^2, \quad i \neq 7$$

이 되는데 $MSR(X_i | X_7)$ 은 X_7 이 있을 때의 X_i 에 의한 부분회귀제곱합이고, $s^2(X_7, X_i)$ 은 X_7 과 X_i 로 구성된 현재모형에서의 오차평균제곱합이다. F_i^* 중에서 가장 큰 값이 $F_\alpha(1, n-3)$ 보다 크면 그 변수는 첨가되고, 그렇지 않으면 여기서 끝낸다. 최종모형: X_7

단계 3. 만약 단계 2에서 X_3 이 추가되었다고 하자. 즉, 현재모형에는 X_7 과 X_3 이 있다. 단계 3에서는 이들 두 변수에 대해 부분 F 검정을 한다. 이미 단계 2에서 X_3 에 대한 부분 F 검정이 실시되었으므로 단계 3에서는 X_7 에 대한 부분 F 검정만 하면 된다. 즉,

$$F_7^* = \frac{MSR(X_7 | X_3)}{s^2(X_3, X_7)}$$

인데 이 값이 $F_{\alpha}(1, n-3)$ 보다 크면 X_7 은 현재모형에 남아있게 되고 그렇지 않으면 제거된다.

단계 4. 만약 단계 3에서 X_7 이 남아있게 된다고 하자. 이제 X_3 과 X_7 이 아닌 변수들에 대해 단계 2와 단계 3을 반복 적용한다.

예제 5.2 (주택판매가격자료) (그림 5.7)은 SAS를 이용한 앞으로부터의 단계적 회귀를 주택판매가격자료에 적용시킨 것이다. 이제 (그림 5.7)에 나타나 있는 출력결과를 단계별로 살펴보자.

(i) 단계 1에서는 한 개의 설명변수만이 있는 단순선형회귀모형에서 F^* 의 값을 계산하였고 그 중에서 가장 큰 것은

$$F_3^* = \frac{MSR(X_3)}{s^2(X_3)} = \frac{1147.9168}{7.3065} = 157.11$$

이며 $F_{0.05}(1, 25) = 4.24$ 를 초과하므로 X_3 는 추가된다.

(ii) 단계 2에서는 X_3 를 제외한 나머지 변수의 부분 F 검정을 실시한다. 즉,

$$F_i^* = \frac{MSR(X_i | X_3)}{s^2(X_3, X_i)}, \quad i = 1, 2, 4$$

을 계산한 결과 F_1^* 가 가장 크고, $F_{0.05}(1, 24) = 4.26$ 을 초과하므로 X_1 을 모형에 추가시킨다.

(iii) 단계 3에서는 현재모형에 있는 X_1 과 X_3 의 부분 F 검정을 실시한다. 그런데

$$F_3^* = \frac{MSR(X_3 | X_1)}{s^2(X_1, X_3)} = 30.45$$

이므로 4.26을 초과하므로 X_3 를 제거시키지 않는다.

(iv) 이제 현재모형에 없는 X_2, X_4 를 X_1, X_3 에 대해 부분 F 검정한다. 즉,

$$F_i^* = \frac{MSR(X_i | X_1, X_3)}{s^2(X_1, X_3, X_i)}, \quad i = 2, 4$$

둘다 $F_{0.05}(1, 23) = 4.28$ 보다 작으므로 더 이상 추가 되지 않는다.

이상의 결과에서 X_1, X_3 가 최적모형으로 선택되었으며, 이 결과는 앞 절에서 여러 가지의 변수선택기준에 의한 결과와도 일치한다. $\square$

The REG Procedure								
Model: MODEL1								
Dependent Variable: Y								
Number of Observations Read				27				
Number of Observations Used				27				
Stepwise Selection: Step 1								
Variable X3 Entered: R-Square = 0.8627 and C(p) = 20.9436								
Analysis of Variance								
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F			
Model	1	1147.91685	1147.91685	157.11	<.0001			
Error	25	182.66315	7.30653					
Corrected Total	26	1330.58000						
Variable	Parameter Estimate	Standard Error	Type II SS	F Value	Pr > F			
Intercept	1.25296	1.52716	4.91834	0.67	0.4197			
X3	0.59511	0.04748	1147.91685	157.11	<.0001			
Bounds on condition number: 1, 1								

Stepwise Selection: Step 2								
Variable X1 Entered: R-Square = 0.9285 and C(p) = 1.9014								
Analysis of Variance								
Source	DF	Sum of Squares	Mean Square	F Value	Pr > F			
Model	2	1235.38450	617.69225	155.73	<.0001			
Error	24	95.19550	3.96648					
Corrected Total	26	1330.58000						
Variable	Parameter Estimate	Standard Error	Type II SS	F Value	Pr > F			
Intercept	0.39497	1.13994	0.47618	0.12	0.7320			
X1	0.05742	0.01223	87.46765	22.05	<.0001			
X3	0.34835	0.06313	120.78214	30.45	<.0001			
Bounds on condition number: 3.2564, 13.026								

All variables left in the model are significant at the 0.1500 level.								
No other variable met the 0.1500 significance level for entry into the model.								
Summary of Stepwise Selection								
Step	Variable Entered	Variable Removed	Number Vars In	Partial R-Square	Model R-Square	C(p)	F Value	Pr > F
1	X3		1	0.8627	0.8627	20.9436	157.11	<.0001
2	X1		2	0.0657	0.9285	1.9014	22.05	<.0001

(그림 5.7) 주택판매가격자료에 대한 SAS(앞으로부터의 단계적 회귀)의 출력 결과

5.3.3 앞으로 부터의 선택

이 방법은 앞으로 부터의 단계적 회귀를 단순화시킨 것으로 한 번 선택된 변수는 제거되지 않는 것이 차이점이다.

5.3.4 뒤로 부터의 제거

이 방법은 앞으로 부터의 선택과 정반대로, 최대모형에서 가장 낮은 F^* 값을 가지는 것이 기준치보다 작으면 제거해 나간다. 예를 들어, 변수 X_1 에 대한 값은

$$F_1^* = \frac{MSR(X_1 | X_2, \dots, X_{k-1})}{s^2(X_1, \dots, X_{k-1})} < F_2(1, n-k)$$

이다. 앞으로 부터의 선택이나 뒤로 부터의 제거는 계산량이 작다는 장점이 있지만 한 번 선택된 변수나 한 번 제거된 변수는 다시 고려되지 않으므로 별로 바람직하지 못하다.

5.4 모형의 확인

training (X, Y) $L(Y, f(x))$: loss func
 test (Z, W)
 $E_Z E_W L(W, \hat{f}(Z)) \rightarrow \sigma^2 + ME$
 $MSE = Var + Bias^2$

5.4.1 교차확인

예측오차를 최소로 하는 모형이 가장 좋은 모형이라고 했는데 예측오차는 미지의 모수들을 포함하고 있어서 직접 사용할 수 없다. 예측오차에 대한 추정치로 흔히 교차확인(cross validation)을 이용하는데 교차확인의 기본 아이디어는 주어진 n 개의 자료를 훈련자료와 시험자료의 두 부분으로 임의로 나누어서 사용한 다음 이를 바탕으로 예측오차를 추정하는 것이다. 우선 교차확인을 수리적으로 정의해 보자. 먼저 집합 $\{1, \dots, n\}$ 을 임의로 K 개로 분할(partition)하여 이를 $I_j, j = 1, \dots, K$ 라 하자. 그리고 함수 κ 는 $\kappa: \{1, \dots, n\} \mapsto \{1, \dots, K\}$ 으로 " $\kappa(i) = j$ "와 " i 가 I_j 에 속한다"가 같은 의미를 나타내도록 정의된 함수이다. 이제 원래의 자료 $\{(X_1, Y_1), \dots, (X_n, Y_n)\}$ 에서 j 번째 분할에 속하는 자료를 제외한 나머지 자료들을 이용하여 적합시킨 추정치를 $\hat{f}_{-j}$ 라고 하면 예측오차에 대한 교차확인 추정치는 다음과 같이 정의된다.

$$\hat{P}_{ECV} = \frac{1}{n} \sum_{i=1}^n L(Y_i, \hat{f}_{-\kappa(i)}(X_i)).$$


특별한 경우로 $K = n$ 이 되면 이를 한점소거교차확인(LOOCV: Leave-One-Out Cross Validation)이라 부르는데 이는 n 개의 자료에서 i 번째 ($i = 1, \dots, n$) 자료를 제외한 나머지 $(n-1)$ 개의 자료를 훈련자료로 사용하고 i 번째 자료를 시험자료로 사용한다. 일반적으로 k -접힘 교차확인(k -fold cross validation)이 널리 사용되는데 이는 전체 n 개의 자료를 k 등분한 다음 $(k-1)$ 등분은 훈련자료로 사용하고 나머지 1등분에 대한 자료를 시험자료

로 사용하는 것인데 흔히 k 는 5 또는 10이 좋다고 알려져 있다. 따라서, 한점소거교차확인인 n -점함교차확인이 된다. 좀 더 구체적으로 $n = 6$ 개의 자료가 있고 3-점함교차확인을 이용한다고 하자. 만약 6개의 자료를 임의로 3등분한 것의 집합이 $\{1, 5\}, \{2, 6\}, \{3, 4\}$ 으로 주어졌을때 훈련자료와 시험자료는 다음과 같이 3가지 경우로 주어지며 예측오차의 교차확인 추정치는 이들 3가지 자료로부터 추정한 손실함수값의 산술평균이 된다.

훈련자료	시험자료
1, 2, 5, 6	3, 4
1, 3, 4, 5	2, 6
2, 3, 4, 6	1, 5

5.4.2 훈련자료와 시험자료, 그리고 예측오차

모형을 구축할 때 사용된 변수가 작은 최소모형은 모형 복잡성(model complexity)이 낮다고 하며 많은 변수가 사용되는 최대모형의 경우 모형 복잡성이 높다고 정의한다. 따라서, 바람직한 회귀모형의 선택이란 너무 단순(낮은 모형복잡성)하지도 너무 복잡(높은 모형복잡성)하지도 않은 적절한 모형 복잡성을 선택하는 것과 같다. 이를 위해 앞에서도 언급했듯이 최적의 모형선택 또는 모형복잡성의 선택은 흔히 예측오차를 최소화하는 기준으로 이루어진다. 예측오차는 축소불가오차와 모형오차의 합으로 표현됨을 보였으며, 또한, 모형오차는 편의의 제곱과 분산의 합으로 이루어진다. 일반적으로 모형 복잡성이 낮을수록 편의는 커지고 분산은 작아진다. 반대로 모형 복잡성이 높아지면 편의는 감소하지만 분산은 커진다 (그림 5.8 참조). 이러한 현상은 5.1.3절에 주어진 예에서도 잘 나타난다.



(그림 5.8) 훈련자료에서는 모형이 복잡해 짐에 따라 예측오차가 감소하지만 시험자료에서는 감소하다가 증가하는 현상을 나타내고 있다.

앞에서도 언급했듯이 예측오차란 훈련자료를 이용하여 적합시킨 모형에 훈련자료를 대입했을 때 계산되는 적합치와 시험자료의 반응치의 차이라고 할 수 있다. 만약 모형을 선택할 때 오직 훈련자료만 사용하면 어떻게 될까? 이론상 주어진 훈련자료를 완벽하게 적합시킬 수 있는 모형은 언제든지 존재한다. 예를 들어 n 개의 훈련자료가 주어졌을 때 n 차 다항식을 채택하면 잔차 제곱합이 0이 된다. 이러한 모형은 주어진 훈련자료에 대해서는 최적모형일 수 있으나 다른 어떤 시험자료에 대해서도 결코 좋은 모형이 될 수 없다. 왜냐하면 적합된 n 차 다항식은 주어진 그 훈련자료에만 좋은 모형이지 다른 어떤 자료에 대해서도 좋을 수 없기 때문이다. (그림 5.8)에 나타난 것 처럼 훈련자료는 모형의 복잡성이 높아질수록 오차가 단순감소하지만 시험자료는 적절한 모형복잡성에 대해서 예측오차가 최소가 됨을 보여준다. 이러한 현상으로 인해 주어진 모형의 적합은 훈련자료가 담당하고, 적합된 모형의 검정은 시험자료가 담당해야 한다.

5.5 변수선택의 진단

몇 개의 관측치가 어떤 추정치에 심각한 영향을 미칠 수 있음은 이미 4장에서 쿡 통계량 등을 통하여 논의한 바 있다. 여기서는 몇 개의 관측치가 변수 선택에 어떤 영향을 미치는지 알아보자. 5.2절에서 논의한 것 처럼 변수 선택의 기준에는 여러 가지가 있으나 가장 널리 사용되는 맬로우즈의 C_p 기준을 이용한다. 만약 계수 집합 $K = \{i_1, \dots, i_k\}$ 에 속하는 k 개의 관측치가 제거 되었을 때 C_p 의 기준은 어떻게 변하며 이에 따라 변수 선택은 어떻게 변하는지 살펴보자. C_p 는 식 (5.6)에 주어진 것처럼

$$C_p = \frac{SSE_P}{s^2} - (n - 2p)$$

을 최소화하는 기준이다. 현재모형에서의 잔차벡터를 e^c , 최대모형에서의 잔차벡터를 e 라 하고, $q - 1$ 을 최대모형의 변수의 개수라 하면

$$C_p = \frac{e^{c'} e^c}{e' e / (n - q)} - (n - 2p) \quad (5.9)$$

가 된다. 이제 K 에 속한 k 개의 관측치를 제거했을 때의 C_p 는

$$C_{p(K)} = \frac{SSE_{p(K)}}{s_{(K)}^2} - (n - k - 2p) \quad (5.10)$$

으로 표현할 수 있다. 이제 $C_{p(K)}$ 의 계산을 쉽게하기 위해 이를 잔차, 모자행렬, C_p 등의 값(이 값들은 n 개의 관측치로 부터 최대모형과 현재모형 하에서 계산된 값)으로 표현할 수 있다. 구체적으로 $C_{p(K)}$ 는 다음과 같이 표현할 수 있는데 이에 대한 증명은 김과 황(Kim & Hwang, 2000)을 참고하기 바란다.

$$C_{p(K)} = \frac{(n - k - q)\{C_p + (n - 2p) - e_K'(\mathbf{I} - \mathbf{H}_K^c)^{-1}e_K^c / s^2\}}{(n - q) - e_K'(\mathbf{I} - \mathbf{H}_K)^{-1}e_K / s^2} - (n - k - 2p) \quad (5.11)$$

예제 5.3 다음 자료는 26개의 자동차 영업소에서 1년 동안 판매한 자동차 판매실적을 나타낸 것으로 광고비(X_1 : 백만원), 영업장 면적(X_2 : m^2), 차량 종류(X_3), 영업사원 수(X_4), 총 판매액(Y : 억원)에 대한 것이다.

<표 5.4> 차량 판매 자료

X_1	X_2	X_3	X_4	Y	X_1	X_2	X_3	X_4	Y
5.5	31	10	8	79.3	5.0	39	10	4	107.2
2.5	55	8	6	200.1	3.5	55	10	4	155.0
8.0	67	12	9	163.2	8.0	70	6	14	291.4
3.0	50	7	16	200.1	6.0	40	11	6	100.2
3.0	38	8	15	146.0	4.0	50	11	8	135.8
2.9	71	12	17	177.7	7.5	62	9	13	223.3
8.0	30	12	8	30.9	7.0	59	9	11	195.0
9.0	56	5	10	291.9	6.7	53	13	5	73.4
4.0	42	8	4	160.0	6.1	38	13	10	47.7
6.5	73	5	16	339.4	3.6	43	9	17	140.7
5.5	60	11	7	159.6	4.2	26	8	3	93.5
5.0	44	12	12	86.3	4.5	75	8	19	259.0
6.0	50	6	6	237.5	5.6	71	4	9	331.2

이 자료를 분석하면 맬로우즈의 C_p 값을 최소로 하는 모형은 (X_1, X_2, X_3) 이며 이때의 C_p 값은 3.48임을 알 수 있다. 그러나 1개의 관측치를 제거하였을 때 C_p 의 최소값은 8번째 관측치를 제거하였을 때 나타났으며 이때의 C_p 는 1.96으로 (X_2, X_3) 를 선택하였다. 즉, 한 개의 관측치가 제거됨으로써 선택되는 변수가 (X_1, X_2, X_3) 에서 (X_2, X_3) 로 바뀌었다. 이제, 전체 관측치 26개에 근거한 모형 (X_1, X_2, X_3) 과 8번째를 제거한 25개의 관측치에 근거한 모형 (X_2, X_3) 를 비교해 보자. (X_1, X_2, X_3) 모형의 경우 $s = 9.49$, $R^2 = 0.989$, $F = 654.06$ 이고, (X_2, X_3) 모형의 경우 $s = 8.87$, $R^2 = .989$, $F = 1027.96$ 으로 나타났다. 오히려 설명변수를 한 개 더 줄임으로써 좋은 결과가 나타났음을 알 수 있다.

□

5.6 모형선택의 기타 논제

5.6.1 젠센 부등식과 칼백-라이블러 거리

[정리 5.1] ϕ 가 열린 구간(open interval) I 에서 아래로 볼록 함수(convex function)이고, 확률변수 X 가 $P(X \in I) = 1$ 와 $E(X) < \infty$ 이면

$$\phi[E(X)] \leq E[\phi(X)]$$

이 항상 성립되며 이를 젠센 부등식(Jensen's inequality)이라 부른다.

[정의 5.1] 두 확률밀도함수 f 와 g 가 주어져 있을 때 g 와 f 간의 칼백-라이블러 거리(Kullback-Leibler distance between g and f 또는 Kullback-Leibler information of g at f) 또는 f 에 대한 f 와 g 간의 엔트로피 거리(entropy distance between f and g with respect to f)는

$$E_f \left[\log \left(\frac{f(X)}{g(X)} \right) \right] = \int \log \left(\frac{f(x)}{g(x)} \right) f(x) dx$$

으로 정의된다.

로그 함수는 위로 볼록한 함수이므로 칼백-라이블러 거리에 젠센 부등식을 이용하면

$$\begin{aligned} E_f \left[\log \left(\frac{f(X)}{g(X)} \right) \right] &= -E_f \left[\log \left(\frac{g(X)}{f(X)} \right) \right] \\ &\geq -\log \left[E_f \left(\frac{g(X)}{f(X)} \right) \right] \\ &= 0 \end{aligned}$$

-log: convex

가 된다. 따라서, 칼백-라이블러 거리는 언제나 0보다 크거나 같으며 특히 $f = g$ 일 경우 0이 된다. 또한, f 와 g 가 차이가 클수록 큰 양의 값을 가진다.

$R_f^2 \quad R_{ap} \sim \sigma_p^2 \quad \textcircled{C_p}$

5.6.2 AIC와 BIC

또 다른 변수선택 또는 모형선택에 대한 측도로 AIC(Akaike Information Criterion, Akaike 1973)가 있다. 참모형(true model)을 $\theta_0 \in R^p$ 라 하고 가정된 모형(postulated

*$\approx AIC$ 라
우려.*

R_f^2 $R_{ap}^2 = s_f^2$ C_p PRESS_p

226 제 5 장 회귀모형의 선택

model)을 $\theta \in R^p$ 라 하자. 또한, $f(x) \equiv f(x : \theta_0)$ 와 $f(x : \theta)$ 를 각각 참모형과 가정된 모형하에서의 확률밀도함수라고 하자. 이제

pop version

$$K(\theta) \equiv -2E_{\theta_0}[\log f(X : \theta)] = -2 \int \log f(x : \theta) f(x) dx$$

라 정의하고 다음과 같은 값을 고려하자.

$$\frac{1}{2}K(\theta) + \int \{\log f(x)\} f(x) dx$$

참고로 이 값은 다음의 식에서 알 수 있듯이 바로 칼백-라이블러 거리(Kullback-Leibler distance)가 된다. 기호의 편의상 $g(x) \equiv f(x : \theta)$ 라 두면

*각: $\theta \approx \theta_0$
3: $\theta \neq \theta_0$*

$$\begin{aligned} \frac{1}{2}K(\theta) + \int \{\log f(x)\} f(x) dx &= - \int \log f(x : \theta) f(x) dx + \int \{\log f(x)\} f(x) dx \\ &= \int \log \left(\frac{f(x)}{g(x)} \right) f(x) dx \quad g(x) = f(x : \theta) \\ &= E_f \left[\log \left(\frac{f(x)}{g(x)} \right) \right]. \end{aligned}$$

AIC는 $K(\theta)$ 를 최소화하는 모형을 선택하는 것인데 문제는 $K(\theta)$ 에 미지의 모수 $f(x) \equiv f(x : \theta_0)$ 를 포함하고 있으므로 이에 대한 추정이 필요하다. $K(\theta)$ 에 대한 좋은 추정량은

Sample version

$$K_n(\theta) = -\frac{2}{n} \sum_{i=1}^n \log f(X_i : \theta)$$

이라 할 수 있다. $\dot{K}_n(\theta) = \partial K_n(\theta) / \partial \theta$, $\ddot{K}_n(\theta) = \partial^2 K_n(\theta) / \partial \theta \partial \theta'$ 이라 하자. 이제 $\hat{\theta}$ 를 θ 의 최우추정치라 하면 $\dot{K}_n(\hat{\theta}) = 0$ 이 되며

$$K_n(\hat{\theta}) = -\frac{2}{n} \sum_{i=1}^n \log f(X_i : \hat{\theta})$$

*← θ 의 MLE
미지 모수*

이라 하자. AIC는 $K(\theta)$ 의 추정치인 $K_n(\theta)$ 에 상수인 $2p/n$ 를 더한 식으로 정의된다. 즉,

$$AIC = \underbrace{-\frac{2}{n} \sum_{i=1}^n \log f(X_i : \hat{\theta})}_{K_n(\hat{\theta}) \rightarrow K(\hat{\theta})} + \frac{2p}{n}$$

est. of $K(\theta)$

으로 주어지며 이는 변수선택 및 모형선택의 측도로 널리 사용된다.

5.6.3 AIC의 정당성

앞에서 정의된 AIC가 $K(\theta)$ 에 대한 좋은 추정치임은 다음의 정리로 부터 알 수 있다.

[정리 5.2]

$$K_n(\hat{\theta}) = K(\hat{\theta}) + R_n + o_p(n^{-1})$$

단, 여기서 $E(R_n) = -2p/n + o(n^{-1})$ 이다.

[증명] $\dot{K}_n(\hat{\theta}) = 0$ 이라는 사실과 테일러 전개를 이용하면

$$\begin{aligned} K_n(\theta_0) &= K_n(\hat{\theta}) + (\theta_0 - \hat{\theta})' \dot{K}_n(\hat{\theta}) + \frac{1}{2}(\theta_0 - \hat{\theta})' \ddot{K}_n(\hat{\theta})(\theta_0 - \hat{\theta}) + o_p(n^{-1}) \\ &= K_n(\hat{\theta}) + \frac{1}{2}(\theta_0 - \hat{\theta})' \ddot{K}_n(\hat{\theta})(\theta_0 - \hat{\theta}) + o_p(n^{-1}) \end{aligned}$$

으로 표현할 수 있다. 또한, $\ddot{K}_n(\hat{\theta})$ 를 1차 테일러 전개하면

$$\begin{aligned} \ddot{K}_n(\hat{\theta}) &= \ddot{K}_n(\theta_0) + o_p(1) = 2I(\theta_0) + o_p(1) \\ &= -\frac{2}{n} \sum \frac{\partial^2 \log f(X_i; \theta)}{\partial \theta \partial \theta'} \sim -2E \left[\frac{\partial^2 \log f(X; \theta)}{\partial \theta \partial \theta'} \right] \\ I(\theta_0) &= -E_{\theta_0} [\partial^2 \log f(X_1; \theta) / \partial \theta \partial \theta'] \\ &= 2I''(\theta_0) \end{aligned}$$

이 되는데 여기서

는 피셔 정보량(Fisher information)이다. 따라서

$$K_n(\hat{\theta}) = K_n(\theta_0) - (\hat{\theta} - \theta_0)' I_n(\theta_0) (\hat{\theta} - \theta_0) + o_p(n^{-1})$$

또한,

$$\begin{aligned} K(\hat{\theta}) &= K(\theta_0) + (\hat{\theta} - \theta_0)' \int \left[-2 \frac{\partial}{\partial \theta} \log f(x; \theta) \right]_{\theta=\theta_0} f(x; \theta_0) dx \\ &\quad + (\hat{\theta} - \theta_0)' \left\{ \int \left[-\frac{\partial^2 \log f(x; \theta)}{\partial \theta \partial \theta'} \right]_{\theta=\theta_0} f(x; \theta_0) dx \right\} (\hat{\theta} - \theta_0) + o_p(n^{-1}) \end{aligned}$$

이다. 따라서

$$= K(\theta_0) + (\hat{\theta} - \theta_0)' I(\theta_0) (\hat{\theta} - \theta_0) + o_p(n^{-1})$$

$$K_n(\hat{\theta}) = K(\hat{\theta}) + \{K_n(\theta_0) - K(\theta_0) - 2(\hat{\theta} - \theta_0)' I_n(\theta_0) (\hat{\theta} - \theta_0)\} + o_p(n^{-1})$$

$$\equiv K(\hat{\theta}) + R_n + o_p(n^{-1})$$

인데 여기서 $R_n = K_n(\theta_0) - K(\theta_0) - 2(\hat{\theta} - \theta_0)' I_n(\theta_0) (\hat{\theta} - \theta_0)$ 이다. 이제 최우추정치의 근사적 정규성인

$$\sqrt{n}(\hat{\theta} - \theta_0) \rightarrow N_p(0, I^{-1}(\theta_0))$$

을 이용하면

$$n(\hat{\theta} - \theta_0)' I(\theta_0) (\hat{\theta} - \theta_0) \rightarrow \chi_p^2$$

$$\sqrt{n}(\hat{\theta} - \theta_0) \rightarrow N(0, \Sigma)$$

$$\hookrightarrow \sqrt{n}(\hat{\theta} - \theta_0) / \Sigma \rightarrow N(0, 1) \Rightarrow \sqrt{n}(\hat{\theta} - \theta_0)' \Sigma^{-1} \sqrt{n}(\hat{\theta} - \theta_0) \rightarrow \chi^2(p)$$

asymptotic normality of the MLE

$$[\sqrt{n}(\hat{\theta} - \theta_0)]' \text{Cov}(\hat{\theta})^{-1} [\sqrt{n}(\hat{\theta} - \theta_0)]$$

$$\rightarrow \chi^2(p)$$

이 된다. 따라서,

$$E_{\theta_0} [n(\hat{\theta} - \theta_0)' I(\theta_0)(\hat{\theta} - \theta_0)] \rightarrow p$$

이 된다. 마지막으로 약대수법칙(WLLN : weak law of large numbers)에 의해

$$K_n(\theta_0) \xrightarrow{p} K(\theta_0)$$

이 성립하므로 증명은 끝나게 된다. □

5.6.4 선형모형에서 AIC의 응용

AIC는 다양한 모형선택에 이용되는데 특히 선형모형에 응용하면 어떤 결과를 주는지 살펴 보자. 다음과 같은 선형모형

$$y = X\beta + \varepsilon, \varepsilon \sim N(0, \sigma^2 I)$$

이 주어져 있고 σ^2 은 알려져 있지 않다고 가정한다. 이제,

$$\begin{aligned} K_n(\hat{\theta}) &= -\frac{2}{n} \sum \log f(X_i : \hat{\theta}) \\ &= -\frac{2}{n} \left\{ -\frac{1}{2\sigma^2} \sum (Y_i - X_i' \hat{\beta})^2 \right\} + \text{const} \\ &= SSE_p / n\sigma^2 + \text{const} \end{aligned}$$

이다. 위에서, “const”는 모수에 의존하지 않는 상수항이란 뜻이다.

$$AIC = \frac{SSE_p}{n\sigma^2} + \frac{2p}{n} = \frac{1}{n} C_p + 1$$

으로 표현할 수 있다. 따라서, AIC는 선형모형인 경우 C_p 와 같은 결과를 주게 된다. 한편, AIC 외에도 BIC(Bayesian Information Criterion)라는 것이 있는데 이를 선형모형의 경우에 적용하면

$$BIC = \frac{SSE_p}{n\sigma^2} + \frac{p \log n}{n}$$

임이 알려져 있다. 따라서, BIC가 AIC나 C_p 보다 상대적으로 모형의 복잡성(model complexity)에 더 많은 벌칙(penalty)을 주므로 더 간단한 모형(설명변수를 작게 쓴 모형)을 선택하는 경향이 있음을 알 수 있다.

연습문제 (5)

[이론 문제]

- 5.1 현재모형이 최대모형 일 때 $C_p = p$ 임을 증명하라.
- 5.2 식 (5.11)의 $C_{p(K)}$ 를 쿡 통계량 C_K 로 표현하라.
- 5.3 $n = 20$ 이고 4개의 변수 $X_1, \dots, X_4$ 가 있을 때 최대모형하에서 Mallows C_p 값을 구하라.
- 5.4 $n = 10$ 이고 두 개의 변수가 있으며 모든 관측치의 지렛값 h_{ii} 가 동일할 때 $PRESS_p$ 의 값을 구하라. 단, $s^2 = 3$ 이다.
- 5.5 확률변수 X 가 항상 0보다 크거나 같으며 평균 μ 와 유한한 분산을 가질 때 Jensen 부등식을 이용하여 $\mu^2 < E(X^2)$ 임을 보여라.
- 5.6 [정리 5.2]의 증명과정에서 $\sqrt{n}(\hat{\theta} - \theta_0) \rightarrow N_p(0, I^{-1}(\theta_0))$ 이면

$$n(\hat{\theta} - \theta_0)'I(\theta_0)(\hat{\theta} - \theta_0) \rightarrow \chi_p^2$$

이 성립함을 보여라.

[응용 문제]

- 5.1 다음 자료는 25명의 고등학교 3학년에 대해 4과목의 학교 성적 (X_1 : 국어, X_2 : 영어, X_3 : 수학, X_4 : 과학)과 수학능력 시험 점수(Y)를 나타낸 것이다.
 - (1) X_i 와 Y 간의 산점도를 그리고 그 특징을 서술하라.
 - (2) X 들간에 상관행렬을 구하고, 다중공선성의 존재를 확인하라.
 - (3) R_{ap}^2 , s_p^2 , C_p , $PRESS_p$ 등을 이용하여 변수 선택작업을 하고, 앞으로 부터의 단계적 회귀를 실행하라.
 - (4) 선택된 모형에 대해 잔차 분석을 실시하고, 영향력 관측치를 탐색하라.

학생	X_1 (국어)	X_2 (영어)	X_3 (수학)	X_4 (과학)	Y (수능성적)
1	57.33	73.33	66.67	58.00	264
2	41.33	64.67	66.00	66.67	240
3	73.33	71.33	68.67	68.67	288
4	67.33	78.00	62.00	63.33	228
5	66.67	67.33	63.33	58.67	240
6	52.00	56.67	63.33	56.00	219
7	80.00	51.33	53.33	49.33	174
8	70.00	81.33	77.33	68.00	348
9	74.67	79.33	70.67	70.00	312
10	80.00	59.33	70.00	64.67	297
11	58.00	54.00	60.00	58.67	192
12	88.67	80.00	75.33	72.00	378
13	93.33	80.67	64.00	59.33	282
14	56.00	75.33	65.33	52.00	213
15	70.67	68.00	72.67	72.67	333
16	72.67	86.00	68.00	72.00	327
17	69.33	55.33	66.67	68.00	300
18	100.00	78.67	71.33	73.33	381
19	65.33	83.33	72.00	63.33	297
20	80.00	62.67	63.33	60.00	246
21	49.33	80.67	60.67	56.67	201
22	64.00	76.00	76.00	68.67	327
23	69.33	48.67	62.00	53.33	234
24	62.67	80.67	76.67	69.33	345
25	60.67	86.00	64.67	55.33	249

제 6 장

선형회귀모형의 변환

- 6.1 가변수를 이용한 회귀분석
- 6.2 다항회귀분석
- 6.3 가중 최소제곱법
- 6.4 박스-콕스 변환모형
- 6.5 로버스트 회귀
- 6.6 역회귀

지금까지는 오차항이 정규성, 등분산성을 갖는 이상적 형태에 대해서만 공부하였다. 이제, 이러한 가정이 만족되지 않을 경우에 대한 대안으로 여러 가지 방법을 소개한다. 설명변수가 연속이 아닌 경우, 잔차분석을 통해 정규성이나 등분산성에 대한 가정이 틀렸을 경우, 설명변수간에 심한 상관관계가 있을 경우 등이 이에 해당되며 이러한 경우에 유효하게 쓸 수 있는 여러 가지 모형들을 소개하고 그 사용법을 설명한다.

6.1 가변수를 이용한 회귀분석

지금까지 소개된 대부분의 예제들에서는 설명변수들이 양적변수로 주어졌으나 질적변수로 주어지는 경우에도 회귀분석이 적용될 수 있을 뿐만 아니라 회귀분석의 중요한 응용 분야로 자리잡고 있다. 이를 테면, 성별, 학년, 원료나 기계의 종류 등 자료가 속하는 범주(category)들을 나타내는 값을 갖는 변수들이 질적변수들의 예들인데 이들 변수에 있어서는 평균 등의 측도가 의미 없으므로 이들을 포함하는 회귀분석에서는 결과의 해석에 주의가 필요하며, 질적변수의 특성에 따른 해석이 요구된다.

6.1.1 하나의 가변수가 있는 경우

예를 들어 3장에서 사용된 광고비 예제에서 각 회사는 신문과 방송 중에서 한가지 광고매체만을 이용하였다고 하자. 이 경우 광고매체의 효과를 함께 분석하려면 광고매체를 나타내는 설명변수를 정의하여 회귀모형에 포함시키면 된다. 변수 Z 를

$$Z = \begin{cases} 1 & \text{광고 매체가 방송인 경우} \\ 0 & \text{광고 매체가 신문인 경우} \end{cases}$$


로 정의하면 변수 Z 를 포함한 다음의 회귀모형을 생각할 수 있다.

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \varepsilon \quad (6.1)$$

위에서 정의된 변수 Z 와 같이 오직 두 가지 값만을 갖는 변수를 가변수(dummy variable) 또는 지시변수(indicator variable)라 부른다. 가변수가 포함된 회귀모형에서 중요한 것은 회귀계수의 해석이다. 회귀모형 (6.1)에서 각 광고매체별로 보면 다음과 같이 정리된다.

- (1) 신문을 광고매체로 한 회사 ($Z = 0$) : $E[Y] = \beta_0 + \beta_1 X$
- (2) 방송을 광고매체로 한 회사 ($Z = 1$) : $E[Y] = (\beta_0 + \beta_2) + \beta_1 X$

그러므로 이용한 광고매체에 의하여 분류되는 두 회사는 판매액과 광고비의 관계에 대하여 기울기는 같고 절편은 다른 회귀식을 각각 갖게 되고, 평균판매액의 차이는 가변수 Z 의 회귀계수인 β_2 로 나타내어진다((그림 6.1) 참조). 만약 β_2 가 0이면 광고 매체간 차이는 없다고 할 수 있으므로 모형(6.1)의 분석에서는 가설 $H_0 : \beta_2 = 0$ 에 대한 검정의 결과가 중요한 관심의 대상이 된다.



(그림 6.1) 기울기는 같고 절편이 다른 두 회귀직선

질적변수를 위해 가변수를 사용하는 경우 가변수를 잘못 정의할 수 있는데, 이를테면 앞의 예제에서 범주 각각에 대해 가변수를

$$Z_1 = \begin{cases} 1 & \text{광고매체가 신문인 경우} \\ 0 & \text{신문이 아닌 경우} \end{cases}$$

$$Z_2 = \begin{cases} 1 & \text{광고매체가 방송인 경우} \\ 0 & \text{신문이 아닌 경우} \end{cases}$$

와 같이 정의하였다고 하자. 이 경우 회귀모형은 $Y = \beta_0 + \beta_1 X + \beta_2 Z_1 + \beta_3 Z_2 + \varepsilon$ 으로 주어지며 총 8개의 회사 중 처음 4개는 신문을, 마지막 4개는 방송을 광고매체로 사용하였다고 가정하면 디자인 행렬 X 는

$$X = \begin{matrix} & \begin{matrix} 1 & X & Z_1 & Z_2 \end{matrix} \\ \begin{bmatrix} 1 & X_1 & 1 & 0 \\ 1 & X_2 & 1 & 0 \\ 1 & X_3 & 1 & 0 \\ 1 & X_4 & 1 & 0 \\ 1 & X_5 & 0 & 1 \\ 1 & X_6 & 0 & 1 \\ 1 & X_7 & 0 & 1 \\ 1 & X_8 & 0 & 1 \end{bmatrix} \end{matrix}$$

와 같이 주어진다. 그러나 행렬 X 의 세 번째와 네 번째 열을 합하면 첫 번째 열과 같아지므로 행렬 X 의 계수(rank)는 4가 아닌 3이 되어 최대계수행렬이 되지 못한다.