

일반적으로 가변수를 사용하는 경우의 기본원칙은 나타내고자 하는 범주의 개수가 c 개 일 때는 $c - 1$ 개의 가변수를 정의하여 모형에 포함시킨다는 것이다. 예를 들어, 베품종에 따른 수확량 조사에서 네 가지 베품종 A, B, C, D가 사용되었다고 하면 이 때는 네 개의 범주가 있으므로 다음과 같이 세 개의 가변수를 정의하여 사용한다.

$$Z_1 = \begin{cases} 1 & \text{벼 품종 A인 경우} \\ 0 & \text{A가 아닌 경우} \end{cases}$$

$$Z_2 = \begin{cases} 1 & \text{벼 품종 B인 경우} \\ 0 & \text{B가 아닌 경우} \end{cases}$$

$$Z_3 = \begin{cases} 1 & \text{벼 품종 C인 경우} \\ 0 & \text{C가 아닌 경우} \end{cases}$$

벼 품종 D에 관한 관측치에는 $Z_1 = Z_2 = Z_3 = 0$ 의 값이 주어진다.

가변수의 정의에서 사용된 0과 1은 수의 의미가 없는 일종의 부호로 다른 숫자를 사용하여도 된다. 그러나 편의상 0과 1, 또는 -1과 1을 보통 사용하고 있다. 가변수가 갖는 값이 달라지면 회귀계수의 추정값도 달라지나 점정통계량 등 다른 추론 통계량들의 값은 변하지 않는다.

질적변수를 사용하는 경우 한가지 조심하여야 할 점은 위의 베품종 예제처럼 범주의 개수가 많을 때 가변수를 사용하지 않고 1, 2, 3, 4 등의 값을 갖는 하나의 설명변수를 사용하여 분석하는 경우의 해석이다. 베품종 예제에서 위와 같이 세 개의 가변수를 사용하여

$$Y = \beta_0 + \beta_1 Z_1 + \beta_2 Z_2 + \beta_3 Z_3 + \varepsilon$$

의 모형을 설정하면, 각 품종에 대하여 수확량의 기댓값은

$$A : E[Y] = \beta_0 + \beta_1$$

$$B : E[Y] = \beta_0 + \beta_2$$

$$C : E[Y] = \beta_0 + \beta_3$$

$$D : E[Y] = \beta_0$$

으로 주어지므로, 예를 들어, 베품종 A와 B의 차이는 $\beta_2 - \beta_1$, B와 C의 차이는 $\beta_3 - \beta_2$, C와 D의 차이는 $-\beta_3$ 등으로 나타난다. 이와는 달리 설명변수 X 를 A, B, C, D에 대해

여 각각 1, 2, 3, 4의 값을 갖게 하여 회귀모형 $Y = \beta_0 + \beta_1 X + \varepsilon$ 을 설정하면 수확량의 기댓값은

$$E[Y] = \beta_0 + \beta_1 X$$

로 주어지므로, 예를 들어, 벼품종 A와 B의 차이는 $2\beta_1 - \beta_1 = \beta_1$, B와 C의 차이는 $3\beta_1 - 2\beta_1 = \beta_1$, C와 D의 차이는 $4\beta_1 - 3\beta_1 = \beta_1$ 등으로 앞의 경우와 비교하면 이 경우에는 인접한 두 범주간의 차이가 모두 β_1 으로 동일하게 주어지는 것을 알 수 있다. 그러므로 설명변수 X를 사용한 모형은 범주간의 차이가 일정하다는 가정을 할 수 있는 경우에만 사용하여야 한다는 것을 알 수 있다. 가변수를 사용하는 모형은 이런 가정이 필요 없는 일반적인 경우에 대하여 설정될 수 있다는 장점이 있다.

예제 6.1 3장의 광고비 예제에 주어진 자료에서(<표 3.9> 참조) $i = 2, 4, 6, 9$ 에 해당하는 회사는 신문을 광고 매체로 하였고, 나머지 회사는 방송을 광고 매체로 하였다. 광고비의 판매액에 대한 효과는 광고 매체에 관계없이 일정하다고 가정을 하고 두 회귀식의 절편의 차이에 대하여 분석을 하라.

<풀이> 가변수 Z를 본문에서와 같이

$$Z = \begin{cases} 1 & \text{광고 매체가 방송인 경우} \\ 0 & \text{광고 매체가 신문인 경우} \end{cases}$$

으로 정의하고, 회귀모형을 다음과 같이 설정하면

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \varepsilon$$

이 모형에 대한 디자인 행렬 $\mathbf{X}$ 는

$$\mathbf{X} = \begin{bmatrix} 1 & 4 & 1 \\ 1 & 6 & 0 \\ 1 & 6 & 1 \\ 1 & 8 & 0 \\ 1 & 8 & 1 \\ 1 & 9 & 0 \\ 1 & 9 & 1 \\ 1 & 10 & 1 \\ 1 & 12 & 0 \\ 1 & 12 & 1 \end{bmatrix}$$

와 같이 작성된다. 이 행렬을 이용한 추정회귀식은 다음과 같다.

$$\hat{Y} = 26.5559 + 2.5650X + 2.6629Z$$

$$(0.4216) \quad (0.0441) \quad (0.2211)$$

(괄호 속의 값은 각 계수추정치에의 표준오차이다). 그러므로 신문을 광고 매체로 한 회사들에 대한 추정회귀식은

$$\hat{Y} = 26.5559 + 2.5650X$$

이며, 방송을 광고 매체로 한 회사들에 대한 추정회귀식은

$$\hat{Y} = (26.5559 + 2.6629) + 2.5650X = 29.2188 + 2.5650X$$

로 주어진다. 절편의 차이를 조사하기 위하여 β_2 에 대한 t -검정을 하면

$$t = \frac{2.6629}{0.2211} = 12.04 > t(\alpha) = 9.$$

로 표에서 구한 t 값보다 크므로 귀무가설 $H_0 : \beta_2 = 0$ 을 기각하게 된다. 즉, 두 회귀식에서 절편의 차이는 통계적으로 유의하다고 판단된다. $\square$

6.1.2 가변수 이용의 확장

가변수를 이용하면 다양한 형태의 회귀모형과 관련된 문제들을 해결할 수 있다. 실제로 모형 (6.1)은 기울기가 같은 두 개의 회귀직선에 대해 절편의 차이 여부를 밝히기 위한 문제에 대한 것으로 해석할 수 있다. 이 절에서는 절편과 함께 기울기 역시 다를 수 있는 두 개의 회귀직선을 비교하는 문제와, 반응변수와 설명변수가 갖는 선형관계가 설명변수의 영역에 따라 달라지는 경우의 문제에 가변수를 응용하는 방법을 설명한다.

먼저 앞의 광고비 예제에서 이용하는 광고매체에 따라 회귀식의 절편과 기울기가 모두 달라질 가능성이 있다고 가정하자. 이 문제에 대한 회귀모형은 모형 (6.1)에 양적설명변수 X 와 가변수 Z 의 교호작용항을 추가하여 주어진다. 즉,

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 XZ + \varepsilon$$


그리고 각 회사에 대한 회귀식은 다음과 같이 주어진다.

$$(1) \text{ 신문을 광고매체로 한 회사 } (Z = 0) : E[Y] = \beta_0 + \beta_1 X$$

$$(2) \text{ 방송을 광고매체로 한 회사 } (Z = 1) : E[Y] = (\beta_0 + \beta_2) + (\beta_1 + \beta_3)X$$

그러므로 β_2 와 β_3 가 0이라는 가설을 검정하면 두 범주에 대한 회귀식의 절편과 기울기가 같은지를 각각 추론할 수 있다. (그림 6.2)는 위의 두 가지 경우의 회귀식을 보여주고 있다.

두 번째 문제는 설명변수의 영역에 따라 회귀식이 달라지는 경우이다. 예를 들어, 광고비를 투자함에 따라 판매액이 일정하게 증가하다가 어느 시점에서 가속효과가 발생하여 판



(그림 6.2) 기울기와 절편이 모두 다른 두 회귀직선

매액이 급증할 수가 있다. (그림 6.3)은 이 경우의 회귀식을 보여주고 있는데 $X = 20$ 과 같이 회귀식의 형태가 변하는 점을 단락점(break point) 또는 변화점(change point)이라 한다. 실제 자료에서는 이러한 단락점이 알려져 있지 않은 경우가 대부분이며 이러한 단락점을 추정하는 문제는 이 책의 수준을 넘으므로 여기서는 단락점이 알려져 있는 경우라 가정하자. 단락점이 알려져 있는 경우 가변수 Z 를

$$Z = \begin{cases} 1 & X > 20 \\ 0 & X \leq 20 \end{cases}$$

와 같이 정의하여 다음과 같은 회귀모형을 설정하면 된다.


$$Y = \beta_0 + \beta_1 X + \beta_2 (X - 20)Z + \varepsilon$$

각 영역에서의 회귀식은 다음과 같이 주어진다.

- (1) X 의 값이 20이하인 경우 : $E[Y] = \beta_0 + \beta_1 X$
- (2) X 의 값이 20보다 큰 경우 : $E[Y] = (\beta_0 - 20\beta_2) + (\beta_1 + \beta_2)X$

그러므로 실제 $X = 20$ 을 단락점으로 볼 수 있는지에 대한 판별여부는 ' β_2 가 0이다'라는 가설에 대한 검정의 결과로 주어지게 된다.

예제 6.2 앞의 예제에서 기울기도 차이가 있을 것이라는 가정 하에 두 회귀식을 비교하라.



(그림 6.3) 영역에 따라 다른 형태를 갖는 회귀직선

<풀이> [예 6.1]에서 정의된 가변수 Z 를 사용하여 회귀모형을 다음과 같이 설정할 수 있다.

$$Y = \beta_0 + \beta_1 X + \beta_2 Z + \beta_3 XZ + \varepsilon$$

이 모형에 대한 디자인 행렬 X 는

$$X = \begin{bmatrix} 1 & 4 & 1 & 4 \\ 1 & 6 & 0 & 0 \\ 1 & 6 & 1 & 6 \\ 1 & 8 & 0 & 0 \\ 1 & 8 & 1 & 8 \\ 1 & 9 & 0 & 0 \\ 1 & 9 & 1 & 9 \\ 1 & 10 & 10 & 1 \\ 1 & 12 & 0 & 0 \\ 1 & 12 & 1 & 12 \end{bmatrix}$$

와 같이 주어지며, 이 행렬을 이용한 추정회귀식은 다음과 같다.

$$\hat{Y} = 27.0667 + 2.5067X + 1.9333Z + 0.0852XZ$$

(0.7197) (0.0798) (0.8563) (0.0965)

(괄호 속의 값은 각 계수추정치의 표준오차이다). 그러므로 신문을 광고매체로 한 회사들에 대한 추정회귀식은

$$\hat{Y} = 27.0667 + 2.5067X$$

이며, 방송을 광고매체로 한 회사들에 대한 추정회귀식은

$$\hat{Y} = (27.0667 + 1.9333) + (2.5067 + 0.0852)X = 29.000 + 2.5919X$$

로 주어진다. 절편의 차이를 조사하기 위한 β_2 에 대한 t -검정통계량의 값은

$$t = \frac{1.9333}{0.8563} = 2.258$$

$$< t_{\alpha}(6)$$

로 표에서 구한 t 값 $t_{0.025}(6) = 2.447$ 보다 약간 작다. 그리고 기울기의 차이를 조사하기 위하여 β_3 에 대해 t -검

정통계량의 값을 구하면

$$t = \frac{0.0852}{0.0965} = 0.8830$$

$$< \frac{t}{\alpha}$$

으로 가설 $H_0 : \beta_3 = 0$ 를 기각하지 못한다. 즉, 두 회귀식에서 기울기의 차이는 없다고 해석할 수 있다. $\square$

위의 예제에서 절편에 대한 검정의 결과가 [예 6.1]의 결과와 일치하지 않는 이유는 현 예제의 회귀모형이 필요이상으로 설명변수를 많이 포함하기 때문이다. 이와 같이 참모형보다 설명변수를 많이 포함시키는 것을 과대적합(overfitting)하였다고 하며, 이 경우에는 추정치의 분산이 커지는 효과를 가져온다. 위의 절편에 대한 t -검정통계량의 값이 기각역보다 약간 작게 나온 것은 이러한 이유 때문이다. 또한, 위의 예제는 회귀계수에 대한 검정의 결과가 유의하지 않게 나왔을 때 유의할 점을 알려주고 있다. 두 개 이상의 회귀계수가 유의하지 않더라도 이들을 회귀모형에서 동시에 제거하여서는 안되며, 제일 유의성이 작은 것부터 하나씩 제거해 나가면서 단계적인 분석을 하여야 한다. 위의 모형에서 유의성이 제일 작은 교호작용항을 제거하면 [예 6.1]의 모형이 되어 이제는 모든 회귀계수의 추정치가 유의하게 됨을 볼 수 있다. *Stepwise*

6.1.3 회귀모형을 이용한 분산분석

분산분석(analysis of variance)은 두 개 이상의 모집단의 평균들을 비교하고자 할 때 사용하는 통계적 방법이다. 이 분석의 일차적인 목적은 모든 모집단에서의 평균들이 같다는 가설에 대한 검정으로, 관측치들이 갖는 총변동을 집단내 변동(within variation)과 집단간 변동(between variation)으로 분할하여 서로 상대적인 크기를 비교하여 판단하게 된다. 분산분석에서도 모든 모집단들의 분산은 일정하다고 가정을 하는데, 만일 모집단들의 평균들까지 같다면 집단의 차이가 적어 집단간 변동은 집단내 변동보다 크지 않게 된다. 그러므로, 역으로 각 변동을 추정하여 집단간 변동이 집단내 변동보다 상대적으로 훨씬 크게 되면 우리는 평균들이 같지 않다는 결론을 내릴 수 있다.

집단(앞 절에서의 범주에 해당)을 나타내는 변수가 한 개인 경우의 분산분석을 일원분산분석(one-way analysis of variance)이라 한다. 만일 모집단의 개수가 c 개이고 각 모집단의 크기 n_i 의 표본을 추출한다 가정하면, 이에 대한 통계모형은 다음과 같이 주어진다.

$$Y_{ij} = \mu + \alpha_i + \varepsilon_{ij}, \quad i = 1, 2, \dots, c; \quad j = 1, 2, \dots, n_i \quad (6.2)$$

$$\mu_i = \mu + \alpha_i$$

위에서 Y_{ij} 는 i 번째 집단의 j 번째 관측값, μ 는 Y 의 전체 모평균을 나타내고, 그리고 α_i 는 i 번째 집단이 다른 집단에 비해 상대적으로 얼마나 더 큰지를 나타내기 위한 모수이다. 따라서, i 번째 집단의 모평균은 $\mu + \alpha_i$ 로 주어지며 흔히 이를 μ_i 로 표현하기도 한다. 오차항 ε_{ij} 에 대한 가정은 회귀분석에서의 가정과 동일하다.

모형 (6.2)는 일종의 회귀모형으로 해석할 수 있는데 이를테면, 모집단의 개수가 $c = 4$ 이고, 각 모집단에서 크기 $n_i = 3$ 의 표본을 추출한다 가정하면 회귀계수벡터와 디자인 행렬을

$$\beta = (\mu, \alpha_1, \alpha_2, \alpha_3, \alpha_4)'$$

$$X = \begin{bmatrix} 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 \end{bmatrix} \rightarrow \text{singular} \\ r(X) = 4$$

와 같이 정의할 수 있다. 그러나 이 경우에도 디자인 행렬의 열들은 선형종속이 되어(마지막 네 개의 열을 합하면 첫 번째 열이 된다) 행렬 X 는 최대계수행렬이 되지 못한다. 실제로 행렬 X 를 가지고 정규방정식을 작성하면 미지수는 5개가 있고 독립적인 식은 4개가 있는 추정불능(non-estimable)의 형태가 됨을 알 수 있다. 이에 대한 해결방법은 네 개의 범주(집단)가 있으므로 세 개의 가변수를 다음과 같이 정의하여

$$Z_1 = \begin{cases} 1 & \text{집단 1에 속하는 경우} \\ 0 & \text{아닌 경우} \end{cases}$$

$$Z_2 = \begin{cases} 1 & \text{집단 2에 속하는 경우} \\ 0 & \text{아닌 경우} \end{cases}$$

$$Z_3 = \begin{cases} 1 & \text{집단 3에 속하는 경우} \\ 0 & \text{아닌 경우} \end{cases}$$

모든 설명변수들이 가변수로 주어지는 회귀모형을

$$Y_i = \beta_0 + \beta_1 Z_{i1} + \beta_2 Z_{i2} + \beta_3 Z_{i3} + \varepsilon_i, \quad i = 1, 2, \dots, 12 \quad (6.3)$$

$$(n_i = 3, \quad c = 4)$$

와 같이 설정하는 것이다(첨자 i 는 이제 임의의 관측치를 나타낸다). 이 경우 각 모집단 평균은 $\beta_0 + \beta_1, \beta_0 + \beta_2, \beta_0 + \beta_3, \beta_0$ 로 주어지고, 추정량 $\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2, \hat{\beta}_3$ 을 대입하면 각 집단의 평균추정값을 얻게 된다.

분산분석에서 각 모집단의 평균들이 같다는 가설은 $H_0 : \alpha_1 = \alpha_2 = \alpha_3 = \alpha_4 = 0$ 로 주어지며, 총변동, 집단내 변동, 집단간 변동 등을 나타내는 제곱합을 계산하여 정리한 분산분석표에서 평균제곱들을 정의하여 F -검정을 하게 되는데, 이 과정은 회귀모형 (6.3)에서 가설 $H_0 : \beta_1 = \beta_2 = \beta_3 = 0$ 에 대한 검정을 회귀분석에서의 분산분석표를 이용하여 F -검정을 하는 것과 동일하다. 실제 회귀제곱합은 집단간 변동을, 오차제곱합은 집단내 변동을 나타내는 제곱합과 같다.

예제 6.3 어느 4년제 대학교에서 학년 별 영어 실력을 비교하기 위하여 각 학년에서 6명씩을 무작위로 추출하여 같은 영어 시험을 보게 한 결과 <표 6.1>의 자료를 얻었다(단, 3학년에서 1명, 4학년에서 2명의 결시자가 있었다고 가정한다). 이 자료에 대하여 회귀모형 (6.3)을 적합하고 F -검정을 하라.

학년이 아니라 영어실력이 평행성을 띠지 않아

<표 6.1> 학년별 영어 성적

학년	영어 점수	평균
1	81 75 69 90 72 83	78.3
2	65 80 73 79 81 69	74.5
3	72 67 62 76 80	71.4
4	89 94 79 88	87.5

<풀이> 이 예제에서도 범주의 개수는 네 개이므로 세 개의 가변수를 위에서와 같이 정의하여 사용할 수 있다. 반응변수의 관측치벡터와 디자인 행렬 X 는 다음과 같이 주어진다.

$$Y = \begin{bmatrix} 81 \\ 75 \\ 69 \\ 90 \\ 72 \\ 83 \\ 65 \\ 80 \\ 73 \\ 79 \\ 81 \\ 69 \\ 72 \\ 67 \\ 62 \\ 76 \\ 80 \\ 89 \\ 94 \\ 79 \\ 88 \end{bmatrix}, \quad X = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 \end{bmatrix}$$

↓ singular

적합된 회귀식은 아래와 같으며, 분산분석표는 <표 6.2>에 주어져 있다.

$$\hat{Y} = 87.50 - 9.17X_1 - 13.00X_2 - 16.10X_3$$

(3.513) (4.535) (4.535) (4.713)

(괄호 속의 값은 각 계수추정치의 표준오차이다). 분산분석표에서 계산된 F 비는 4.35로 MSR의 값이 MSE의 값보다 4배 이상 크다는 것을 보여준다. 또한, 이 값은 F 분포표에서 구한 값 $F_{0.05}(3, 17) = 3.20$ 보다 크다. 그러므로 우리는 유의수준 0.05하에서 귀무가설 $H : \beta_1 = \beta_2 = \beta_3 = 0$ 을 기각할 수 있다. 다시 말해서, 이 대학교의 학년간에는 영어 실력의 차이가 있다고 말할 수 있다.

위의 추정회귀계수를 이용하여 각 학년의 평균영어성적을 추정할 수 있다.

1학년의 평균영어성적 추정치는 $\hat{\beta}_0 + \hat{\beta}_1 = 87.50 - 9.17 = 78.33$

2학년의 평균영어성적 추정치는 $\hat{\beta}_0 + \hat{\beta}_2 = 87.50 - 13.00 = 74.50$

3학년의 평균영어성적 추정치는 $\hat{\beta}_0 + \hat{\beta}_3 = 87.50 - 16.10 = 71.4$

4학년의 평균영어성적 추정치는 $\hat{\beta}_0 = 87.50$

즉, 각 학년의 평균영어성적 추정치는 각 학년 표본들의 표본평균과 같다. □

<표 6.2> 영어성적 자료의 분산분석표

요인	제곱합	자유도	평균제곱	F
회귀	643.6	3	214.5	4.35
오차	839.0	17	49.4	
전체	1482.7	20		

분산분석모형 (6.2)에서 $c = 4$ 인 경우 모수는 5개($\mu, \alpha_1, \alpha_2, \alpha_3, \alpha_4$) 있지만 행렬 X 의 계수는 4이므로 실제 이들 5개의 모수를 개별적으로 추정할 수는 없고, 단지 각 평균값 $\mu + \alpha_i$ ($i = 1, 2, 3, 4$)만을 추정할 수 있다. 이에 반해 회귀모형 (6.3)에서는 회귀계수 $\beta_0, \beta_1, \beta_2, \beta_3$ 가 개별적으로 추정되며 각 모집단의 평균은 $\beta_0 + \beta_1, \beta_0 + \beta_2, \beta_0 + \beta_3, \beta_0$ 로 주어졌다. 이 두 모형의 비교에서 회귀모형 (6.3)은 분산분석모형 (6.2)에서 $\alpha_4 = 0$ 으로 가정하여 유도된 것이라 볼 수 있다. 가변수의 정의에 따라 $\alpha_1 = 0$ 이라는 가정하에도 유도할 수 있고 $\sum \alpha_i = 0$ 이라는 가정하에서도 구할 수 있다. 다만 각 가정하에서 구한 추정치를 해석할 때 주의를 요한다. 이에 대한 논의는 9장에서 자세히 다루게 된다.

이와 같이 디자인 행렬 X 가 최대계수가 아닌 경우 적당한 개수의 모수에 임의의 값을 주어 모수들이 개별적으로 추정될 수 있는 모형으로 변환하는 것을 모수의 축소화(parameter reduction)라 한다. 이 모수의 축소화를 이용하면 범주를 나타내는 변수가 2개인 이원분산분석을 포함한 훨씬 복잡한 분산분석모형도 회귀모형으로 변환하여 분석할 수 있다.

6.2 다항회귀분석

회귀모형에서 회귀식이 설명변수들의 다항식으로 표시되는 경우 이를 다항회귀모형 (polynomial regression model)이라 한다. 예를 들어, 단순회귀모형은 설명변수가 하나 있는 일차(first-order) 다항회귀모형으로 볼 수 있고, 다음은 이차(second-order) 다항회귀모형의 예들이다.

설명변수가 1개 : $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \varepsilon$

설명변수가 2개 : $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_{11} X_1^2 + \beta_{22} X_2^2 + \beta_{12} X_1 X_2 + \varepsilon$

설명변수가 k 개 : $Y = \beta_0 + \sum_{i=1}^k \beta_i X_i + \sum \beta_{ii} X_i^2 + \sum_{i < j}^k \beta_{ij} X_i X_j + \varepsilon$

← interaction term

다항회귀모형은 보통 반응변수와 설명변수들 간의 함수관계가 명확하게 알려져 있지 않을 때 근사적인 관계식을 나타내기 위하여 사용된다. 이 모형도 다양한 응용분야에서 이용되고 있으나 이 책에서는 그 중에서 제일 기본적이고 중요하게 사용되는, 회귀식이 하나의 설명변수의 k 차 다항회귀식으로 주어지는 경우와 회귀식이 설명변수들의 이차다항식으로 주어지는 경우의 두 가지에 대한 이론과 응용을 설명한다.

6.2.1 k 차 다항회귀모형

$X =$

설명변수가 하나인 k 차 다항회귀모형은 다음과 같이 주어진다.

$$Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \cdots + \beta_k X^k + \varepsilon \quad (6.4)$$

수학에서의 중요한 정리 중의 하나는 두 변수간의 모든 함수관계는 다항식으로 표현이 가능하다는 것이다. 그러므로, 반응변수와 설명변수간의 관계는 적당한 차수 k 를 찾으면 위의 모형에 의하여 근사적으로 나타낼 수 있다.

모형 (6.4)에서 X 의 각 거듭제곱항을 하나의 새로운 설명변수로 해석을 하면 3장에서 설명된 중회귀모형과 동일하게 된다. 그러므로 다항회귀분석에서는 중회귀모형에 대한 분석방법을 그대로 적용하여 사용할 수 있다. 다만 모형식의 특성상 두 가지 중요한 문제가 발생하게 된다. 첫 번째는 각 항이 X 의 거듭제곱으로 주어지는 까닭으로 설명변수들 간의 상관관계가 높아지므로 다중공선성의 문제가 발생할 수 있어 최소제곱추정치를 구하는 특별한 알고리즘이 필요하게 되며, 두 번째는 적당한 차수 k 의 선택문제이다. 3장에서 언급된 간결함의 원칙에 따라 두 변수간의 관계를 충분히 설명하면서도 차수가 낮은 모형을 선택하여야 한다.

먼저 추정문제를 살펴보자. 중회귀모형에서의 최소제곱추정공식을 그대로 적용하는 경우에는 설명변수들 간의 상관관계를 작게 하기 위하여 평균에 대한 수정을 하여 사용할 수 있다. 즉, 설명변수 X 의 관측값들의 표본평균을 $\bar{X}$, 최소값과 최대값을 각각 X_{min} , X_{max} 라 나타내면 각 관측값에 대해 $X_i - \bar{X}$ 또는

$$\frac{X_i - \frac{X_{min} + X_{max}}{2}}{\frac{X_{max} - X_{min}}{2}} \approx E(X) \quad (6.5)$$

와 같은 변수변환을 하여 새로운 설명변수로 사용하면 상관관계의 정도는 일반적으로 작아진다. 그러나 여전히 다중공선성의 문제가 있을 수 있으므로 통계패키지 등에서는 정확한 계산을 위해서 직교다항식(orthogonal polynomial)을 이용한 알고리즘을 이용한다. 설명변수 X 의 r 차 직교다항식을 $\phi_r(X)$ 라 나타내면 식 (6.4)의 다항회귀모형은 다음과 같이 변환될 수 있다.

$$Y_i = \alpha_0 \phi_0(X_i) + \alpha_1 \phi_1(X_i) + \cdots + \alpha_k \phi_k(X_i) + \varepsilon_i \quad (6.6)$$

즉, 설명변수 X 의 각 거듭제곱을 직교다항식 $\phi_r(X)$ 로 변환하여 이들을 새로운 설명변수로 하는 회귀모형을 생각하는 것이다. 직교다항식 $\phi_r(X)$ 들은 서로 직교하므로 상관관계가 전혀 없게 되어 다중공선성의 문제가 발생하지 않는다. 그러므로 모형(6.6)을 이용하여 계수 α_i 들의 추정치를 구한 다음 β_i 들과의 관계식을 이용하여 β_i 의 추정치를 구할 수 있다. 참고로 α_i 들의 최소제곱추정량은

$$\hat{\alpha}_r = \frac{\sum_{i=1}^n \phi_r(X_i) Y_i}{\sum_{i=1}^n \phi_r^2(X_i)}, \quad r = 0, 1, \dots, k$$

와 같이 주어진다. 직교다항식을 유도하는 방법, α_i 와 β_i 들과의 관계식, 그리고 그 외 통계량들을 계산하는 공식은 이 책의 수준을 넘으므로 케네디와 젠틀(Kennedy and Gentle, 1980)을 참조하기 바란다.

다항회귀분석에서 적당한 차수 k 를 선택하는 문제는 여러 가지 방법이 있으나 일반적인 방법은 다항회귀모형의 차수를 하나씩 높여가면서 매 단계에서 가장 높은 차수의 회귀계수에 대하여 t -검정 또는 부분 F -검정을 실시하는 것이다. 이 과정을 간단히 요약하면 다음과 같다. 먼저 1차모형 $Y = \beta_0 + \beta_1 X + \varepsilon$ 을 적합 시킨 다음 가설 $H_0 : \beta_1 = 0$ 에 대

한 검정을 한다. 귀무가설 H_0 를 기각할 수 없으면 분석을 끝내고, 아니면 2차모형 $Y = \beta_0 + \beta_1 X + \beta_2 X^2 + \varepsilon$ 을 적합 시킨다. 그리고 가설 $H_0 : \beta_2 = 0$ 에 대한 검정을 하여 귀무가설을 기각할 수 없으면 분석을 끝내고, 아니면 3차이상의 모형을 적합 시키는 과정을 계속하면 된다. 물론 이를테면 이차항은 유의하지 않고 삼차항은 유의한 모형이 있을 수 있으나 위의 방법은 이와 같은 모형을 배제하고 있다.

예제 6.4 어느 효소에 대한 연구에서 농도에 따른 반응속도를 조사하였다. <표 6.3>은 12개의 관측자료를 보여주며, (그림 6.4)는 이들의 산점도를 보여주고 있다. 이 자료에 대해 적당한 차수의 다항회귀모형을 적합시켜라.

<표 6.3> 농도별 반응속도


농도	0.02	0.02	0.06	0.06	0.11	0.11	0.22	0.22	0.56	0.56	1.10	1.10
반응속도	76	47	97	107	123	139	159	152	191	201	207	200

<풀이> 농도를 설명변수, 반응속도를 반응변수로 하여 일차모형부터 적합 시켜 나가면 3차 다항식까지는 모든 회귀계수의 추정치가 유의하게 나온다. 그러나 4차 다항식의 적합에서는 4차항의 계수추정치가 유의하지 않으므로 우리는 3차 다항식을 최종모형으로 선택한다. 적합된 3차 다항식은 다음과 같으며

$$\hat{Y} = 56.3 + 716.8X - 1159.3X^2 + 572.1X^3$$

(9.0) (118.1) (294.1) (178.9)

(괄호 속의 값은 각 계수추정치의 표준오차이다.) (그림 6.4)의 산점도에 나타내어 졌다. 이 모형에서 계산된 결정계수의 값은 95.9%로 설명력이 높다고 할 수 있다. □



(그림 6.4) 농도별 반응속도자료의 산점도와 적합된 회귀직선

6.2.2 반응표면분석

생산공정 등에서 많이 사용되고 있는 회귀분석의 응용 중에 반응표면분석(response surface analysis)이 있다. 이 방법에서는 분석에 포함된 여러 개의 설명변수가 변함에 따른 반응변수의 변화가 만드는 반응표면에 대한 통계적 추정과 검정을 실시하게 되며, 보통 반응변수와 설명변수들 간의 관계를 일차 또는 이차다항회귀모형으로 적합 한다. 그리고 일반 회귀분석에서와는 달리 추정량의 유의성 등에 대한 분석보다는 반응표면의 형태에 대한 분석과 반응변수의 최적조건을 찾는 것이 주요 목적이다.

먼저 간단한 모형 몇 가지를 살펴보자. 설명변수가 1개인 이차모형을 적합하여 다음과 같은 추정식을 얻었다 하자.

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X + \hat{\beta}_2 X^2$$

위 식은 X 의 이차식이므로 Y 의 최적조건은 이 식을 X 에 대해 미분하여 구해진다. 즉,

$$\frac{d\hat{Y}}{dX} = \hat{\beta}_1 + 2\hat{\beta}_2 X = 0$$

에서 극점

$$X_m = -\frac{\hat{\beta}_1}{2\hat{\beta}_2}$$

을 얻을 수 있으며, 이 점에서 $\hat{Y}$ 의 최대(최소)값

$$\hat{Y}_m = \hat{\beta}_0 - \frac{\hat{\beta}_1^2}{4\hat{\beta}_2}$$

이 주어짐을 알 수 있다. 그리고 이차도함수가

$$\frac{d^2\hat{Y}}{dX^2} = 2\hat{\beta}_2$$

이므로, $\hat{\beta}_2$ 가 양수이면 $\hat{Y}_m$ 은 최소값이 되고, 음수이면 $\hat{Y}_m$ 은 최대값이 된다.

예를 들어 설명변수가 2개인 일차모형을 적합하여 다음과 같은 추정식을 얻었다 하자.

$$\hat{Y} = \hat{\beta}_0 + \hat{\beta}_1 X_1 + \hat{\beta}_2 X_2$$

위의 식은 X_1 과 X_2 의 일차함수이므로 Y 의 최적점은 구할 수 없고 단지 증가 또는 감소하는 방향만을 구할 수 있다. 위의 식에서 $\hat{Y}$ 의 값을 고정시키면 X_1 과 X_2 는 다음과 같은 직선의 식을 형성하는데

$$X_2 = -\frac{\hat{\beta}_1}{\hat{\beta}_2}X_1 + c$$

(c 는 상수) 이 직선의 기울기와 다른 방향으로 X_1 과 X_2 의 값을 움직이면 $\hat{Y}$ 의 값은 증가 또는 감소하게 된다. 이 중에서 위 직선의 기울기와 직각이 되는 방향을 최대상승(하강)(steepest ascent(descent))방향이라 하며 이 방향의 기울기는 $\hat{\beta}_2 / \hat{\beta}_1$ 로 주어진다.

일반적으로 반응표면분석에서 많이 사용되는 모형은 설명변수가 k 개 있는 다음과 같은 이차모형이다.

$$Y = \beta_0 + \sum_{i=1}^k \beta_i X_i + \sum_{i=1}^k \beta_{ii} X_i^2 + \sum_{i < j}^k \beta_{ij} X_i X_j + \varepsilon \quad (6.7)$$

그리고 행렬을 이용하면 위의 모형은

$$Y = \beta_0 + \mathbf{x}\boldsymbol{\beta} + \mathbf{x}'\mathbf{B}\mathbf{x} + \varepsilon$$

와 같이 나타낼 수 있다. 위의 식에서 $\mathbf{x} = (X_1, X_2, \dots, X_k)'$, $\boldsymbol{\beta} = (\beta_1, \beta_2, \dots, \beta_k)'$ 이며 $k \times k$ 행렬 $\mathbf{B}$ 는 다음과 같이 정의된다.

$$\mathbf{B} = \begin{bmatrix} \beta_{11} & \frac{\beta_{12}}{2} & \dots & \frac{\beta_{1k}}{2} \\ \frac{\beta_{12}}{2} & \beta_{22} & \dots & \frac{\beta_{2k}}{2} \\ \vdots & \vdots & & \vdots \\ \frac{\beta_{1k}}{2} & \frac{\beta_{2k}}{2} & \dots & \beta_{kk} \end{bmatrix}$$

모형 (6.7)은 이차모형이므로 설명변수들 간의 상관관계가 그렇게 크지가 않아 각 설명변수를 식 (6.5)와 같이 변환한 후 중회귀모형을 위한 계산공식을 사용하여 최소제곱추정량을 구한다. 이와 같이 적합된 회귀식을

$$\hat{Y} = \hat{\beta}_0 + \mathbf{x}'\hat{\boldsymbol{\beta}} + \mathbf{x}'\hat{\mathbf{B}}\mathbf{x} \quad (6.8)$$

이라 하자($\hat{\mathbf{B}}$ 은 행렬 $\mathbf{B}$ 의 각 원소를 추정량으로 대체한 행렬이다). 반응변수 Y 의 최적값

은 역시 식 (6.8)을 설명변수에 대하여 미분하여 구해진다. 즉,

$$\frac{\partial \hat{Y}}{\partial \mathbf{x}} = \hat{\beta} + 2\hat{B}\mathbf{x} = 0$$

에서 극점

$$\mathbf{x}_s = -\frac{1}{2}\hat{B}^{-1}\hat{\beta} \quad (6.9)$$

를 얻을 수 있는데 이 점을 정상점(stationary point)이라 한다. 반응변수 Y 는 이 점에서 최대값 또는 최소값을 가질 수 있다. 그리고 이 정상점 주위에서 반응변수가 생성하는 반응표면의 형태에 대한 분석을 정준분석(canonical analysis)이라 하며 행렬 $\hat{B}$ 에 대한 고유치분석(eigenvalue analysis)과 반응표면의 등고선그림(contour plot)을 이용한다.

반응변수 Y 가 정상점에서 갖는 값은

$$\hat{Y}_s = \hat{\beta}_0 + \mathbf{x}'_s \hat{\beta} + \mathbf{x}'_s \hat{B} \mathbf{x}_s$$

로 주어지며 정준분석을 하기 위하여 설명변수들의 원점을 정상점 $\mathbf{x}_s$ 로 옮기는 변환을 한다. 즉, 새로운 벡터 $\mathbf{w}$ 를

$$\mathbf{w} = \mathbf{x} - \mathbf{x}_s$$

라 정의하여 식 (6.8)에 대입하면

$$\begin{aligned} \hat{Y} &= \hat{\beta}_0 + (\mathbf{x}_s + \mathbf{w})' \hat{\beta} + (\mathbf{x}_s + \mathbf{w})' \hat{B} (\mathbf{x}_s + \mathbf{w}) \\ &= \hat{\beta}_0 + \mathbf{x}'_s \hat{\beta} + \mathbf{x}'_s \hat{B} \mathbf{x}_s + \mathbf{w}' \hat{\beta} + 2\mathbf{w}' \hat{B} \mathbf{x}_s + \mathbf{w}' \hat{B} \mathbf{w} \\ &= \hat{Y}_s + \mathbf{w}' \hat{B} \mathbf{w} + \mathbf{w}' (\hat{\beta} + 2\hat{B} \mathbf{x}_s) \\ &= \hat{Y}_s + \mathbf{w}' \hat{B} \mathbf{w} \end{aligned}$$


$$\hat{Y} = \hat{Y}_s + \mathbf{w}' \hat{B} \mathbf{w}$$

의 식을 얻는다(마지막 등식은 식 (6.9)에 의하여 $\hat{\beta} + 2\hat{B}\mathbf{x}_s = 0$ 이므로 성립한다). 그러므로 이 식에서 행렬 $\hat{B}$ 가 양정치이면 정상점에서의 값 $\hat{Y}_s$ 은 최소값이 되고, 음정치이면 $\hat{Y}_s$ 은 최대값이 됨을 알 수 있다. 행렬의 양정치 여부를 판별하는 간단한 방법은 행렬의 고유치를 구해보는 것으로 고유치가 모두 양수이면 양정치이고, 모두 음수이면 음정치가 된다. 그러므로 $\lambda_1, \lambda_2, \dots, \lambda_k$ 를 행렬 $\hat{B}$ 의 고유치라 하면 다음과 같이 판별할 수 있다.

$$\hat{B} \text{ p.d.} > 0 \\ \hat{B} \text{ n.d.} < 0$$

- (1) 모든 λ_j 가 양수이면 정상점 x_s 는 최소점으로 $\hat{Y}$ 은 최소값 $\hat{Y}_s$ 를 갖는다.
- (2) 모든 λ_j 가 음수이면 정상점 x_s 는 최대점으로 $\hat{Y}$ 은 최대값 $\hat{Y}_s$ 를 갖는다.
- (3) λ_j 가 일부는 양수이고 일부는 음수이면 $\hat{Y}$ 은 x_s 에서 벗어나는 방향에 따라 증가 또는 감소를 하게 되는데 이때 x_s 를 안부점(saddle point)이라 한다.

반응표면의 형태는 등고선그림을 이용하면 더욱 확실하게 알 수 있다. 등고선그림은 반응표면에서 $\hat{Y}$ 의 값이 같은 점들을 연결하여 선으로 나타낸 것으로 $\hat{Y}$ 이 증가 또는 감소하는 방향과 속도를 쉽게 파악할 수 있게 하여준다. (그림 6.5)는 등고선그림으로 나타낸 반응표면의 여러 가지 형태를 보여주고 있다.



(그림 6.5) 여러 가지 형태의 반응표면

예제 6.5 <표 6.4>의 자료는 어느 화학공정에서 공정시간과 공정온도에 따른 효율을 조사한 것이다. 이 자료에 대해 이차모형을 이용한 반응표면분석을 실시하라.

<표 6.4> 공정시간과 공정온도별 효율

시간(X_1)	온도(X_2)	효율(Y)
4.0	250	83.8
20.0	250	81.7
12.0	250	82.4
12.0	250	82.9
12.0	220	84.7
12.0	280	67.9
12.0	250	81.2
6.3	229	81.3
6.3	271	83.1
17.7	229	85.3
17.7	271	72.7

<풀이> 위의 자료에 대한 식 (6.7)의 모형을 적합 시키면 다음과 같다.

$$\hat{Y} = -324.86 + 6.9010X_1 + 3.1399X_2 + 0.0171X_1^2 - 0.005968X_2^2 - 0.0301X_1X_2$$

반응분석에서는 반응표면의 형태에 대한 분석이 주목적이므로 각 추정치의 유의성에 대한 검정은 별로 중요하지 않다. 정준분석을 위한 벡터 $\hat{\beta}$ 와 행렬 $\hat{B}$ 는 다음과 같이 주어진다.

$$\hat{\beta} = \begin{bmatrix} 6.9010 \\ 3.1399 \end{bmatrix}, \quad \hat{B} = \begin{bmatrix} 0.0171 & -0.01505 \\ -0.01505 & -0.005968 \end{bmatrix}$$

그러므로 정상점은 식 (6.9)에 의하여


$$\begin{aligned} \mathbf{x}_s &= -\frac{1}{2}\hat{B}^{-1}\hat{\beta} \\ &= \begin{bmatrix} 9.18201 \\ 239.922 \end{bmatrix} \end{aligned}$$

와 같이 계산되며 이 점에서의 반응변수의 적합치는 $\hat{Y}_s = 83.4926$ 이다.

반응표면의 형태를 알아보기 위하여 행렬 $\hat{B}$ 의 고유치를 계산하여 보면

$$\lambda_1 = 2.70858, \quad \lambda_2 = -6.98338$$

로 주어지므로, 정상점은 일종의 안부점으로 정상점에서 공정시간 X_1 을 변화시키면 효율은 증가하고, 반대로 공정온도 X_2 를 변화시키면 효율은 감소한다는 것을 알 수 있다. (그림 6.6)은 정상점 근처에서의 반응표면을 보여주는 등고선그림으로 위의 사실을 뒷받침하여 주고 있다. $\square$



(그림 6.6) 공정시간과 공정온도별 효율의 반응표면

6.3 가중 최소제곱법

회귀분석에서 가장 중요한 가정들 중의 하나는 오차항의 분산이 σ^2 으로 항상 일정하다는 것이었다. 즉,

$$\text{Cov}(\epsilon) = I\sigma^2 = \text{Cov}(Y)$$

이었으며, 이를 등분산(homoscedasticity) 가정이라 하였다. 이러한 가정의 타당성은 잔차 분석을 통해 알 수 있다. 그런데 잔차분석의 결과에서 등분산 가정이 틀렸다고 하면 더 이상 $\text{Cov}(\epsilon) = I\sigma^2$ 의 가정하에 최소제곱법을 사용할 수 없다. 이 경우 타당한 것은 어떤 대각행렬 $W = \text{diag}(w_1, \dots, w_n)$ 에 대해

$$\text{Cov}(\epsilon) = \sigma^2 W^{-1}$$

이 성립한다고 가정하는 것이다. 여기서 W 를 대각행렬로 가정하는 것은 오차항이 서로 독립이라는 가정이 성립할 경우에 한한다. 이 경우 대각행렬 W 의 역행렬 W^{-1} 는 역시 대각행렬이며, 각 대각원소는 W 의 대각원소들의 역수로 주어지므로 오차항 ϵ_i 의 분산은

$$\text{Var}(\epsilon_i) = \sigma^2 / w_i$$

*in dependence
between Y_i 's*



으로 일정하지 않다는 것이다. 이러한 경우를 이분산성(heteroscedasticity)라 부른다. 전개의 편의상 W 라는 대각 행렬이 알려져 있다고 하자. (실제 자료에서는 W 가 알려져 있지 않으므로 이에 대한 추정이 필요하며 여러 가지 추정법중의 한 방법이 예제 6.6에 주어져 있다). 이 때

$$P^2 = W$$

가 되는 유일한 비정칙행렬 P 가 존재함을 보일 수 있으며 (예를 들어, $\sqrt{w_i}$ 를 대각원소로 하는 대각행렬) 이 행렬을 이용한 오차벡터 ϵ 의 선형변환인

$$\delta = P\epsilon$$

는 $E(\delta) = 0$ 이고

$$Cov(\delta) = E(\delta\delta') = E(P\epsilon\epsilon'P) = PW^{-1}P\sigma^2 = I\sigma^2$$

이므로 δ 의 각 원소들은 같은 분산 σ^2 을 가지게 된다.

따라서 $y = X\beta + \epsilon$ 의 각 항에 대칭행렬 P 를 곱한 모형을 생각하면

$$Py = PX\beta + P\epsilon$$

이 되고, $Py = z$, $PX = Q$ 라 놓으면

$$z = Q\beta + \delta$$

$$E(\delta) = 0 \quad Cov(\delta) = \sigma^2 I$$

라는 새로운 모형을 얻을 수 있다. 이제 새로운 오차항 δ 는 등분산성을 만족하므로 최소제곱법을 적용시킬 수 있다. 따라서 새로운 회귀모형에 대한 정규방정식은

$$Q'Q\hat{\beta} = Q'z$$

으로 주어지며 여기서

$$X'X\hat{\beta} = X'y$$

$$Q'Q = X'PPX = X'WX$$

$$Q'z = X'PPy = X'Wy$$

이므로 새롭게 정의된 회귀모형에서 회귀계수의 최소제곱추정량은

$$\hat{\beta} = (X'WX)^{-1}X'Wy \quad \text{WLS E} \\ \text{(Weighted LSE)}$$

와 같이 나타낼 수 있다. 또한, $\hat{\beta}$ 의 분산-공분산 행렬은

$$\text{Cov}(\hat{\beta}) = (Q'Q)^{-1}\sigma^2 = (X'WX)^{-1}\sigma^2$$

으로 표현되며 다른 통계량들도 행렬 W 가 포함된 식으로 나타내어진다. 예를 들어, 회귀 제곱합(SSR)은

$$\hat{\beta}'Q'z = y'WX(X'WX)^{-1}X'Wy$$

으로 주어짐을 확인할 수 있다.

위에서와 같이 각 오차항의 분산이 서로 다르다고 가정하여 분석하는 것은 반응변수의 각 값에 서로 다른 가중치(weight)를 주어 분석하는 것과 동일하다. 구체적으로 설명하면, 회귀모형에서 오차항 ε_i 의 분산과 Y_i 의 분산이 같으므로

$$\text{Var}(Y_i) = \sigma^2/w_i$$

이며, 앞에서 언급한대로 변환된 모형에서는 새로운 반응변수


$$Z_i = \sqrt{w_i}Y_i$$

와 같이 변환하여 새로운 반응변수 Z_i 들의 분산을 동일하게 만들고 있다. 가중치 w_i 가 큰 관측값의 경우 분산은 상대적으로 작아지게 되는데 이는 정확도가 높은 (즉, 분산이 작은) 관측값에 큰 가중치를 주는 것으로 해석할 수 있다. 이런 이유로 분산이 일정하지 않다는 가정하에 수행되는 최소제곱법을 가중최소제곱법(weighted least squares method)라 부른다.


예제 6.6 <표 6.5>에는 35개의 관측치로 이루어진 자료가 제시되어 있다. 이 자료를 등 분산 가정하에서 단순선형회귀에 적합시키면 $\hat{y} = -0.579 + 1.135x$ 가 된다. (그림 6.7)에는 잔차대 예측치와 설명변수의 산점도가 주어져 있는데 $\hat{y}_i$ 값이 커질수록 잔차의 분산이 커지고, x_i 가 커질수록 잔차의 분산이 커진다는 것을 알 수 있다.

<표 6.5> 가중회귀 자료

X	Y	$\hat{w}_i$	X	Y	$\hat{w}_i$
1.15	0.99	1.24028	7.94	8.50	0.78342
1.90	0.98	2.18224	9.03	9.47	0.47385
3.00	2.60	7.84930	9.07	11.45	0.46621
3.00	2.67	7.84930	9.11	12.14	0.45878
3.00	2.66	7.84930	9.14	11.50	0.45327
3.00	2.78	7.84930	9.16	10.65	0.44968
3.00	2.80	7.84930	9.37	10.64	0.41435
5.34	5.92	7.43652	10.17	9.78	0.31182
5.38	5.35	6.99309	10.18	12.39	0.31079
5.40	4.33	6.78574	10.22	11.03	0.30672
5.40	4.89	6.78574	10.22	8.00	0.30672
5.45	5.21	6.30514	10.22	11.90	0.30672
7.70	7.68	0.89204	10.18	8.68	0.31079
7.80	9.81	0.84420	10.50	7.25	0.28033
7.81	6.52	0.83963	10.23	13.46	0.30571
7.85	9.71	0.82171	10.03	10.19	0.32680
7.87	9.82	0.81296	10.23	9.93	0.30571
7.91	9.81	0.79588			



(a)



(b)

(그림 6.7) 잔차 대 예측치와 설명변수와의 산점도

따라서 등분산 가정이 틀렸음을 알 수 있다. 이제 가중 최소 제곱법을 적용시켜보자. 이를 위해서는 W 의 대각원소들인 가중치를 구해야 하는데, 여러 가지 방법 중 다음의 방법을 소개한다. 우선 x 값이 비슷한 것끼리 그룹화하여, 각 그룹내에 속하는 X 값들의 표본 평균 $\bar{x}_j$ 와 반응변수 값들의 표본분산 s_j^2 을 계산한다. (그림 6.7)을 보면 이 예제의 경우 관

측치들을 대략 5개의 그룹으로 묶을 수 있으므로 각 그룹에 속하는 관측치들에 대한 표본 평균과 표본분산을 구해보면 다음과 같이 주어진다.

$$\begin{aligned}\bar{x}_j &: 3.0 \quad 5.4 \quad 7.8 \quad 9.1 \quad 10.2 \\ s_j^2 &: 0.0072 \quad 0.3440 \quad 1.7404 \quad 0.8683 \quad 3.8964\end{aligned}$$


그리고 s_j^2 을 반응변수로, $\bar{x}_j$ 를 설명변수로 하는 적절한 회귀모형을 찾으면 이 예제의 경우에는 다음과 같은 이차모형을 얻을 수 있다.

$$\hat{s}^2 = 1.5329 - 0.7334\bar{x} + 0.0883\bar{x}^2$$

그리고 이 회귀식에서 $\bar{x}$ 대신에 각 관측값 x_i 를 대입하여 $\hat{s}_i^2$, $i = 1, \dots, 35$ 를 계산한다. 가중치 w_i 는 $\hat{s}_i^2$ 의 역수로 주어진다. 이와 같이 계산된 w_i 의 추정치 $\hat{w}_i$ 가 <표 6.5>의 세 번째 열에 주어져 있다. 이 때 행렬 P 의 대각원소는 $\hat{w}_i^{1/2}$ 이 된다. 이를 이용하여 가중 최소제곱법을 적용하면 $\hat{y} = -0.8891 + 1.1648x$ 가 되며, 이에 따른 분산분석표는

요 인	자유도	제곱합	평균제곱합
회 귀	1	496.96	496.96
잔 차	33	42.66	1.29
총 합	34	539.62	

와 같다. 이제 새로운 잔차 $z_i - \hat{z}_i$ 의 $\hat{z}_i = \hat{w}_i^{1/2} \hat{y}_i$ 과 $\hat{w}_i^{1/2} x_i$ 에 대한 그림을 그려보면 매우 만족스럽게 나타남을 알 수 있다. ((그림 6.8) 참고) □



(그림 6.8) $\hat{z}_i = \hat{w}_i^{1/2} \hat{y}_i$ 과 $\hat{w}_i^{1/2} x_i$ 에 대한 그림

6.4 박스-콕스 변환모형

중회귀모형의 중요한 가정 중의 하나는 오차항의 정규성 $\varepsilon \sim N(0, \sigma^2 I)$ 이다. 즉, 반응 변수가 정규분포를 따른다는 가정인데 이에 대한 검토는 회귀모형을 적합한 후 잔차분석을 통해 알 수 있다. 만약, 잔차들이 정규분포로부터 많이 벗어나 있을 경우, 이에 대한 대안 중의 하나로 변수변환이 있다. 변수변환에는 반응변수만 변환하는 것, 설명변수만 변환하는 것, 반응변수와 설명변수 모두 변환하는 것 등이 있으나 여기서는 반응변수만 변환하는 것을 고려한다.

박스와 콕스(Box & Cox, 1964)는, 반응변수 y_i 를 적당한 상수 λ 에 대해

$$y_i \rightarrow w_i(\lambda) \quad w_i(\lambda) = \begin{cases} (y_i^\lambda - 1) / \lambda, & \lambda \neq 0 \\ \log y_i, & \lambda = 0 \end{cases} \quad (6.10)$$

와 같은 변환을 해 주면 $w_i(\lambda)$ 는 근사적으로 정규분포에 가깝게 되는 λ 가 존재한다고 제안하였다. 이러한 변환에 대해 여러 가지 논란이 있는데 그 중에서도 이런 변환이 존재하기 위해서는 우선 반응변수 y_i 가 양수이어야 한다는 조건이 꼭 필요하다. 이는 반응변수의 정규성(정규분포를 따르는 변수는 양수와 음수 모두 가질 수 있음)이라는 원래의 가정과 모순된다. 그러나, 많은 논란 끝에 이러한 변환이 타당하다고 결론을 내렸고 반응변수가 음수를 취할 수 있는 경우에도 이러한 변환이 가능해야 하며 이에 대한 변환은 연습문제 6.3을 참고하기 바란다. 한편, $\lambda = 0$ 일 때 로그 변환을 해주는 이유는 $\lambda \neq 0$ 경우의 변환에서 λ 가 0에 가까워 갈 경우의 수렴값이 로그이기 때문이다. 즉, λ 에 따른 변환의 연속성을 최대한 유지하기 위한 것이다.

우선, $w(\lambda) = (w_1(\lambda), \dots, w_n(\lambda))'$ 라 하자. 기존의 회귀모형 $y = X\beta + \varepsilon$ 에서 반응변수 y 의 정규성이 의심되어 이를 변환한 모형

$$w(\lambda) = X\beta + \varepsilon \quad (6.11)$$

을 사용하면 오차항의 정규성, 즉 $\varepsilon \sim N(0, \sigma^2 I)$ 이 되는 λ 가 존재하며 이렇게 변환된 모형하에서 β 를 추정하자는 것이다. 이 처럼 반응변수(또는 오차항)의 정규성이 의심될 경우 위와 같은 변환된 반응변수를 사용한 모형을 박스-콕스 변환모형(Box-Cox transformation model)이라 부른다. 박스-콕스 변환모형을 추정하기 위해 우선 변환모수 λ 의 추정이 필요하다.

λ 의 추정은 흔히 최우추정법을 사용한다. 최우추정법을 이용하기 위해서는 우도함수가

$$= \prod_{i=1}^n (2\pi\sigma^2)^{-1/2} \exp \left[-\frac{(w_i(\lambda) - x_i^T \beta)^2}{2\sigma^2} \right] = (2\pi\sigma^2)^{-n/2} \exp \left[\dots \right]$$

258 제 6 장 선형회귀모형의 변환

필요하며 이 우도함수는 β, σ^2, λ 등의 모수를 포함하고 있다. $w_i(\lambda)$ 가 근사적으로 정규분포에 가깝게 되는 적절한 λ 가 존재한다고 가정하였으므로 우도함수는

$$L(\lambda, \beta, \sigma^2) = (2\pi\sigma^2)^{-n/2} \exp \left[-\frac{1}{2\sigma^2} (w(\lambda) - X\beta)'(w(\lambda) - X\beta) \right] J(\lambda)$$

으로 표현된다. 여기서

$$w_i(\lambda) = \frac{y_i^\lambda - 1}{\lambda} \rightarrow \frac{\partial w_i(\lambda)}{\partial y_i} J(\lambda) = \prod_{i=1}^n \frac{\partial w_i(\lambda)}{\partial y_i} = \prod_{i=1}^n y_i^{\lambda-1}$$

는 변수변환에 따른 자코비안 값이다. 우선 λ 를 고정시키고 β 와 σ^2 에 대한 최우추정치를 구하면 각각

$$\begin{aligned} \arg \max L(\lambda, \beta, \sigma^2) &\Rightarrow \left[\begin{array}{l} \text{Fix } \lambda (\lambda: \text{known}) \\ \text{then, maximum} \\ L(\lambda_0, \beta, \sigma^2) \\ \text{w.r.t. } \beta \text{ \& } \sigma^2 \end{array} \right] \\ (\hat{\lambda}, \hat{\beta}, \hat{\sigma}^2) & \quad \hat{\beta}(\lambda) = (X'X)^{-1} X'w(\lambda) \\ & \quad s^2(\lambda) = w(\lambda)'(I - H)w(\lambda) / n \end{aligned}$$

임을 쉽게 보일 수 있다. 이제 우도함수에 모수 β, σ^2 대신 추정치 $\hat{\beta}(\lambda), s^2(\lambda)$ 를 대입하여 로그우도함수를 계산하면 이는 다음과 같이 λ 만의 함수가 된다. 즉,

$$\begin{aligned} l(\lambda; \hat{\beta}(\lambda), s^2(\lambda)) &= -\frac{n}{2} \log s^2(\lambda) + \log J(\lambda) \\ &= -\frac{n}{2} \log s^2(\lambda) + (\lambda - 1) \sum \log y_i. \end{aligned}$$

이제 이 로그우도함수를 이용하여 λ 의 최우추정치를 구하기 위해 $l(\lambda; \hat{\beta}(\lambda), s^2(\lambda))$ 가 최대가 되는 λ 의 값을 구해야 한다. 이를 위해 로그우도함수를 λ 에 대해 편미분하여 0으로 놓은 식(즉, 스코어 함수)을 구해야 하지만 이 식은 풀리지 않는다. 왜냐하면, 로그우도함수가 $s^2(\lambda)$ 과 $l(\lambda)$ 를 포함하고 있으며 스코어 함수가 λ 에 대해 비선형이 되기 때문이다. 이런 경우에 최대값을 찾는 방법으로 여러 가지가 있으나, 박스-콕스 변환모형에서는 주로 격자탐색법(grid search)으로 구한다. 즉, λ 를 적절한 구간 (흔히 -2 부터 2까지)에서 조금씩 움직이면서 로그우도함수가 최대가 되는 λ 값을 얻는다. 예를 들어, 이렇게 구한 λ 의 추정치가 1/2 근처의 값이면 반응변수를 제곱근 변환하고 0 근처의 값을 얻으면 로그변환을 하면 된다. 또한, 1 근처의 값이면 원래의 반응변수를 변환없이 그대로 사용하면 된다.

λ 의 추정치 $\hat{\lambda}$ 은 몇 개의 관측치에 의해 많은 영향을 받을 수 있다. 즉, $\hat{\lambda}$ 에 대한 진단이 필요하며, 이는 흔히 $\hat{\lambda} - \hat{\lambda}_{(K)}$ 을 계산함으로써 알 수 있는데 여기서 $\hat{\lambda}_{(K)}$ 은 집합

$K = \{i_1, i_2, \dots, i_k\}$ 에 속하는 k 개의 관측치를 제거한 후 계산한 λ 의 추정치를 뜻한다. 이에 대한 자세한 연구는 채이와 우(Tsai & Wu, 1990)와 김, 스토러와 정(Kim, Storer, & Jeong, 1996) 등에 의해 논의되었다.

예제 6.7 (기름 점성 자료) <표 6.6>은 충전재(X_1) 양과 나프탈렌(X_2) 양에 따른 기름의 점성을 나타낸 것이다.

<표 6.6> 기름 점성 자료

나프탈렌 (X_2)	충전재(X_1)					
	0	12	24	36	48	60
0	26	38	50	76	108	157
10	17	26	37	53	83	124
20	13	20	27	37	57	87
30	-	15	22	27	41	63

<표 6.7>는 여러 가지 λ 에 따른 $l(\lambda)$ 의 값으로 $\lambda = -0.05$ 근처에서 최대값을 가지므로 로그변환이 바람직하다.

<표 6.7> λ 값의 변화에 대한 로그우도값의 변화

λ	$l(\lambda)$	λ	$l(\lambda)$
-1.00	-53.70	-0.04	-14.82
-0.80	-47.68	-0.02	-15.09
-0.60	-40.52	0.00	-15.60
-0.40	-31.46	0.05	-17.65
-0.20	-20.07	0.10	-20.43
-0.15	-17.40	0.20	-26.53
-0.10	-15.47	0.40	-37.27
-0.08	-15.02	0.60	-45.69
-0.06	-14.80	0.80	-52.67
-0.05	-14.78	1.00	-58.80

이를 바탕으로 구한 모형의 적합치는


$$\log \hat{y} = 3.212 + 0.03088X_1 - 0.03152X_2$$

로서 $R^2 = 0.9951$, $F = 2045$ 이다. 반면, 변환시키지 않은 원래의 모형에 대한 적합치는

$$\hat{y} = 28.184 + 1.55X_1 - 1.717X_2$$

이며, $R^2 = 0.8793$, $F = 72.9$ 로서, 박스-카스 변환모형보다 훨씬 적합도가 떨어짐을 알 수 있다. 또한, 원래자료 및 로그변환시킨 자료를 적합시켰을 때의 잔차에 대한 정규확률도가

각각 (그림 6.9)에 주어져 있는데 로그변환시킨 자료가 훨씬 정규분포에 더 가까움을 알 수 있다. □



(그림 6.9) (a) 원래 자료를 적합시켰을 때의 잔차에 대한 정규확률도, (b) 로그변환 시킨 자료를 적합시켰을 때의 잔차에 대한 정규확률도

6.5 로버스트 회귀

중선형회귀모형에서 오차항의 정규성(이는 반응변수의 정규성과 같음)에 대한 가정이 의심스러울 때, 그 대안 중의 하나로 반응변수를 변환시켜 정규분포에 가깝게 되는 박스-콕스 변환을 6.4절에서 다루었다. 여기서는 또 다른 방법으로 로버스트 회귀(robust regression)를 소개한다. 로버스트 회귀는 오차항의 분포가 정규분포보다 더 두터운 꼬리(heavy-tail)를 가질 때 주로 이용하는 것으로서, 그 핵심은 큰 값의 잔차를 갖는 관측치의 비중을 상대적으로 작게 하는 방법이다.

정규분포보다 두터운 꼬리를 갖는 분포 중에 이중지수분포(double exponential distribution)

Laplace distⁿ

$$f(\varepsilon) = \frac{1}{2\sigma} e^{-|\varepsilon|/\sigma}, \quad -\infty < \varepsilon < \infty$$

가 있다((그림 6.10) 참고). 만약 오차항이 이중지수분포를 가질 때 회귀계수에 대한 최우


추정량을 구하려면 우도함수

$$\frac{1}{(2\sigma)^n} \exp[-\sum |y_i - x'_i \beta| / \sigma]$$

를 최대화하는 β 를 구해야 하고, 이는 $\sum |y_i - x'_i \beta|$ 를 최소화하는 것과 같다. 즉, 오차의 절대값의 합을 최소화하는 것인데 이를 흔히 L_1 -크기 회귀(L_1 -norm regression)이라 부른다. 한편, 오차항이 정규분포일 때의 최우추정량은 $\sum (y_i - x'_i \beta)^2$ 을 최소화하는 것으로 L_2 -크기 회귀라고 부른다. 일반적으로 L_p -크기 회귀란

$$\sum_{i=1}^n (y_i - x'_i \beta)^p$$

을 최소화 하는 것으로 가장 적절한 p 가 무엇인가에 대한 연구는 아직도 진행중인데 오차항의 분포가 정규분포보다 꼬리가 두터운 경우에는 주로 $p = 1$ 을 많이 사용한다.



(그림 6.10) 이중지수분포 모양 (--- : 정규분포, — : 이중지수분포)

6.5.1 M - 추정량

오차항이 이중지수분포를 따르는 경우 최우추정량은 L_1 -크기 회귀가 됨을 살펴보았다. 일반적으로 로버스트 회귀는 다음과 같이 오차항의 함수 ρ 를 최소화하는 것으로 정의할 수

있다.

$$\arg \min_{\beta} \sum_{i=1}^n \rho(\varepsilon_i) = \min_{\beta} \sum_{i=1}^n \rho(y_i - \mathbf{x}_i' \beta) \quad (6.12)$$

이러한 추정량을 M -추정량(M -estimator)이라 부르는데 이는 최우추정량을 구할 때의 논리를 그대로 적용한 것으로 첫글자 M 을 따서 붙인 이름이다. 예를 들어, 최소제곱추정(L_2 -크기 회귀)은 $\rho(u) = \frac{1}{2}u^2$ 에 해당되고, L_1 -크기 회귀는 $\rho(u) = |u|$ 에 해당된다. 실제로 로버스트 회귀에서는 식 (6.12)보다 척도무관한 형태인

$$\min \sum_{i=1}^n \rho\left(\frac{\varepsilon_i}{s}\right) = \min \sum_{i=1}^n \rho\left(\frac{y_i - \mathbf{x}_i' \beta}{s}\right) \quad (6.13)$$

를 사용한다. 여기서 s 는 σ 의 로버스트 추정치로서 주로

$$y_i - \hat{y}_i = e_i$$

$$s = \frac{\text{median}|e_i - \text{median}(e_i)|}{0.6745} \quad (6.14)$$

을 사용한다. 관측치의 개수 n 이 크고 오차항이 정규분포를 따를 때 s 는 근사적으로 σ 의 불편추정치가 됨을 보일 수 있다.

식 (6.13)를 최소화하기 위해서는 ρ 를 β_j , $j = 0, 1, \dots, p-1$ 에 대해 일차미분한 것을 0으로 놓는다. 즉, 다음과 같은 p 개의 식

$$\sum_{i=1}^n x_{ij} \psi\left(\frac{y_i - \mathbf{x}_i' \beta}{s}\right) = 0, \quad j = 0, 1, \dots, p-1 \quad (6.15)$$

이 생기는데 x_{ij} 는 $\mathbf{x}_i$ 의 j 번째 원소이고 $\psi = \rho'$ 이다. 그런데 ψ 는 β 에 대해 비선형함수이므로 일반적으로 식 (6.15)는 β_j 의 명시된 해(explicit solution)를 줄 수 없고 반복적 방법(iterative method)으로 풀어야 한다. 비선형함수에 대한 반복적 방법에는 여러 가지가 있으나 여기서는 비튼과 투키(Beaton & Tukey, 1974)의 반복 가중 최소제곱법(IRLS : Iterative Reweighted Least Squares)을 소개한다. 이를 위해 먼저 가중치

$$w_{i\beta} = \frac{\psi\{(y_i - \mathbf{x}_i' \beta)/s\}}{(y_i - \mathbf{x}_i' \beta)/s}, \quad i = 1, 2, \dots, n \quad (6.16)$$


을 정의하는데 만약 $y_i - \mathbf{x}_i' \beta = 0$ 이면 $w_{i\beta} = 1$ 이라 두자. 그러면 식 (6.15)은

$$\sum_{i=1}^n x_{ij} w_{i\beta} (y_i - \mathbf{x}_i' \beta) = 0, \quad j = 0, 1, \dots, p-1 \quad (6.17)$$

여러 종류의 영향력 함수들 중에서 어떤 함수를 택할 것인가 하는 문제와 a, b, c 등으로 표현된 상수(흔히 조율상수(tuning constants)라고 함)에 어떤 값을 대입할 것인가 하는 문제가 있다. 함수들간의 비교우위를 논하는 것은 매우 어려운 문제이며, 잔차에 가해지는 가중치를 살펴봄으로써 함수간의 비교를 해볼 수 있다. 최소제곱추정은 모든 잔차에 같은 가중치를 주는 반면, 후버와 햄펠의 경우 표준화된 잔차의 절대값이 a (후버($a = 2$), 햄펠($a = 1.7$)) 보다 작을 때는 같은 가중치를 주지만 a 보다 크면 서서히 감소하는 가중치를 부여한다. 따라서, 최소제곱추정치는 큰 잔차의 값에 영향을 많이 받지만(sensitive to outliers) 후버와 햄펠의 경우는 큰 잔차에 대해 상대적으로 영향을 줄여주는 효과가 있다(robust to outliers). 한편, 앤드류와 투키의 경우 표준화된 잔차의 절대값이 어떤 값(앤드류($1.339\pi \simeq 4.207$), 투키(5와 6사이))보다 크면 아예 가중치를 부여하지 않음을 알 수 있다.

<표 6.8> 여러 종류의 영향력 함수

함수종류	$\rho(u)$	$\psi(u)$	$w(u)$	제한된 조율상수
최소제곱법	$\frac{1}{2}u^2, -\infty < u < \infty$	u	1	
후버(Huber)	$\begin{cases} \frac{1}{2}u^2, & u \leq a \\ a u - \frac{1}{2}a^2, & u > a \end{cases}$	$\begin{cases} u \\ a \cdot \text{sign}(u) \end{cases}$	$\begin{cases} 1 \\ a/ u \end{cases}$	2
램지(Ramsay)	$\{1 - e^{-a u }(1 + a u)\}/a^2, -\infty < u < \infty$	$ue^{-a u }$	$e^{-a u }$	0.3
앤드류(Andrews)	$\begin{cases} a(1 - \cos(u/a)), & u \leq a\pi \\ 2a, & u > a\pi \end{cases}$	$\begin{cases} \sin(u/a) \\ 0 \end{cases}$	$\begin{cases} \frac{\sin(u/a)}{u/a} \\ 0 \end{cases}$	1.339
투키(Tukey)	$\begin{cases} \frac{1}{2}u^2 - \frac{u^4}{4a^2}, & u \leq a \\ \frac{1}{4}u^2, & u > a \end{cases}$	$\begin{cases} u(1 - u^2/a^2) \\ 0 \end{cases}$	$\begin{cases} 1 - u^2/a^2 \\ 0 \end{cases}$	$5 \leq a \leq 6$
햄펠(Hampel)	$\begin{cases} \frac{1}{2}u^2, & u \leq a \\ a u - \frac{1}{2}a^2, & a < u \leq b \\ \frac{a(c u - \frac{1}{2}u^2)}{c - b}, & b < u < c \\ a(b + c - a), & u > c \end{cases}$	$\begin{cases} u \\ a \cdot \text{sign}(u) \\ \frac{(c \cdot \text{sign}(u) - u)a}{c - b} \\ 0 \end{cases}$	$\begin{cases} 1 \\ a/ u \\ \frac{(c/ u - 1)a}{c - b} \\ 0 \end{cases}$	$\begin{matrix} a = 1.7 \\ b = 3.4 \\ c = 8.5 \end{matrix}$



(그림 6.11) 여러 형태의 $\psi(u)$. (a)최소제곱법 (b)후버 (c)램지 (d)앤드류 (e)투키 (f)햄펠

예제 6.8 (암모니아 산화자료) 회귀진단을 설명하기 위해 [예제 4.1]에서 암모니아 산화 자료(<표 4.1>)를 분석하였다. 3개의 설명변수를 이용하여 최소제곱추정을 구하면

$$\hat{y} = -36.9 + 0.72X_1 + 1.30X_2 - 0.15X_3$$

가 되는데 다니엘과 우드(Daniel & Wood, 1971)는 여러 과정의 잔차분석을 통하여 4개의 관측치(1, 3, 4, 21)를 제거한 후

$$\hat{y} = -37.6 + 0.80X_1 + 0.58X_2 - 0.07X_3 \quad (6.21)$$


가 더 적합함을 보였다. 실제로 다니엘과 우드가 얻은 식은 X_3 대신 X_1^2 을 이용하였으나 두 식은 거의 같음을 앤드류(Andrews, 1974)가 보였다.

앤드류는 원래의 자료(21개)에 근거하여 자신의 영향력 함수($a = 1.5$ 를 이용)를 이용한

로버스트회귀를 실시한 결과

$$\hat{y} = -37.2 + 0.82X_1 + 0.52X_2 - 0.07X_3 \quad (6.22)$$

을 얻었고, 이 식은 4개의 관측치를 제거한 식 (6.21)과 거의 같음을 보였다. 식 (6.22)로부터 얻은 잔차의 정규확률도가 (그림 6.12(a))에 주어져 있는데 4개의 관측치(1, 3, 4, 21)가 명백히 이상한 것으로 드러났으며, 이러한 4개의 관측치를 제거한 후 로버스트회귀를 실시하면 식 (6.22)와 같은 회귀식을 얻는다. 즉, 4개의 영향력 관측치는 로버스트회귀에 의해 회귀식에 영향을 미치지 못하며 이러한 점이 로버스트회귀의 장점이라 볼 수 있다. 또한, 이 때의 정규확률도(그림 6.12(b))는 거의 직선을 형성하여 바람직한 모양이 된다. □



(그림 6.12) 정규확률도 : (a) 전체 자료를 사용하여 적합시킨 모형의 잔차의 정규확률도, (b) 4개의 관측치를 제거한 후 적합시킨 모형의 잔차의 정규확률도

6.6 역회귀

회귀모형에서 대부분의 추정 또는 예측문제는 설명변수 $X = x$ 가 주어져 있을 때 반응변수 Y 의 추론에 대한 것이다. 여기서는 역회귀(inverse regression)문제를 다루어 보자. 즉, Y 가 y_0 로 주어져 있을 때 추정된 회귀식을 이용하여 y_0 에 해당되는 x_0 를 구하는 문제이다. 예를 들어, X 를 나이테에 근거한 나무의 나이라고 하고 Y 를 탄소추정법(carbon-dating process)에 근거한 나무의 나이라 하자. 물론 나이테가 탄소추정법보다 정확한 방

법이지만, 나이테는 나무를 잘라야만 알 수 있는 어려움이 있고 탄소추정법은 쉬운 대신 부정확하다. 여기서 나이테를 설명변수로, 탄소추정법을 반응변수로 놓고 구한 회귀식이 주어져 있다면, 탄소추정법으로 구한 y 값으로부터 정확한 나이 x 를 추정할 수 있다. 따라서, 역회귀문제를 흔히 측정(calibration)문제 또는 판별(discrimination)문제라고도 한다.

역회귀문제에서는 기본적으로 점추정치와 구간추정치를 구하는 것인데, 여기서는 신뢰대(confidence band)에 의한 방법을 소개한다. 이를 위해 가장 간단한 단순선형회귀모형

$$Y = \beta_0 + \beta_1 X + \epsilon$$

을 고려한다. 반응변수 Y 가 y_0 라는 특정한 값을 가질 때 역회귀문제를 생각하면 점추정치는 당연히

$$\hat{x}_0 = \frac{y_0 - \hat{\beta}_0}{\hat{\beta}_1} \quad \frac{y_0 - (\hat{\beta}_0 + \hat{\beta}_1 x)}{s \sqrt{1 + \frac{1}{n} + \frac{(x - \bar{x})^2}{\sum (x_i - \bar{x})^2}}} \sim t^{(n-2)}$$

가 될 것이다. x_0 에 대한 $100(1 - \alpha)\%$ 신뢰구간은

$$\frac{(y_0 - \hat{\beta}_0 - \hat{\beta}_1 x)^2}{s^2 A^2} \leq t^2 \quad (6.23)$$

을 만족하는 x 값이 된다. 여기서

$$A^2 = 1 + \frac{1}{n} + \frac{(x - \bar{x})^2}{\sum (x_i - \bar{x})^2} \quad (6.24)$$

이고, s^2 은 σ^2 의 불편추정치이며

$$t = t_{\alpha/2}(n - 2)$$

이다. 식 (6.23)은 x 에 대한 이차 부등식으로서 x 의 해는 (a, b) , $(-\infty, a)$, (b, ∞) , 또는 $(-\infty, \infty)$ 의 형태를 가진다. 이는 (그림 6.13)에 잘 나타나 있으며, 실제로 의미있는 해는 (a, b) 형태이다. 해의 형태는 $H_0 : \beta_1 = 0$ 를 검정하는 t -검정통계량의 크기에 의해 완전히 결정된다. (a, b) 형태의 해는 $H_0 : \beta_1 = 0$ 가 기각될 때만 얻어짐을 보일 수 있으며, 이 때의 해는 $X_L \leq X_0 \leq X_U$ 이며 $X_L = \bar{X} + d_1$, $X_U = \bar{X} + d_2$ 이고 d_1, d_2 는

$$d^2 \left\{ \hat{\beta}_1^2 - \frac{t^2 s^2}{\sum (x_i - \bar{x})^2} \right\} - 2d\hat{\beta}_1(y_0 - \bar{y}) + \left\{ (y_0 - \bar{y})^2 - t^2 s^2 \left(1 + \frac{1}{n} \right) \right\} = 0$$

> 0 - ~~crossed out~~

$$Y_i = \beta_0 + \beta_1 X_i + \epsilon_i \quad \epsilon_i \sim N(0, \sigma^2)$$

$$H_0: \beta_1 = 0 \quad t = \frac{\hat{\beta}_1 - 0}{\frac{s}{\sqrt{\sum (X_i - \bar{X})^2}}} \quad (\text{검정통계량})$$


268 제 6 장 선형회귀모형의 변환

의 해이며 $d = x - \bar{x}$ 이다. 위의 식은 d 에 대한 이차방정식인데 신뢰구간이 의미있는 형태로 구해지기 위한 조건을 살펴보자. 일반적으로 이차부등식 $ax^2 + bx + c \leq 0$ 의 근이 (x_1, x_2) 인 유한한 형태로 주어지기 위해서는 $a > 0$ 이어야 하는데 이는 위의 식에서

$$H_0: \beta_1 = 0 \text{ 이 기각되도록 기각역} \longrightarrow \hat{\beta}_1^2 - \frac{t^2 s^2}{\sum (x_i - \bar{x})} > 0$$

X 와 Y 의 회귀관계가 있다. X 에 해당되며 이러한 조건은 $H_0: \beta_1 = 0$ 를 기각하는 조건과 일치함을 알 수 있다. 즉, 회귀 계수 β_1 이 0이 아니라는 가정하에서 역회귀문제가 해결되는데 이는 설명변수와 반응변수 간에 회귀관계가 있어야 가능하다는 뜻이다.

지금까지는 반응변수가 특정한 값 y_0 로 주어졌을 때의 역회귀문제였으나, 만약 반응변수의 기댓값이 $E(Y) = y_0$ 라는 상수에 대한 역회귀문제는 식 (6.24)의 A^2 에서 1을 빼 값을 이용하면 되고 q 개의 y 값에 대한 평균 $\bar{Y}_q = \sum_{j=1}^q Y_j / q$ 에 대한 역회귀문제는 A^2 의 1 대신 $1/q$ 을 대입하면 된다(3장 참조). 즉, 이러한 경우에 점추정치는 $\hat{x}_0$ 로 동일하지만 신뢰구간이 달라짐을 알 수 있다.




(그림 6.13) x 에 대한 이차 부등식의 해

예제 6.9 어떤 물체의 온도는 100°C 부터 400°C 사이의 값을 갖는데 온도계로 정확히 잴 수 있으나 열전지(thermocouple)로부터 쉽게 측정할 수도 있다고 한다. 10°C 부터 400°C 사이를 15등분하여 온도계로 정확한 값(x)을 재고 그에 해당되는 열전지의 측정값(y)을 구한 것이 <표 6.9>에 주어져 있고 (그림 6.14)에 산점도가 주어져 있다.

<표 6.9> 온도계와 열전지 측정값 자료

	온도계 측정값(x)	열전지 측정값(y)
1	100	88.8
2	120	108.7
3	140	129.8
4	160	146.2
5	180	161.6
6	200	179.9
7	220	202.4
8	240	224.5
9	260	245.1
10	280	257.7
11	300	277.0
12	320	298.1
13	340	318.8
14	360	334.6
15	380	355.2
16	400	377.0



(그림 6.14) 온도계와 열전지 측정값 자료에 대한 산점도

예를 들어 $y_0 = 200$ 가 관측되었을 때 역회귀를 구해보자. 점 추정치는

$$\hat{x}_0 = \frac{y_0 - \hat{\beta}_0}{\hat{\beta}_1} = \frac{200 - (-6.5860)}{0.9525} = 216.89$$

이고, x_0 의 95%신뢰구간은 식 $0.907d^2 + 60.103d + 965.771 = 0$ 을 풀면 $d_1 = -38.876$, $d_2 = -27.389$ 이므로 $\bar{x} + d_1 \leq x_0 \leq \bar{x} + d_2$ 즉, $211.124 \leq x_0 \leq 222.611$ 이 된다.

□

연습문제 (6)

[이론 문제]

6.1 다음은 어느 실험에서 얻은 반응변수 Y 와 설명변수 X_1, X_2, X_3 의 자료이다.

$$Y = \begin{bmatrix} 2 \\ 3 \\ 1 \\ 2 \\ 2 \\ 1 \\ 3 \\ 3 \end{bmatrix} \quad X = \begin{bmatrix} 1 & -1 & -1 & -1 \\ 1 & +1 & -1 & -1 \\ 1 & -1 & +1 & -1 \\ 1 & +1 & +1 & -1 \\ 1 & -1 & -1 & +1 \\ 1 & +1 & -1 & +1 \\ 1 & -1 & +1 & +1 \\ 1 & +1 & +1 & +1 \end{bmatrix} \quad (X \text{의 첫 열은 상수항임})$$

- (1) 회귀모형 $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$ 을 적합시킬 때 회귀계수들의 최소제곱추정치를 구하라.
- (2) 회귀모형 $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \varepsilon$ 을 적합시킬 때 회귀계수들의 최소제곱추정치를 구하라.
- (3) 위의 두 결과를 비교하고, 추정치들이 그와같이 나온 이유를 설명하라.
- 6.2 설명변수가 두 개인 반응표면분석에서 일차회귀모형 $\hat{Y} = 200 + 20X_1 + 46X_2$ 을 적합시켰다. 반응변수를 최소화하기 위한 최대 하강의 방향을 구하라.
- 6.3 박스-콕스 변환 (6.10)은 Y 가 양수이어야 한다. 이런 제약조건의 번거로움을 피하기 위해 반응변수값이 모든 실수를 가질 수 있을 때 다음과 같은 변환

$$w = \begin{cases} \text{sign}(y) \{ (|y| + 1)^\lambda - 1 \} / \lambda, & \lambda \neq 0 \\ \text{sign}(y) \log(|y| + 1), & \lambda = 0 \end{cases}$$

을 고려한다. 이 경우 λ 에 대한 추정을 논하라(존과 드레이퍼(John & Draper, 1980) 참조).

6.4 박스-콕스 변환모수 λ 에 대한 근사적인 $100(1 - \alpha)\%$ 신뢰구간으로

$$\left\{ \lambda : l(\hat{\lambda}) - l(\lambda) \leq \frac{1}{2} \chi_{\alpha}^2(1) \right\}$$

이 타당함을 보여라.

[응용 문제]

6.1 반응변수 Y 와 설명변수 $X1$ 의 산점도에서 $X1 = 54$ 근처에서 불연속점의 가능성이 나타나 이것을 구체적으로 조사하기 위해 다음의 모형을 적합하였다.

$$Y = \beta_0 + \beta_1 X1 + \beta_2 Xa + \beta_3 X3 + \varepsilon$$

위의 식에서 $Xa = (X1 - 54) \cdot X2$ 이고, $X2$ 와 $X3$ 는 각각 $X1$ 이 54보다 크면 1, 작으면 0의 값을 갖는 지시변수(indicator variable)이다.

The regression equation is

$$Y = 30.5 + 2.93X1 - 1.75Xa + 1.24X3$$

Predictor	Coef	Stdev	t - ratio	p
Constant	30.50	3.640	8.37	0.000
X1	2.83	0.361	7.94	0.000
Xa	-1.75	0.412	-4.25	0.005
X3	1.24	0.408	3.04	0.023

- (1) 위의 적합된 식에서 $X1$ 이 54보다 작은 경우와 큰 경우에 대해 각각 해당되는 회귀식을 구하여라.
- (2) 불연속점(discontinuity)의 가능성에 대해 검정하여라.
- (3) 두 부분의 기울기가 같다는 가설을 검정하여라.

6.2 다음은 임의의 두 변수 X 와 Y 에 대해 남자와 여자의 두 집단의 관측치를 이용하여 구한 회귀분석의 결과이다. 남자와 여자에 따라 회귀모형이 같은지를 검정하라.

남자의 관측치만 사용한 경우 : 추정회귀식 : $y = 0.234 + 0.108x$

요인	DF	SS	MS
회귀	1	24.355	24.355
잔차	8	0.754	0.094
전체	9	25.109	

여자의 관측치만 사용한 경우 : 추정회귀식 : $y = 0.622 + 0.0919x$

요인	DF	SS	MS
회귀	1	19.084	19.048
잔차	8	1.733	0.217
전체	9	20.781	

남자, 여자 모두의 관측치를 사용한 경우 : 추정회귀식 : $y = 0.422 + 0.0997x$

요인	DF	SS	MS
회귀	1	43.470	43.470
잔차	18	2.812	0.156
전체	19	46.282	

6.3 다음 자료는 30개 레스토랑의 광고비 (X)와 매출액 (Y)을 나타낸 것이다.

i	Y_i	X_i	i	Y_i	X_i
1	81,464	3,000	16	144,630	12,310
2	72,661	3,150	17	147,041	13,700
3	72,344	3,085	18	179,021	15,000
4	90,743	5,225	19	166,200	15,715
5	98,588	5,350	20	180,732	14,995
6	96,507	6,090	21	178,187	15,050
7	126,574	8,925	22	185,304	15,200
8	114,133	9,015	23	155,931	15,150
9	115,814	8,885	24	172,579	16,800
10	123,181	8,950	25	188,851	16,500
11	131,434	9,000	26	192,424	17,830
12	140,564	11,345	27	203,112	19,500
13	151,352	12,275	28	192,482	19,200
14	146,926	12,400	29	218,715	19,000
15	130,963	12,525	30	214,317	19,350

(1) 단순선형모형에 적합시키고 잔차를 분석하라.

(2) 잔차분석으로 부터 가중회귀가 필요함을 지적하고 가중최소제곱추정치를 구하라.

6.4 다음 자료는 4개의 설명변수와 반응변수를 나타낸 것이다.

i	Y_i	X_{1i}	X_{2i}	X_{3i}	X_{4i}
1	78.5	7	26	6	60
2	74.3	1	29	15	52
3	104.3	11	56	8	20
4	87.6	11	31	8	47
5	95.9	7	52	6	33
6	109.2	11	55	9	22
7	102.7	3	71	17	6
8	72.5	1	31	22	44
9	93.1	2	54	18	22
10	115.9	21	47	4	26
11	83.8	1	40	23	34
12	113.3	11	66	9	12
13	109.4	10	68	8	12

(1) 설명변수 행렬 X 의 상관계수행렬을 구하고 다중공선성의 존재를 확인하라.

(2) 능형추정치를 구하라.

6.5 다음 자료는 53가구의 한달간 전기사용량(X : KWH)과 하루 중 최대 전력 사용할 동안에 이용된 전기 사용량(Y : KW)을 나타낸 것이다.

가구	X (KWH)	Y (KW)	가구	X (KWH)	Y (KW)
1	679	.70	28	1748	4.88
2	292	.44	29	1381	3.48
3	1012	.56	30	1428	7.58
4	493	.79	31	1255	2.63
5	582	2.70	32	1777	4.99
6	1156	3.64	33	370	.59
7	997	4.73	34	2316	8.19
8	2189	9.50	35	1130	4.79
9	1097	5.34	36	463	.51
10	2078	6.85	37	770	1.74
11	1818	5.84	38	724	4.10
12	1700	5.21	39	808	3.94
13	747	3.25	40	790	.96
14	2030	4.43	41	783	3.29
15	1643	3.16	42	406	.44
16	414	.50	43	1242	3.24
17	354	.17	44	658	2.14
18	1276	1.88	45	1746	5.17
19	745	.77	46	468	.64
20	435	1.39	47	1114	1.90
21	540	.56	48	413	.51
22	874	1.56	49	1787	8.33
23	1543	5.28	50	3560	14.94
24	1029	.64	51	1495	5.11
25	710	4.00	52	2221	3.85
26	1434	.31	53	1526	3.93
27	837	4.20			

(1) 단순선형모형에 적합시키고, 잔차의 정규성을 검토하라.

(2) 이를 바탕으로 적절한 박스-콕스 변환모형을 설정하고 적합시켜라.

제 7 장

편의추정법

- 7.1 재임스-슈타인 축소법
- 7.2 능형회귀
- 7.3 주성분회귀
- 7.4 부분최소제곱법
- 7.5 LASSO
- 7.6 예제
- 7.7 편의 추정치와 베이스 추정치

중 회귀모형에서 최소제곱추정치는 $\hat{\beta} = (X'X)^{-1}X'y$ 로 주어지는데, 수학적으로는 $X'X$ 가 정칙행렬이면 역행렬은 언제나 존재하므로 문제가 없다. 그러나 설명변수들간에 상관관계가 매우 커서 $X'X$ 가 수학적으로 정칙(mathematically nonsingular)이지만 계산상으로는 거의 비정칙(computationally near-singular)에 가까운 경우가 흔히 있다. 즉, $X'X$ 의 행렬식이 거의 0에 가깝게 되고 $X'X$ 의 역행렬은 매우 불안정한 값이 된다. 이러한 행렬을 나쁜 상태(ill-conditioned)행렬이라고 부른다. 이러한 상황에서는 $\hat{\beta}$ 의 계산은 가능하지만 $\hat{\beta}$ 값 자체는 매우 불안정하며 신뢰도가 떨어진다. 구체적으로 이 경우 4.7절에서 정의된 분산팽창인수(VIF)들 중 큰 값이 존재하여 해당 최소제곱추정치 b_k 의 분산이 크게 된다. 즉, 다중공선성이 존재하면 β 에 대한 불편추정치 $\hat{\beta} = (X'X)^{-1}X'y$ 는 바람직하지 않다. 이를 보완하기 위해 지금까지 여러 가지 편의 추정법이 소개되었는데 편의추정의 효시는 재임스와 슈타인(James & Stein, 1961)의 축소추정치(shrinkage estimator)이다. 따라서 우선 슈타인의 축소추정치를 소개하고, 능형회귀, LASSO, 주성분 회귀, 부분최소제곱법등을 자세히 다루며, 베이지안적 접근법과의 관계를 설명한다.

$$\begin{aligned}
 & \theta \in R^1 \text{ case.} \\
 & MSE(\hat{\theta}) = E(\hat{\theta} - \theta)^2 = E\left[\underbrace{(\hat{\theta} - E(\hat{\theta}))}_{\text{const}} + \underbrace{E(\hat{\theta}) - \theta}_{\text{const}}\right]^2 \\
 & = E[(\hat{\theta} - E(\hat{\theta}))^2] + \{E(\hat{\theta}) - \theta\}^2 \\
 & \quad + 2\{E(\hat{\theta} - \theta) \cdot \underbrace{E[\hat{\theta} - E(\hat{\theta})]}_0\} \\
 & = Var(\hat{\theta}) + Bias^2(\hat{\theta})
 \end{aligned}$$

$$\begin{aligned}
 & \theta \in R^p. \\
 & MSE(\hat{\theta}) =
 \end{aligned}$$

7.1 재임스-슈타인 축소법

p -벡터인 $z = (z_1, z_2, \dots, z_p)'$ 가 서로 독립이고 평균이 $\mu = (\mu_1, \mu_2, \dots, \mu_p)'$ 이고 분산은 각각 1인 정규분포를 따른다고 가정하자. 즉,

$$z \sim N_p(\mu, I).$$

잘 알려진 대로 μ 에 대한 좋은 추정치로는 z 이다. 실제로 z 는 μ 에 대한 최우추정치이며 또한, 일양최소분산불편추정치(UMVUE : Uniformly Minimum Variance Unbiased Estimator)이다. 따라서 당연히 $E(z) = \mu$ 이므로 불편성(1차 적률의 관점)을 만족하지만 재임스와 슈타인(James & Stein, 1961)의 의문점은 평균오차제곱(MSE : Mean Squared Error)의 관점(2차 적률의 관점)에서도 여전히 z 가 μ 에 대한 좋은 추정치가 되는가 에서 출발했다. 이제

$$E(z'z) = \sum_{i=1}^p E(z_i^2) = \sum_{i=1}^p (1 + \mu_i^2) = p + \mu'\mu > \mu'\mu$$

임을 쉽게 알 수 있다. 즉, 평균오차제곱의 관점에서 $z'z$ 은 $\mu'\mu$ 에 대해서 불편추정치가 아니라 그 기대값이 $\mu'\mu$ 보다 큰 값을 갖는 편향의 추정치임을 알 수 있다. 따라서 μ 에 대한 추정치로 z 가 아닌 축소된 추정치(shrinkage estimator)

$$\tilde{\mu} = cz, \quad 0 < c < 1$$

을 고려하면 비록 불편추정치는 될 수 없지만 평균오차제곱의 개념에서는 z 보다 더 작은 값을 가질 수 있음을 알 수 있다(즉, 불편성을 잃게 되지만 평균오차제곱의 감소를 얻을 수 있다). 이제 문제는 축소상수(shrinkage constant)인 c 가 존재하는가, 만약 존재한다면 c 를 어떻게 찾는가 이다. 즉, $MSE(\tilde{\mu}) \leq MSE(z)$ 이 성립되는 c 가 존재한다면 이를 구하는 것이다. 이제, $\tilde{\mu}$ 에 대한 평균오차제곱 $MSE(\tilde{\mu}) = E(\|\tilde{\mu} - \mu\|^2)$ 을 계산하면

$$\begin{aligned} MSE(\tilde{\mu}) &= E[(\tilde{\mu} - \mu)'(\tilde{\mu} - \mu)] \\ &= E[(\tilde{\mu} - E(\tilde{\mu}) + E(\tilde{\mu}) - \mu)'(\tilde{\mu} - E(\tilde{\mu}) + E(\tilde{\mu}) - \mu)] \\ &= E[(\tilde{\mu} - E(\tilde{\mu}))'(\tilde{\mu} - E(\tilde{\mu}))] + [E(\tilde{\mu}) - \mu]'[E(\tilde{\mu}) - \mu] \\ &= \text{tr}[Cov(\tilde{\mu})] + \|Bias(\tilde{\mu})\|^2 \end{aligned}$$

이므로

$$\begin{aligned}\text{MSE}(\tilde{\mu}) &= \text{tr}(c^2 \mathbf{I}) + (\mu - E(\tilde{\mu}))'(\mu - E(\tilde{\mu})) \\ &= pc^2 + (1-c)^2 \mu' \mu\end{aligned}$$

으로 나타난다. 한편,

$$\text{MSE}(z) = p$$

이다. 이제 $\text{MSE}(\tilde{\mu})$ 를 최소화하는 c 를 찾기 위해 $\text{MSE}(\tilde{\mu})$ 를 c 에 대해 미분한 다음 0으로 놓는다. 즉,

$$0 = \frac{\partial \text{MSE}(\tilde{\mu})}{\partial c} = 2cp - 2(1-c)\mu' \mu = 2c(p + \mu' \mu) - 2\mu' \mu$$

이므로 이를 c 에 대하여 풀면

$$c = \frac{\mu' \mu}{p + \mu' \mu}$$

이므로

$$\tilde{\mu} = \left(1 - \frac{p}{p + \mu' \mu}\right) z$$

이 된다. 그런데 이 추정치는 미지의 모수인 μ 를 포함하고 있으므로 $\mu' \mu$ 에 대한 불편추정치인 $z'z - p$ 를 대체한

$$\tilde{\mu} = \left(1 - \frac{p}{z'z}\right) z$$

을 고려할 수 있다. 그런데, 실제로

$$\tilde{\mu}_s = \left[1 - \frac{(p-2)}{z'z}\right] z$$

이 cz 형태의 추정치중 가장 평균오차제곱이 작은 것으로 알려져 있으며 이를 슈타인 축소 추정치라 부른다.

7.2 능형회귀

7.2.1 능형회귀의 정의와 추정

설명변수들 간에 상관관계가 있을 때 다중공선성(4.7절 참조)이 발생되며 이 경우 아무런 조치없이 구한 최소제곱추정치 $\hat{\beta} = (X'X)^{-1}X'y$ 는 매우 심각한 문제를 발생한다. 특히, $X'X$ 의 행렬식이 0에 가까워져 회귀계수의 추정치에 대한 분산이 매우 커져서 신뢰구간의 폭이 매우 넓어지게 된다. 다중공선성이 존재하는 경우 호엘과 케나드(Hoerl & Kennard, 1970)는 β 에 대한 추정치로 최소제곱추정치 대신 능형추정량(ridge estimator)

$$\hat{\beta}(\theta) = (X'X + \theta I)^{-1}X'y \quad \frac{a}{c + \theta} : \arg e \quad (7.1)$$

을 제안하였는데, 여기서 θ 는 양수로서 추정되어야 할 모수이며 흔히 편의모수(biasing parameter) 또는 축소모수(shrinkage parameter)라 한다.

능형추정치의 형태로 부터 알 수 있듯이 최소제곱추정치의 $X'X$ 에 축소모수 θ 를 더한 것이다. 즉, 능형추정량의 아이디어는, 0에 가까운 수의 역수는 매우 불안정하고 여기에 적당한 양수를 더해주면 그 역수는 안정된다는 것이다. 이를 행렬로 확대하면 행렬식이 0에 가까운 행렬일 때 이 행렬에 적절한 양정치 행렬을 더해주면 그 역행렬은 안정될 것이다. 물론 이렇게 구한 능형추정치는 최소제곱추정치의 불편성을 잃게 된다. 즉, 능형추정치는 더 이상 불편추정치가 아닌 편의추정치가 된다. 그러나, 7.2.2절에 소개된 것처럼 능형추정치는 불편추정치인 최소제곱추정치보다 평균오차제곱의 관점에서 더 좋은 성질을 가지고 있음을 알게 될 것이다.

능형추정치 $\hat{\beta}(\theta)$ 가 모수 θ 를 포함하고 있으므로, 완전한 추정치가 되기 위해선 θ 의 값을 결정해야 한다. θ 의 추정법에는 여러 가지가 제안되었으며 다음의 두 가지 방법을 소개한다.

(1) 능형 트레이스(ridge trace)

$\hat{\beta}_j(\theta)$, $j = 0, \dots, p-1$ 를 여러 가지 θ 값에 대해 그림을 그린 다음 $\hat{\beta}_j(\theta)$ 값들이 수렴하기 시작하는 값을 찾아 이를 θ 의 추정치로 사용하는 것이다. 이러한 $\hat{\beta}_j(\theta)$ 와 θ 의 그림을 능형 트레이스(ridge trace)라 부른다((그림 7.1) 참고). 능형 트레이스에 의한 θ 의 추정은 수렴하는 값을 주관적으로 판단하므로 θ 의 적절한 값을 개략적으로 알 수 있다. 따라서, 보다 정확한 값은 다음에 소개하는 두 번째 방법을 주로 사용한다.