


(그림 7.1) θ 의 변환에 따른 능형추정량 $\hat{\beta}_j(\theta)$ 의 변화(2) GCV_θ

GCV_θ 는 와바, 골럽과 히스(Wahba, Golub & Heath, 1979)가 제안한 일반화 교차확인법(Generalized Cross Validation : GCV)으로

$$GCV_\theta = \sum e_{i,\theta}^2 / \left[1 - \frac{1}{n} \text{tr}(\mathbf{H}_\theta) \right]^2$$

로 정의되며, 이를 최소화 하는 θ 를 추정치로 사용한다. 여기서,

$$e_{i,\theta} = y_i - \hat{y}_{i,\theta}$$

는 θ 가 주어졌을 때의 잔차이고

$$\mathbf{H}_\theta = \mathbf{X}(\mathbf{X}'\mathbf{X} + \theta\mathbf{I})^{-1}\mathbf{X}'$$

인데 능형회귀에서 모자행렬의 역할을 한다.

예제 7.1 (체내 지방 자료) <표 7.1>은 20명에 대한 체내 지방 자료를 나타낸 것으로 삼두근 두께(x_1), 허벅지 둘레(x_2), 팔의 중간부위 둘레(x_3)등 세가지 설명변수와 체내 지방량(body fat)을 나타내는 반응변수로 구성되어 있다. 설명변수들의 상관계수 행렬에서 알 수 있듯이 x_1 과 x_2 의 상관계수가 0.92로 매우 높다.

<표 7.1> 체내 지방자료와 상관계수 행렬

i	X_{i1}	X_{i2}	X_{i3}	Y_i
1	19.5	43.1	29.1	11.9
2	24.7	49.8	28.2	22.8
3	30.7	51.9	37.0	18.7
4	29.8	54.3	31.1	20.1
5	19.1	42.2	30.9	12.9
6	25.6	53.9	23.7	21.7
7	31.4	58.5	27.6	27.1
8	27.9	52.1	30.6	25.4
9	22.1	49.9	23.2	21.3
10	25.5	53.5	24.8	19.3
11	31.1	56.6	30.0	25.4
12	30.4	56.7	28.3	27.2
13	18.7	46.5	23.0	11.7
14	19.7	44.2	28.6	17.8
15	14.6	42.7	21.3	12.8
16	29.5	54.4	30.1	23.9
17	27.7	55.3	25.7	22.6
18	30.2	58.6	24.6	25.4
19	22.7	48.2	27.1	14.8
20	25.2	51.0	27.5	21.1

$$\text{Corr}(X_1, X_2, X_3) = \begin{bmatrix} 1.00 & 0.92 & 0.46 \\ 0.92 & 1.00 & 0.08 \\ 0.46 & 0.08 & 1.00 \end{bmatrix}$$

이 자료에 능형회귀를 적용해 보자. θ 를 찾기 위해 0에서 0.001씩 증가 시켜나가면 θ 가 0.02 근처에서 $\hat{\beta}_j(\theta)$ 값들이 수렴하기 시작한다(<표 7.2>). 따라서 $\theta = 0.02$ 로 놓고 능형회귀를 구해보면

$$\hat{y} = 3.485 + 0.909x_1 + 0.080x_2 - 0.376x_3$$

(17.943) (0.581) (0.479) (0.316)

가 된다. 한편, 원래 자료를 능형회귀가 아닌 최소제곱추정치를 구하면

$$\hat{y} = 117.888 + 4.362x_1 - 2.879x_2 - 2.199x_3$$

(100.077) (3.024) (2.590) (1.600)

로 되어 회귀계수 추정치의 표준편차들이 매우 크게 됨을 알 수 있다. 이는 설명변수들간의 상관관계가 매우 높아 다중공선성이 심하게 나타났기 때문이다. 따라서, 다중공선성이 심한 경우 최소제곱추정치를 그대로 사용하면 회귀계수 추정치 및 그 신뢰구간이 매우 불안정하게 된다.

<표 7.2> 체내 지방 자료에서 θ 의 변화에 따른 $\hat{\beta}_j(\theta)$ 값의 변화


θ	$\hat{\beta}_1(\theta)$	$\hat{\beta}_2(\theta)$	$\hat{\beta}_3(\theta)$
0.000	4.3617	-2.8791	-2.1986
0.001	2.1565	-0.9897	-1.0350
0.002	1.6368	-0.5483	-0.7602
0.003	1.4067	-0.3466	-0.6386
0.004	1.2758	-0.2345	-0.5694
0.005	1.1916	-0.1625	-0.5249
0.006	1.1327	-0.1121	-0.4939
0.007	1.0896	-0.0749	-0.4710
0.008	1.0561	-0.0466	-0.4535
0.009	1.0298	-0.0238	-0.4396
0.010	1.0083	-0.0056	-0.4283
0.020	0.9088	0.0799	-0.3756
0.030	0.8741	0.1095	-0.3573
0.040	0.8566	0.1246	-0.3481
0.050	0.8459	0.1337	-0.3424
0.060	0.8388	0.1398	-0.3387
0.070	0.8336	0.1442	-0.3359
0.080	0.8298	0.1475	-0.3339
0.090	0.8267	0.1500	-0.3323
0.100	0.8243	0.1521	-0.3311
0.200	0.8130	0.1615	-0.3252
0.300	0.8088	0.1648	-0.3231
0.400	0.8065	0.1665	-0.3220
0.500	0.8049	0.1676	-0.3213
0.600	0.8037	0.1684	-0.3207
0.700	0.8027	0.1690	-0.3203
0.800	0.8017	0.1695	-0.3199
0.900	0.8009	0.1770	-0.3196
1.000	0.8002	0.1703	-0.3193

7.2.2 능형회귀 추정치의 성질

능형추정량의 여러 가지 성질 중에서 그 첫 번째는 능형추정량은 제한된 조건하에서 구한 최소제곱추정치라는 것이다. 좀 더 구체적으로 설명하면 $\hat{\beta}(\theta)$ 는

$$\beta' \beta = c^2$$

라는 제한하에서 오차제곱합 $(y - X\beta)'(y - X\beta)$ 를 최소화하는 추정치다. 이 사실은 라그랑지 방법을 사용하여 쉽게 증명할 수 있다. 제한된 최소제곱추정치의 기하학적 의미는 다음과 같다. $p = 2$ 라고 가정하면 $\beta' \beta = c^2$ 은 반지름 c 인 원을 나타내고, $(y - X\beta)'(y - X\beta)$ 는 β 의 값이 변함에 따라 여러 가지 타원을 나타낸다. 따라서 $\hat{\beta}(\theta)$ 는 원과 타원의 접점이 된다(그림 7.2 참조). 또한, c 와 θ 는 일대일로 대응됨을 알 수 있다(연습문제 7.2).

(그림 7.2) $\beta' \beta = c^2$ 과 $(y - X\beta)'(y - X\beta)$

다음으로, $\hat{\beta}(\theta)$ 는 적당한 θ 에 대해 최소제곱 추정치보다 더 작은 평균오차제곱(mean square error: MSE)을 가진다는 것이다. 이는 매우 바람직한 사실로서 능형 추정치의 큰 장점이 된다.

[정리 7.1] $MSE(\hat{\beta}) - MSE(\hat{\beta}(\theta))$ 는 적절한 양의 상수 θ 에 대해 양정치이다.

[증명] 평균오차제곱은 언제나 분산과 편의제곱의 합으로 표현되므로

$$\begin{aligned} MSE(\hat{\beta}(\theta)) &= E[(\hat{\beta}(\theta) - \beta)(\hat{\beta}(\theta) - \beta)'] \\ &= Cov[(\hat{\beta}(\theta))] + [E(\hat{\beta}(\theta)) - \beta][E(\hat{\beta}(\theta)) - \beta]' \end{aligned}$$

그런데 $K = (X'X + \theta I)^{-1}$ 라 두면

$$\begin{aligned} Cov[\hat{\beta}(\theta)] &= Cov[(X'X + \theta I)^{-1} X'y] \\ &= (X'X + \theta I)^{-1} X'X(X'X + \theta I)^{-1} \sigma^2 \\ &= KX'XK\sigma^2 \end{aligned}$$

이고,

$$E(\hat{\beta}(\theta)) - \beta = E(KX'y) - \beta = (KX'X - KK^{-1})\beta = -\theta K\beta$$

따라서

$$MSE(\hat{\beta}(\theta)) = KX'XK\sigma^2 + \theta^2 K\beta\beta'K$$

가 된다. 그런데 $Cov(\hat{\beta}) = MSE(\hat{\beta}) = (X'X)^{-1}\sigma^2$ 이므로

$$\begin{aligned} MSE(\hat{\beta}) - MSE(\hat{\beta}(\theta)) &= (X'X)^{-1}\sigma^2 - KX'XK\sigma^2 - \theta^2 K\beta\beta'K \\ &= KK^{-1}(X'X)^{-1}K^{-1}K\sigma^2 - KX'XK\sigma^2 - \theta^2 K\beta\beta'K \\ &= K[K^{-1}(X'X)^{-1}K^{-1}\sigma^2 - X'X\sigma^2 - \theta^2\beta\beta']K \end{aligned}$$

이 된다. K 가 양정치 행렬이므로 $MSE(\hat{\beta}) - MSE(\hat{\beta}(\theta))$ 가 양정치 행렬임을 보이기 위해서는

$$\Delta = K^{-1}(X'X)^{-1}K^{-1}\sigma^2 - X'X\sigma^2 - \theta^2\beta\beta'$$

이 양정치임을 보이면 된다. 그런데

$$\begin{aligned} K^{-1}(X'X)^{-1}K^{-1} &= (X'X + \theta I)(X'X)^{-1}(X'X + \theta I) \\ &= X'X + 2\theta I + \theta^2(X'X)^{-1} \end{aligned}$$

이므로

$$\Delta = \theta[2I + \theta(X'X)^{-1}]\sigma^2 - \theta\beta\beta'$$

이다. 여기서, $(X'X)^{-1}$ 가 양정치행렬이고 $\theta > 0$ 이므로 Δ 가 양정치임을 보이기 위해서는 $2\sigma^2 I - \theta\beta\beta'$ 가 양정치임을 보이면 된다. 이제 α 를 임의의 0이 아닌 p 차원벡터라 하면

$$\alpha'(2\sigma^2 I - \theta\beta\beta')\alpha = 2\sigma^2 \alpha'\alpha - \theta(\alpha'\beta)^2 \geq 2\sigma^2 \alpha'\alpha - \theta(\alpha'\alpha)(\beta'\beta) = (2\sigma^2 - \theta\beta'\beta)\alpha'\alpha$$

이 성립한다. 단, 위에서 부등식은 코오시-슈바르츠 부등식이 사용되었다. 따라서 $2\sigma^2 - \theta\beta'\beta > 0$ 이면 $2\sigma^2 I - \theta\beta\beta'$ 는 양정치이다. 즉, $0 < \theta < 2\sigma^2/\beta'\beta$ 이면 능형추정치의 MSE는 최소제곱추정치의 그것보다 언제나 작다. □

능형추정치의 성질 중 마지막으로 소개할 것은, 회귀계수 β 가 적절한 사전분포(prior distribution)를 따르면 제곱오차 손실함수의 가정하에 능형추정치는 베이스 추정치임을 보일 수 있다. 좀 더 구체적으로,

$$y = X\beta + \varepsilon, \quad \varepsilon \sim N(0, \sigma^2 I)$$

에서 β 의 사전분포를

$$\beta \sim N\left(0, \frac{\sigma^2}{\theta} I\right)$$

라 두면 β 의 사후분포(posterior distribution)는 평균이 $\hat{\beta}(\theta) = (X'X + \theta I)^{-1}X'y$ 이고, 분산-공분산행렬이 $(X'X + \theta I)^{-1}\sigma^2$ 인 정규분포임(연습문제 7.3)을 보일 수 있으며, 제곱 손실함수하에서 베이스 추정치는 사후분포의 평균이므로 $\hat{\beta}(\theta)$ 는 베이스 추정치가 된다.

7.3 주성분회귀

흔히 설명변수의 갯수가 많은 경우 설명변수들간에 무시할 수 없을 정도의 상관관계가 존재한다. 이 상황에서 두 가지 처방이 필요하다. 하나는 설명변수의 갯수를 줄이는 것이고 또 다른 하나는 설명변수들 간의 상관관계로 인한 다중공선성을 처리하는 것이다.

이 두 가지 처방을 위한 방법 중의 하나가 주성분회귀(PCR : Principal Component Regression)인데 주성분회귀의 기본 아이디어는 설명변수들을 선형결합시켜 새롭게 만든 변수를 몇 개만 사용한다는 것이다. 이러한 목적을 만족시켜주는 설명변수의 결합을 위해 비정칙치 분해(SVD): singular values decomposition, 부록 A 참조)가 사용된다.

$n \times p$ 행렬 X 를 비정칙치 분해하면

$$X = UDV'$$

이 되는데 여기서 U 와 V 는 각각 $n \times p$ 와 $p \times p$ 인 직교행렬이며, D 는 $p \times p$ 인 대각행렬인데 대각원소로 $d_1 \geq d_2 \geq \dots \geq d_p \geq 0$ 을 가지며 이들을 비정칙치라 부른다. 따라서

$$X'X = VD^2V'$$

이 되며 이는 바로 $X'X$ 의 스펙트럴 분해(부록 A 참조)이다. 여기서, $d_1^2 \geq d_2^2 \geq \dots \geq d_p^2 \geq 0$ 은 $X'X$ 의 고유치이고 이에 해당되는 고유벡터는 $v_1, v_2, \dots, v_p$ 인데 이들은 V 의 열벡터들로서 직교벡터이다. 행렬 $X = (x_1, x_2, \dots, x_p)$ 에서 x_i 를 i 번째 설명변수인 n -벡터라 하면 p 개로 이루어진 원래의 설명변수들을 다음과 같이 선형결합하여 새로운 변수를 정의한다. 즉,

$$z_i = Xv_i = u_i d_i, \quad i = 1, 2, \dots, p$$

으로 표현하는데 여기서 z_i 를 i 번째 주성분(i th principal component)이라 부르고, u_i 는 행렬 U 의 i 번째 열벡터이다. 따라서 z_i 의 표본분산은

$$Var(z_i) = Var(Xv_i) = d_i^2/n, \quad i = 1, 2, \dots, p$$

이 되는데 특히, 가장 큰 분산을 가지는 z_1 을 첫번째 주성분(1st principal component)이라 부른다. i 번째 주성분 $z_i = Xv_i$ 를 결정하는 v_i 를 i 번째 주성분 방향(i th principal com-

ponent direction)이라 부르며 이는 다음과 같은 식을 만족하는 벡터이다.

$$\begin{aligned} \max_{\|\alpha\|=1} \quad & \text{Var}(X\alpha) \\ \text{s.t.} \quad & v_l'S\alpha = 0 \\ & l=1, 2, \dots, i-1 \end{aligned}$$

단, 여기서

$$S = X'X/n$$

으로 설명변수들의 분산-공분산 행렬이다. 또한, $v_l'S\alpha = 0$ 이란 조건 때문에 $z_i = X\alpha$ 와 그 전의 선형결합들인 $z_l = Xv_l$, $l = 1, 2, \dots, i-1$ 이 서로 직교(상관관계가 없음)하게 된다.

주성분회귀는 원래의 설명변수들을 선형결합시켜 새롭게 만든 주성분 $z_1, z_2, \dots, z_p$ 중에서 분산이 큰 몇 개의 주성분 $z_1, z_2, \dots, z_M$ ($M \ll p$)만을 사용하여 반응변수에 회귀시키는데 z_i 들이 서로 직교하므로 반응변수 y 를 각 z_i 에 단순회귀시켜 이들을 합하기만 하면 된다. 편의상 반응변수와 설명변수들이 중심화 되었다고 가정하자. 즉, 평균을 빼서 중심화시키면 각 변수들의 평균은 0이 된다. 이 가정하에서 주성분회귀의 적합치는

$$\hat{y} = \sum_{m=1}^M \hat{\theta}_m z_m$$

으로 표현할 수 있는데 여기서,

$$\hat{\theta}_m = z_m'y / z_m'z_m$$

은 반응변수 y 를 설명변수 z_m 에 단순회귀 시켰을 때의 회귀계수에 대한 추정치다. 여기서 몇 개의 주성분을 사용할 것인가, 즉 M 을 어떻게 추정할 것인가의 선택이 필요한데 이를 위해 흔히 교차확인법이 사용된다.

7.4 부분최소제곱법

이 방법 역시 주성분분석과 마찬가지로 설명변수 X_j , $j = 1, 2, \dots, p$ 들의 선형결합을 이용하는 것인데 근본적인 차이점은 주성분분석이 X 만의 정보를 이용하는 것에 비해 부분최소제곱법(PLS : partial least squares)은 X 뿐만 아니라 y 의 정보도 함께 사용한다는 것이다. 즉, i 번째 부분최소제곱 방향(i th PLS direction) v_i 는 다음과 같은 식을 만족하는

벡터이다.

$$\max_{\substack{\|\alpha\|=1 \\ v_l' S \alpha = 0 \\ l=1,2,\dots,i-1}} \text{Corr}^2(y, X\alpha) \text{Var}(X\alpha)$$

편의상 각 설명변수는 평균이 0이고 분산이 1이라 가정하면 부분최소제곱법에 대한 알고리즘은 다음과 같다.

(알고리즘)

- (1) y 를 x_j 에 회귀시켜 회귀계수 $\hat{v}_{1j} = \langle x_j, y \rangle$, $j = 1, 2, \dots, p$ 를 계산한다.
- (2) 첫번째 PLS 방향인 $z_1 = \sum \hat{v}_{1j} X_j$ 을 구한다.
- (3) y 를 새롭게 유도된 변수 z_1 에 회귀시켜 회귀계수 $\hat{\theta}_1 = \langle z_1, y \rangle$ 을 계산한다.
- (4) $x_1, \dots, x_p$ 을 z_1 에 대해 직교화한다. 즉, $x_j - \frac{\langle z_1, x_j \rangle}{\langle z_1, z_1 \rangle} z_1$, $j = 1, \dots, p$
- (5) 위의 과정을 M 번째 방향까지 반복한다.

주성분 회귀와 마찬가지로 M 은 주로 교차확인법으로 구한다.

7.5 LASSO

7.5.1 LASSO의 정의와 추정

LASSO(Least Absolute Shrinkage and Selection Operator)는 티브쉬라니(Tibshirani, 1996)에 의해 제안된 편회 추정의 한 방법이며 다음과 같은 동기에서 제안되었다. 첫째, 변수선택은 해석하기 좋은 모형을 제공하지만 이산적 과정(특정 변수가 최종 선택된 모형에 포함되거나 제거되는 과정)으로 인해 변동성이 매우 심하다. 둘째, 능형회귀는 연속적 과정(특정 변수를 포함시키거나 제거시키는 대신 추정치의 값을 축소시키는 과정)으로 보다 안정적이지만 변수 선택의 기능이 없어 해석하기 좋은 모형을 제공하지 못한다. 따라서 변수 선택과 능형회귀의 장점인 모형해석의 용이함과 연속적 과정을 동시에 가진 방법이 필요한데 LASSO가 바로 그것이라고 주장한다. 즉, LASSO는 변수선택의 기능을 연속적 과정으로 수행한다는 것이다.

LASSO 추정법은 능형회귀와 매우 흡사한데, 능형회귀의 β 에 대한 제약조건이 제곱 형태(L_2 restriction)라면, LASSO는 제약조건이 절대값 형태(L_1 restriction)이다. 즉, LASSO는

$$\begin{aligned}\hat{\beta}_L &= \arg \min_{\beta} (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta) \text{ s.t. } \sum_{j=1}^p |\beta_j| \leq s \\ &= \arg \min_{\beta} (\mathbf{y} - \mathbf{X}\beta)'(\mathbf{y} - \mathbf{X}\beta) + \lambda \sum_{j=1}^p |\beta_j|\end{aligned}$$

으로 주어진다. 여기서, s 와 λ 는 일대일로 대응하는 미지의 모수인데 능형회귀의 편의모수처럼 추정되어야 할 값이다. 능형회귀는 편의모수가 주어지면 추정치가 식으로 주어지지만 LASSO 추정치는 s 가 주어지더라도 식으로 표현할 수 없는 단점이 있다. LASSO를 추정하기 위해 여러 가지 계산 방법이 있으나 그 중에서도 LARS(least angle regression)라는 알고리즘을 주로 사용하는데 이는 R 패키지에서 사용 가능하다.

특별한 경우로 설명변수가 한 개일 때는 LASSO 추정치가 식으로 간단히 표현된다. 먼저 반응변수와 설명변수가 중심화되었고(즉, $\sum y_i = 0$, $\sum x_i = 0$) $\sum x_i^2 = 1$ 이라고 가정하자. 이제 모형 $y_i = \beta x_i + \varepsilon_i$ 에서 LASSO 추정치는

$$\hat{\beta}_L(\lambda) = \text{sign}(\hat{\beta})(|\hat{\beta}| - \lambda)_+$$

으로 표현된다. 여기서 $(x)_+ = xI(x > 0)$ 인데 이는 다음과 같이 증명할 수 있다.

$$\begin{aligned}f(\beta) &= \frac{1}{2} \sum (y_i - x_i\beta)^2 + \lambda|\beta| \\ &= \frac{1}{2} \sum (y_i - x_i\hat{\beta} + x_i\hat{\beta} - x_i\beta)^2 + \lambda|\beta| \\ &= \frac{1}{2} \sum (y_i - x_i\hat{\beta})^2 + \frac{1}{2}(\hat{\beta} - \beta)^2 + \lambda|\beta|\end{aligned}$$

따라서, $f(\beta)$ 의 최소값은

$$\min_{\beta} f(\beta) \Leftrightarrow \min_{\beta} g(\beta) = \frac{1}{2}(\hat{\beta} - \beta)^2 + \lambda|\beta|$$

이므로 $\partial g(\beta)/\partial \beta = 0$ 의 해가 바로 LASSO 추정치가 된다.

LASSO 모수 s 를 추정하는 방법으로 교차확인법과 일반화 교차확인법 등이 있는데 여기서는 일반화 교차확인법을 소개한다. 먼저, 제약조건 $\sum |\beta_j| \leq s$ 을 $\sum \beta_j^2/|\beta_j| \leq s$ 으로

표현할 수 있는데 이 제약조건은 마치 능형회귀에서의 제곱형태 제약조건처럼 표현되므로 능형회귀 추정치를 이용할 수 있다. 즉, 이 제약조건하에서 능형회귀 추정치는

$$\tilde{\beta} = (X'X + \lambda W^-)^{-1} X'y$$

으로 표현할 수 있는데 여기서 $W = \text{diag}(|\tilde{\beta}_1|, \dots, |\tilde{\beta}_p|)$ 이고 λ 는 $\sum |\tilde{\beta}_j| = s$ 를 만족하는 값이다. 위의 식에서 W^{-1} 대신 일반화 역행렬 W^- 을 사용한 이유는 $\tilde{\beta}_j$ 들 중에서 0인 것이 있을 수 있기 때문이다. 따라서 모자행렬은

$$H_s = X(X'X + \lambda W^-)^{-1} X'$$

이 되고 이를 이용한 일반화 교차확인법은

$$GCV(s) = \frac{1}{n} \sum (y_i - \hat{y}_i)^2 / \left\{ 1 - \frac{1}{n} \text{tr}(H_s) \right\}^2$$


으로 표현된다. 일반화 교차확인법을 이용하여 축소모수 s 를 찾기 위해 s 를 0에서 조금씩 움직여 가면서 $GCV(s)$ 가 최소가 되는 s 를 격자 탐색법으로 구한다.

7.5.2 LASSO의 성질

(그림 7.3)에 주어진 능형회귀 추정치의 기하학적 의미와 LASSO 추정치의 기하학적 의미를 비교해 보자. 타원과 원이 접하는 점이 능형회귀 추정치가 되고 타원과 정사각형이 만나는 점이 LASSO 추정치임을 나타낸다. 타원과 원의 접점은 β_1 과 β_2 가 모두 양인 점에서 발생될 가능성이 높아서 능형회귀는 최소제곱추정치들을 축소시키는 기능만 가지는 반면 타원과 정사각형의 접점은 β_1 또는 β_2 가 0인 점에서 발생할 가능성이 높아서 최소제곱추정치의 축소 및 변수선택의 기능을 동시에 가지게 된다.


두 번째로 능형회귀 추정치는 오차항의 정규성 가정하에서 β 에 대한 사전분포가 정규분포로 주어질 때 베이스 추정치(즉, 사후분포의 평균)였는데 LASSO 추정치는 β 에 대한 사전분포가 이중지수분포로 주어질 때 사후분포의 최빈치(posterior mode)가 됨을 보일 수 있다.

마지막으로 LASSO 추정치를 다른 추정치와 비교하기 위해 직교정규디자인(orthonormal design)인 $X'X = I$ 를 가정하면 다음과 같이 표현할 수 있으며 (그림 7.4)에 잘 나타나 있다.



(그림 7.3) 능형 추정치(좌)와 LASSO 추정치(우)의 기하학적 의미

- (1) 변수선택 : $\hat{\beta}_{S,j} = \hat{\beta}_j I(|\hat{\beta}_j| > \lambda)$
- (2) 능형회귀 : $\hat{\beta}_{R,j} = \hat{\beta}_j / (1 + \lambda)$
- (3) LASSO : $\hat{\beta}_{L,j} = \text{sign}(\beta_j)(|\beta_j| - \lambda)_+$



(그림 7.4) 최소제곱추정치와의 비교((a) 변수선택, (b) 능형회귀, (c) LASSO)

(참고) lasso라는 일반명사(또는 동사)의 뜻은 야생말 등을 옴아매는 밧줄을 의미한다. 즉, 회귀계수를 올가미 밧줄로 일정한 값 이상으로 커지는 것을 막는다고 볼 수 있다. 티브쉬라니(Tibshirani, 1996)가 논문에서 밝힌 것처럼 LASSO 추정치는 브라이만(Breiman, 1995)의 거룻(garrotte) 추정치로 부터 아이디어를 얻었다고 한다. 거룻은 스페인에서 사용되던 교수형구 인데 이는 기둥에 달린 쇠고리에 목을 끼워 넣고 나사로 줄라 죽이는 것이라 한다. 거룻 추정치 역시 LASSO 추정치처럼 회귀계수를 축소시키는 방법으로 알려져 있다.

7.6 예제

본 예제에서 사용하게 될 자료는 전립선암(prostate cancer)에 대한 것인데 이는 스태미 등(Stamey et al., 1989)의 연구에서 나온 것이다. 이 자료는 전립선암 치료를 받아야 할 97명의 남성에 대한 것으로 자료는 아래의 R 패키지에서 볼 수 있는데 1개의 반응변수와 8개의 설명변수로 구성되어 있으며 각 변수에 대한 설명은 다음과 같다.


반응변수 :	lpsa (log of the level of prostate specific antigen : 전립선 항원 수준의 로그값)
설명변수 :	1. lcavol (log-cancer-volume : 암부피의 로그값)
	2. lweight (log prostate weight : 전립선 무게의 로그값)
	3. age (나이)
	4. lbph (log of benign prostatic hyperplasia amount : 양성 전립선 세포의 증식량의 로그값)
	5. svi (seminal vesicle invasion : 정낭 침입)
	6. lcp (log of capsular penetration : 정낭 침범정도의 로그값)
	7. gleason (Gleason score : 글리슨 수치)
	8. pgg45 (percent of Gleason scores 4 or 5 : 글리슨 수치가 4 또는 5의 퍼센트)

(그림 7.5)는 9개의 변수에 대한 산점도 행렬을 나타낸 것인데 svi는 이진자료 (0 또는 1)이고 글리슨 수치는 순서형 자료임을 알 수 있다. 또한, lcavol과 lcp가 반응변수인 lpsa와 상관관계가 뚜렷함을 알 수 있다. 설명변수들 간의 상관관계 행렬이 <표 7.3>에 주어져 있는데 몇 개의 변수들이 매우 높은 상관관계를 가짐을 알 수 있다.

우선 8개의 설명변수를 모두 사용하여 중선형회귀모형에 적합시킨 결과가 (그림 7.6)에 R의 출력 결과물로 주어져 있는데 lcavol, lweight, svi등이 큰 t 값을 나타내고 있다. 또한, 결정계수가 0.6548이고 F 통계량도 20.86으로 매우 큰 값을 가지므로 잘 적합된 모형으로 판단할 수 있다. 또한, 변수선택법을 적용하면 <표 7.4>에 주어진 것처럼 lcavol, lweight, svi등의 변수가 선택됨을 알 수 있다.

<표 7.3> 전립선암 자료에서 반응변수와 7개의 설명변수들 간의 상관계수를 나타낸 상관계수행렬

	lweight	age	lbph	svi	lcp	gleason	pgg45	lpsa
lcavol	0.194	0.225	0.027	0.539	0.675	0.432	0.434	0.734
lweight		0.308	0.435	0.109	0.100	-0.001	0.051	0.354
age			0.350	0.118	0.128	0.269	0.276	0.170
lbph				-0.086	-0.007	0.078	0.078	0.180
svi					0.673	0.320	0.458	0.566
lcp						0.515	0.632	0.549
gleason							0.752	0.369
pgg45								0.422



(그림 7.5) 전립선암 자료에서 반응변수와 7개의 설명변수들 간의 산점도를 나타낸 행렬도

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	2.47839	0.07193	34.456	< 2e-16 ***
lcavol	0.69188	0.10363	6.677	2.11e-09 ***
lweight	0.22570	0.08443	2.673	0.00896 **
age	-0.14620	0.08318	-1.758	0.08229 .
lbph	0.15531	0.08480	1.832	0.07040 .
svi	0.31719	0.10114	3.136	0.00233 **
lcp	-0.14748	0.12726	-1.159	0.24964
gleason	0.03260	0.11371	0.287	0.77503
pgg45	0.12763	0.12470	1.024	0.30886

 Residual standard error: 0.7084 on 88 degrees of freedom
 Multiple R-squared: 0.6548, Adjusted R-squared: 0.6234
 F-statistic: 20.86 on 8 and 88 DF, p-value: < 2.2e-16

(그림 7.6) 전립선암자료에 대한 최소제곱추정치의 R 출력결과물

그러나 설명변수간의 높은 상관관계로 인해 다중공선성이 존재할 수 있으므로 앞서 소개한 여러 가지 편의 추정법을 적용해 보자.

우선 능형회귀추정치를 구하기 위해 편의모수 θ 에 따른 회귀계수추정치의 변화하는 모습을 살펴 보자(그림 7.7). 편의모수를 추정하는 법은 앞에서 소개한 것 처럼 여러 가지 방법이 있으나 여기서는 GCV를 최소로 하는 값 6.5를 택하였으며 이에 근거한 능형회귀추정치가 <표 7.4>에 주어져 있다. 모든 회귀계수 추정치가 최소제곱 추정치보다 작음을 알 수 있다.


다음으로 LASSO 추정은 (그림 7.8)에 나타난 것 처럼 축소모수 s 를 0.6으로 추정하였으며 이에 근거한 추정치가 <표 7.4>에 주어져 있다. (그림 7.8)에 나타난 것 처럼 축소모수 s 가 1일 때는 최소제곱 추정치와 같으며 (그림에는 표준화된 추정치, 즉 회귀계수 추정치를 표준오차로 나눈 t 값이 주어져 있음), s 의 값이 작아짐에 따라 추정치의 값이 단순 감소하는 형태를 보여준다. 또한, s 의 값이 작아짐에 따라 어떤 추정치는 0으로 되어 변수선택에서 제외됨을 알 수 있다. 즉, LASSO 추정은 회귀계수를 축소시키는 역할과 변수선택 역할을 동시에 하고 있음을 알 수 있다. 이는 <표 7.4>에서도 쉽게 알 수 있으며 최종적으로 선택된 변수는 변수선택법의 결과와 유사하지만 선택된 변수들의 계수 추정치는 최소제곱추정치보다 더 작음을 알 수 있다.

주성분회귀는 7개의 주성분을 사용하였지다. 그러나, 실제로는 교차확인 등의 방법에 의해 사용하는 주성분 개수를 더 작게 해야 하지만 여기서는 주성분 개수를 크게하여 최소제곱추정치와 유사하게 나오는 경향을 확인하고자 하였다. 부분최소제곱법은 2개의 주성분을 사용하여 적합시킨 결과가 <표 7.4>에 주어져 있다.


한편, <표 7.4>를 얻기 위한 R 프로그램이 (그림 7.9)에 주어져 있으니 이를 이용하여 각자 결과를 확인해 보기 바란다.

<표 7.4> 전립선암 자료에 대한 최소제곱추정치, 단계적회귀에 의한 변수선택, 능형회귀추정치, LASSO 추정치, 주성분회귀추정치와 부분최소제곱추정치

변수명	최소제곱	변수선택	능형회귀	LASSO	주성분회귀	부분최소제곱
절편	2.478	2.478	2.478	2.478	2.478	2.478
lcavol	0.692	0.650	0.609	0.608	0.563	0.492
lweight	0.226	0.253	0.220	0.172	0.244	0.293
age	-0.146		-0.116		-0.112	-0.064
lbph	0.155		0.139	0.074	0.143	0.134
svi	0.317	0.276	0.288	0.235	0.301	0.276
lcp	-0.147		-0.059		0.055	0.141
gleason	0.033		0.044		0.206	0.002
pgg45	0.128		0.099	0.043	-0.126	0.021



(그림 7.7) 능형회귀에서 편의모수를 찾기 위한 GCV값과 능형 트레이스



(그림 7.8) LASSO 추정에서 축소모수를 추정하기 위한 CV값과 축소모수의 변화에 따른 추정치(오른쪽의 숫자는 설명변수 앞에 붙어 있는 숫자를 나타낸 것임)

```
library(faraway); attach(prostate)
X = as.matrix(scale(prostate[, -9])); y = lpsa

LSE = lm(y ~ X); summary(LSE)

library(MASS)
RIDGE = lm.ridge(y ~ X, lambda = seq(0,100,0.1)); plot(RIDGE)
coef(lm.ridge(y ~ X, lambda=6.5, scale=F), intercept=T)

library(lars)
LASSO = lars(X, y, type="lasso", normalize=F); plot(LASSO)
cv.lars(X, y, type="lasso", fraction=seq(0,1,by=0.1), se=F)
coef(LASSO, s=6, intercept=T)

library(pls)
PCR = pcr(y ~ X, scale=F, validation="CV"); summary(PCR)
coef(PCR, ncomp=7, intercept=T)

PLS = pls(y ~ X, ncomp=2, scale=F, validation="CV"); summary(PLS)
coef(PLS, ncomp=2, intercept=T)
```

(그림 7.9) 전립선암자료에 대한 R 코드

7.7 편의 추정치와 베이스 추정치

7.7.1 베이스 추정치

확률변수 X 의 밀도함수를 $f(x; \theta)$ 라 하자. 즉,

$$X \sim f(x; \theta)$$

인데 여기서 θ 는 모수이다. 비-베이지안(non-Bayesian or frequentist)의 입장에서는 모수를 알려져 있지 않은 상수로 취급하지만 베이지안은 모수 θ 를 또 다른 분포를 갖는 확률변수로 간주한다. 따라서 베이지안의 입장에서는 X 의 밀도함수 $f(x; \theta)$ 를 θ 가 주어졌을 때 X 의 분포, 즉 조건부 밀도함수로 간주한다. 이런 이유로 X 의 밀도함수를 $f(x|\theta)$ 로 표현하기도 한다. 즉,

$$X \sim f(x|\theta)$$

으로 나타내기도 한다. 이제 모수 θ 는 상수가 아니라 확률변수이므로 θ 의 밀도함수 $g(\theta; \gamma)$ 가 존재한다. 따라서

$$\theta \sim g(\theta; \gamma)$$

으로 표현할 수 있는데 여기서 γ 는 또 다른 모수이다. 이처럼 기존의 모수 θ 가 따르는 분포를 사전분포(prior distribution)라 부른다. 조건부 밀도함수 $f(x|\theta)$ 에 θ 의 사전분포 $g(\theta; \gamma)$ 를 곱하여 생긴 분포를 사후분포(posterior distribution)라 부르며 이는 실제로 X 와 θ 의 결합확률분포이지만 베이지안 입장에서는 x 가 주어졌을 때 θ 에 대한 조건부 분포로 간주한다. 이를 표현하면

$$g(\theta|x; \gamma) = \frac{f(x|\theta)g(\theta; \gamma)}{\int f(x|\theta)g(\theta; \gamma)d\theta}$$

으로 주어진다.

모수 θ 에 대한 추정치를 $\delta \equiv \delta(x)$ 라 하고 이에 대한 손실함수(loss function)를 $L(\theta, \delta)$ 라 하면 $L(\theta, \delta) = (\theta - \delta)^2$ 을 제곱 손실함수(squared error loss function), $L(\theta, \delta) = |\theta - \delta|$ 를 절대값 손실함수(absolute error loss function)라 부른다. 한편 손실함수의 기댓값,

즉 $R(\theta, \delta) = E[L(\theta, \delta)]$ 를 위험함수(risk function)라 부르는데 이 때 기댓값은 변수 X 에 대한 기댓값이다. 즉, 위험함수는

$$R(\theta, \delta) = \int_{\mathcal{X}} L(\theta, \delta) f(x|\theta) dx$$

으로 정의된다. 한편, 베이스 위험(Bayes risk)은 다음과 같이 정의된다.

$$r(\theta, \delta) = \int_{\Theta} R(\theta, \delta) g(\theta; \gamma) d\theta$$

즉, 베이스 위험은 위험함수를 θ 에 대해 기댓값을 구한 것으로 해석할 수 있다. 다시 말해서, 베이스 위험은 손실함수를 변수 X 와 모수 θ 에 대해 각각 기댓값을 취한 것이다. 따라서 베이스 위험은

$$\begin{aligned} r(\theta, \delta) &= \int_{\Theta} R(\theta, \delta) g(\theta; \gamma) d\theta \\ &= \int_{\Theta} \int_{\mathcal{X}} L(\theta, \delta) f(x|\theta) g(\theta; \gamma) dx d\theta \\ &= \int_{\mathcal{X}} \int_{\Theta} L(\theta, \delta) f(x|\theta) g(\theta; \gamma) d\theta dx \\ &= \int_{\mathcal{X}} E[L(\Theta, \delta) | X = x] dx \end{aligned}$$

으로 표현할 수 있는데 $E[L(\Theta, \delta) | X = x]$ 를 사후 위험(posterior risk)이라 부른다. 베이스 추정치(Bayes estimator)는 베이스 위험 또는 사후 위험을 최소화하는 추정치이다. 즉,

$$\hat{\delta}_{Bayes} = \underset{\delta}{\operatorname{argmin}} r(\theta, \delta)$$

인데 만약 제곱 손실함수가 주어지면 베이스 추정치는 사후분포의 평균임을 쉽게 보일 수 있고, 절대값 손실함수가 주어지면 베이스 추정치는 사후분포의 최빈값(posterior mode)임을 보일 수 있다.

7.7.2 슈타인 축소추정치와 경험적 베이스 추정치

베이스 추정치는 흔히 사전분포의 모수 γ 를 포함한다. γ 가 알려져 있는 경우에는 베이스 추정치를 추정치로 간주할 수 있지만 만약 알려져 있지 않다면 추정치로 간주할 수 없

다. 이 경우 γ 를 추정하기 위해, 사후분포를 모수 θ 에 대해 적분한 X 주변분포로부터 구할 수 있고, 이렇게 구한 γ 의 추정치를 베이스 추정치에 대입한 추정치를 경험적 베이스 추정치(empirical Bayes estimator)라 부른다. 따라서 경험적 베이스 추정치는 베이지안과 비-베이지안의 절충이라 볼 수 있다.

[정리 7.2] 확률벡터 z 의 분포가 $z \sim N_p(\mu, I)$ 이고 μ 에 대한 사전분포가 $\mu \sim N_p(0, \sigma^2 I)$ 으로 주어질 때 슈타인 축소 추정치는 제곱 손실함수 하에서 경험적 베이스 추정치가 된다.

[증명]

$$\begin{aligned} f(z|\mu)g(\mu) &\propto \exp\left[-\frac{1}{2}(z-\mu)'(z-\mu)\right] \exp\left[-\frac{1}{2\sigma^2}\mu'\mu\right] \\ &\propto \exp\left[-\frac{1}{2}(z'z - 2\mu'z + \mu'\mu + \frac{1}{\sigma^2}\mu'\mu)\right] \\ &\propto \exp\left[-\frac{1}{2}\left\{\left(1+\frac{1}{\sigma^2}\right)\mu'\mu - 2\frac{\sigma^2}{1+\sigma^2}\mu'z + \frac{\sigma^2}{1+\sigma^2}z'z\right\}\right] \end{aligned}$$

인데 여기서

$$w = \frac{\sigma^2}{1+\sigma^2}$$

라 두면 사후분포는

$$\begin{aligned} &\propto \exp\left[-\frac{1}{2w}(\mu'\mu - 2w\mu'z + w^2z'z)\right] \exp\left[-\frac{1}{2}(1-w)z'z\right] \\ &\propto \exp\left[-\frac{1}{2w}(\mu - wz)'(\mu - wz)\right] \exp\left[-\frac{1}{2}(1-w)z'z\right] \end{aligned}$$

으로 표현된다. 따라서 사후분포는

$$\mu|z \sim N_p(wz, wI)$$

이 된다. 베이스 추정치는 제곱 손실함수하에서 사후분포의 평균이므로

$$wz = \frac{\sigma^2}{1+\sigma^2}z = \left(1 - \frac{1}{1+\sigma^2}\right)z$$

이 베이스 추정치다. 그런데 이 베이스 추정치는 미지의 모수 σ^2 을 포함하고 있으므로 이를 추정하기 위해 z 의 주변분포를 이용한다. z 의 주변분포는

$$\int f(z|\mu)g(\mu)d\mu \propto \exp\left[-\frac{1}{2}(1-w)z'z\right] \sim N_p(0, (1+\sigma^2)I)$$

이 된다. 이를 σ^2 의 추정에 이용하기 위해 아래의 통계량을 정의한다.

$$V \equiv \frac{z'z}{1+\sigma^2} \sim \chi^2(p)$$

$$\begin{aligned} X &\sim N(0, \sigma^2) \\ \frac{X}{\sigma} &\sim N(0, 1) \\ \frac{X^2}{\sigma^2} &\sim \chi^2(1) \end{aligned}$$

이제,

$$E\left(\frac{1}{V}\right) = \int_0^\infty \frac{1}{v} \frac{v^{\frac{p}{2}-1} e^{-v/2}}{\Gamma(\frac{p}{2}) 2^{\frac{p}{2}}} dv = \frac{\Gamma(\frac{p}{2}-1) 2^{\frac{p}{2}-1}}{\Gamma(\frac{p}{2}) 2^{\frac{p}{2}}} = \frac{\Gamma(\frac{p}{2}-1)}{2(\frac{p}{2}-1)\Gamma(\frac{p}{2}-1)} = \frac{1}{p-2}$$

이므로

$$E\left[\frac{1+\sigma^2}{z'z}\right] = (p-2)^{-1} = E\left[\frac{(1+\sigma^2)}{z'z}\right] = \frac{1}{p-2}$$

이 된다. 따라서 $(1+\sigma^2)^{-1}$ 의 불편추정치는 $(p-2)/z'z$ 이 되며 최종적으로 경험적 베이스 추정치는

$$(1 - \frac{p-2}{z'z})z \quad \cdot \quad E\left(\frac{p-2}{z'z}\right) = \frac{1}{1+\sigma^2}$$

이며 이는 다름 아닌 슈타인 축소 추정치이다. $\square$

$$\therefore \text{ie. } \frac{1}{1+\sigma^2} \text{의 UE is } \frac{p-2}{z'z}$$

7.7.3 베이스 추정치와 회귀계수 추정치

오차항이 정규분포를 따르는 중선형모형

$$y = X\beta + \varepsilon, \varepsilon \sim N(0, \sigma^2 I)$$

을 고려하자. 이를 다시 표현하면 $y \sim N_n(X\beta, \sigma^2 I)$ 이 된다. 이제 β 에 대한 사전분포를

$$\beta \sim N_p(m, \sigma^2 V)$$

라 하면 제곱 손실함수 하에서 β 에 대한 베이스 추정치는 사후분포의 평균이므로 이를 위해 사후분포를 구해보자.

$$\exp\left[-\frac{1}{2\sigma^2}(y - X\beta)'(y - X\beta)\right] \exp\left[-\frac{1}{2\sigma^2}(\beta - m)'V^{-1}(\beta - m)\right]$$

$$\propto \exp\left[-\frac{1}{2\sigma^2}(\beta'X'X\beta + \beta'V^{-1}\beta - 2\beta'X'y - 2\beta'V^{-1}m + \dots)\right]$$

$$\propto \exp\left[-\frac{1}{2\sigma^2}\{\beta'(X'X + V^{-1})\beta - 2\beta'(V^{-1}m + X'y) + \dots\}\right]$$

$$\propto \exp\left[-\frac{1}{2\sigma^2}\{(\beta - \mu_\beta)'(X'X + V^{-1})(\beta - \mu_\beta)\}\right]$$

여기서 μ_β 를 사후분포의 평균이라 놓고 이를 구하기 위해 두면 위의 마지막 두 식을 같게

놓으면

$$-2\beta'(X'X + V^{-1})\mu_{\beta} \equiv -2\beta'(V^{-1}m + X'y)$$

이 되므로 사후분포의 평균은

$$\mu_{\beta} = (X'X + V^{-1})^{-1}(V^{-1}m + X'y) \equiv \tilde{\beta}_{Bayes}$$

이 된다.

위에서 유도한 베이스 추정치의 특별한 경우를 고려해 보자. 먼저, 주어진 $\lambda > 0$ 에 대하여 $V = \lambda^{-1}I_p$ 이고 $m = 0$ 이면

$$\tilde{\beta}_{Bayes} = (X'X + \lambda I)^{-1}X'y$$

이 되는데 이는 다름 아닌 능형회귀 추정치가 된다. 다음으로 $V = \lambda^{-1}(X'X)^{-1}$ 이고 $m = 0$ 이면

$$\tilde{\beta}_{Bayes} = (X'X + \lambda X'X)^{-1}X'y = (1 + \lambda)^{-1}\hat{\beta}$$

이 되는데 이를 흔히 재임스-슈타인 회귀 추정치(James-Stein regression estimator)라 부른다. $\lambda > 0$ 이므로 재임스-슈타인 추정치는 최소제곱추정치를 축소시키는 추정치라고 할 수 있다.

연습문제 (7)

[이론 문제]

7.1 능형 추정치 $\hat{\beta}(\theta) = (X'X + \theta I)^{-1}X'y$ 의 평균오차제곱 행렬 $MSE(\theta)$ 에서

$$\begin{aligned} \text{tr}[MSE(\theta)] &= \sigma^2 \text{tr}[(X'X + \theta I)^{-1}X'X(X'X + \theta I)^{-1}] + \theta^2 \beta'(X'X + \theta I)^{-2}\beta \\ &= \sigma^2 \sum_{j=1}^p \frac{\lambda_j}{(\lambda_j + \theta)^2} + \theta^2 \beta'(X'X + \theta I)^{-2}\beta \end{aligned}$$

임을 보여라. 단, $\lambda_1, \dots, \lambda_p$ 는 $X'X$ 의 고유치이다. 이를 바탕으로 θ 가 증가함에 따라 분산은 감소하고 편의는 커짐을 보여라.

7.2 능형 추정치 $\hat{\beta}(\theta) = (X'X + \theta I)^{-1}X'y$ 는 $X'X \leq c^2$ 이라는 조건하에서 $(y - X'\beta)'(y - X'\beta)$ 를 β 에 대해서 최소화 한 것임을 보여라. 또한, c 와 θ 는 일대일로 대응됨을 보여라.

7.3 β 의 사전분포가 $\beta \sim N(0, \frac{\sigma^2}{\theta} I)$ 일 때 능형추정치 $\hat{\beta}(\theta)$ 는 제곱오차 손실함수 하에서 β 의 베이스 추정치임을 보여라.

[응용 문제]

7.1 <표 7.1>에 주어진 체내지방자료에 대해 LASSO, PCR, PLS 추정치를 구하라.

제 8 장

일반화 선형모형 I

- 8.1 자료와 통계적 모형의 분류
- 8.2 지수분포군
- 8.3 일반화 선형모형의 구성
- 8.4 회귀계수의 추정
- 8.5 모형의 적합도
- 8.6 가설검정과 잔차
- 8.7 분산분석모형

지금까지는 반응변수가 연속형일 때 설명변수와의 관계를 선형모형으로 가정한 회귀모형에 대해 연구하였다. 더욱이 회귀계수의 추정치에 대한 분석에는 반응변수가 연속형이면서 동시에 정규분포를 따른다는 가정이 필요했었다. 만약, 반응변수가 연속형이 아닌 이산형일 경우는 어떤가? 이 장에서는 반응변수가 정규분포 뿐만 아니라 이항분포, 포아송 분포 등을 따를 때 설명변수와의 관계를 모형화 하는 것에 대해 소개하고 분석방법을 설명한다. 이러한 모형들을 총체적으로 일반화 선형모형(*generalized linear model*)이라 부른다. 그리고 이와 대비하여 6장까지 설명되었던 회귀모형을 고전적 회귀모형(*classical linear model*)이라 부르기도 한다.

8.1 자료와 통계적 모형의 분류

자료의 분류는 기본적으로 변수의 분류(1.1.2절 참조)와 같다. 자료는 크게 범주형(categorical)자료와 연속형(continuous)자료로 구분되고, 범주형자료는 질적(qualitative)자료라고도 하며, 다시 명목형(nominal)자료와 순서형(ordinal)자료로 구분된다. 명목형자료는 단지 구분을 위한 것으로 숫자의 대응 개념이 없다. 예를 들어, 성별(남 - 0, 여 - 1), 인종(황인 - 0, 백인 - 1, 흑인 - 2) 등인데 성별의 경우 남자를 1, 여자를 0으로 하더라도 아무런 문제가 없다. 이에 비해 순서형자료는 구분을 위한 것으로 숫자의 대응 개념이 있다. 예를 들어, 연령(유아 - 0, 청소년 - 1, 장년 - 2, 노년 - 3), 김치를 좋아하는 정도(매우 싫다 - 0, 조금 싫다 - 1, 보통 - 2, 조금 좋다 - 3, 매우 좋다 - 4) 등인데, 연령의 경우 유아를 2, 청소년을 4 등으로 놓을 수 없고 크기 순으로 분류 되어야 한다.

범주형자료는 범주의 개수가 2개인 경우를 이진(binary 또는 dichotomous)자료, 3개 이상인 경우를 다진(polytomous)자료라 부른다. 범주형자료는 각 범주에 속하는 반응치의 개수 또는 도수로 기록되며, 이러한 도수를 흔히 이산형(discrete)자료라 부른다. 또한, 설명변수가 범주형일 경우 그 변수를 요인(factor)이라 부르고, 이 때 각 범주를 그 요인의 수준(level)이라 한다.

통계적 모형은 반응변수와 설명변수가 어떤 형태의 자료를 가지느냐에 따라 <표 8.1>과 같이 도식화 할 수 있다.

<표 8.1> 자료의 종류에 따른 통계적 모형의 분류

반응변수 설명변수	범주형 자료	연속형 자료
범주형 자료	· $r \times c$ 분할표 · 로지스틱 모형 또는 로그 선형 모형	· 분산분석(ANOVA)모형
연속형 자료	· 로지스틱 모형	· 중선형회귀모형
연속형과 범주형 자료의 혼합	· 로지스틱모형	· 공분산분석(ANOCOVA) 및 가변수모형

중선형회귀모형은 앞에서 많이 다루었던 내용이고, 고전적 회귀모형을 이용한 분산분석과 공분산분석은 6.1.3절에서 가변수를 이용한 모형으로 소개되었다. 일반화 선형모형을 이용한 분산분석은 8.7절에서, 로지스틱 회귀모형과 로그 선형모형은 9장에 소개된다.

8.2 지수 분포군

확률변수 Y 가 갖는 확률밀도함수 $f(y; \theta, \phi)$ 가

$$f(y; \theta, \phi) = \exp \left[\frac{y\theta - b(\theta)}{a(\phi)} + c(y, \phi) \right] \quad (8.1)$$

의 형태로 표현되고 ϕ 가 알려져 있을 때, Y 의 분포는 자연모수(natural parameter or canonical parameter) θ 인 지수분포군(exponential family)에 속한다고 한다. 여기서, $a(\cdot)$, $b(\cdot)$, $c(\cdot, \cdot)$ 는 알려져 있는 함수이다. 만약, 모수 ϕ 가 알려져 있지 않다면 식 (8.1)의 분포는 이모수 지수분포군(two-parameter exponential family)이 될 수도 있고 안 될 수도 있다. 지수분포군에 대한 좀 더 자세한 내용은 반도르프-닐슨(Barndorff-Nielsen, 1978)을 참고하기 바란다. 실제로 우리가 흔히 사용하고 있는 많은 분포들이 지수분포군에 속하는데, 정규분포(분산이 알려져 있는 경우), 이항분포, 포아송분포 등이 여기에 해당된다.

예제 8.1 (정규분포) $Y \sim N(\mu, \sigma^2)$ 이고 σ^2 이 알려져 있다고 하면

$$f(y; \theta, \phi) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{(y - \mu)^2}{2\sigma^2} \right\} = \exp \left\{ \frac{1}{\sigma^2} \left(y\mu - \frac{\mu^2}{2} \right) - \frac{1}{2} \left(\frac{y^2}{\sigma^2} + \log(2\pi\sigma^2) \right) \right\}$$

이므로 $\theta = \mu$, $\phi = \sigma^2$ 이 되고

$$a(\phi) = \phi, \quad b(\theta) = \frac{\theta^2}{2}, \quad c(y, \phi) = -\frac{1}{2} \left\{ \frac{y^2}{\sigma^2} + \log(2\pi\sigma^2) \right\}$$

인 지수분포군에 속한다. □

예제 8.2 (포아송분포) $Y \sim P(\lambda)$ 이면

$$f(y; \theta, \phi) = \lambda^y e^{-\lambda} / y! = \exp(y \log \lambda - \lambda - \log y!), \quad y = 0, 1, 2, \dots$$

이므로 $\theta = \log \lambda$, $\phi = 1$ 이 되고

$$a(\phi) = 1, \quad b(\theta) = e^\theta, \quad c(y, \phi) = -\log y!$$

인 지수분포군에 속한다. □

예제 8.3 (이항분포) $Y \sim B(n, \pi)$ 이면

$$\begin{aligned} f(y; \theta, \phi) &= \binom{n}{y} \pi^y (1 - \pi)^{n-y}, \quad y = 0, 1, \dots, n \\ &= \exp \left\{ \frac{\frac{1}{n} y \log \left(\frac{\pi}{1 - \pi} \right) + \log(1 - \pi)}{1/n} + \log \binom{n}{y} \right\} \end{aligned}$$

이므로 $\theta = \log \left(\frac{\pi}{1 - \pi} \right)$, $\phi = 1/n$ 이 되고

$$\pi = \frac{e^\theta}{1 + e^\theta}$$

$$a(\phi) = \phi, \quad b(\theta) = \log(1 + e^\theta), \quad c(y, \phi) = \log \binom{1/\phi}{y}$$

인 지수분포군에 속한다. □

확률밀도함수 $f(y; \theta, \phi)$ 는 모수 θ 가 주어졌을 때 (여기서 모수 ϕ 는 알려져 있거나 관심 없는 모수(nuisance parameter)로 취급함) y 의 함수이지만, 역으로 y 가 주어졌을 때 θ 의 함수로 해석하면 우도함수(likelihood function)가 된다. 이 우도함수에 로그를 취하면 로그 우도함수가 되고 $l(\theta; \phi, y)$ 로 나타낸다. 즉,

$$l(\theta; \phi, y) = \log f(y; \theta, \phi)$$

으로 나타내고, 혼동의 염려가 없을 때 흔히 $l(\theta; \phi, y)$ 를 간단히 l 로 나타낸다. 로그 우도함수 l 의 θ 에 대한 일차 도함수와 이차 도함수를 구하여 기댓값을 취하면 다음의 두 식이 성립함을 쉽게 보일 수 있다.

[정리 8.1]

$$E \left(\frac{\partial l}{\partial \theta} \right) = 0 \tag{8.2}$$

$$E \left(\frac{\partial^2 l}{\partial \theta^2} \right) + E \left[\left(\frac{\partial l}{\partial \theta} \right)^2 \right] = 0 \quad \text{i.e.} \quad E \left[\frac{\partial^2 l}{\partial \theta^2} \right] \leq 0 \tag{8.3}$$

[증명] $f(y; \theta)$ 를 Y 의 확률밀도함수, l 을 로그 우도함수라 하자. 또한, 미분과 적분의 순서를 바꿀 수 있다는 가