

306 제 8 장 일반화 선형모형 I

정하에서 다음이 성립된다.

$$E\left(\frac{\partial l}{\partial \theta}\right) = \int \frac{1}{f(y; \theta)} \left(\frac{\partial}{\partial \theta} f(y; \theta)\right) f(y; \theta) dy = \int \frac{\partial}{\partial \theta} f(y; \theta) dy = \frac{\partial}{\partial \theta} \int f(y; \theta) dy = 0.$$

한편,

$$\frac{\partial^2 l}{\partial \theta^2} = \frac{\partial}{\partial \theta} \left(\frac{\frac{\partial}{\partial \theta} f(y; \theta)}{f(y; \theta)} \right) = \frac{\frac{\partial^2}{\partial \theta^2} f(y; \theta)}{f(y; \theta)} - \left\{ \frac{\frac{\partial}{\partial \theta} f(y; \theta)}{f(y; \theta)} \right\}^2$$

따라서 양변에 기댓값을 취하면

$$E\left(\frac{\partial^2 l}{\partial \theta^2}\right) = \int \frac{\partial^2}{\partial \theta^2} f(y; \theta) dy - E\left[\left(\frac{\partial l}{\partial \theta}\right)^2\right] = \frac{\partial^2}{\partial \theta^2} \int f(y; \theta) dy - E\left[\left(\frac{\partial l}{\partial \theta}\right)^2\right] = -E\left[\left(\frac{\partial l}{\partial \theta}\right)^2\right].$$

흔히 일차도함수 $U = \frac{\partial l}{\partial \theta}$ 를 스코어 함수(score function), 그리고

$$-E\left(\frac{\partial^2 l}{\partial \theta^2}\right) = E\left[\left(\frac{\partial l}{\partial \theta}\right)^2\right]$$

을 피셔 정보량(Fisher information number)이라고 부른다.

위의 두 식을 지수분포군에 적용시켜 보자. 우선, 지수분포군에 속하는 분포의 로그 우도함수는

$$l(\theta; y) = \frac{\{y\theta - b(\theta)\}}{a(\phi)} + c(y, \phi)$$

이므로 $l(\theta; y)$ 의 모수 θ 에 대한 일차 및 이차 도함수는 각각

$$\frac{\partial l}{\partial \theta} = \frac{\{y - b'(\theta)\}}{a(\phi)} \Rightarrow 0 = E\left[\frac{\partial l}{\partial \theta}\right] = E\left[\frac{y - b'(\theta)}{a(\phi)}\right] = 0 \quad (8.4)$$

$$\frac{\partial^2 l}{\partial \theta^2} = -\frac{b''(\theta)}{a(\phi)} \quad (8.5)$$

으로 주어진다. 위에서 $b'(\theta)$ 와 $b''(\theta)$ 는 $b(\theta)$ 의 θ 에 대한 일차 및 이차 도함수를 나타낸다.

식 (8.2)를 식 (8.4)에 적용시키면

$$E(Y) = \mu = b'(\theta)$$

이 성립되고, 식 (8.3)을 식 (8.5)에 적용시키면 $-\frac{b''(\theta)}{a(\phi)} + \frac{Var(Y)}{a^2(\phi)} = 0$ 이므로

$$Var(Y) = b''(\theta)a(\phi)$$

의 관계가 성립된다. 여기서, $b''(\theta)$ 를 분산함수(variance function)라고 부르며, ϕ 를 산포모수(dispersion parameter)라 한다. 또한, θ 는 $\mu = E(Y)$ 의 함수로 표현이 가능하며, 흔히 분산함수를 $V(\mu)$ 로 나타낸다.

8.3 일반화 선형모형의 구성

일반화 선형모형(GLM : Generalized Linear Models)은 넬더와 웨더번(Nelder & Wedderburn, 1972)에 의해 처음으로 체계화된 것으로 고전적 회귀모형을 확장하여 이산형 반응변수의 경우도 분석이 가능하게 하는 모형이다. 참고문헌으로는 맥컬러그와 넬더(McCullagh & Nelder, 1989), 돕슨(Dobson, 1990) 등이 있다. 일반화 선형모형은 다음의 세 부분으로 구성된다.

- (1) 반응변수 : 서로 독립인 반응변수 $Y_1, \dots, Y_n$ 의 분포는 지수분포군에 속한다.
- (2) 선형 예측치(linear predictor) : 설명변수 $X_1, \dots, X_{p-1}$ 의 선형결합

$$\eta = \sum_{j=0}^{p-1} X_j \beta_j = X^T \beta$$

$X = \begin{pmatrix} 1 & x_{11} & \dots & x_{1,p-1} \\ \vdots & \vdots & & \vdots \\ 1 & x_{n1} & \dots & x_{n,p-1} \end{pmatrix}^T$
 $\beta = (\beta_0, \beta_1, \dots, \beta_{p-1})^T$

를 선형 예측치라고 한다(단, $X_0 \equiv 1$).

- (3) 연계함수(link function) : 반응변수 Y_i 의 평균 μ_i 와 선형 예측치 η_i 는 $g(\mu_i) = \eta_i$ 라는 관계를 가지고 g 를 연계함수라 부른다. 흔히 g 는 미분 가능한 단조함수(monotone and differentiable)이다.

$$\eta = g(\mu)$$

예제 8.4 (고전적 선형모형) 우리가 지금까지 다루었던 고전적 선형모형에서는 반응변수 $Y_1, \dots, Y_n$ 이 서로 독립이며 정규분포를 따르고, Y_i 의 평균 μ_i 가

$$E(Y_i) = \mu_i = \sum_{j=0}^{p-1} x_{ij} \beta_j = \eta_i$$

이므로, 이것은 연계함수가 항등함수(identity function)인 일반화 선형모형의 특수한 형태로 볼 수 있다.

$$\eta_i = \mu_i \Leftarrow g(\mu_i) = \mu_i$$

일반적으로 일반화 선형모형은 연계함수를 어떻게 정의하느냐에 따라 무수히 많은 모형이 될 수 있다. 그러나 연계함수를 정의 할 때는 반응변수의 분포를 고려해야 하며 자료의 특성을 잘 나타내는 연계함수를 사용해야 한다. 예를 들어, 반응변수가 이항분포를 따를 때는 주로 다음의 세 가지가 사용된다.

- log (odds ratio) = logit*
- (1) 로짓(logit) : $\eta = \log\{\mu/(1-\mu)\}$, $0 < \mu < 1$
- (2) 프로빗(probit) : $\eta = \Phi^{-1}(\mu)$, $\Phi(\cdot)$ 는 정규분포의 누적분포함수
- (3) 부 로그-로그(complementary log-log) : $\eta = \log\{-\log(1-\mu)\}$

그러나 이 세 가지 중에서 어떤 연계함수가 가장 좋다는 규칙은 없으며, 자료의 특성에 따라 선택하는 것이 일반적이다. 이처럼, 연계함수에는 여러 가지가 있을 수 있으나, 그 중에서도 식 (8.1)에 주어진 지수족의 확률밀도함수에서

$$\theta = \eta$$

라는 식을 만족하는 연계함수를 특별히 자연연계함수(natural link or canonical link)라 부른다. 몇가지 지수족 분포에 대한 자연연계함수는 다음과 같다.

- 정규분포 : $\eta = \mu$ *identity*
- 포아송 분포 : $\eta = \log \mu$ *log*
- 이항분포 : $\eta = \log\{\mu/(1-\mu)\}$ *logit*
- 감마분포 : $\eta = \mu^{-1}$
- 역가우스분포 : $\eta = \mu^{-2}$

각 분포의 산포 모수, 평균, 분산함수, 자연연계함수 등이 <표 8.2>에 요약되어 있다.

<표 8.2> 지수분포군에 속하는 분포들의 특성치

분포	정규분포	포아송 분포	이항 분포	감마분포	역가우스 분포
기호	$N(\mu, \sigma^2)$	$P(\mu)$	$B(m, \pi)$	$G(\mu, \nu)$	$IG(\mu, \sigma^2)$
산포모수	σ^2	1	$1/m$	ν^{-1}	σ^2
$b(\theta)$	$\theta^2/2$	e^θ	$\log(1+e^\theta)$	$-\log(-\theta)$	$-(-2\theta)^{1/2}$
$\mu(\theta)$	θ	e^θ	$e^\theta/(1+e^\theta)$	$-1/\theta$	$(-2\theta)^{-1/2}$
자연연계함수	항등	로그	로짓	역함수	$1/\mu^2$
$V(\mu)$	1	μ	$\mu(1-\mu)$	μ^2	μ^3

8.4 회귀계수의 추정

고전적 선형모형 $y = X\beta + \epsilon$ 에서 회귀계수 β 의 추정은 최소제곱추정법에 의해 $\hat{\beta} = (X'X)^{-1}X'y$ 로 주어졌다. 또한, y 의 분포가 정규분포이면 β 의 최우추정량도 같은 값으로 주어짐을 보였다. 일반화 선형모형에서 선형예측치에 나타나는 회귀계수 β 의 추정은 최우추정법으로 구한다. 즉, 로그 우도함수를 β 에 대해 한 번 미분한 값인 스코어 함수를 0으로 놓고 그 해를 구하면 된다. 그러나 많은 경우

$$\frac{\partial l}{\partial \beta} = \left(\frac{\partial l}{\partial \beta_j} \right)_{j=0, \dots, p-1} = 0$$

이라는 식은 β 에 대해 비선형이므로 위 식의 해가 간단한 식으로 표현될 수 없다. 이런 상황에서는 반복법(iterative method)을 사용하여 해의 근사적인 값을 구하는 수 밖에 없다. 가장 널리 사용되는 반복법으로는 뉴턴-랩슨방법(Newton-Raphson method)과 피셔의 스코어링방법(Fisher's method of scoring)등이 있는데, 이는 모두 테일러전개식(Taylor expansion)을 이용한 것이다. y 를 μ 근처의 값이라고 하고 함수 f 가 μ 에서 미분가능할 때 $f(y)$ 를 μ 에 대해 1차 테일러 전개하면

$$f(y) \simeq f(\mu) + (y - \mu)f'(\mu)$$

가 된다. 이 사실을 $\partial l / \partial \beta_j$ 에 적용해 보면

$$0 = \frac{\partial l}{\partial \beta_j} \quad (8.6)$$

$$\simeq \left. \frac{\partial l}{\partial \beta_j} \right|_{\beta_j = \hat{\beta}_j^{(0)}} + (\beta_j - \hat{\beta}_j^{(0)}) \cdot \left. \frac{\partial^2 l}{\partial \beta_j^2} \right|_{\beta_j = \hat{\beta}_j^{(0)}}, \quad j = 0, \dots, p-1 \quad (8.7)$$

이 된다. 여기서, $\hat{\beta}_j^{(0)}$ 는 적당한 초기치(initial value)로서, 사용자가 β_j 에 가깝다고 여겨지는 임의의 값을 대입하면 된다. 식 (8.6)을 모든 $j = 0, 1, \dots, p-1$ 에 대해 한꺼번에 벡터 및 행렬로 표현해 보면

$$0 = \frac{\partial l}{\partial \beta} \simeq \underbrace{\left. \frac{\partial l}{\partial \beta} \right|_{\beta = \hat{\beta}^{(0)}}}_{\text{Score Vector}} + \underbrace{\left. \frac{\partial^2 l}{\partial \beta \partial \beta'} \right|_{\beta = \hat{\beta}^{(0)}}}_{\text{Hessian matrix}} \cdot (\beta - \hat{\beta}^{(0)})$$

이 된다. 위의 식은 β 에 대한 일차방정식이므로 이것의 해를 $\hat{\beta}^{(1)}$ 이라고 하면 $\hat{\beta}^{(1)}$ 은 다음

과 같이 주어진다.

$$\hat{\beta}^{(1)} = \hat{\beta}^{(0)} + A^{-1}(\hat{\beta}^{(0)}) \cdot U(\hat{\beta}^{(0)})$$

단, 여기서 $A^{-1}(\hat{\beta}^{(0)})$ 는 $p \times p$ 행렬

$$A(\hat{\beta}^{(0)}) = - \left[\frac{\partial^2 l}{\partial \beta \partial \beta'} \Big|_{\beta = \hat{\beta}^{(0)}} \right]$$

의 역행렬이며 $U(\hat{\beta}^{(0)})$ 는

$$U(\hat{\beta}^{(0)}) = \left[\frac{\partial l}{\partial \beta} \Big|_{\beta = \hat{\beta}^{(0)}} \right]$$

로 주어진다. 다음 단계에서는 $\hat{\beta}^{(1)}$ 을 초기치로 하여 위의 과정을 되풀이 한다. 이러한 과정을 반복하면

$$\hat{\beta}^{(t+1)} = \hat{\beta}^{(t)} + A^{-1}(\hat{\beta}^{(t)}) \cdot U(\hat{\beta}^{(t)}), \quad t = 0, 1, \dots \quad (8.8)$$

이 되는데 인접한 두 단계에서 $\hat{\beta}^{(t+1)}$ 과 $\hat{\beta}^{(t)}$ 의 값이 비슷해질 때까지 반복한다. 이러한 방법을 뉴턴-랩슨방법이라고 부른다. 그리고 이차 도함수 행렬 A 대신 피셔정보행렬

$$I = -E \left(\frac{\partial^2 l}{\partial \beta \partial \beta'} \right)$$

을 사용하여 위의 과정을 반복하는 방법을 피셔의 스코어링방법이라 부른다.

[정리 8.2] 피셔의 스코어링방법에서 U 와 I 를 구체적으로 구해보면

$$U = X'W(y - \mu) \frac{\partial \eta}{\partial \mu} \quad (8.9)$$

로 표현되는데 $W = \text{diag}(w_{ii}) = V^{-1} \left(\frac{\partial \mu}{\partial \eta} \right)^2$ 이고 $V = a(\phi) \text{diag}(\nu_{ii})$ 이며

$$I = X'WX \quad (8.10)$$

가 된다.

[증명] 먼저, $U = (U_0, \dots, U_{p-1})'$ 를 계산해 보면

$$U_j = \frac{\partial l}{\partial \beta_j} = \sum \frac{\partial l_i}{\partial \beta_j} = \sum \frac{\partial l_i}{\partial \theta_i} \frac{\partial \theta_i}{\partial \mu_i} \frac{\partial \mu_i}{\partial \eta_i} \frac{\partial \eta_i}{\partial \beta_j}$$

인데

$$l = \sum l_i = \sum \left[\frac{y_i \theta - b_i(\theta)}{a(\phi)} + c(y_i, \phi) \right] = \frac{1}{a(\phi)} \sum \{y_i \theta - b_i(\theta)\} + \sum c(y_i, \phi)$$

이므로

$$\begin{aligned} \frac{\partial l_i}{\partial \theta} &= \frac{1}{a(\phi)} (y_i - b'_i(\theta)) = \frac{1}{a(\phi)} (y_i - \mu_i) \\ \frac{\partial \theta}{\partial \mu_i} &= \left(\frac{\partial \mu_i}{\partial \theta} \right)^{-1} = \left(\frac{\partial b'_i(\theta)}{\partial \theta} \right)^{-1} = \frac{1}{\nu_{ii}} \\ \frac{\partial \eta_i}{\partial \beta_j} &= x_{ij} \end{aligned}$$

이 되고

$$U_j = \sum_i \frac{(y_i - \mu_i)}{a(\phi)} \frac{1}{\nu_{ii}} \frac{\partial \mu_i}{\partial \eta_i} x_{ij} = \sum_i (y_i - \mu_i) w_{ii} \frac{\partial \eta_i}{\partial \mu_i} x_{ij}$$

이다. 단, 여기서 $w_{ii} = \left(\frac{\partial \mu_i}{\partial \eta_i} \right)^2 / a(\phi) \nu_{ii}$ 이다. 따라서 식 (8.8)이 성립 된다.

한편, $I = (I_{jk})$, $j, k = 0, \dots, p-1$ 를 구해 보면,

$$\begin{aligned} I_{jk} &= -E \left(\frac{\partial^2 l}{\partial \beta_j \partial \beta_k} \right) = -E \left(\frac{\partial U_j}{\partial \beta_k} \right) \\ &= -E \left[\frac{\partial}{\partial \beta_k} \left\{ \sum (y_i - \mu_i) w_{ii} \frac{\partial \eta_i}{\partial \mu_i} x_{ij} \right\} \right] \\ &= \sum \frac{\partial \mu_i}{\partial \beta_k} w_{ii} \frac{\partial \eta_i}{\partial \mu_i} x_{ij} = \sum \frac{\partial \eta_i}{\partial \beta_k} w_{ii} x_{ij} = \sum x_{ik} w_{ii} x_{ij} \end{aligned}$$

이다. 따라서 식 (8.9)가 된다. □

그런데 피셔의 스코어링 방법은

$$\hat{\beta}^{(t+1)} = \hat{\beta}^{(t)} + I^{-1}(\hat{\beta}^{(t)}) U(\hat{\beta}^{(t)})$$

이므로 양변의 왼쪽에 정보행렬 $I(\hat{\beta}^{(t)})$ 를 곱하면

$$I(\hat{\beta}^{(t)}) \hat{\beta}^{(t+1)} = I(\hat{\beta}^{(t)}) \hat{\beta}^{(t)} + U(\hat{\beta}^{(t)}) \quad (8.11)$$

이 된다. 이 식의 좌변에 식 (8.9)를 대입하면

$$X' W X \hat{\beta}^{(t+1)} \quad (8.12)$$

이 되고, 우변에 식 (8.8)과 (8.9)를 대입하면

$$\begin{aligned}
 & X'W\hat{\beta}^{(t)} + X'W(y - \hat{\mu})\frac{\partial \eta}{\partial \mu} \\
 &= X'W \left\{ \hat{\eta}^{(t)} + (y - \hat{\mu}^{(t)})\frac{\partial \eta}{\partial \mu} \right\} \\
 &= X'Wz^{(t)}
 \end{aligned} \tag{8.13}$$

가 된다. 여기서, $\hat{\eta}^{(t)} = X\hat{\beta}^{(t)}$, $\hat{\mu}^{(t)} = g^{-1}(\hat{\eta}^{(t)})$ 이고

$$z^{(t)} = \hat{\eta}^{(t)} + (y - \hat{\mu}^{(t)})\frac{\partial \eta}{\partial \mu}$$

로 정의되며, 이 $z^{(t)}$ 를 교정된 반응변수(adjusted dependent variable)라고 한다. 식 (8.11)과 (8.12)를 같게 놓으면 다음의 방정식

$$X'WX\hat{\beta}^{(t+1)} = X'Wz^{(t)}, \quad t = 0, 1, \dots$$

$$X^TWX\hat{\beta} = X^TWy$$

↑
weighted
LSE

을 얻을 수 있는데 이것은 가중 최소제곱 추정에서의 정규방정식의 형태를 하고 있다. 이런 이유로, 일반화 선형모형에서 최우추정법에 사용되는 뉴튼-랩슨 방법이나 피셔의 스코어링방법을 흔히 반복 가중 최소제곱(IRLS : Iterative Reweighted Least Squares)추정법이라고 부른다.

8.5 모형의 적합도

일반화 선형모형에서 모형의 적합을 나타내는 측도를 구하기 위해 우선 최대모형(maximal model)을 정의한다. 최대모형이란 관측치의 개수만큼 모수를 사용하여 얻어진 모형이다. 즉, 모수의 개수를 최대한 많이 사용하여 얻어진 포화상태의 모형을 의미한다. 이런 이유로 최대모형을 흔히 포화모형(saturated model)이라고도 한다. 이와는 반대로, 모수를 최소한 작게(흔히 한 개) 사용한 모형을 최소모형(minimal model or null model)이라고 부르며, 이는 최대모형과 정반대의 의미를 가지고 있다. 현재 우리가 적합한 모형이 p 개의 모수를 사용한 모형이라 가정하면 이런 모형을 현재모형(current model)이라고 부른다. 일반화 선형모형에서 모형의 적합도는 현재모형이 최대모형과 비교하여 어느 정도 반응변수를 잘 설명해 주느냐의 정도를 가지고 이루어진다. 이 개념은 바로 가설검정에서 우도비 검정(likelihood ratio test)의 개념과 동일하다.

최대모형하에서 β 에 대한 최우추정량을 $\hat{\beta}_{max}$ 라 하고, 현재모형하에서 β 에 대한 최우추정량을 $\hat{\beta}$ 라고 하자. 또한, 우도함수를 L 이라고 하면 우도비 통계량은

$$\lambda = \frac{L(\hat{\beta}_{max}; y)}{L(\hat{\beta}; y)}$$

가 된다. 만약, 현재모형의 적합도가 좋다면 λ 는 1에 가까운 값이 되고, 그렇지 않으면 λ 는 매우 큰 값을 갖게 된다. 이에 착안하여 넬더와 웨더번(Nelder & Wedderburn, 1972)은 모형의 적합도를 판단하는 값으로

$$D = 2\log \lambda = 2[l(\hat{\beta}_{max}; y) - l(\hat{\beta}; y)] \quad (8.14)$$

를 제안하였으며 이를 데이언스(deviance)라 부른다. 데이언스 D 는 근사적으로 자유도 $n - p$ 인 χ^2 분포를 따른다는 것을 보일 수 있으므로 D 의 값이 $\chi^2_{\alpha}(n - p)$ 보다 크면 현재 모형의 적합도가 좋지 않다고 판단한다.

예제 8.5 (정규분포) $Y_1, \dots, Y_n$ 이 서로 독립이고 $N(\mu_i, \sigma^2)$ 을 따를 때 데이언스를 구해 보자. 로그 우도함수는 다음과 같이 주어진다.

$$l(\beta; y) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu_i)^2 - \frac{n}{2} \log(2\pi\sigma^2)$$

이 경우 최대모형을 $E(Y_i) = \mu_i, i = 1, \dots, n$ 이라 두면 모수 μ_i 의 최우추정치는 $\hat{\mu}_i = y_i$ 임을 쉽게 알 수 있다. 따라서, 최대모형하에서의 로그 우도함수는

$$l(\hat{\beta}_{max}; y) = -\frac{n}{2} \log(2\pi\sigma^2)$$

이 된다. 그리고 현재모형을 한 개의 모수 μ 를 사용하는 $E(Y_i) = \mu$ 라 두면 μ 의 최우추정치는 $\hat{\mu} = \bar{y}$ 가 되므로 현재모형하에서의 로그 우도함수는 다음과 같다.

$$l(\hat{\beta}; y) = -\frac{1}{2\sigma^2} \sum (y_i - \bar{y})^2 - \frac{n}{2} \log(2\pi\sigma^2)$$

따라서 데이언스는 다음과 같고 이는 정확하게 자유도 $n - 1$ 인 χ^2 분포를 따른다.

$$D = 2 \left[l(\hat{\beta}_{max}; y) - l(\hat{\beta}; y) \right] = \frac{1}{\sigma^2} \sum (y_i - \bar{y})^2$$

예제 8.6 (포아송분포) $Y_1, \dots, Y_n$ 이 서로 독립이면서 각각 평균이 λ_i 인 포아송분포를 따른다고 가정하면, 로그 우도함수는

$$l(\beta; \mathbf{y}) = \sum y_i \log \lambda_i - \sum \lambda_i - \sum \log y_i!$$

이 되고, 최대모형 $E(Y_i) = \lambda_i$ 하에서는 $\hat{\lambda}_i = y_i$ 이므로

$$l(\hat{\beta}_{max}; \mathbf{y}) = \sum y_i \log y_i - \sum y_i - \sum \log y_i!$$

이다. 한편, 현재모형을 한 개의 모수 λ 를 사용한 모형이라 가정하고 $E(Y_i) = \lambda$ 라 두면 현재모형하에서 $\hat{\lambda} = \bar{y}$ 가 되므로

$$l(\hat{\beta}; \mathbf{y}) = \sum y_i \log \bar{y} - n\bar{y} - \sum \log y_i!$$

이다. 따라서 데비언스는

$$D = 2 \left[\sum y_i \log y_i - \sum y_i \log \bar{y} \right] = 2 \sum y_i \log(y_i / \bar{y})$$

가 되며, 이것은 근사적으로 $\chi^2(n-1)$ 분포를 따른다. 이 통계량은 범주형 자료분석에서 흔히 G^2 통계량이라고도 불리운다. $\square$

<표 8.3>에 여러 분포에 대한 데비언스가 주어져 있다. 예를 들어, 정규분포의 경우 현재모형에서 p 개의 모수 $\beta_0, \beta_1, \dots, \beta_{p-1}$ 을 사용하여 추정된 $\mu_i, i = 1, \dots, n$ 의 값을 $\hat{\mu}_i$ 이라 하면 로그 우도함수가

$$l(\hat{\beta}; \mathbf{y}) = -\frac{1}{2\sigma^2} \sum (y_i - \hat{\mu}_i)^2 - \frac{n}{2} \log(2\pi\sigma^2)$$

로 주어진다. 따라서 데비언스는

$$D = 2 \left[l(\hat{\beta}_{max}; \mathbf{y}) - l(\hat{\beta}; \mathbf{y}) \right] = \frac{1}{\sigma^2} \sum (y_i - \hat{\mu}_i)^2$$

이 된다. 이는 3장에서 다루었던 중선형회귀모형에서 SSE/σ^2 과 같은 것으로 $\chi^2(n-p)$ 를 따르게 된다. 다른 분포의 경우도 같은 방법으로 데비언스를 계산할 수 있으니 확인 해 보기 바란다(연습문제 8.2).

<표 8.3> 지수분포군에 속하는 분포들의 데비언스

분포	데비언스
정규분포	$\sum (y_i - \hat{\mu}_i)^2 / \sigma^2$ <i>$d_i = (y_i - \hat{\mu}_i)^2 / \sigma^2$</i>
포아송분포	$2 \sum \{y_i \log(y_i / \hat{\mu}_i) - (y_i - \hat{\mu}_i)\}$
이항분포	$2 \sum \{y_i \log(y_i / \hat{\mu}_i) + (m_i - y_i) \log[(m_i - y_i) / (m_i - \hat{\mu}_i)]\}$
감마분포	$2 \sum \{-\log(y_i / \hat{\mu}_i) + (y_i - \hat{\mu}_i) / \hat{\mu}_i\}$
역 가우스 분포	$\sum (y_i - \hat{\mu}_i)^2 / (\hat{\mu}_i^2 y_i)$

일반화 선형모형에서 사용되는 모형의 적합도를 나타내는 측도로 데비언스 외에 피어슨의 카이제곱 통계량(Pearson's χ^2 statistic)이 있다. 이것은

$$X^2 = \sum (y_i - \hat{\mu}_i)^2 / V(\hat{\mu}_i) \quad (8.15)$$

으로 주어진다. 위에서 $V(\hat{\mu}_i)$ 은 8.2절에 정의된 분산함수에 추정치를 대입한 것이다. 데비언스와 마찬가지로 X^2 의 근사적 분포는 $\chi^2(n-p)$ 를 따르며, 반응변수가 정규분포인 경우에는 $D = X^2$ 이 되고 정확하게 $\chi^2(n-p)$ 를 따른다. D 와 X^2 중 어느 것이 더 좋은 측도인가에 대해서는 여러 가지 연구가 진행되고 있으나, 장단점을 서로 가지고 있어서 둘 다 많이 사용되고 있다.

$V(\mu)$: Variance function
 $Var(Y) = b''(\theta) a(\phi) = V(\mu) a(\phi)$

8.6 가설 검정과 잔차

현재모형이 p 개의 모수를 가지고 있다고 하자. 즉, $\beta = (\beta_0, \dots, \beta_{q-1}, \beta_q, \dots, \beta_{p-1})'$ 일 때, 이 중 일부의 모수가 0인지에 대한 검정을 하고 싶다. 예를 들어, p 개의 모수 중에서 q 개는 0이 아니고 나머지는 0이라는 가설, 즉

$\leftarrow p-q$
 $H_0 : \beta_q = \dots = \beta_{p-1} = 0$

에 대한 검정은 다음과 같이 이루어진다. 귀무가설 H_0 하에서의 모형은 q 개의 모수로 구성되고, 검정통계량은 현재모형에서의 데비언스(D_1)와 귀무가설 하에서의 데비언스(D_0)와의 차로 이루어진다. 즉, 귀무가설 하에서의 모형과 현재모형 하에서의 β 의 추정치를 각각

$\hat{\beta}_0$ 와 $\hat{\beta}_1$ 으로 나타내면 데비언스의 차는

$$\begin{aligned}\Delta D &= D_0 - D_1 \\ &= 2[l(\hat{\beta}_{max}; y) - l(\hat{\beta}_0; y)] - 2[l(\hat{\beta}_{max}; y) - l(\hat{\beta}_1; y)] \\ &= 2[l(\hat{\beta}_1; y) - l(\hat{\beta}_0; y)]\end{aligned}$$

로 주어진다. 현재모형 하에서 D_1 은 근사적으로 $\chi^2(n-p)$ 를 따르고, 귀무가설 하에서의 축소된 모형의 D_0 는 근사적으로 $\chi^2(n-q)$ 를 따르므로, 검정 통계량 ΔD 는 근사적으로 $\chi^2(p-q)$ 분포를 따른다는 것이 알려져 있다. 따라서 $\Delta D > \chi^2_{\alpha}(p-q)$ 이면 귀무가설 H_0 를 기각한다.

일반화 선형모형에서 잔차는 여러 가지로 정의될 수 있는데 여기서는 세 가지 정의를 소개한다.

(1) 피어슨 잔차(Pearson residual)

피어슨 잔차는

$$r_{Pi} = \frac{y_i - \hat{\mu}_i}{\sqrt{V(\hat{\mu}_i)}}$$

로 정의되는데, 식 (8.15)에서 정의한 피어슨 카이제곱 통계량과는

$$X^2 = \sum_{i=1}^n r_{Pi}^2$$

와 같은 관계를 가진다.

(2) 앤스콤 잔차(Anscombe residual)

피어슨 잔차의 단점은 잔차들의 분포가 한쪽으로 매우 치우쳐져 있어서, 정규분포와 거리가 멀다는 것이다. 이를 극복하기 위해 $A(\cdot)$ 라는 변환을 하여 정규분포와 가깝게 되도록 했다. 구체적으로,

$$A(\cdot) = \int V^{-1/3}(\mu) d\mu$$

로 주어진다. 예를 들어, 포아송분포의 경우 $V(\mu) = \mu$ 이므로

$$\int \mu^{-1/3} d\mu = \frac{3}{2} \mu^{2/3}$$

이 되고, 표준편차는 델타법에 의해 $\sqrt{V(A(Y))} \approx A'(\mu)\sqrt{V(\mu)} = \mu^{-1/3}\mu^{1/2} = \mu^{1/6}$ 이므로
 앤스콤 잔차는

$$r_{Ai} = \frac{\frac{3}{2}(y_i^{2/3} - \hat{\mu}_i^{2/3})}{\hat{\mu}_i^{1/6}}$$

로 주어진다.

delta method

$$\begin{aligned} \text{Var}[A(Y)] &\approx A'(\mu)^2 \text{Var}(Y) \\ \text{ie. } V[A(Y)] &\approx A'(\mu)^2 V(\mu) \end{aligned}$$

(3) 데비언스 잔차(deviance residual)

데비언스 D 는 n 개의 항의 합으로 표현된다(<표 8.2> 참조). 즉, $D = \sum d_i$ 인데, 데비언스 잔차는

$$r_{Di} = \text{sign}(y_i - \hat{\mu}_i)\sqrt{d_i}$$

로 정의된다. 여기서, $\text{sign}(y_i - \hat{\mu}_i)$ 은 $y_i - \hat{\mu}_i$ 의 부호를 의미한다. 예를 들어, 포아송분포의 경우는

$$r_{Di} = \text{sign}(y_i - \hat{\mu}_i) \left\{ 2 \left(y_i \log \left(\frac{y_i}{\hat{\mu}_i} \right) - y_i + \hat{\mu}_i \right) \right\}^{1/2}$$

로 주어진다.

이상의 세가지 잔차들 중에서 데비언스 잔차가 정규분포에 가장 가깝다는 연구 결과가 있어서 가장 널리 사용되고 있다.

8.7 분산분석 모형

반응변수가 연속형 자료이고 설명변수들이 모두 범주형일 때의 선형모형을 분산분석모형(analysis of variance model)이라 부른다. 연속형인 반응변수는 흔히 정규분포를 따른다고 가정한다. 설명변수가 한 개일 때를 일원계획법(one-factor experiment) 또는 일원배치법(one-way classification)이라 하고, 두 개일 때를 이원계획법(two-factor experiment) 또는 이원배치법(two-way classification)이라 부른다. 이외에도 분산분석 모형에는 자료가 주어지는 방법 또는 실험이 행해지는 방법에 따라 여러 가지 모형이 있으나 여기서는 분산분석 모형이 일반화 선형모형의 한 부분이라는 사실을 강조하고 모형의 적합이 이루어지는 과정을 주로 취급한다.

예제 8.7 세 가지 종류의 비료를 투여했을 때 식물 성장치를 각 비료에 대해 세 번 반복 실험한 결과가 다음과 같다.

<표 8.4> 비료의 종류에 따른 식물의 성장치

비료 A	4.17	5.58	5.18
비료 B	4.81	4.17	4.41
비료 C	6.31	5.12	5.54

이 경우 세 종류의 비료가 같은 효과를 가지는지 알고자 한다. 반응변수는 각 식물의 성장치이고, 설명변수는 비료의 종류이다. 이것은 설명변수가 한 개이므로 일원배치법이고 각 성장치는 정규분포를 따른다고 가정할 수 있다. 또한, 요인의 수준은 세 개이다. □

<표 8.4>의 자료는 중선형회귀모형 $y = X\beta + \varepsilon$ 의 형태로 표현할 수 있다. 중선형회귀 모형에서 β 의 추정치는 정규방정식

$$X'X\hat{\beta} = X'y$$

로부터 얻을 수 있으나, 분산분석 모형에서는 디자인 행렬 X 가 비정칙행렬이므로 $X'X$ 의 역행렬이 존재하지 않아 $\hat{\beta}$ 의 유일한 해를 구할 수 없다. 따라서 β 에 대한 추가조건이 주어져야 β 의 추정치가 구해진다. 만약 X 가 $n \times p$ 행렬($p < n$)이라 하고, p 개의 열벡터 중 선형독립인 것의 개수가 q 개이면 β 에 대한 추가조건의 개수는 $p - q$ 개가 되어야 한다.

분산분석 모형에서 $\varepsilon \sim N(0, \sigma^2 I)$ 로 가정하면 연계함수가 항등함수이므로 데비언스는 [예제 8.5]의 형태가 되는데, 만약 현재모형이 p 개의 수준을 가진 것이라면

$$D = \frac{1}{\sigma^2} \sum (y_i - \hat{y}_i)^2 = \frac{1}{\sigma^2} (y'y - \hat{\beta}' X'y) \sim \chi^2(n-p)$$

가 된다. 이것은 중선형회귀모형에서의 오차제곱합(SSE)과 같음을 알 수 있고 D 가 $\chi^2(n-p)$ 를 따른다는 사실이 8.5절에 소개된 바 있다.

이제 β 의 추정치를 구하는 구체적인 방법을 소개한다. 이를 위해 가장 간단한 경우인 일원배치법에서 추정법을 소개하는데, 이는 <표 8.5>에 주어져 있다.

<표 8.5> 수준의 개수가 J 인 일원배치법

수준	반 응 치				합
A_1	Y_{11}	Y_{12}	...	Y_{1n_1}	$Y_{1\cdot}$
A_2	Y_{21}	Y_{22}	...	Y_{2n_2}	$Y_{2\cdot}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$
A_J	Y_{J1}	Y_{J2}	...	Y_{Jn_J}	$Y_{J\cdot}$

전체 반응치의 개수를 $N = \sum_{j=1}^J n_j$ 라 나타내면, 모든 반응치들의 벡터는 N 차원 벡터

$$\mathbf{y} = (Y_{11}, \dots, Y_{1n_1}, \dots, Y_{J1}, \dots, Y_{Jn_J})'$$

이며 각 수준에서의 반복치가 모두 K 개로 같다고 하면 전체 반응치의 개수는 $N = JK$ 가 된다. 한편, 디자인 행렬 $\mathbf{X}$ 는 β 의 제약조건에 따라 두 가지 표현이 가능하다.

(1) 합이 0인 제약(sum-to-zero constraint)

반응치 Y_{jk} 의 전반적인 효과를 μ 라하고, 수준 j 에서의 부가적인 효과를 α_j 라하면

$$E(Y_{jk}) = \mu + \alpha_j, \quad j = 1, \dots, J; \quad k = 1, \dots, K$$

$$\sum_{j=1}^J \alpha_j = 0$$

로 표현할 수 있다. 이를 $\mathbf{y} = \mathbf{X}\beta + \epsilon$ 형태로 나타낼 때 $\mathbf{X}$ 와 β 는 각각 다음과 같다.

$$\mathbf{X} = \begin{matrix} & \begin{matrix} 1 & 2 & \dots & J \end{matrix} \\ \begin{matrix} JK \times (J+1) \\ = N \end{matrix} & \begin{bmatrix} 1 & 1 & 0 & \dots & 0 \\ 1 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 0 & 0 & \dots & 1 \end{bmatrix} \end{matrix}, \quad \beta = \begin{bmatrix} \mu \\ \alpha_1 \\ \vdots \\ \alpha_J \end{bmatrix}$$

여기서, 1은 모든 원소가 1이며 0은 모든 원소가 0으로 크기 K 인 벡터이다. 따라서

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} N & K & \dots & K \\ K & K & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ K & 0 & \dots & K \end{bmatrix} \begin{bmatrix} \mu \\ \alpha_1 \\ \vdots \\ \alpha_J \end{bmatrix} = \mathbf{X}'\mathbf{y} = \begin{bmatrix} Y_{..} \\ Y_{1.} \\ \vdots \\ Y_{J.} \end{bmatrix}$$

$$\begin{aligned} r(\mathbf{X}'\mathbf{X}) &= J < J+1 \\ J+1 - J &= 1 \\ \text{1개의 선형독립성} \end{aligned}$$

이 된다. 그런데 $\mathbf{X}'\mathbf{X}$ 의 첫째 열은 나머지 J 개 열의 합이므로 비정칙행렬이 된다. 따라서 선형독립인 열벡터의 개수는 J 개이고 β 에 대한 1개의 제약식이 필요하다. 합이 0인 제약이란 $\sum_{j=1}^J \alpha_j = 0$ 을 의미한다. 이 제약식 하에서는

$$\hat{\mu} = \frac{Y_{..}}{N} = \bar{y}_{..}, \quad \hat{\alpha}_j = \frac{Y_{j.}}{K} - \frac{Y_{..}}{N} = \bar{y}_{j.} - \bar{y}_{..}$$

$$\begin{aligned} N\mu + K\alpha_1 + \dots + K\alpha_J &= Y_{..} \\ K\mu + K\alpha_1 &= Y_{1.} \\ &\vdots \\ K\mu + K\alpha_J &= Y_{J.} \end{aligned}$$

로 β 의 추정이 되고

$$\hat{\beta}'\mathbf{X}'\mathbf{y} = \frac{Y_{..}^2}{N} + \sum_{j=1}^J Y_{j.} \left(\frac{Y_{j.}}{K} - \frac{Y_{..}}{N} \right) = \frac{1}{K} \sum_{j=1}^J Y_{j.}^2$$

으로 주어진다. $\hat{\alpha}_j$ 의 값으로부터 알 수 있듯이 합이 0인 제약 하에서의 α_j 의 추정치는 반드시 $\sum_{j=1}^J \hat{\alpha}_j = 0$ 이라는 조건을 만족한다.

(2) 구석점 제약(corner-point constraint)

구석점 제약이란 어떤 수준의 부가적인 효과를 0이라고 놓은 것인데 흔히 $\alpha_1 = 0$ 이라고 둔다. 이 경우 X 와 β 는 각각

$$X_{JK \times J} = \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 \\ 1 & 1 & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 0 & 0 & \cdots & 1 \end{bmatrix}, \quad \beta_{J \times 1} = \begin{bmatrix} \mu \\ \alpha_2 \\ \vdots \\ \alpha_J \end{bmatrix}$$

으로 표현되며, $X'X$ 와 $X'y$ 는

$$X'X_{J \times J} = \begin{bmatrix} N & K & K & \cdots & K \\ K & K & 0 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ K & 0 & 0 & \cdots & K \end{bmatrix}, \quad X'y = \begin{bmatrix} Y_{..} \\ Y_{2.} \\ \vdots \\ Y_{J.} \end{bmatrix}$$

로 주어진다. 따라서 $X'X$ 는 정칙행렬이 되고 β 의 추정치는

$$\hat{\beta} = \begin{bmatrix} \hat{\mu} \\ \hat{\alpha}_2 \\ \vdots \\ \hat{\alpha}_J \end{bmatrix} = \frac{1}{K} \begin{bmatrix} Y_{1.} \\ Y_{2.} - Y_{1.} \\ \vdots \\ Y_{J.} - Y_{1.} \end{bmatrix}$$

으로 주어진다. 다음으로 데비언스 D 의 계산에 필요한 $\hat{\beta}'X'y$ 는

$$\hat{\beta}'X'y = \frac{1}{K} \left[Y_{..} Y_{1.} + \sum_{j=2}^J Y_{j.} (Y_{j.} - Y_{1.}) \right] = \frac{1}{K} \sum_{j=1}^J Y_{j.}^2$$

이므로 합이 0인 제약 하에서 구해진 $\hat{\beta}'X'y$ 와 같음을 알 수 있다. 또한, 식 (8.13)에 주어진 데비언스 D 의 값도 두 가지 제약 하에서 하나를 사용하여 계수 β 의 추정이 이루어지며, 각 제약 하에서 나온 추정치는 $\sum_{j=1}^J \hat{\alpha}_j = 0$ 또는 $\hat{\alpha}_1 = 0$ 을 만족하는 값이 발생되지만 적합도 검정치인 D 의 값은 같음을 알 수 있다. 대부분의 통계패키지는 구석점 제약 하에서 구해진 추정치를 제시하지만 합이 0인 제약을 이용하는 패키지도 있으므로 계수의 추정치를 해석할 때 주의를 요한다.

분산분석 모형에서는 계수 β 의 추정 이외에도

$$H_0 : \alpha_1 = \cdots = \alpha_J = 0$$

이라는 가설 검정에 관심이 있다. 즉, 각 수준에서의 효과가 모두 같은 지에 대한 검정이다. 이는 8.6절에서 소개된 데비언스의 차로 검정할 수 있다. H_0 하에서는 $E(Y_{jk}) = \mu$ 이므로 $X'X = N$, $X'y = Y_{..}$, $\hat{\beta} = \hat{\mu} = Y_{..} / N$ 이 된다. 따라서

$$D_0 = \frac{1}{\sigma^2}(y'y - \hat{\beta}'X'y) = \frac{1}{\sigma^2} \left(\sum_{j=1}^J \sum_{k=1}^K Y_{jk}^2 - \frac{Y_{..}^2}{N} \right) \sim \chi^2(N-1).$$

으로 주어지며 이는 귀무가설 하에서 $\chi^2(N-1)$ 을 따른다. 한편, 현재모형 하에서는

$$D_1 = \frac{1}{\sigma^2}(y'y - \hat{\beta}'X'y) = \frac{1}{\sigma^2} \left(\sum_{j=1}^J \sum_{k=1}^K Y_{jk}^2 - \frac{1}{K} \sum_{j=1}^J Y_{j.}^2 \right) \sim \chi^2(N-J)$$

이고 이는 현재모형 하에서 $\chi^2(N-J)$ 를 따르므로

$$\Delta D = D_0 - D_1 = \frac{1}{\sigma^2} \left(\frac{1}{K} \sum_{j=1}^J Y_{j.}^2 - \frac{1}{N} Y_{..}^2 \right) \sim \chi^2(N-1 - (N-J))$$

으로 주어지고, 이는 $\chi^2(J-1)$ 을 따르게 된다. 따라서 σ^2 이 알려져 있을 경우 ΔD 와 $\chi^2_{\alpha}(J-1)$ 을 비교하여 H_0 를 검정할 수 있다. 즉,

$$\Delta D > \chi^2_{\alpha}(J-1)$$

이면 귀무가설 H_0 를 기각하게 된다. 한편, σ^2 을 모를 경우에는

$$F = \frac{D_0 - D_1}{(N-1) - (N-J)} \bigg/ \frac{D_1}{(N-J)}$$

$$\frac{D_0 - D_1}{df_F} \quad \leftarrow$$

$D_0 - D_1$ & D_1 independent

가 $F(J-1, N-J)$ 를 따른다는 사실을 이용하면 된다. 즉, D_0 와 D_1 의 차이가 크면 F 값이 커지므로 $F > F_{\alpha}(J-1, N-J)$ 이면 귀무가설을 기각한다.

예제 8.8 비료의 종류가 식물의 성장에 어떤 영향을 미치는지를 알기 위해 세 종류의 비료를 사용하여 식물의 성장치를 조사하였다.

<표 8.6> 비료의 종류에 따른 식물의 성장치

비료 A	4.17	5.58	5.18	6.11
비료 B	4.81	4.17	4.41	3.59
비료 C	6.31	5.12	5.54	5.50

이 자료는 $J = 3$, $K = 4$, $N = 12$ 인 경우이다. 분산분석 모형은

$$E(Y_{jk}) = \mu + \alpha_j, \quad j = 1, 2, 3; k = 1, 2, 3, 4$$

로 세울 수 있고, 우선 합이 0인 제약 하에서 X 와 β 를 표현해 보면

$$X = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 1 & 0 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 1 \end{bmatrix}, \quad \beta = \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \end{bmatrix}$$

로 주어진다. 따라서

$$X'X = \begin{bmatrix} 12 & 4 & 4 & 4 \\ 4 & 4 & 0 & 0 \\ 4 & 0 & 4 & 0 \\ 4 & 0 & 0 & 4 \end{bmatrix}, \quad X'y = \begin{bmatrix} Y_{..} \\ Y_{1.} \\ Y_{2.} \\ Y_{3.} \end{bmatrix} = \begin{bmatrix} 60.49 \\ 21.04 \\ 16.98 \\ 22.47 \end{bmatrix}$$

인데 $X'X$ 가 비정칙이므로 $\alpha_1 + \alpha_2 + \alpha_3 = 0$ 이라는 조건을 부여하면

$$\hat{\beta} = \begin{bmatrix} \bar{Y}_{..} \\ \bar{Y}_{1.} - \bar{Y}_{..} \\ \bar{Y}_{2.} - \bar{Y}_{..} \\ \bar{Y}_{3.} - \bar{Y}_{..} \end{bmatrix} = \begin{bmatrix} 5.04 \\ 0.22 \\ -0.80 \\ 0.58 \end{bmatrix}$$

으로 주어진다. 당연히 $\hat{\alpha}_1 + \hat{\alpha}_2 + \hat{\alpha}_3 = 0$ 임을 알 수 있고 $\hat{\beta}'X'y = 308.95$ 로서 $D = (y'y - \hat{\beta}'X'y) / \sigma^2 = (312.52 - 308.95) / \sigma^2 = 3.57 / \sigma^2$ 이다.

다음으로 $\alpha_1 = 0$ 이라는 구속점제약 하에서 X 와 β 는

$$X = \begin{matrix} & \mu & \alpha_2 & \alpha_3 \\ \begin{matrix} 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \\ 1 & 0 & 1 \end{matrix} & \begin{bmatrix} \mu \\ \alpha_2 \\ \alpha_3 \end{bmatrix} \end{matrix}$$

로 주어진다. 따라서

$$X'X = \begin{bmatrix} 12 & 4 & 4 \\ 4 & 4 & 0 \\ 4 & 0 & 4 \end{bmatrix} \quad X'y = \begin{bmatrix} Y_{..} \\ Y_{2.} \\ Y_{3.} \end{bmatrix} = \begin{bmatrix} 60.49 \\ 16.98 \\ 22.47 \end{bmatrix}$$

이므로

$$\hat{\beta} = \begin{bmatrix} \bar{Y}_{1.} \\ \bar{Y}_{2.} - \bar{Y}_{1.} \\ \bar{Y}_{3.} - \bar{Y}_{1.} \end{bmatrix} = \begin{bmatrix} 5.26 \\ -1.02 \\ 0.36 \end{bmatrix}$$

으로 주어지고, $\hat{\beta}'X'y = 308.95$ 로서 합이 0인 제약 하의 값과 동일함을 알 수 있고, D 또한, 같은 값을 갖게 된다.

이제 $H_0: \alpha_1 = \alpha_2 = \alpha_3 = 0$ 이라는 가설검정을 해 보자. 이 가설하에서 데비언스값은

$$D_0 = \frac{1}{\sigma^2} \left(\sum_{j=1}^3 \sum_{k=1}^4 Y_{jk}^2 - \frac{Y_{..}^2}{12} \right) = 7.60 / \sigma^2$$

이므로 $\Delta D = D_0 - D_1 = 4.03 / \sigma^2$ 이고, 이 경우 σ^2 은 알려져 있지 않으므로 F -통계량을 이용하면

$$F = \frac{(4.03 / \sigma^2)}{(11 - 9)} \bigg/ \frac{(3.57 / \sigma^2)}{9} = 5.08$$

이다. 이 값은 $F_{.05}(2, 9) = 4.26$ 보다 크므로 두 모형간에 설명정도의 차이가 있다는 것을

의미한다. 따라서 유의수준 5%에서 H_0 는 기각된다. 즉, 각 수준의 효과는 같다고 얘기할 수 없다. 분산분석표는 <표 8.7>에 요약되어 있다. 한편, ΔD 를 검정통계량으로 사용하려면 σ^2 의 추정치인 $3.57/9 = 0.40$ 을 대입하여 얻은 값 $\Delta D = 10.08$ 을 $\chi^2_{0.05}(2) = 5.99$ 와 비교하면 같은 검정결과를 얻을 수 있다. $\square$

<표 8.7> 비료의 종류에 따른 식물의 성장치 자료에 대한 분산분석표

변동요인	자유도	제곱합	평균제곱합	F
처리	2	4.03	2.02	5.08
오차	9	3.57	0.40	
전체	11	7.60		

예제 8.9 앞에서 논의했던 일원배치법은 설명변수가 2개인 이원배치법으로 쉽게 확장될 수 있다. <표 8.7>은 온도와 압력에 따른 타이어의 점성을 나타낸 자료이다. 온도는 세 가지 수준 ($J = 3$)에서, 압력은 두 수준 ($K = 2$)에서 측정하고 각 수준에서 2회 반복 ($L = 2$) 측정하였다. 따라서 전체 관측치의 개수는 $N = 12$ 가 된다.

<표 8.8> 온도와 압력에 따른 타이어의 점성

압력 온도	B_1		B_2		합
A_1	6.8	6.6	5.3	6.1	24.8
A_2	7.5	7.4	7.2	6.5	28.6
A_3	7.8	9.1	8.8	9.1	34.8
합	45.2		43.0		88.2

이러한 자료를 바탕으로 분석하고자 하는 점은 다음 세 가지로 요약된다.

A : 온도의 영향이 있는가?

B : 압력의 영향이 있는가?

I : 온도와 압력의 교호작용(interaction)은 있는가?

이러한 문제들을 모형화 하기 위해 우선 최대모형을

$$Y_{jkl} = \mu + \alpha_j + \beta_k + (\alpha\beta)_{jk} + \varepsilon_{jkl}$$

로 세울 수 있다. 여기서 α_j 는 온도에 따른 주효과(main effect), β_k 는 압력에 따른 주효과, $(\alpha\beta)_{jk}$ 는 온도와 압력의 교호작용효과이다. 따라서 위에서 제시된 세 가지 문제는 다음과

같은 현재모형으로 요약될 수 있다.

$$A : Y_{jkl} = \mu + \alpha_j + \varepsilon_{jkl}$$

$$B : Y_{jkl} = \mu + \beta_k + \varepsilon_{jkl}$$

$$I : Y_{jkl} = \mu + (\alpha\beta)_{jk} + \varepsilon_{jkl}$$

따라서 최대모형하에서의 데이비언스와 현재모형 하에서의 데이비언스를 비교함으로써 주효과 및 교호작용효과의 존재여부를 검정 할 수 있다. 우선, 각 모형 하에서 계수의 추정이 어떻게 이루어지는지를 살펴보자. 최대모형하에서의 X , β , 그리고 $X'y$ 는

$$X = \begin{bmatrix} 110010100000 \\ 110010100000 \\ 110001010000 \\ 110001010000 \\ 101010001000 \\ 101010001000 \\ 101001000100 \\ 101001000100 \\ 100110000010 \\ 100110000010 \\ 100101000001 \\ 100101000001 \end{bmatrix}, \quad \beta = \begin{bmatrix} \mu \\ \alpha_1 \\ \alpha_2 \\ \alpha_3 \\ \beta_1 \\ \beta_2 \\ (\alpha\beta)_{11} \\ (\alpha\beta)_{12} \\ (\alpha\beta)_{21} \\ (\alpha\beta)_{22} \\ (\alpha\beta)_{31} \\ (\alpha\beta)_{32} \end{bmatrix}, \quad X'y = \begin{bmatrix} Y_{..} \\ Y_{1..} \\ Y_{2..} \\ Y_{3..} \\ Y_{.1} \\ Y_{.2} \\ Y_{11} \\ Y_{12} \\ Y_{21} \\ Y_{22} \\ Y_{31} \\ Y_{32} \end{bmatrix} = \begin{bmatrix} 88.2 \\ 24.8 \\ 28.6 \\ 34.8 \\ 45.2 \\ 43.0 \\ 13.4 \\ 11.4 \\ 14.9 \\ 13.7 \\ 16.9 \\ 17.9 \end{bmatrix}$$

로 주어지는데 X 는 12×12 행렬이지만 6개의 열벡터만 서로 선형독립이다. 따라서 6개의 제약식이 필요한데 우선 합이 0인 제약식은

$$\begin{aligned} \alpha_1 + \alpha_2 + \alpha_3 &= 0 & \beta_1 + \beta_2 &= 0 \\ (\alpha\beta)_{11} + (\alpha\beta)_{12} &= 0 & (\alpha\beta)_{21} + (\alpha\beta)_{22} &= 0 \\ (\alpha\beta)_{31} + (\alpha\beta)_{32} &= 0 & (\alpha\beta)_{11} + (\alpha\beta)_{21} + (\alpha\beta)_{31} &= 0 \end{aligned}$$

로 표현된다. 이러한 제약식 하에서 $\hat{\beta} = (7.35, -1.15, -0.2, 1.35, 0.18, -0.18, 0.32, -0.32, 0.12, -0.12, -0.43, 0.43)'$, $\hat{\beta}' X'y = 662.62$ 가 된다. 한편, 구석점 제약은

$$\alpha_1 = \beta_1 = (\alpha\beta)_{11} = (\alpha\beta)_{12} = (\alpha\beta)_{21} = (\alpha\beta)_{31} = 0$$

로 설정된다. 이는 주효과와 교호작용효과의 구석점을 모두 0으로 놓은 것이 된다. 이에

대한 X 와 β , $X'y$ 는

$$X = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 0 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 0 & 0 & 1 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 0 & 0 \\ 1 & 1 & 0 & 1 & 1 & 0 \\ 1 & 1 & 0 & 1 & 1 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 \\ 1 & 0 & 1 & 1 & 0 & 1 \\ 1 & 0 & 1 & 1 & 0 & 1 \end{bmatrix}, \quad \beta = \begin{bmatrix} \mu \\ \alpha_2 \\ \alpha_3 \\ \beta_2 \\ (\alpha\beta)_{22} \\ (\alpha\beta)_{32} \end{bmatrix}, \quad X'y = \begin{bmatrix} Y_{...} \\ Y_{2..} \\ Y_{3..} \\ Y_{12.} \\ Y_{22.} \\ Y_{32.} \end{bmatrix} = \begin{bmatrix} 88.2 \\ 28.6 \\ 34.8 \\ 43.0 \\ 13.7 \\ 17.9 \end{bmatrix}$$

이 된다. 따라서 $\hat{\beta} = (X'X)^{-1}X'y = (6.7, 0.75, 1.75, -1.0, 0.4, 1.5)'$ 이고 $\hat{\beta}'X'y = 662.62$ 로 합이 0인 제약을 사용하는 경우와 같게 된다. 각 모형에 대한 검정은 다음의 분산분석표에 근거하여 이루어진다.

<표 8.9> 타이어 점성 자료에 대한 분산분석표

변동요인	자유도	제곱합	평균제곱합	F
A(온도)	2 <i>3-1</i>	12.74	6.37	25.82
B(압력)	1 <i>2-1</i>	0.40	0.40	1.63
A × B	2	1.21	0.60	2.45
오차	6 <i>N-</i>	1.48	0.25	
전체	11 <i>12-1</i>	15.83		

분산분석표로 알 수 있듯이 온도에 대한 주효과만 유의하고, 압력의 주효과 및 교호작용 효과는 유의하지 않다. 여기서도 [예제 8.8]에서 처럼 데비언스의 차이에 근거하여 가설 검정을 할 수 있으며 결과도 같음을 알 수 있다(연습문제 8.4).

□

연습문제 (8)

[이론 문제]

8.1 <표 8.2>의 각 수식을 증명하라.

8.2 <표 8.3>의 데비언스를 증명하라.

[응용 문제]

8.1 [예제 8.8]에서 모형 A, B, I 각각에 대하여 합이 0인 제약과 구석점 제약을 이용하여 추정하고, 이 결과를 이용하여 <표 8.8>에 나타나 있는 분산분석표의 여러 가지 값을 유도하라.

8.2 반복이 없는 이원배치법 자료가 다음과 같이 주어져 있다.

	A_1	A_2	A_3
B_1	9	10	11
B_2	4	5	6

모형 $Y_{ij} = \mu + \alpha_i + \beta_j + \varepsilon_{ij}$ 를 $y = X\beta + \varepsilon$ 으로 표현할 때

- (1) 합이 0인 제약 하에서 X 와 β 를 표현하고 Y_{11} 의 추정치를 구하라.
- (2) 구석점 제약 하에서 X 와 β 를 표현하고 Y_{11} 의 추정치를 구하라. 이 때 Y_{11} 의 추정치는 (1)에서 구한 값과 같음을 보여라.

8.3 분산분석 모형에서 디자인 행렬 X 는 크로네커곱(부록 A.8.3 참고)으로 표현하면 매우 간단해진다. 예를 들어, [예제 8.8]의 합이 0인 제약하에서의 디자인 행렬 X 는

$$X = (1_{12} \ I_3 \otimes 1_4)$$

로 표현된다. 단, 1_n 은 차원 n 인 1로 구성된 벡터이고, I_n 은 $n \times n$ 단위행렬이다.

- (1) [예제 8.8]에서 $\alpha_1 = 0$ 이라는 제약하에서의 디자인 행렬 X 를 크로네커곱으로 표현하라.
- (2) [예제 8.9]에서 최대모형하에서의 디자인 행렬 X 는

$$X = (1_{12} \ I_3 \otimes I_4 \ 1_3 \otimes I_2 \otimes 1_2 \ I_3 \otimes I_2 \otimes 1_2)$$

임을 보여라.

8.4 [예제 8.9]의 가설검정을 데비언스의 차에 근거하여 실시하고 그 결과가 F 검정의 결과와 같음을 보여라.

제 9 장

일반화 선형모형 II

9.1 로지스틱 회귀모형

9.2 로그선형모형

9.3 과산포

9.4 로지스틱모형과 로그선형모형

binomial
poisson
nominal
 $n\pi(1-\pi) < \text{Sample Variance}$
 $n < \text{Sample}$
Lexis ratio

본 장에서 정의된 일반화선형모형에서는 특히 반응변수가 이항분포일 경우를 소개한다. 이항분포에 해당되는 연계함수는 여러 가지가 있으나 여기서는 주로 로지스틱회귀모형을 설명한다. 또한, 반응변수는 개수로 나타날 때가 있다. 실험계획법에서 이런 경우가 주로 나타나는데 여기서는 개수를 포아송 분포로 가정하고 자연연계함수인 로그함수를 사용한 로그 선형모형을 주로 소개한다.

9.1 로지스틱 회귀 모형

binomial

9.1.1 이항분포와 이진자료


반응변수 Z 가 두 가지 결과만 가지는 경우가 흔히 있다. 어떤 병에 걸린 경우와 그렇지 않은 경우, 암 환자가 5년 이내에 사망하는지 여부, 물체에 일정한 힘을 가했을 때 파손되는지의 여부 등이다. 이 경우 두 가지 결과를 흔히 0과 1로 나타낸다. 이처럼 반응치가 0 또는 1만 취하는 경우를 이진자료(binary data or dichotomous data)라고 부른다. 이 때 확률변수 Z 는 베르누이 시행 $B(1, \pi_i)$ 를 따르게 되며 π_i 는 성공의 확률(1을 취하는 확률)이다. 이제 Z 를 설명해 줄 것으로 여겨지는 설명변수 $(X_1, \dots, X_p)'$ 가 있다고 할 때 각 설명변수의 값 $(x_{i1}, \dots, x_{ip})'$ 에 대해 m_i 개의 서로 독립인 반응치가 있다고 하자. m_i 개 반응치 중 1을 취하는 것의 개수를 Y_i 라고 하면, Y_i 는 이항분포 $B(m_i, \pi_i)$ 를 따르게 된다.

<표 9.1> 살충제 자료

살충제 양(x_i)	벌레 수(m_i)	죽은 벌레수(y_i)
1.6907	59	6
1.7242	60	13
1.7552	62	18
1.7842	56	28
1.8113	63	52
1.8369	59	53
1.8610	62	61
1.8839	60	60

 y_i m_i

sample proportion

S-shape distⁿ

(그림 9.1) 살충제 자료에서 살충제 양에 따른 벌레의 치사율

<표 9.1>에 주어진 자료는 살충제의 양을 증가시킴에 따라서 죽는 벌레의 숫자를 나타낸 것이다. 또한, 죽은 벌레의 비율 (y_i/m_i)이 (그림 9.1)에 나타나 있다. 이제, 우리의 관심은 살충제의 양이 x 로 주어졌을 때 벌레의 치사율(π)에 대한 추정이다. 가장 쉽게 생각할 수 있는 것은 단순선형회귀모형이다. 즉,

$$\pi_i = \beta_0 + \beta_1 X_i, \quad i = 1, \dots, n$$

이다. 그러나 이 모형은 심각한 단점이 있다. 왜냐하면 β_0 와 β_1 의 최소제곱추정치들 $\hat{\beta}_0$ 와 $\hat{\beta}_1$ 이라 할 때 $\hat{\pi}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$ 가 되는데, 경우에 따라서 $\hat{\pi}_i < 0$ 또는 $\hat{\pi}_i > 1$ 이 될 수 있기 때문이다. 이러한 현상은 이차다항회귀를 사용하더라도 피할 수 없으며 반응변수가 이항분포를 따르는 경우 기존의 어떤 고전적 선형회귀모형으로도 제대로 적합할 수 없다.

9.1.2 로지스틱 회귀모형

$$y = g(u) = x^T \beta \quad g: \text{link func.}$$

$$u = g^{-1}(y) \quad u = E(Y)$$

앞 절에서 설명한 것처럼 $\pi_i = \beta_0 + \beta_1 X_i$ 라는 모형은 적절하지 못하다. 그렇다면, 적합치 $\hat{\pi}_i$ 이 어떠한 X 값에 대해서도 0과 1 사이의 값이 될 수 있는 모형이 어떤 것일까? 즉, $g(\pi_i) = x'_i \beta$ 에서 연계함수 g 가 항등함수이면 적당하지 못하고, $\hat{\pi}_i$ 이 언제나 0과 1 사이가 될 수 있는 g 를 찾아야 한다. 가장 쉬운 경우는 g 를 임의의 누적분포함수의 역함수로 두면 된다. 왜냐하면, 누적분포함수는 언제나 0과 1 사이의 값을 가지기 때문이다. 이 경우 g 의 역함수 g^{-1} 는 누적분포함수이므로 다음과 같이 나타낼 수 있다.

$$\pi = g^{-1}(x'\beta) = \int_{-\infty}^{\eta} f(s)ds$$

여기서 $f(s)$ 는 사용된 분포함수의 확률밀도함수이다.

먼저, $f(s)$ 를 표준정규분포의 확률밀도함수라고 하고, 누적분포함수를 Φ 라 나타내면 $\pi = \Phi(x'\beta)$ 이 성립하고, 선형예측치는 $\Phi^{-1}(\pi) = x'\beta$ 로 주어진다. 이 경우 $\hat{\pi} = \Phi(x'\hat{\beta})$ 이므로 항상 $0 \leq \hat{\pi} \leq 1$ 을 만족한다. 이와 같이, 연계함수로 $\Phi^{-1}(\cdot)$ 를 사용한 모형을 프로빗 모형(probit model)이라고 부른다.

다음으로, $f(s)$ 를 로지스틱 분포의 확률밀도함수라 두면 $f(s) = e^s / (1 + e^s)^2$ 이고 $\pi = \int_{-\infty}^{\eta} f(s)ds = e^{\eta} / (1 + e^{\eta})$ 이 된다. 그리고 $\eta = x'\beta$ 를 대입하면

$$\pi = \frac{\exp(x'\beta)}{1 + \exp(x'\beta)}$$

$$e^{x^T \beta} = \pi + \pi e^{x^T \beta} \\ (1 - \pi) e^{x^T \beta} = \pi \Rightarrow e^{x^T \beta} = \frac{\pi}{1 - \pi}$$

이고, 이 식으로부터 $\log\left(\frac{\pi}{1 - \pi}\right) = x' \beta$ 의 관계식을 얻을 수 있다. 즉, 연계함수가 π 의 로짓(logit)함수 $\text{logit}(\pi) = \log\left(\frac{\pi}{1 - \pi}\right)$ 로 주어지며 이 모형을 로지스틱 회귀모형(logistic regression model)이라 부른다.

이 외에도 연계함수로 부 로그-로그(complementary log-log)함수(8.3절 참조)를 사용하는 모형이 있고, 확률밀도함수가 $f(s) = \exp(s - \exp(s))$ 인 극한값분포(extreme value distribution)를 사용한 모형도 있다.

여기서는 로지스틱 회귀모형에 대한 소개를 한다. 설명변수가 한 개인 로지스틱 회귀모형의 적합과정을 살펴보자. 반응변수 $Y_1, \dots, Y_n$ 이 서로 독립적으로 이항분포 $B(m_i, \pi_i)$ 를 따를 때 로그 우도함수는

$$l = \sum_{i=1}^n \left\{ y_i \log\left(\frac{\pi_i}{1 - \pi_i}\right) + m_i \log(1 - \pi_i) + \log\left(\frac{m_i}{y_i}\right) \right\}$$

로 주어진다. 설명변수가 한 개인 경우 로지스틱 회귀모형은

$$\log\left(\frac{\pi_i}{1 - \pi_i}\right) = \beta_0 + \beta_1 x_i$$

이므로 로그 우도함수는 다음과 같게 된다.

$$l = \sum_{i=1}^n \left\{ y_i(\beta_0 + \beta_1 x_i) - m_i \log[1 + \exp(\beta_0 + \beta_1 x_i)] + \log\left(\frac{m_i}{y_i}\right) \right\}$$

그리고 스코어함수는

$$U_1 = \frac{\partial l}{\partial \beta_0} = \sum \left\{ y_i - m_i \left[\frac{\exp(\beta_0 + \beta_1 x_i)}{1 + \exp(\beta_0 + \beta_1 x_i)} \right] \right\} = \sum (y_i - m_i \pi_i) \\ U_2 = \frac{\partial l}{\partial \beta_1} = \sum \left\{ y_i x_i - m_i x_i \left[\frac{\exp(\beta_0 + \beta_1 x_i)}{1 + \exp(\beta_0 + \beta_1 x_i)} \right] \right\} = \sum x_i (y_i - m_i \pi_i)$$

로 주어지며, 피셔정보행렬은 다음과 같이 주어짐을 쉽게 보일 수 있다(연습문제 9.4).

$$I = \begin{pmatrix} \sum m_i \pi_i (1 - \pi_i) & \sum m_i x_i \pi_i (1 - \pi_i) \\ \sum m_i x_i \pi_i (1 - \pi_i) & \sum m_i x_i^2 \pi_i (1 - \pi_i) \end{pmatrix}$$

따라서 $U = (U_1, U_2)'$ 라 두면 β 에 대한 추정치 $\hat{\beta}$ 는 적당한 초기치 $\hat{\beta}^{(0)}$ 를 이용하여 다음

의 뉴턴-랩슨 반복과정을 거쳐 얻을 수 있다.

$$\hat{\beta}^{(t+1)} = \hat{\beta}^{(t)} + [I^{(t)}]^{-1}U^{(t)}, \quad t = 0, 1, 2, \dots$$

예제 9.1 (살충제 자료) <표 9.1>에 주어진 살충제 자료에 로지스틱 회귀모형을 적용하여 모수를 추정하는 반복과정이 <표 9.2>에 주어져 있다. 10번의 반복과정 후 추정치는 $\hat{\beta}_0 = -60.72$, $\hat{\beta}_1 = 34.27$ 로 얻어지며 이들의 표준편차는 각각 $\sqrt{26.802} = 5.18$, $\sqrt{8.469} = 2.91$ 이다. 또한, 데비언스 $D = 11.23$ 이며, 모형의 적합 정도는 $\chi^2_{0.05}(8-2) = 12.59$ 이므로, 로지스틱 회귀모형이 비교적 잘 적합 되었음을 알 수 있다.

<표 9.2> 살충제 자료에 대한 로지스틱 모형의 적합

반복회수 추정치	t	0	1	2	4	10
	$\hat{\beta}_0$	0	-37.849	-53.851	-60.700	-60.717
	$\hat{\beta}_1$	0	21.334	30.382	34.261	34.270
	관측치	적합치	적합치	적합치	적합치	적합치
y_1	6	29.5	8.508	4.544	3.460	3.458
y_2	13	30.0	15.369	11.254	9.845	9.842
y_3	18	31.0	24.810	23.059	22.454	22.451
y_4	28	28.0	30.983	32.946	33.896	33.898
y_5	52	31.5	43.361	48.197	50.092	50.096
y_6	53	29.5	46.739	51.704	53.288	53.291
y_7	61	31.0	53.593	58.060	59.220	59.222
y_8	60	30.0	54.732	58.036	58.742	58.743

$$I^{-1} = \begin{pmatrix} 26.802 & 15.061 \\ 15.061 & 8.469 \end{pmatrix}, D = 11.23$$

이 자료에 대해 프로빗 모형과 극한값 분포모형을 적용시킨 결과가 <표 9.3>에 나타나 있다. 이 표에 주어진 적합치와 데비언스의 값을 비교하면 살충제 자료의 경우 극한값 분포모형이 가장 적절한 것으로 여겨진다. □

<표 9.3> 살충제 자료의 세가지 모형에 대한 분석결과 : 적합치와 데비언스

관측치	로지스틱 모형	프로빗 모형	극한값 모형
6	3.46	3.36	5.59
13	9.84	10.72	11.28
18	22.45	23.48	20.95
28	33.90	33.82	30.37
52	50.10	49.62	47.78
53	53.29	53.32	54.14
61	59.22	59.66	61.11
60	58.74	59.23	59.95
D	11.23	10.12	3.45