


예제 9.2 (꽃씨 발아 자료) 이 자료는 우드(Wood, 1978)로 부터 발췌한 것으로 꽃씨 발아에 대한 자료이며 <표 9.4>에 주어져 있다.

n_{jk} 개의 꽃씨 중 y_{jk} 개가 발아하였는데 두 가지 변수가 고려되고 있다. 하나는 질적 변수로 3°C 에서 48시간 동안 저장 여부(저장된 것은 처리군, 안된 것은 대조군)를 나타내며, 다른 변수는 양적 변수로 3가지의 서로 다른 원심력을 작용시켰다. 이때, 두 가지 변수들이 꽃씨의 발아 비율에 어떤 영향을 미치는지 알고 싶다.

<표 9.4> 꽃씨 발아 자료

저장 상태		원심력(g)		
		40	150	350
대조군	y_{1k}	55	52	57
	n_{1k}	102	99	108
처리군	y_{2k}	55	50	50
	n_{2k}	76	81	90



(그림 9.2) 원심력의 변화에 따른 꽃씨 발아 비율(C는 대조군, T는 처리군을 나타냄)

발아된 꽃씨의 비율 $p_{jk} = y_{jk}/n_{jk}$ 이 원심력의 로그 값인 x_k 에 대한 산점도가 (그림 9.2)에 주어져 있다. 이 그림으로부터 알 수 있는 것은 처리군이 대조군보다 발아비율이 높고 또한, 처리군 내에서는 원심력에 대해 감소하는 경향이 뚜렷하다. 여기서, 3가지의 로지스틱 모형을 택해 어떤 모형이 적당한가를 살펴보자.

모형 1 : $\text{logit } \pi_{jk} = \alpha_j + \beta_j x_k$

모형 2 : $\text{logit } \pi_{jk} = \alpha_j + \beta x_k$

모형 3 : $\text{logit } \pi_{jk} = \alpha + \beta x_k$

full model.
 $j=1, 2$
 $k=1, 2, 3$

모형 3은 처리군과 대조군이 같은 절편과 기울기를 가지는 것이고, 모형 2는 절편은 다르나 기울기는 같은 것이며, 모형 1은 절편과 기울기 모두 다른 것이다.

각 모형을 적합시켜 얻어진 모수의 추정치 및 데비언스가 <표 9.5>에 요약되어 있다.

<표 9.5> 꽃씨 발아 자료에 대한 3가지 로지스틱 모형의 최우추정치 및 데비언스(괄호 안의 값은 표준오차)

모형 1	모형 2	모형 3
$a_1 = .238(.628)$	$a_1 = .877(.487)$	$a = 1.021(.481)$
$a_2 - a_1 = 1.977(.998)$	$a_2 - a_1 = .407(.175)$	$b = -.148(.096)$
$b_1 = -.023(.127)$	$b = -.155(.097)$	
$b_2 - b_1 = -.319(.199)$		
$D_1 = .0277$	$D_2 = 2.619$	$D_3 = 8.092$

우선 모형 3과 모형 2를 비교해보면 $\Delta D = D_3 - D_2 = 5.473$ 으로서 $\chi^2_{0.05}(1) = 3.84$ 보다 큰 값이다. 즉, 모형 3보다 모형 2가 1개의 모수를 더 사용하였으나, 충분한 데비언스의 감소를 가져오므로 모형 3은 적절하지 못하다. 다시 말해서, 처리군과 대조군의 절편은 차이가 있는 것으로 판단된다.

한편 모형 2와 모형 1을 비교해 보면 $\Delta D = D_2 - D_1 = 2.591$ 로서 $\chi^2_{0.05}(1)$ 보다 크지 못하다. 즉, 모형 1이 모형 2보다 더 낫다고 판단할 수 없다. 다시 말해서, 처리군과 대조군의 기울기는 다르다고 판단하기 어려우므로 모형 2가 가장 적절하다고 결론지을 수 있다.

<표 9.6>은 모형 1과 모형 2를 사용하였을 때 발아비율의 적합치를 비교한 것이다. 물론, 모형 1이 모형 2보다 관측치에 더 가까운 적합치를 나타낸다. 이것은, 모형 1이 모형 2보다 1개의 모수를 더 사용한 것으로서, 당연한 결과라고 볼 수 있다. □

<표 9.6> 모형 1과 2에서 발아 비율의 적합치

저장상태	로그(원심력)	관측치(p_{jk})	모형 1($\hat{\pi}_{jk}$)	모형 2($\hat{\pi}_{jk}$)
대조군	x_1	.539	.537	.576
	x_2	.525	.530	.526
	x_3	.528	.525	.493
처리군	x_1	.724	.721	.671
	x_2	.617	.623	.625
	x_3	.555	.553	.593

9.1.3 중간값의 추정

로지스틱 회귀를 구한 후 추정곡선의 0.5에 해당되는 중간값에 관심이 있을 경우가 많다. 예를 들어, 특정한 약을 복용할 경우 약의 복용량에 따라 반응을 나타내는 비율이 다를 때 약 50%의 복용자가 반응을 나타내는 복용량을 중간 유효 복용량(median effective dose)이라 하며 흔히 ED50이라 부른다. 또 다른 예로, 살충제의 경우 벌레의 약 50%가 사망하는 살충제 양을 중간 치사량(median lethal dose)이라 부르며 LD50으로 표현한다. ED50이나 LD50에 대한 점 추정과 구간추정을 해 보자. 로지스틱 회귀모형

$$\log(\pi/(1-\pi)) = \beta_0 + \beta_1 x$$

에 적합시킨 후 $\hat{\pi} = 0.5$ 가 되는 중간값은

$$\hat{\theta}_{.5} = -\hat{\beta}_0/\hat{\beta}_1$$

이 된다. 이에 대한 신뢰구간을 구하기 위해 $Var(\hat{\theta}_{.5})$ 을 계산해야 되는데 이에 대한 정확한 값은 구할 수 없으므로 다변량 델타법(multivariate delta method)을 이용한다. 즉,

$$Var[g(\hat{\beta}_0, \hat{\beta}_1)] \simeq \left(\frac{\partial g}{\partial \hat{\beta}_0}\right)^2 Var(\hat{\beta}_0) + \left(\frac{\partial g}{\partial \hat{\beta}_1}\right)^2 Var(\hat{\beta}_1) + 2\left(\frac{\partial^2 g}{\partial \hat{\beta}_0 \partial \hat{\beta}_1}\right) Cov(\hat{\beta}_0, \hat{\beta}_1)$$

이므로

$$Var(\hat{\theta}_{.5}) \simeq (v_{00} - 2\hat{\rho}v_{01} + \hat{\rho}^2 v_{11})/\hat{\beta}_1^2$$

으로 주어진다. 단, 여기서

$$(v_{00} + 2\hat{\rho}v_{01} + \hat{\rho}^2 v_{11})/\hat{\beta}_1^2$$

$$v_{00} = Var(\hat{\beta}_0), \hat{\rho} = \hat{\beta}_0/\hat{\beta}_1, v_{01} = Cov(\hat{\beta}_0, \hat{\beta}_1), v_{11} = Var(\hat{\beta}_1)$$

을 나타낸다. 따라서, 중간값 $\theta_{.5}$ 에 대한 $100(1-\alpha)\%$ 근사적 신뢰구간은

$$\hat{\theta}_{.5} \pm z_{\alpha/2} s.e.(\hat{\theta}_{.5})$$

으로 주어지는데 여기서 $s.e.(\hat{\theta}_{.5}) = \{Var(\hat{\theta}_{.5})\}^{1/2}$ 을 나타낸다.

9.1.4 최소제곱법의 이용

뉴턴-랩슨 방법이나 피셔의 스코어링 방법으로 구하는 β 의 추정치 $\hat{\beta}$ 는 반복을 이용하여 수렴할 때까지 계산해야 하는 불편함이 있다. 이러한 반복을 피하기 위해 최소제곱법을 대신 이용할 수 있다. 물론, 이러한 방법은 반복을 이용하는 것보다 추정치의 정확성은 떨어지지만 계산상의 이점은 있다. $Y_i \sim B(m_i, \pi_i)$, $i = 1, \dots, n$ 일 때 π_i 의 관측치를 $p_i = y_i / m_i$ 라하고 p_i 의 함수 $\psi(p_i)$ 를 π_i 에 대해 테일러급수 전개하면

$$\psi(p_i) = \psi(\pi_i) + (p_i - \pi_i)\psi'(\pi_i) + o(m_i^{-2})$$

라 나타낼 수 있다. 따라서 1차 급수 전개까지만 고려하면, $E(p_i) = \pi_i$ 이므로 $E(\psi(p_i)) \simeq \psi(\pi_i)$ 이 되고, 또한,

$$Var(\psi(p_i)) \simeq Var[(p_i - \pi_i)\psi'(\pi_i)] = \psi'(\pi_i)^2 \frac{\pi_i(1 - \pi_i)}{m_i}$$

이 된다. 여기에 피어슨의 카이제곱 통계량을 고려하면

$$X^2 = \sum_{i=1}^n \frac{\{\psi(p_i) - \psi(\pi_i)\}^2}{\psi'(\pi_i)^2 \pi_i(1 - \pi_i) / m_i}$$

으로 표현되는데, X^2 를 최소화하는 추정법이 최소제곱법이 된다. 이때, ψ 는 여러 가지 함수로 표현 가능한데 가장 널리 사용되는 3가지 함수를 <표 9.7>에 소개한다.

<표 9.7> 이진자료에 사용되는 여러 가지 최소제곱모형

$\psi(\pi_i)$	X^2
π_i	$\sum \frac{(p_i - \pi_i)^2}{\pi_i(1 - \pi_i) / m_i}$
$\text{logit } \pi_i$	$\sum \{(\text{logit } p_i - \text{logit } \pi_i)^2 \pi_i(1 - \pi_i)m_i\}$
$\arcsin \sqrt{\pi_i}$	$\sum 4m_i \{\arcsin \sqrt{p_i} - \arcsin \sqrt{\pi_i}\}^2$

먼저, $\psi(\pi_i) = \pi_i$ 이고 $\pi_i = \mathbf{x}_i' \boldsymbol{\beta}$ 이면

$$X^2 = \sum \frac{(p_i - \mathbf{x}_i' \boldsymbol{\beta})^2}{\pi_i(1 - \pi_i) / m_i}$$

인데, 모수의 추정을 쉽게 하기 위해 분모의 π_i 를 p_i 로 대체시키면 다음의 수정된 카이제곱 통계량 X_{mod}^2 이 얻어진다.

$$X_{mod}^2 = \sum \frac{(p_i - \mathbf{x}_i' \boldsymbol{\beta})^2}{p_i(1 - p_i) / m_i} \quad (9.1)$$

위 식은 β 에 대해 이차함수이므로 반복없이 X_{mod}^2 를 최소화시키는 추정치 $\hat{\beta}$ 를 얻을 수 있다. 그 때의 적합치는 $\hat{\pi}_i = \mathbf{x}_i' \hat{\beta}$ 인데 $\hat{\pi}_i$ 이 0 과 1 사이에 있다는 보장이 없으므로 바람직한 추정치가 될 수 없다.

두 번째로, $\psi(\pi_i) = \text{logit } \pi_i$, 즉 $\pi_i = \exp(\mathbf{x}_i' \beta) / [1 + \exp(\mathbf{x}_i' \beta)]$ 이면

$$X_{mod}^2 = \sum (\text{logit } p_i - \mathbf{x}_i' \beta)^2 p_i(1 - p_i) m_i \quad (9.2)$$

된다. 콕스(Cox, 1970)는 $\text{logit } p_i$ 대신

$$z_i = \log \left(\frac{y_i + 0.5}{m_i - y_i + 0.5} \right) \quad (9.3)$$

를 사용하는 것이 더 바람직함을 보였다.

$$\text{logit } p_i = \log \left(\frac{y_i}{m_i - y_i} \right)$$

이므로 분자와 분모에 1/2을 각각 더한 것이 z_i 이며, 콕스의 이러한 변환을 경험적 로지스틱 변환(empirical logistic transformation)이라 한다. 식 (9.2)를 최소화시킨 추정치 $\hat{\beta}$ 를 사용하면 적합치 $\hat{\pi}_i = \exp(\mathbf{x}_i' \hat{\beta}) / [1 + \exp(\mathbf{x}_i' \hat{\beta})]$ 는 언제나 0 과 1 사이의 값이 된다.

마지막으로, 역사인 변환(arcsine transformation)은 분산안정화 변환(variance stabilizing transformation)으로부터 나왔다. 분산안정화 변환이란 변환된 p_i 의 분산, 즉 $\psi(p_i)$ 의 분산이 모수 π_i 에 의존하지 않고 상수가 되는 변환을 말한다. 이항분포의 경우

$$\text{Var}[\psi(p_i)] \simeq \psi'(\pi_i)^2 \pi_i(1 - \pi_i) / m_i \equiv \text{상수}$$

라는 미분방정식을 풀면

$$\psi(\pi_i) = \arcsin \sqrt{\pi_i}$$

가 되고

$$\text{Var}[\arcsin \sqrt{p_i}] = 1/4m_i$$

로 되어 변환된 p_i 의 분산이 상수로 주어진다. 즉, 역사인변환을 통해 관측치 p_i 의 분산을 상수로 만들 수 있다.

9.1.5 다항 분포와 다진 자료

반응변수 Y 가 k 개의 가능한 값을 가질 경우 반응치는 다진 자료(polytomous data)로 주어진다. 혈액형의 종류(A, B, O, AB), 김치의 맛(나쁨, 보통, 좋음), 혈압(90이하, 90에서 110, 110이상) 등이 그 예라 할 수 있다. 따라서, 앞에서 다루었던 이진자료는 다진자료의 특별한 경우라고 볼 수 있고, 다진자료에 대한 모형 역시 로지스틱 모형으로 적합 시킬 수 있음을 예상할 수 있다.

설명변수 $\mathbf{x}_i = (X_{i1}, \dots, X_{ip})'$ 가 주어졌을 때 반응치 Y_i 가 j 번째 범주에 속할 확률을 π_j 라 하면 $\sum_{j=1}^k \pi_j = 1$ 이 된다. 다진 자료의 경우에는 각 범주에 속할 확률 π_j 보다 누적확률 $\gamma_j = \pi_1 + \dots + \pi_j$ 이 더욱 편리하고 해석하기 좋다. 이 경우 로지스틱 회귀모형은

$$\log \left(\frac{\gamma_j(\mathbf{x})}{1 - \gamma_j(\mathbf{x})} \right) = \theta_j - \beta' \mathbf{x}, \quad j = 1, \dots, k-1 \quad (9.4)$$

으로 주어지고 $\gamma_j(\mathbf{x}) = P(Y \leq j | \mathbf{x})$ 이다. 이 모형은 일명 비례-오즈모형(proportional-odds model)이라고 불린다. 왜냐하면 $\mathbf{x} = \mathbf{x}_1$ 과 $\mathbf{x} = \mathbf{x}_2$ 에서 사건 $Y \leq j$ 에 대한 오즈비(odds ratio)가

$$\frac{\gamma_j(\mathbf{x}_1) / (1 - \gamma_j(\mathbf{x}_1))}{\gamma_j(\mathbf{x}_2) / (1 - \gamma_j(\mathbf{x}_2))} = \exp\{-\beta'(\mathbf{x}_1 - \mathbf{x}_2)\} \quad (9.5)$$

does not depend on j

로 주어지므로 특정한 범주 j 와 무관하기 때문이다. 또한, $\mathbf{X}$ 가 지시변수로서 두 처리(T_1, T_2)를 나타내면 식 (9.5)은

$$\frac{\text{odds}(Y \leq j | T_1)}{\text{odds}(Y \leq j | T_2)} = e^{-\Delta}$$

로서 Δ 는 처리효과를 나타낸다.

예제 9.3 다음 자료는 영국의 혹스베리(Hawkesbury)농과 대학에서 4종류의 치즈에 대한 맛을 조사한 것이다. 맛을 9가지로 분류하여 1번은 '매우 싫음'을 나타내고 9번은 '매우 좋음'을 나타내며, 52명에 대해 조사하였다. 모형(9.7)을 이용하면

$$\text{logit } \gamma_{ij} = \theta_j - \beta_i, \quad i = 1, 2, 3, 4; \quad j = 1, \dots, 8$$

으로 주어지고 구석점 제약($\beta_4 = 0$)을 이용하여 얻은 추정치의 결과는 $\hat{\beta}_1 = -1.613(0.378)$, $\hat{\beta}_2 = -4.965(0.474)$, $\hat{\beta}_3 = -3.323(0.425)$, $\hat{\beta}_4 = 0$ 이다.(괄호안의 숫자는 표준오차). 따

라서, D, A, C, B순으로 맛이 좋음을 알 수 있다.

귀무가설 ($\beta = 0$) 하에서 데비언스는 168.8이고 자유도는 $(9 - 1) \times 4 - 8 = 24$ 이며, 현재 모형 하에서 데비언스는 20.31, 자유도는 $24 - 3 = 21$ 이므로 귀무가설은 기각됨을 알 수 있다. 즉, 치즈에 따른 맛의 차이가 있음을 알 수 있다. □

<표 9.8> 4종류의 치즈의 맛에 대한 자료

선호도 치즈	1	2	3	4	5	6	7	8	9	합
A	0	0	1	7	8	8	19	8	1	52
B	6	9	12	11	7	6	1	0	0	52
C	1	1	6	8	23	7	5	1	0	52
D	0	0	0	1	3	7	14	16	11	52
합	7	10	19	27	41	28	39	25	12	208

예제 9.4 다음 자료는 광부들이 근무기간에 따른 진폐증(pneumoconiosis) 감염여부를 나타낸 것이다(애쉬포드(Ashford, 1959)). 진폐증 증세를 가벼운 것과 심각한 것으로 나누어서 반응치는 '정상', '가벼운 진폐증', '심각한 진폐증'의 3가지 범주로 분류되었다.

<표 9.9> 광부의 근무기간과 진폐증 감염 정도

근무기간(년)	정상	가벼운 진폐증	심각한 진폐증
5.8	98	0	0
15.0	51	2	1
21.5	34	6	3
27.5	35	5	8
33.5	32	10	9
39.5	23	7	8
46.0	12	6	1
51.5	4	2	5

맥켈러그와 넬드(McCullagh & Nelder, 1989)는 로지스틱 모형에 적합하기 전에 근무기간 x 보다 $\log x$ 를 사용하는 것이 선형성의 가정에 더 적절함을 보였다. 따라서

$$\text{logit } \gamma_{ij} = \theta_j - \beta \log x_i, \quad j = 1, 2; \quad i = 1, \dots, 8$$

을 사용하는 것이 바람직하다. 추정치는 $\hat{\beta} = 2.60(.38)$, $\hat{\theta}_1 = 9.68$, $\hat{\theta}_2 = 10.58$ 으로 계산되었다. 예를 들어, 5년 근무한 광부가 진폐증에 걸릴 위험은 $\exp(9.68 - 2.60 \log 5) = 243$ 명 중 1명 풀이고, 10년 근무하면 40명 중 1명 풀, 20년 근무하면 7명 중 1명 풀로 해석할 수 있다. 5년 근무한 광부가 심각한 진폐증에 걸릴 위험은 $\exp(10.58 - 2.60 \log 5) = 600$ 명 중 1명 풀이고 20년 근무하면 17명 중 1명 풀이다. □

9.2 로그선형모형

9.2.1 범주형 자료

몇 개의 변수가 범주형(categorical) 변수이고, 각 범주마다 발생한 개수(count) 또는 도수(frequency)로 구성된 자료를 흔히 범주형자료(categorical data)라고 한다. 이와 같은 범주형자료는 분할표(contingency table)를 이용하여 정리된다. 여기서는 범주형자료 분석에 대해 연구하고, 이에 대한 통계모형을 제시한다. 우선, 몇 가지 대표적인 범주형자료를 소개해 보자.

예제 9.5 (악성 종양 자료) 이 자료는 로버츠 등(Roberts et al., 1981)으로부터 인용한 것으로, 400명의 악성 종양 환자 중에서 종양의 종류와 부위에 따라 발생하는 빈도를 나타낸 것이다(<표 9.10> 참조). 반응변수는 종류를 나타내는 명목형 변수와 부위를 나타내는 명목형 변수로 2개가 있다. 이 문제에서 주 관심은 두 변수간에 관련성 여부를 밝히는 것이다. 분할표에 주어진 도수들은 합이 $n = 400$ 인 제약을 가지는 확률변수이다. □

Neither margin fixed design

<표 9.10> 악성종양 자료 : 종류 및 부위에 따른 빈도

부위 종류	얼굴	몸통	손, 발	합계
허친슨 종양	22	2	10	34
표피성 종양	16	54	115	185
결절성 종양	19	33	73	125
기타	11	17	28	56
합계	68	106	226	400

예제 9.6 (인플루엔자 백신 자료) 새로 개발된 인플루엔자 백신이 인플루엔자의 예방에 효과가 있는지 알아보기 위해, 35명에게 백신을 투여하고, 38명에게 식염수를 투여했다. 투여 6주 후에 혈액 속에 있는 HIA(Haemagglutinin Inhibiting Antibody) 양을 조사하여 <표 9.11>에 나타내었다. 이 경우, 설명변수는 처리(treatment)군과 대조(control)군을 구분하는 변수이고, 반응변수는 3가지로 구분된 HIA의 양이다. 이런 실험이 전형적인 사전연구(prospective study)의 예이다. □

Start of study → time

<표 9.11> 인플루엔자 백신자료

HIA	적음	보통	많음	합계
대조군(식염수)	25	8	5	38
처리군(백신)	6	18	11	35
합계	31	26	16	73

*not fixed
one margin fixed design*

예제 9.7 (위궤양과 십이지궤양 자료) 이 자료는 더건 등(Duggan et al., 1986)으로부터 인용한 것으로, 아스피린을 자주 복용하는 것이 위궤양 또는 십이지궤양에 어떤 영향을 주는가를 알아보기 위한 것이다. 위궤양이 있는 환자(case : 사례군) 64명에 대해 아스피린의 복용여부를 조사하고, 이들과 나이, 성별, 사회적 지위, 경제적 정도 등이 비슷한 사람들 중에서 위궤양이 없는 환자(control : 대조군) 68명에 대해 아스피린의 복용여부를 조사했다. 같은 방법으로 십이지궤양에 대해서 사례군 57명, 대조군 61명을 조사하였다(<표 9.12> 참조). 이러한 연구는, 인플루엔자 백신 자료의 사전연구와는 달리, 이미 병이 있는 사람들을 대상으로 하는 것으로 사후연구(retrospective study)라고 한다. 이러한 사후연구에서 주의해야 할 점은 대조군의 선정 시에 사례군과 여러 가지 외적요인이 동질적(homogeneous)이어야 한다는 것이다.

<표 9.12> 궤양과 아스피린 복용에 대한 사례-대조 연구

		아스피린		합계
		복용 안함	복용 함	
위궤양	사례군	39	25	64
	대조군	62	6	68
십이지궤양	사례군	49	8	57
	대조군	53	8	61

<표 9.12>는 $2 \times 2 \times 2$ 분할표로, 아스피린의 복용여부가 반응변수이고, 2개의 설명변수(궤양의 종류를 나타내는 변수와 사례군, 대조군을 나타내는 변수)가 있다. 그리고 이 예제에서는 다음의 세가지 문제에 대한 분석을 생각할 수 있다.

1. 위궤양은 아스피린 복용과 관련이 있는가?
2. 십이지궤양은 아스피린 복용과 관련이 있는가?
3. 아스피린의 복용이 위궤양과 십이지궤양에 같은 영향을 미치는가?

□

9.2.2 포아송 분포와 다항분포

범주형 자료는 9.2.1절에서 소개한 것처럼 분할표로 표현된다. <표 9.13>에는 행의 개수가 J 개, 열의 개수가 K 개인 $J \times K$ 이차원 분할표가 주어져 있는데 Y_{jk} 는 A 변수의 j 번째, B 변수의 k 번째 항목에 속하는 도수를 나타낸다. 그리고 $Y_{j\cdot}$ 는 A 변수의 j 번째 항목에 속하는 도수의 합, $Y_{\cdot k}$ 는 B 변수의 k 번째 항목에 속하는 도수의 합을 나타내고 총합은

$Y_{..} = n$ 으로 표시하였다. 또한, $Y_{j.}$ 이나 $Y_{.k}$ 를 주변합(marginal sum)이라 부르며, $Y_{j.}$ 은 행의 주변합이고 $Y_{.k}$ 는 열의 주변합이 된다.

<표 9.13> $J \times K$ 분할표

	B_1	B_2	...	B_K	합계
A_1	Y_{11}	Y_{12}	...	Y_{1K}	$Y_{1.}$
A_2	Y_{21}	Y_{22}	...	Y_{2K}	$Y_{2.}$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$
A_J	Y_{J1}	Y_{J2}	...	Y_{JK}	$Y_{J.}$
합계	$Y_{.1}$	$Y_{.2}$	...	$Y_{.K}$	$n = Y_{..}$

<표 9.13>에 주어져 있는 2차원 분할표처럼 자료가 생성되었을 때 사용되는 여러 가지 분포를 생각해 보자.

첫째, 가장 단순한 경우는 주변합에 대한 제약조건이 없을 때 사용가능한 것으로 Y_{jk} 가 서로 독립이고 평균이 λ_{jk} 인 포아송분포를 따른다고 가정한다. 즉,

$$Y_{jk} \sim P(\lambda_{jk}).$$

이 경우 Y_{jk} 들의 결합분포는 다음과 같이 각 주변분포의 곱으로 주어진다.

$$f(\mathbf{y}; \boldsymbol{\lambda}) = \prod_{j=1}^J \prod_{k=1}^K \frac{\lambda_{jk}^{y_{jk}} e^{-\lambda_{jk}}}{y_{jk}!} \quad (9.6)$$

여기서 $\mathbf{y}$ 와 $\boldsymbol{\lambda}$ 는 각각 Y_{jk} 와 λ_{jk} 들로 이루어진 벡터이다.

둘째, 총합 ($n = Y_{..}$)이 정해져 있는 경우가 흔히 있다. [예제 9.5]에 주어져 있는 악성 종양 자료가 이런 경우로, 총합이 400으로 정해져 있다. 이때는 Y_{jk} 의 분포가 총합이 n 이라는 조건하에서 구해져야 한다. 이러한 조건부 분포는 다항분포(multinomial distribution)가 된다. 예를 들어, 두 확률변수 Y_1 과 Y_2 가 서로 독립이고, 각각 평균이 λ_1 과 λ_2 인 포아송분포를 따를 때 $Y_1 + Y_2$ 는 평균이 $\lambda_1 + \lambda_2$ 인 포아송분포를 따르고, $Y_1 + Y_2 = n$ 으로 주어질 때 Y_1 의 조건부분포는 시행횟수가 n 이고 성공의 확률이 $\lambda_1/(\lambda_1 + \lambda_2)$ 인 이항분포를 따르게 된다(연습문제 9.5). 즉,

$$Y_1 | Y_1 + Y_2 = n \sim B(n, \frac{\lambda_1}{\lambda_1 + \lambda_2}).$$

이와 같은 성질은 두 개 이상의 포아송 확률변수에 대해서도 성립하며, 이를 이용하면

Y_{jk} 의 총합이 n 으로 주어졌을 때 Y_{jk} 들의 조건부분포는 다음과 같이 주어진다.

$$f(\mathbf{y} | Y_{..} = n) = \frac{\prod_{j=1}^J \prod_{k=1}^K \frac{\lambda_{jk}^{y_{jk}} e^{-\lambda_{jk}}}{y_{jk}!}}{\frac{\lambda_{..}^n e^{-\lambda_{..}}}{n!}} = n! \prod_{j=1}^J \prod_{k=1}^K \frac{\theta_{jk}^{y_{jk}}}{y_{jk}!} \quad (9.7)$$

여기서 $\lambda_{..}$ 와 θ_{jk} 는 각각

$$\lambda_{..} = \sum \sum \lambda_{jk}, \quad \theta_{jk} = \lambda_{jk} / \lambda_{..}$$

으로 정의된다. 식 (9.7)은 한 번 시행에서 JK 개의 가능한 결과 중에서 한가지가 발생하는 실험에서 각 결과의 성공의 확률이 θ_{jk} 라 하면, 이러한 실험을 독립적으로 n 번 시행했을 때 jk 번째 결과가 나타난 횟수 Y_{jk} 에 대한 분포이다. 즉,

$$\mathbf{y} | Y_{..} = n \sim \mathcal{M}(n, \theta_{11}, \dots, \theta_{JK})$$

인데 여기서 $\sum \sum Y_{jk} = n$, $\sum \sum \theta_{jk} = 1$ 이 된다.

셋째, 행 또는 열의 주변합이 사전에 정해져 있는 경우가 흔히 있다. [예제 9.6]의 인플루엔자 백신 자료가 이에 해당하는 것으로, 자료를 조사하기 전에 대조군을 38명($Y_{1.}$), 처리군을 35명($Y_{2.}$)으로 정해놓고 실험을 한 것이다. 이처럼 행의 주변합 $Y_{j.}$ 이 고정되어 있는 경우, j 번째 행의 각 도수 $Y_{j1}, \dots, Y_{jK}$ 의 조건부분포는

$$f(y_{j1}, \dots, y_{jK} | y_{j.}) = \frac{\prod_{k=1}^K \frac{\lambda_{jk}^{y_{jk}} e^{-\lambda_{jk}}}{y_{jk}!}}{\frac{\lambda_{j.}^{y_{j.}} e^{-\lambda_{j.}}}{y_{j.}!}} = y_{j.}! \prod_{k=1}^K \frac{\theta_{jk}^{y_{jk}}}{y_{jk}!}$$

로 주어지는 다항분포가 된다. 여기서, $\theta_{jk} = \lambda_{jk} / \lambda_{j.}$, $\sum_k \theta_{jk} = 1$ 이 된다. 또한, 각 행이 서로 독립이면 모든 도수 Y_{jk} ($j = 1, \dots, J$; $k = 1, \dots, K$)의 조건부 분포는 위의 다항 분포 확률함수의 곱이므로

$$f(\mathbf{y} | y_{j.}, j = 1, \dots, J) = \prod_{j=1}^J \left\{ y_{j.}! \prod_{k=1}^K \frac{\theta_{jk}^{y_{jk}}}{y_{jk}!} \right\} \quad (9.8)$$

와 같이 주어지는데 이를 적다항분포(product multinomial distribution)라고 부른다.

지금까지는 2차원 분할표에 대해 언급하였으나, 3차원 이상의 분할표도 같은 논리로 설

명할 수 있다. 예를 들어, $J \times K \times L$ 3차원 분할표를 생각해 보자. 이 때, 각 항목의 도수는

$$Y_{jkl} \quad (j = 1, \dots, J; k = 1, \dots, K; l = 1, \dots, L)$$

로 주어진다. 이 경우에도 각 도수 Y_{jkl} 은 평균 λ_{jkl} 인 포아송분포를 따른다고 가정한다. 그러므로 먼저 총합 및 주변합에 대한 제약조건이 없으면 이 때의 분포는

$$f(\mathbf{y} : \boldsymbol{\lambda}) = \prod_{j=1}^J \prod_{k=1}^K \prod_{l=1}^L \lambda_{jkl}^{y_{jkl}} \frac{e^{-\lambda_{jkl}}}{y_{jkl}!} \quad (9.9)$$

이다. 만약, 총합(n)에 대한 제약조건이 있으면

$$f(\mathbf{y} | Y_{\dots} = n) = \frac{\prod_{j=1}^J \prod_{k=1}^K \prod_{l=1}^L \frac{\lambda_{jkl}^{y_{jkl}} e^{-\lambda_{jkl}}}{y_{jkl}!}}{\frac{\lambda_{\dots}^n e^{-\lambda_{\dots}}}{n!}} \quad (9.10)$$

$$= n! \prod_{j=1}^J \prod_{k=1}^K \prod_{l=1}^L \frac{\theta_{jkl}^{y_{jkl}}}{y_{jkl}!} \quad (9.11)$$

인 다항분포로 주어진다. 여기서 $\theta_{jkl} = \lambda_{jkl} / \lambda_{\dots}$ 로 정의되며, $\sum \sum \sum \theta_{jkl} = 1$ 임을 알 수 있다. 그리고 3개의 변수 중 한 개(예를 들어, L)의 주변합에 대한 제약이 있는 경우에는 Y_{jkl} 들의 분포가

$$f(\mathbf{y} | y_{\dots l}, l = 1, \dots, L) = \prod_{j=1}^J \prod_{l=1}^L y_{\dots l}! \prod_{k=1}^K \frac{\theta_{jkl}^{y_{jkl}}}{y_{jkl}!} \quad (9.12)$$

인 적다항분포이고, 두 개(예를 들어, J 와 L)의 주변합에 대한 제약이 있는 경우에는

$$f(\mathbf{y} | y_{j \cdot l}, j = 1, \dots, J; l = 1, \dots, L) = \prod_{j=1}^J \prod_{l=1}^L y_{j \cdot l}! \prod_{k=1}^K \frac{\theta_{jkl}^{y_{jkl}}}{y_{jkl}!} \quad (9.13)$$

인 적다항분포로 주어짐을 알 수 있다.

[예제 9.7]에 주어진 위궤양과 십이지궤양 자료의 경우, $J = 2$ (사례군, 대조군), $K = 2$ (아스피린 복용여부), $L = 2$ (위궤양, 십이지궤양) 인데 각 궤양별로 사례군과 대조군의 숫자를 미리 정해 놓고 아스피린의 복용여부를 조사한 것이므로 두 개 (J 와 L)의 주변합에 대한 제약이 있는 경우(식 (9.12))에 해당된다.

이며, D 와 X^2 은 근사적으로 카이제곱분포를 따른다. 또한, 잔차도 데비언스 잔차와 피어슨 잔차 등을 이용해서 계산 할 수 있다.

[예제 9.5](악성 종양 자료)에 주어져 있는 악성 종양 자료를 로그선형 모형으로 분석해보자. 우리의 관심은 종양의 종류와 부위가 서로 독립인가에 있다. 따라서, 두 변수가 독립이라는 가정하에서 로그선형 모형은

$$\eta_{jk} = \log E(Y_{jk}) = \mu + \alpha_j + \beta_k, \quad j = 1, \dots, 4; k = 1, 2, 3$$

으로 표현되는데, 이 때 디자인 행렬은 각 열들의 선형종속으로 인해 $X'X$ 의 역행렬이 존재할 수 없다. 이를 위해 8.7절에서 논의한 것처럼 합이 0인 제약 ($\sum \alpha_j = 0, \sum \beta_k = 0$) 또는 구석점제약 ($\alpha_1 = 0, \beta_1 = 0$)을 이용한다. 따라서 이러한 제약 하에서 추정되어야 할 모수의 개수는 $1 + (J - 1) + (K - 1) = J + K - 1 = 6$ 개이다. 한편, 최대모형은

$$\eta_{jk} = \mu + \alpha_j + \beta_k + (\alpha\beta)_{jk}$$

으로, 추정되어야 할 모수의 개수는 $1 + (J - 1) + (K - 1) + (J - 1)(K - 1) = 12$ 개로 y_{jk} 의 개수와 같다. 즉, $\hat{\eta}_{jk} = \log \hat{\mu}_{jk} = \log y_{jk}$ 이며 데비언스는 $D = 0$ 이 된다. <표 9.14>는 SAS를 이용하여 악성종양 자료를 적합 시키는 과정을 보여주는데, 이 경우 구석점 제약 하에 추정되었다. 이 결과 TYPE(1)과 SITE(1)의 추정치는 0이 됨을 알 수 있다. 또한, $\hat{\mu} = 1.7544$ (다음 페이지의 SAS output에 Intercept로 표시), $SE(\hat{\mu}) = 0.2040$, $\hat{\alpha}_2 = 1.694$, $SE(\hat{\alpha}_2) = 0.1866$ 등이다. 아울러, $y_{11} = 22$ 에 대한 적합치(fitted value)는 다음과 같이 계산되었다.

$$\hat{\mu}_{11} = \hat{\mu} + \hat{\alpha}_1 + \hat{\beta}_1 = 1.754 + 0 + 0 = 1.754$$

$$\hat{y}_{11} = \exp(\hat{\eta}_{11}) = e^{1.754} = 5.78$$

다음으로 잔차를 살펴보자. SAS에서는 피어슨잔차(다음 페이지의 SAS output에 Reschi로 표시), 데비언스잔차(Resdev로 표시) 등 여러 형태의 잔차가 표시되어 있다. 예를 들어, 첫 번째 관측치의 피어슨잔차는

$$r_{11} = \frac{y_{11} - \hat{y}_{11}}{\sqrt{\hat{y}_{11}}} = \frac{22 - 5.78}{\sqrt{5.78}} = 6.747$$

으로 계산되며 첫 번째 관측치의 데비언스잔차 식(9.16)에 의해 5.135로 주어짐을 확인하

기 바란다. 또한, $D = 51.795$, $X^2 = 65.813$ 으로 $\chi^2_{0.05}(n-p) = \chi^2_{0.05}(6) = 12.59$ 보다 훨씬 큰 값이므로 귀무가설을 기각한다. 즉, 종양의 종류에 따라 부위는 서로 다르다고 결론 내릴 수 있다.

<표 9.14> SAS를 사용한 악성 종양 자료 분석

Criteria For Assessing Goodness Of Fit

Criterion	DF	Value	Value/DF
Deviance	6	51.7950	8.6325
Scaled Deviance	6	51.7950	8.6325
Pearson Chi-Square	6	65.8129	10.9688
Scaled Pearson X2	6	65.8129	10.9688
Log Likelihood		1124.3272	

Algorithm converged.

Analysis Of Parameter Estimates

Parameter	DF	Estimate	Standard Error	Wald 95% Confidence Limits	Chi-Square	Pr > ChiSq
Intercept	1	1.7544	0.2040	1.3546 2.1542	73.96	<.0001
type Type(4)=기타	1	0.4990	0.2174	0.0729 0.9251	5.27	0.0217
type Type(3)=결절성 종양	1	1.3020	0.1934	0.9229 1.6811	45.31	<.0001
type Type(2)=포리성 종양	1	1.6940	0.1866	1.3283 2.0597	82.42	<.0001
type Type(1)=악진성 종양	0	0.0000	0.0000	0.0000 0.0000	.	.
site Site(3)=손,발	1	1.2010	0.1383	0.9299 1.4721	75.40	<.0001
site Site(2)=몸통	1	0.4439	0.1554	0.1394 0.7485	8.16	0.0043
site Site(1)=얼굴	0	0.0000	0.0000	0.0000 0.0000	.	.
Scale	0	1.0000	0.0000	1.0000 1.0000		

NOTE: The scale parameter was held fixed.

Observation Statistics

Observation	y	Pred Reschi	Xbeta Resdev	Std StResdev	HessWgt StReschi	Resraw Reslik
1	22	5.78	1.7544037	0.204004	5.78	16.22
		6.7466306	5.1353779	5.8928151	7.7417178	6.3866483
2	2	9.01	2.1983351	0.1906456	9.01	-7.01
		-2.33537	-2.828294	-3.448819	-2.847747	-3.264194
3	10	19.21	2.955431	0.1770213	19.21	-9.21
		-2.101338	-2.315833	-3.670727	-3.33074	-3.470056
4	16	31.45	3.448399	0.1327075	31.45	-15.45
		-2.754978	-3.045336	-4.559392	-4.124676	-4.324017
5	54	49.025	3.8923304	0.1110827	49.025	4.975
		0.7105331	0.698997	1.1120964	1.1304501	1.123235
6	115	104.525	4.6494263	0.0856165	104.525	10.475
		1.0245754	1.0081398	2.0849079	2.1188981	2.1109998
7	19	21.25	3.0563569	0.1421474	21.25	-2.25
		-0.488094	-0.497111	-0.658079	-0.646142	-0.65298
8	33	33.125	3.5002883	0.1222046	33.125	-0.125
		-0.021719	-0.021732	-0.030572	-0.030553	-0.030563
9	73	70.625	4.2573842	0.0996232	70.625	2.375
		0.282608	0.2810458	0.5139207	0.5167773	0.5159246
10	11	9.52	2.2533948	0.1733869	9.52	1.48
		0.4796708	0.4679843	0.5539149	0.5677472	0.5579087
11	17	14.84	2.6973262	0.1574519	14.84	2.16
		0.5607081	0.5478701	0.6891039	0.7052513	0.6950881
12	28	31.64	3.4544221	0.1406482	31.64	-3.64
		-0.647118	-0.660161	-1.079334	-1.058009	-1.066037

예제 9.8 (위궤양과 십이지궤양 자료) [예제 9.7]에 주어져 있는 위궤양과 십이지궤양 자료를 여러 가지 형태의 로그선형모형에 적합시킨 결과가 <표 9.15>에 정리되어 있다. 이를 이용하여 다양한 분석을 할 수 있다.

<표 9.15> 위궤양과 십이지궤양 자료의 로그선형 모형 분석

모형	D (데비언스)	$d.f.$ (자유도)
$\mu + \alpha + \beta + \gamma$	21.79	4
$\mu + \alpha + \beta + \gamma + \alpha\beta$	10.54	3
$\mu + \alpha + \beta + \gamma + \alpha\gamma$	21.79	3
$\mu + \alpha + \beta + \gamma + \beta\gamma$	21.70	3
$\mu + \alpha + \beta + \gamma + \alpha\beta + \alpha\gamma$	10.54	2
$\mu + \alpha + \beta + \gamma + \alpha\beta + \beta\gamma$	6.45	2
$\mu + \alpha + \beta + \gamma + \alpha\gamma + \beta\gamma$	17.70	2
$\mu + \alpha + \beta + \gamma + \alpha\beta + \alpha\gamma + \beta\gamma$	6.28	1

이 표에서 α 는 대조군과 사례군, β 는 아스피린 복용여부, γ 는 궤양 부위를 나타낸다. 예를 들어, 아스피린의 복용이 궤양 발생에 영향을 미치는지 알고 싶으면 α 와 β 의 교호작용인 $\alpha\beta$ 가 없는 모형과 최대모형을 비교하면 된다. 즉,

$$H_0 : \eta = \mu + \alpha + \beta + \gamma + \alpha\gamma + \beta\gamma$$

를 최대모형 $\eta = \mu + \alpha + \beta + \gamma + \alpha\beta + \alpha\gamma + \beta\gamma$ 과 비교한다. $\Delta D = 17.70 - 6.28 = 11.42$ 이므로 $\chi^2_{0.05}(1) = 3.84$ 보다 크다. 따라서 귀무가설이 기각되며 아스피린의 복용이 궤양 발생에 영향을 미친다고 볼 수 있다. 한편, 아스피린의 복용이 위궤양과 십이지궤양 발생에 같은 영향을 미치는지 알고 싶으면 β 와 γ 의 교호작용인 $\beta\gamma$ 가 없는 모형과 최대모형을 비교하면 $\Delta D = 10.54 - 6.28 = 4.26$ 이므로 이것 역시 귀무가설을 기각시킨다. 즉, 아스피린의 복용이 위궤양과 십이지궤양의 발생에 서로 다른 영향을 미친다고 할 수 있다. $\square$

9.3 과산포

9.3.1 이항분포의 과산포

분석대상이 되는 모집단은 흔히 여러 집단(cluster)으로 구성되어 있다. 가족, 가구, 한 배 새끼(litter) 등이 집단의 좋은 예들이다. 과산포(overdispersion)는 이러한 집단에서 흔히 일어난다.

예를 들어, k 개의 집단이 있고, 각 집단으로부터 m 개의 관측치가 있을 때 X_i 를 m 번 시행중 성공의 횟수라 하자. 즉, $X_i \sim B(m, \pi_i)$, $i = 1, \dots, k$ 라고 하자. 또한, $Y = \sum_{i=1}^k X_i$ 를 전체 집단에서 성공의 회수라 하자. 대부분의 경우 성공의 확률 π_i 가 고정된 상수라고 가정하지만 여러 개의 집단으로 구성되어 있는 경우 성공의 확률들 간의 변동성이 존재하는 경우가 흔히 있다. 이는 표본분산이 이항분포의 분산보다 클 경우에 이런 현상이 나타날 경우가 많다. 따라서, 각 집단의 성공의 확률을 더 이상 고정된 상수가 아닌 변수로 취급하는 것이다. 이를 모형화하기 위해 각 집단에서 성공의 확률 π_i 가 주어져 있을 때 성공의 횟수 X_i 에 대한 조건부 분포를

$$X_i | \pi_i \sim B(m, \pi_i) \quad (9.17)$$

와 같이 정의한다. 또한, 성공의 확률 π_i 에 대한 평균과 분산을

$$E(\pi_i) = \pi, \quad \text{Var}(\pi_i) = \sigma^2 \pi(1 - \pi)$$

으로 가정한다. 이제 $n = mk$ 라 하면 전체 집단에 대한 성공의 회수 Y 의 평균과 분산은

$$E(Y) = n\pi \quad (9.18)$$

$$\text{Var}(Y) = n\pi(1 - \pi)\{1 + (m - 1)\sigma^2\}$$

이 되는데 이는 다음과 같이 증명할 수 있다. 우선 Y 의 기댓값을

$$\textcircled{1} E(Y) = \sum E(X_i) = \sum E[E(X_i | \pi_i)] = \sum E[m\pi_i] = mk\pi$$

이 된다. 한편 Y 의 분산은 k 개의 집단이 서로 독립이므로

$$\text{Var}(Y) = \sum_{i=1}^k \text{Var}(X_i)$$

이 되고, $\text{Var}(X_i)$ 를 계산하기 위해 다음과 같은 사실을 이용한다. 두 확률변수 X, Z 가 있을 때

$$\text{Var}(X) = E[\text{Var}(X | Z)] + \text{Var}[E(X | Z)]$$

이 성립된다. 우선 이 사실을 증명해 보자.

$$\begin{aligned}
 E(Y) &= E_X(E_Y(Y|Z)) \\
 \text{Var}(X) &= E[(X - E(X))^2] \\
 &= E[E\{(X - E(X))^2 | Z\}] \\
 &= E[E\{(X - E(X|Z) + E(X|Z) - E(X))^2 | Z\}] \\
 &= E[E\{(X - E(X|Z))^2 | Z\} + E\{(E(X|Z) - E(X))^2 | Z\} + 2E\{(X - E(X|Z))(E(X|Z) - E(X)) | Z\}] \\
 &= E[\text{Var}(X|Z)] + \text{Var}[E(X|Z)] \\
 &= E[\text{Var}(X|Z)] + \text{Var}[E(X|Z)]
 \end{aligned}$$

따라서,

$$\begin{aligned}
 \text{Var}(X_i) &= E[\text{Var}(X_i | \pi_i)] + \text{Var}[E(X_i | \pi_i)] \\
 &= E[m\pi_i(1 - \pi_i)] + \text{Var}[m\pi_i] \\
 &= mE[\pi_i - \pi_i^2] + m^2\text{Var}[\pi_i] \\
 &= m\pi - m(\pi^2 + \sigma^2\pi(1 - \pi)) + m^2\sigma^2\pi(1 - \pi) \\
 &= m\pi(1 - \pi)\{1 + (m - 1)\sigma^2\}
 \end{aligned}$$

임을 보일 수 있다. 이 때

$$\phi = 1 + (m - 1)\sigma^2$$

를 산포모수(dispersion parameter)라 하고 ϕ 가 1보다 매우 크면 과산포가 발생한 것이다.

이러한 과산포 현상은 일찍이 렉시스(Lexis, 1879)에 의해 지적되었으며, 그는 각 집단에서의 일양성(homogeneity)을 검정하기 위해 렉시스비(Lexis ratio)

$$Q = \frac{\sum_{i=1}^k (\hat{\pi}_i - \hat{\pi})^2 / k}{\hat{\pi}(1 - \hat{\pi}) / n} \quad (9.19)$$

← sample variance ← Variance under Binomial

을 제안한 바 있으며 $\hat{\pi}_i = X_i/m$, $\hat{\pi} = Y/n$ 이다. 여기서 분자는 표본분산(sample variance)이고 분모는 명목분산(nominal variance)이다. 따라서 과산포 현상은 표본분산이 명목분산보다 매우 클 때 발생된다고 할 수 있으며 Q 가 1보다 매우 클 때 나타난다.

과산포가 발생하였을 때 그 다음 조치는 이에 맞는 적절한 분포를 찾는 것인데 이항분포에서 과산포가 발생되면 흔히 베타-이항분포(beta-binomial distribution)가 대안으로 사용된다.

$$X_i | \pi_i \sim B(m, \pi_i) \quad \pi_i \sim \text{Beta}(\alpha, \beta) \Rightarrow \text{posterior}$$

original mixture dist'n prior

$$g(\pi | x) \propto \binom{m}{x} \pi^x (1-\pi)^{m-x} \cdot \frac{T(\alpha+\beta)}{T(\alpha)T(\beta)} \pi^{\alpha-1} (1-\pi)^{\beta-1}$$

$$\propto \pi^{x+\alpha-1} (1-\pi)^{m-x+\beta-1}$$

9.3 과산포 353

예제 9.9 다음 자료는 12명의 자녀를 둔 6115가구를 대상으로 각 가구의 남자 자녀수를 조사한 것이다.

<표 9.17> 12명의 자녀를 둔 6115가구에서 남자 자녀 수

남자 자녀수	0	1	2	3	4	5	6
가구수	3	24	104	286	670	1033	1343
남자 자녀수	7	8	9	10	11	12	
가구수	1112	829	478	181	45	7	

즉, $k = 6115$, $m = 12$ 이며 렉시스비 $Q = 1.165$ 로서 과산포가 어느 정도 있음을 알 수 있다. $\square$

9.3.2 포아송분포의 과산포

이항분포와 마찬가지로 포아송분포에서도 과산포가 흔히 발생한다. 포아송분포에서는 평균과 분산이 같으므로 $Var(Y) > E(Y)$ 인 상황이 포아송 모형에서의 과산포현상이다. 이러한 현상은 포아송과정(Poisson process)이 여러 집단으로 나타날 때 발생되기 쉬우며 다음과 같이 수식화 할 수 있다. 총 발생건수 Y 를

N 자체가 $r.v$ 이라.

$$Y = Z_1 + \cdots + Z_N$$

으로 표시할 때 Z_i 들은 서로 독립이고 N 은 포아송분포를 따르며 Z 와 독립이다. 이 경우

$$E(Y) = E[E(Y | N)] = E[NE(Z)] = E(N)E(Z)$$

$$Y/N = \sum_{i=1}^N Z_i \rightarrow E(Y/N)$$

이고,

$$= \sum_{i=1}^N E(Z_i) = N \cdot E(Z)$$

$$Var(Y) = E[Var(Y | N)] + Var[E(Y | N)]$$

$$= E[NVar(Z)] + Var[NE(Z)]$$

$$= E(N)Var(Z) + Var(N)\{E(Z)\}^2$$

$$= E(N)E(Z^2)$$

이다. 따라서 $E(Z^2) > E(Z)$ 일 경우 과산포가 발생된다.

$$Var(Y) > E(Y)$$

실제 자료에서 과산포의 존재 여부를 확인하는 가장 쉬운 방법은 이항분포에서처럼 표본분산과 명목분산을 비교하여 표본분산이 명목분산보다 훨씬 클 때 과산포를 의심하게 된다. 여기서, 명목분산이란 포아송분포이므로 표본평균이 그 추정치가 된다.

예제 9.10 다음 자료는 벨기에 운전자 중 9461명이 1년 동안 낸 사고 횟수를 나타낸 것이다. 표본분산은 0.289인데 명목분산의 추정치인 표본평균은 0.214이다. 따라서, 상당한 과산포 현상이 있음을 짐작 할 수 있다. $\square$

<표 9.18> 9461명의 벨기에 운전자가 1년동안 낸 사고 횟수

횟수	0	1	2	3	4	5	6	7
인원	7840	1317	239	42	14	4	4	1

$X \sim p(m)$
 $\Rightarrow$ negative Bin
 (과산포 현상)

9.4 로그 선형 모형과 로지스틱 모형과의 관계

$J \times K$ 분할표에서 반응치 Y_{jk} 에 대한 로그 선형모형은

$$\log \mu_{jk} = \varphi_j + \mathbf{x}'_{jk} \boldsymbol{\beta} \quad (9.20)$$

$\mu, \alpha_j, \beta_k, (\alpha\beta)_{jk}$

로 표현할 수 있다. 여기서 $\mu_{jk} = E(Y_{jk})$, $\mathbf{x}_{jk}$ 는 p 차원벡터 설명변수, $\boldsymbol{\beta}$ 는 관심 있는 모수(parameter of interest), $\varphi_1, \dots, \varphi_J$ 는 부수적인 모수(incidental parameter)이다. 따라서 로그 우도함수는 포아송분포로부터

$$\begin{aligned} l_Y(\varphi, \boldsymbol{\beta}) &= \sum_j \sum_k \{y_{jk}(\varphi_j + \mathbf{x}'_{jk} \boldsymbol{\beta}) - \exp(\varphi_j + \mathbf{x}'_{jk} \boldsymbol{\beta})\} \\ &= \sum_j \varphi_j y_{j\cdot} + \sum_j \sum_k y_{jk} \mathbf{x}'_{jk} \boldsymbol{\beta} - \sum_j \sum_k \exp(\varphi_j + \mathbf{x}'_{jk} \boldsymbol{\beta}) \end{aligned}$$

이 되며 $m_j = y_{j\cdot}$ 이라 두고 $\tau_j = \sum_k \mu_{jk} = \sum_k \exp(\varphi_j + \mathbf{x}'_{jk} \boldsymbol{\beta})$ 라 두자. 그러면 로그 우도함수는 $(\varphi, \boldsymbol{\beta})$ 의 함수가 아닌 $(\boldsymbol{\tau}, \boldsymbol{\beta})$ 의 함수로 표현된다. 즉,

$$\begin{aligned} l_Y(\boldsymbol{\tau}, \boldsymbol{\beta}) &= \sum_j (m_j \log \tau_j - \tau_j) + \sum_j \left\{ \sum_k y_{jk} \mathbf{x}'_{jk} \boldsymbol{\beta} - m_j \log \left(\sum_k \exp(\mathbf{x}'_{jk} \boldsymbol{\beta}) \right) \right\} \\ &= l_m(\boldsymbol{\tau}; \mathbf{m}) + l_{Y|m}(\boldsymbol{\beta}; \mathbf{y}) \end{aligned} \quad (9.21)$$

으로 표현 가능하다. 여기서, $l_m(\tau; \mathbf{m})$ 은 $Y_j \sim P(\tau_j)$ 로부터 얻어진 로그 우도함수이고 $l_{Y|m}(\beta; \mathbf{y})$ 는 $\mathbf{m} = (Y_1, \dots, Y_J)'$ 이 주어졌을 때의 조건부 로그 우도함수이다. 따라서, 관심 있는 모수 β 에 대한 모든 정보는 $l_{Y|m}(\beta; \mathbf{y})$ 에 들어 있으며 β 에 대한 추정은 $l_{Y|m}(\beta; \mathbf{y})$ 을 최대화함으로써 얻어진다.

이제 이러한 로그 선형모형이 다진 자료의 다항분포와 어떤 관계를 가지는 지 알아보자. $Y_{jk} \sim M(Y_j; \pi_{j1}, \dots, \pi_{jk})$ 라하고 여기서 $\pi_{jk} = \exp(\mathbf{x}'_{jk}\beta) / \sum_k \exp(\mathbf{x}'_{jk}\beta)$ 라 두면 $\mathbf{y}$ 의 로그 우도함수는

$$\begin{aligned} \sum_j \sum_k y_{jk} \log \pi_{jk} &= \sum_j \left\{ \sum_k y_{jk} \mathbf{x}'_{jk} \beta - \sum_k y_{jk} \log \sum_k \exp(\mathbf{x}'_{jk} \beta) \right\} \\ &= \sum_j \left\{ \sum_k y_{jk} \mathbf{x}'_{jk} \beta - m_j \log \left(\sum_k \exp(\mathbf{x}'_{jk} \beta) \right) \right\} \end{aligned}$$

이 된다. 이것은 다름 아닌 식 (9.20)의 $l_{Y|m}(\beta; \mathbf{y})$ 이며, 결론적으로 각 범주의 확률 π_{jk} 가 식 (9.21)처럼 정의되면 다진 자료의 로지스틱 모형과 같게 됨을 알 수 있다.

$$\pi_{j1}^{y_{j1}} \cdot \pi_{j2}^{y_{j2}} \cdots \pi_{jk}^{y_{jk}}$$

연습문제 (9)

$$\begin{aligned} &= \sum y_{jk} \log \pi_{jk} \cdot e^{\mathbf{x}_{jk}^T \beta} \\ &= \sum y_{jk} \log \frac{e^{\mathbf{x}_{jk}^T \beta}}{\sum_k e^{\mathbf{x}_{jk}^T \beta}} \end{aligned}$$

[이론 문제]

9.1 경험적 로지스틱 변환(식 (9.3))시킨 변수의 근사적 분산을 델타법(delta method)으로 구하라.

9.2 $Y \sim B(n, \pi)$ 일 때 $\varphi\left(\frac{Y+a}{n+b}\right)$ 를 생각하자. 단, a, b 는 상수이다.

(1) $\varphi\left(\frac{Y+a}{n+b}\right)$ 를 $\varphi(\pi)$ 에 대해 2차 테일러 급수 전개하라.

(2) $\frac{Y+a}{n+b} - \pi = \frac{1}{n}\{(Y - n\pi) + (a - \pi)\}(1 + O(n^{-1}))$ 을 이용하여 각각

$$E\left[\varphi\left(\frac{Y+a}{n+b}\right)\right] = \varphi(\pi) + \frac{1}{n}\varphi'(\pi)(a - b\pi) + \frac{1}{2n}\varphi''(\pi)\pi(1 - \pi) + O(n^{-2})$$

$$\text{Var}\left[\varphi\left(\frac{Y+a}{n+b}\right)\right] = \frac{1}{n}[\varphi'(\pi)]^2\pi(1 - \pi) + o(n^{-2})$$

임을 보여라.

(3) $\varphi(t) = \log[t/(1-t)]$ 이고 $a = \frac{1}{2}$, $b = 1$ 일 때

$$E \left[\varphi \left(\frac{Y+a}{n+b} \right) - \varphi(\pi) \right] = o(n^{-2})$$

임을 보여라.

(4) $\log \left[\left(Y + \frac{1}{2} \right) / \left(n - Y + \frac{1}{2} \right) \right]$ 이 $\log[Y / (n-Y)]$ 보다 편의(bias)가 작음을 보여라.

9.3 포아송분포에 대한 분산안정화 변환을 구하라.

9.4 설명변수가 한 개인 경우 로지스틱 회귀모형의 피셔 정보행렬이

$$I = \begin{bmatrix} \sum m_i \pi_i (1 - \pi_i) & \sum m_i x_i \pi_i (1 - \pi_i) \\ \sum m_i x_i \pi_i (1 - \pi_i) & \sum m_i x_i^2 \pi_i (1 - \pi_i) \end{bmatrix}$$

임을 보여라.

9.5 $X_1, \dots, X_n$ 이 서로 독립이면서 포아송분포 $P(\lambda)$ 를 따를 때 $X_1 \mid \sum X_i = t$ 의 분포는 이항분포 $B(t, 1/n)$ 임을 보여라.

9.6 포아송분포의 과산포 현상은 또 다른 방법으로 설명될 수 있다. 발생 건수 Y 가 평균 Z 인 포아송분포를 따르고 Z 는 상수가 아닌 감마분포 $\gamma(\varphi\mu, \frac{1}{\varphi})$ 을 따른다고 하자.

(1) $E(Z) = \mu$, $Var(Z) = \mu / \varphi$ 임을 보여라.

(2) Y 의 분포는 음이항분포(negative binomial distribution), 즉

$$P(Y = y; \mu, \varphi) = \frac{\gamma(y + \varphi\mu) \varphi^{\varphi\mu}}{y! \gamma(\varphi\mu) (1 + \varphi)^{y + \varphi\mu}}$$

임을 보여라.

(3) $E(Y) = \mu$, $Var(Y) = \mu(1 + \varphi)$ 임을 보여라.

[응용 문제]

9.1 다음 자료는 흡연을 하는 광부들을 대상으로 숨이 차는 것(breathlessness)과 천식(wheeze)과의 관계를 연령별로 조사한 것이다.

연령	숨이 찬다		숨이 차지 않는다		계
	천식 있음	천식 없음	천식 있음	천식 없음	
20-24	9	7	95	1841	1952
25-29	23	9	105	1654	1791
30-34	54	19	177	1863	2113
35-39	121	48	257	2357	2783
40-44	169	54	273	1778	2274
45-49	269	88	324	1712	2393
50-54	404	117	245	1324	2090
55-59	406	152	225	967	1750
60-64	372	106	132	526	1136

(1) 숨이 찬 여부와 연령간의 관계를 알기 위해 경험적 로지스틱 변환

$$Z_a = \log\left\{\left(y_{1\cdot} + \frac{1}{2}\right) / \left(y_{2\cdot} + \frac{1}{2}\right)\right\}$$

을 하여 그림을 그려 보고 연령과 숨이 찬 여부간에 강력한 선형관계와 미약한 이차(quadratic)관계가 있음을 보여라.

(2) 경험적 오즈-비(empirical odds-ratio)

$$Z_{ab} = \log \left\{ \frac{(y_{11} + \frac{1}{2})(y_{22} + \frac{1}{2})}{(y_{12} + \frac{1}{2})(y_{21} + \frac{1}{2})} \right\}$$

를 연령에 대해 그려 보고 선형적으로 감소함을 보여라.

(3) 로지스틱 회귀모형에 적합하라.

9.2 [예제 9.7]의 인플루엔자 백신자료에서 처리군과 대조군간에 차이가 있는지를 검정하라.

9.3 다음 자료는 가구의 형태와 이웃간의 접촉 정도가 어떤 영향을 미치는지 조사한 것이다.

만족도	접촉정도					
	낮음	낮음 보통	높음	낮음	높음 보통	높음
연립주택	65	54	100	34	47	100
아파트	130	76	111	141	116	191
단독주택	67	48	62	130	105	104

각 변수간의 교호 작용이 존재하는지 검정하고 최적모형에 적합 시켜라.

제 10 장

비선형회귀모형

- 10.1 비선형회귀모형
- 10.2 모수의 추정
- 10.3 비선형회귀분석에서의 추론

선형회귀분석에서는 변수들 간의 관계를 선형함수로 나타내어 설명을 하였으나, 과학의 여러 분야에서 나타나는 현상들은 변수들 간의 비선형관계의 결과로 설명되는 것이 더욱 자연스러운 경우가 많다. 물론 변수들 간의 관계가 알려져있지 않은 경우에는 근사적 방법으로 선형모형을 사용할 수 있지만, 과학과 기술의 발달로 더욱 많은 분야에서 비선형관계를 갖는 경우가 알려지고 있다. 회귀모형에 주어진 회귀식이 모수들의 비선형함수로 나타내어지는 경우 이 모형을 비선형회귀모형(nonlinear regression model)이라 한다. 이 모형에 대한 통계적분석은 회귀계수의 추정방법에서 선형회귀모형의 경우와 큰 차이가 있으며, 대부분의 결과는 근사적 방법으로 유도된다.

10.1 비선형회귀모형

$$\underline{x} \in R^k \quad \underline{\theta} \in R^p \quad \underline{f: \text{known}}$$

반응변수 Y 와 k 개의 설명변수들 $\mathbf{x} = (X_1, X_2, \dots, X_k)'$ 간의 관계를 설명하는 일반적인 회귀모형은 다음과 같이 나타낼 수 있다.

$$Y_i = f(\mathbf{x}_i, \boldsymbol{\theta}) + \varepsilon_i, \quad i = 1, 2, \dots, n \quad (10.1)$$

이 식에서 $f(\mathbf{x}_i, \boldsymbol{\theta})$ 는 설명변수들 $\mathbf{x}$ 와 미지의 p 차원 모수벡터 $\boldsymbol{\theta} = (\theta_1, \theta_2, \dots, \theta_p)'$ 의 함수로 주어지는 회귀식을 나타낸다. 이 회귀식이 모수 $\boldsymbol{\theta}$ 들의 비선형함수로 주어지면 모형 (10.1)은 비선형회귀모형이 된다(비선형모형을 판정하는 방법은 3.1.2절에서 설명되었다). 그리고 ε_i 는 오차항으로 선형회귀모형에서와 같은 성질을 갖는다고 가정한다. 즉, ε_i 는 서로 독립인 확률변수들로 평균이 0이고 분산은 σ^2 으로 주어진다.

일반적으로 비선형회귀모형을 사용하는 대부분의 문제들에서 회귀식 $f(\mathbf{x}_i, \boldsymbol{\theta})$ 의 형태는 과학적 이론이나 분석에 근거하여 알려져 있다. 예를 들어, 가장 간단한 형태의 화학반응을 생각하여 보자. 만일 A라는 화학물질이 반응을 일으켜 B라는 물질로 변해간다고 하고, 반응속도는 현재 남아 있는 A의 농도에 비례한다고 가정하면(이를 first-order kinetics라 한다), 이 화학반응 시스템은 다음과 같은 미분방정식으로 표현될 수 있다.

$$\frac{\partial f_A(X, \theta)}{\partial X} = -\theta f_A(X, \theta), \quad \frac{\partial f_B(X, \theta)}{\partial X} = \theta f_A(X, \theta) \quad (\theta > 0)$$

여기에서 $f_A(X, \theta)$ 와 $f_B(X, \theta)$ 는 화학물질 A와 B의 농도를 나타낸다. 시간 $X = 0$ 에서 A의 농도는 100%이고, B는 전혀 없다고 가정하면 위의 미분방정식의 해는 다음과 같이 주어진다.

$$f_A(X, \theta) = e^{-\theta X}, \quad f_B(X, \theta) = 1 - e^{-\theta X} \quad (10.2)$$

그러므로 반응이 시작한 후 적당한 간격의 시간들에서 A 또는 B의 농도를 측정하면 비선형회귀모형을 $Y_A = e^{-\theta X} + \varepsilon$ 또는 $Y_B = 1 - e^{-\theta X} + \varepsilon$ 로 설정할 수 있을 것이다(Y_A 와 Y_B 는 각각 A와 B의 농도의 관측치를 나타낸다). 그러므로 비선형회귀분석에서는 모형의 설정보다는 모수의 추정에 더 큰 비중을 준다고 할 수 있다.

다음 예제는 비선형회귀모형의 또 다른 경우를 보여준다.

예제 10.1 어느 식물의 성장 속도에 관한 실험에서 <표 10.1>의 자료를 얻었다. 성장

치(Y)와 시간(X)에 대한 관계를 나타내는 회귀모형을 설정하라.

<표 10.1> 식물의 성장에 관한 자료

i	1	2	3	4	5	6	7	8	9
X_i	1	1.5	2	3	4	5	6	7.5	8.5
Y_i	2.1	2.5	4.9	5.5	7.0	8.4	9.6	10.2	11.4
i	10	11	12	13	14	15	16	17	18
X_i	10	12.5	15	17.5	20	25	30	35	40
Y_i	12.5	13.1	14.6	17.0	16.8	18.6	19.7	21.3	21.6


<풀이> 동식물들의 성장에 관한 연구에서 성장치(Y)와 시간(X)의 관계를 나타내는 회귀식들 중의 하나는 다음과 같이 주어진다.

$$f(X, \theta_1, \theta_2) = \frac{\theta_1 X}{\theta_2 + X} \quad (10.3)$$

위의 자료에 대한 산점도는 (그림 10.1)에 주어져 있는데 모형 (10.3)은 이와 같은 산점도의 형태를 설명하기에 적당한 것이다. 그러므로 우리는 두 변수간의 관계에 대한 비선형회귀모형을

$$Y_i = \frac{\theta_1 X_i}{\theta_2 + X_i} + \epsilon_i, \quad i = 1, 2, \dots, 18 \quad (10.4)$$

와 같이 설정하여 분석할 수 있다. □



(그림 10.1) 식물의 성장 자료의 산점도

비선형회귀모형과 선형회귀모형의 또 다른 차이점은 모수의 해석에 있다. 선형회귀모형에서의 모든 회귀계수는 설명변수의 변화량에 따른 반응변수의 변화량으로 해석되지만 비선형회귀모형에서는 각 모수가 특정한 의미를 갖는다는 것이다. 이를 테면, 위의 화학반응 문제에서는 모수 θ 가 반응속도로 해석이 된다. 그리고 회귀식 (10.3)에서는 시간 X 가 무

한대로 가면 $f(X, \theta)$ 는 θ_1 이 된다. 즉,

$$X \rightarrow \infty \Rightarrow f(X, \theta_1, \theta_2) = \frac{\theta_1}{\theta_2 / X + 1} \rightarrow \theta_1$$

그러므로 θ_1 는 성장치가 접근하는 최대값으로 해석할 수 있다. 그리고 이 최대 성장치의 반만큼 성장하기에 걸리는 시간 $X_{1/2}$ 을 생각하여 보자. 이 경우에는 다음 식이 성립하며

$$\frac{1}{2}\theta_1 = \frac{\theta_1 X_{1/2}}{\theta_2 + X_{1/2}}$$

이 식을 정리하면 $\theta_2 = X_{1/2}$ 라는 결과를 얻는다. 즉, θ_2 는 동식물이 자랄 수 있는 최대 성장치의 반만큼 성장하기까지 걸리는 시간의 의미를 가지고 있다. 이 경우 우리는 모수의 값을 정확하게 추정하지 않더라도 대략적인 값을 알 수 있다. 이를테면, 위의 성장속도에 대한 예제에서는 θ_1 이 최대성장치를 나타내므로 (그림 10.1)의 산점도에서 대략 22 정도의 값이 됨을 알 수 있고, θ_2 는 이것의 반인 11에 해당하는 시간으로 9 정도의 값이 됨을 알 수 있다. 그러므로 비선형회귀분석에서는 각 모형에 포함된 모수들의 의미를 정확하게 먼저 파악하는 것이 모형의 해석과 분석에 필수적이다.

10.2 모수의 추정

10.2.1 최소제곱법

비선형회귀분석에서도 모수 θ 의 추정방법으로 최소제곱법을 사용한다. 즉, θ 의 최소제곱추정량 $\hat{\theta}$ 은 오차의 제곱합

$$S = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (Y_i - f(x_i, \theta))^2$$

을 최소화하는 θ 의 값으로 주어진다. 선형회귀분석에서와 같이 제곱합 S 에 대한 편미분을 계산하면

$$\frac{\partial S}{\partial \theta_j} = (-2) \sum_{i=1}^n (Y_i - f(x_i, \theta)) \frac{\partial f(x_i, \theta)}{\partial \theta_j}, \quad j = 1, 2, \dots, p$$

와 같이 주어지며 이들을 0으로 놓고 정리한 후 θ 에 추정량 $\hat{\theta}$ 을 대입하면 다음의 정규방정

식을 얻을 수 있다.

$$\sum_{i=1}^n f(x_i, \hat{\theta}) \frac{\partial f(x_i, \theta)}{\partial \theta_j} \Big|_{\theta=\hat{\theta}} = \sum_{i=1}^n Y_i \frac{\partial f(x_i, \theta)}{\partial \theta_j} \Big|_{\theta=\hat{\theta}}, \quad j = 1, 2, \dots, p \quad (10.5)$$

그러나 위의 정규방정식은 $\hat{\theta}$ 의 비선형함수이므로 위 식을 만족하는 $\hat{\theta}$ 의 값을 직접 구하는 못하며 7장에서와 같이 뉴턴-랩슨(Newton-Raphson)방법 등과 같은 반복추정방법을 사용하여야 한다.

예를 들어, 앞의 화학 반응 예제에서 주어진 회귀식

$$Y_i = e^{-\theta X_i} + \varepsilon_i$$

에서는

$$f(X_i, \theta) = e^{-\theta X_i}, \quad \frac{\partial f(X_i, \theta)}{\partial \theta} = (-X_i)e^{-\theta X_i} \quad (10.6)$$

이므로 이들을 식 (10.4)에 대입하여 정리하면 정규방정식은

$$\sum_{i=1}^n X_i e^{-2\hat{\theta} X_i} = \sum_{i=1}^n X_i Y_i e^{-\hat{\theta} X_i}$$

로 주어지게 되나 이를 해 $\hat{\theta}$ 에 대한 식으로 나타내지를 못한다.

10.2.2 가우스-뉴튼 방법

비선형회귀분석에서 최소제곱추정량을 구하기 위하여 사용하는 반복추정방법들 중에서 가장 기본적인 것은 가우스-뉴튼(Gauss-Newton) 방법(또는 선형화 방법)이다. 이 방법은 매 단계에서 비선형회귀식을 모수 θ 에 대한 선형함수로 근사화하여 선형회귀분석에서의 방법으로 모수 θ 를 추정해 나가는 것이다. 즉, 모수 θ 에 대해 타당한 초기값 $\theta^0 = (\theta_1^0, \theta_2^0, \dots, \theta_p^0)'$ 이 주어진다고 가정하면 일차 테일러(Taylor) 전개를 이용하여 비선형회귀식을

$$f(x_i, \theta) \approx \underbrace{f(x_i, \theta^0)}_{\text{const}} + \sum_{j=1}^p \underbrace{\frac{\partial f(x_i, \theta)}{\partial \theta_j} \Big|_{\theta=\theta^0}}_{\text{linear}} (\theta_j - \theta_j^0) \quad (10.7)$$

와 같이 θ 들의 선형함수로 근사화시킬 수 있다. (편미분 $\partial f(x_i, \theta) / \partial \theta_j$ 에서는 θ 대신에

$$\approx f(\tilde{x}_i : \theta^{(n)}) + \nabla f(\tilde{x}_i : \theta^{(n)})^T (\theta - \theta^{(n)})$$

초기값 θ^0 를 대입하므로 상수가 된다.) 식 (10.7)를 비선형회귀모형 (10.1)에 대입하면

$$Y_i = f(x_i, \theta^0) + \sum_{j=1}^p \frac{\partial f(x_i, \theta)}{\partial \theta_j} \bigg|_{\theta=\theta^0} (\theta_j - \theta_j^0) + \varepsilon_i, \quad i = 1, 2, \dots, n$$

가 되며 이를 벡터와 행렬을 사용하여 다음과 같이 나타낼 수 있다.

$$\underset{n \times 1}{y} = \underset{n \times 1}{\eta(\theta^0)} + \underset{n \times p}{V} \underset{p \times 1}{(\theta - \theta^0)} + \underset{n \times 1}{\varepsilon} \quad (10.8)$$

이 식에서

$$\eta(\theta^0) = (f(x_1, \theta^0), \dots, f(x_n, \theta^0))'$$

이며 V 는 $n \times p$ 행렬로 (i, j) 번째 원소는

$$v_{ij} = \frac{\partial f(x_i, \theta)}{\partial \theta_j} \bigg|_{\theta=\theta^0}$$

로 정의되며, V 를 도함수행렬(derivative matrix)이라 부른다.

식 (10.8)에서 $\eta(\theta^0)$ 는 상수값을 가지므로 이 식을

$$y - \eta(\theta^0) = V(\theta - \theta^0) + \varepsilon \quad (10.9)$$

으로 나타내면 위의 식은 반응변수의 벡터가 $y^* = y - \eta(\theta^0)$, 디자인 행렬이 V 이고, 모수 벡터가 $\beta = (\theta - \theta^0)$ 인 선형회귀모형의 형태가 된다. 즉,

$$y^* = V\beta + \varepsilon \quad (10.10)$$

그러므로 선형회귀모형에서의 공식 (3.8)을 사용하면 β 의 추정량은

$$\begin{aligned} \hat{\beta} &= (V'V)^{-1}V'y^* \\ &= (V'V)^{-1}V'(y - \eta(\theta^0)) \end{aligned} \quad (10.11)$$

으로 주어진다. 이 것은 첫 번째 단계에서의 추정량이므로 $\hat{\beta}^{(1)}$ 이라 나타내면, $\beta = (\theta -$