

θ^0 의 관계식에서 θ 의 첫 번째 단계에서의 추정량은

$$\hat{\theta}^{(1)} = \hat{\beta}^{(1)} + \theta^0 \quad (10.12)$$

의 식으로 주어진다. 두 번째 단계에서는 위에서 구한 $\hat{\theta}^{(1)}$ 의 값을 초기치로 가정하여 식 (10.7)에서 식 (10.12)까지의 과정을 반복하면 두 번째 추정량을 얻을 수 있다. 이와 같은 단계들을 반복하여 얻는 추정량

$$\hat{\theta}^{(i)} = \hat{\beta}^{(i)} + \hat{\theta}^{(i-1)}, \quad i = 1, 2, \dots \quad (10.13)$$

들은 오차제곱합 S 를 최소화하는 θ 의 값에 수렴하게 된다.

식 (10.13)의 반복과정은 $\hat{\theta}^{(i)}$ 와 $\hat{\theta}^{(i-1)}$ 의 값의 차이가 무시할 수 있을 정도로 작게 되면 끝나게 된다. 그리고 확실한 수렴을 확인하기 위하여 매 단계에서 제곱합 S 의 값을 계산하여 실제로 그 값이 감소하고 있는가를 검사할 필요가 있다.

결론적으로 가우스-뉴튼(Gauss-Newton)방법은 비선형회귀식의 θ 에 대한 선형근사화를 이용하여(가우스의 생각), θ 의 최소제곱추정량을 반복적으로(뉴튼의 생각) 구해 나가는 것이라 할 수 있다.

10.2.3 초기치의 계산

앞 절에서 설명된 가우스-뉴튼방법을 사용하기 위해서는 사전에 알려진 모수 θ 의 초기치가 필요하다. 이 초기치로는 과거의 분석에서 알려진 θ 의 값이나, 또는 해당 전문가의 경험이나 지식에 의해 주어지는 값을 사용할 수 있다. 가우스-뉴튼방법에서의 반복추정량이 제대로 수렴을 하기 위해서는 정확한 초기치의 선택이 중요하다. 오차제곱합 S 의 공간은 매우 복잡한 형태를 가질 수 있으므로 시작점에 따라 값이 다른 국소최적점(local optimum)에 수렴하는 경우가 있을 수 있다. 그러므로 정확한 초기치를 사용할수록 대역최적점(global optimum)에 도달할 가능성이 높아진다.

이 절에서는 과거의 분석에서 알려진 θ 의 값이 없는 경우 현재의 관측치를 이용하여 θ 의 타당한 초기치를 구하는 방법을 예제를 이용하여 알아보자. 일반적인 방법은 각 회귀식의 특성을 이용하는 것이다. 예를 들어, 화학반응의 예에서 모형

$$f_A(X_i, \theta) = e^{-\theta X_i}$$

를 사용한다고 하자. 양변에 로그함수를 취하면 $\log f_A = -\theta X_i$ 으로 θ 의 선형함수를 얻게 된다. 그러므로 f_A 대신에 관측치 Y_i 를 사용하여 $\log Y_i$ 의 $(-X_i)$ 에 대한 절편이 없는 선형 회귀식을 적합시켜 구한 기울기를 θ 의 초기값으로 사용할 수 있다.

예제 10.2 식물의 성장에 관한 예제에서 주어진 비선형회귀식 (10.3)에 나타나는 모수 θ_1 과 θ_2 의 초기치를 구하고, 가우스-뉴튼방법을 이용하여 최소제곱추정치를 구하라.

<풀이> 이 경우에도 10.1절에서 설명된 회귀식 (10.3)의 특성을 이용하면 된다. 즉, θ_1 은 성장치의 최대값을 나타내므로 θ_1^0 는 관측치 Y_i 의 최대값보다 약간 큰 값으로 주면 되고, θ_2 는 θ_1 의 반만큼 성장할 때까지 걸리는 시간이므로 자료의 산점도에서 대충 짐작하여 θ_2^0 의 값을 구할 수 있다. 그러므로 이 자료에서 성장치의 최대값은 21.6이므로 θ_1^0 은 22정도로 생각할 수 있고, 이 값의 반인 성장치 11에 해당하는 시간의 대략적인 값은 (그림 10.1)의 산점도에서 9정도 되므로 이 값을 θ_2^0 로 하면 된다. 가우스-뉴튼방법을 적용하기 위해서는 먼저 도함수 행렬 V 를 계산하여야 한다. 회귀식 (10.3)의 각 모수에 대한 도함수는

$$\frac{\partial f(X, \theta_1, \theta_2)}{\partial \theta_1} = \frac{X}{\theta_2 + X}, \quad \frac{\partial f(X, \theta_1, \theta_2)}{\partial \theta_2} = -\frac{\theta_1 X}{(\theta_2 + X)^2}$$

이므로 초기값 $\theta^0 = (22, 9)'$ 과 X 의 관측값을 대입하면 행렬 V 를 계산할 수 있다. <표 10.2>는 초기치 θ^0 에서 계산된 행렬 V 와 벡터 $y^* = y - \eta(\theta^0)$ 의 값을 보여준다.

<표 10.2> 초기치 θ^0 에서 계산된 벡터 $y^* = y - \eta(\theta^0)$ 와 행렬 V

y^*	V	
-0.100000	0.07366781	-0.1526983
-0.642857	0.10657610	-0.2130625
0.900000	0.13722645	-0.2649258
0.000000	0.19262317	-0.3479961
0.230769	0.24133531	-0.4096947
0.542857	0.28450392	-0.4554965
0.800000	0.32302437	-0.4893255
0.200000	0.37360924	-0.5236638
0.714285	0.40333200	-0.5384991
0.921052	0.44297868	-0.5521336
0.309302	0.49851542	-0.5594042
0.850000	0.54398184	-0.5550807
2.471698	0.58188928	-0.5444039
1.627586	0.61397813	-0.5303400
2.423529	0.66534573	-0.4982339
2.776923	0.70464798	-0.4656952
3.800000	0.73568901	-0.4351100
3.640816	0.76082584	-0.4071825

이 값들을 식 (10.9)에 대입하면 추정치 $\hat{\beta}^{(1)} = (5.54322, 3.23545)'$ 을 얻게 되므로 θ 의 첫 번째 추정량은 식 (10.11)을 이용하면

$$\hat{\theta}^{(1)} = \begin{bmatrix} 5.54322 \\ 3.23545 \end{bmatrix} + \begin{bmatrix} 22 \\ 9 \end{bmatrix} = \begin{bmatrix} 27.54322 \\ 12.23545 \end{bmatrix}$$

로 주어진다. 그리고 이것은 두 번째 단계를 위한 θ 의 초기값으로 사용된다. 이와 같은 과정을 반복하여 오차제곱합 S 를 최소화해 나갈 수 있는데 <표 10.3>은 각 단계에서의 θ 와 S 의 값을 보여주고 있다. 이 예제에서는 단계 4와 5에서 θ 와 S 의 값들의 변화가 거의 없으므로 반복과정을 끝내고 θ 의 최종추정치로

$$\hat{\theta} = (28.13705, 12.57445)'$$

을 얻게 된다. □

<표 10.3> 가우스-뉴튼 방법에서의 단계별 결과치

단 계	θ_1	θ_2	오차제곱합(S)
0	22.00000	9.00000	54.476590
1	27.54322	12.23545	4.710087
2	28.12124	12.55969	4.302396
3	28.13652	12.57386	4.302271
4	28.13703	12.57443	4.302271
5	28.13705	12.57445	4.302271

10.3 비선형회귀분석에서의 추론

가우스-뉴튼(Gauss-Newton)방법을 이용하여 모수 θ 의 최소제곱추정치 $\hat{\theta}$ 을 구한 다음에는 θ 에 대한 신뢰구간을 구하거나 가설검정을 할 필요가 있다. 가우스-뉴튼방법에서 알 수 있듯이 도함수 행렬 V 는 선형회귀모형에서의 디자인 행렬 X 와 같은 역할을 하는데 이는 추론의 과정에서도 마찬가지이다.

앞에서 오차항 ε_i 가 정규분포를 따른다는 가정을 추가하면 선형회귀분석에서와 같이 최소제곱추정량 $\hat{\theta}$ 은 최우추정량이 된다. 그리고 표본의 크기 n 이 어느 정도 크면 추정량 $\hat{\theta}$ 의 분포는 근사적으로 평균이 θ 이고 분산-공분산행렬이 $(\hat{V}'\hat{V})^{-1}\sigma^2$ 인 정규분포를 따르게 된다. 즉,

$$\hat{\theta} \sim N(\theta, (\hat{V}'\hat{V})^{-1}\sigma^2) \quad (10.14)$$

위에서 $\hat{V}$ 는 $\theta = \hat{\theta}$ 에서 계산된 행렬 V 를 나타낸다.

오차분산 σ^2 의 추정량도 선형회귀분석에서와 같이 잔차의 제곱합을 자유도로 나눈 값으로 정의된다. 즉,

$$s^2 = \frac{1}{n-p} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \frac{1}{n-p} \sum_{i=1}^n (Y_i - f(x_i, \hat{\theta}))^2$$

식 (10.14)에서 주어진 $\hat{\theta}$ 의 분포와 추정량 s^2 을 이용하면 선형회귀분석에서와 같은 공식을 사용하여 모수 θ 에 대한 추론을 할 수 있다. 이를 테면, θ 에 대한 $100(1 - \alpha)\%$ 공동신뢰영역은 3장의 식 (3.18)을 이용하면

$$(\theta - \hat{\theta})' \hat{V}' \hat{V} (\theta - \hat{\theta}) \leq ps^2 F_{\alpha}(p, n - p) \quad (10.15)$$

으로 주어진다. 그리고 각 모수 θ_j 에 대한 개별적인 추론을 하려면 추정량 $\hat{\theta}_j$ 의 표준오차

$$SE(\hat{\theta}_j) = \sqrt{c_{jj}} \cdot s$$

를 이용하면 된다(c_{jj} 는 $(\hat{V}' \hat{V})^{-1}$ 의 j 번째 대각원소를 나타낸다). 즉, θ_j 에 대한 $100(1 - \alpha)\%$ 신뢰구간은

$$\hat{\theta}_j - t_{\alpha/2}(n - p)SE(\hat{\theta}_j) < \theta_j < \hat{\theta}_j + t_{\alpha/2}(n - p)SE(\hat{\theta}_j)$$

으로 주어지며, 가설 $H_0 : \theta_j = \theta_{j0}$ 에 대한 검정은 t -통계량

$$t_j = \frac{\hat{\theta}_j - \theta_{j0}}{SE(\hat{\theta}_j)}$$

이 근사적으로 자유도가 $(n - p)$ 인 t 분포를 따른다는 것을 이용하여 선형회귀분석에서와 같이 할 수 있다.

잔차분석을 위한 방법도 선형회귀분석에서의 방법과 동일하다. 비선형회귀분석에서의 모자행렬은

$$H = \hat{V}(\hat{V}' \hat{V})^{-1} \hat{V}'$$

으로 정의되며, 이 행렬의 i 번째 대각원소를 h_{ii} 라 하면, 표준화잔차는 다음과 같이 정의된다.

$$r_i = \frac{Y_i - \hat{Y}_i}{s\sqrt{1 - h_{ii}}}$$

그러므로 잔차분석은 표준화잔차 r_i 들의 설명변수 X_i 들과 예측치 Y_i 들에 대한 산점도와 r_i 의 정규확률도를 이용하여 분석한다. 그 외 4장에서 설명된 회귀진단을 위한 각종 통계

량들도 위에서 정의된 r_i 와 h_{ii} 를 이용하여 계산할 수 있다.

위에서 알 수 있듯이 비선형회귀분석에서는 회귀식 $f(x_i, \theta)$ 의 θ 에 대한 선형근사화에 근거하여 선형모형에서의 방법을 그대로 사용하고 있다. 그러므로 모든 분석결과는 근사적으로 성립하며, 결과의 정확도는 회귀식의 선형근사화가 얼마나 정확한가에 의해 결정된다. 표본의 크기 n 이 어느 정도 큰 경우에는 별 문제가 없지만 그렇지 않은 경우에는 추론의 결과가 잘못된 결론을 유도할 수 있다. 이 선형근사화의 정확도는 같은 비선형회귀모형을 사용하는 경우에도 설명변수들의 값에 따라 달라진다. 그러므로 각 비선형모형에 대해 일반적인 분석을 하는 것은 불가능하고 관측치를 포함한 각 문제마다 개별적으로 조사를 해야한다는 어려움이 있다.

이 선형근사화의 정확도는 회귀식의 모수에 대한 이차도함수를 이용하여 분석할 수 있으나(베이츠와 와츠(Bates & Watts, 1988)), 계산상의 어려움으로 보통 응용문제에서는 하지 않고 있다. 그러나 앞으로 통계 소프트웨어의 지속적인 발전으로 쉽게 계산할 수 있는 경우에는 이 선형근사화의 정확도 여부도 조심스럽게 분석할 필요가 있다.

예제 10.3 식물의 성장에 관한 예제에서

- (1) 모수 θ_1 과 θ_2 에 대한 신뢰구간과 공동신뢰영역을 구하라.
- (2) 가설 $H_0 : \theta_1 = 30$ 에 대한 t -검정을 실시하라.
- (3) 잔차분석을 실시하라.

<풀이> (1) 앞의 예제에서 최소제곱추정치는 $\hat{\theta} = (28.13705, 12.57445)'$ 로 주어졌으며 이 값에서 계산된 행렬 V 를 이용하여 각 추정치의 표준오차를 구하면 다음과 같다.

$$SE(\hat{\theta}_1) = 0.72798, \quad SE(\hat{\theta}_2) = 0.76305$$

참고로 위의 계산에는 오차분산의 추정치

$$s^2 = \frac{4.302271}{16} = 0.268892$$


가 사용되었다. 그리고 $t_{0.025}(16) = 2.120$ 이므로 θ_1 에 대한 95% 신뢰구간은

$$\theta_1 = 28.13705 \pm (2.120)(0.72798) = 28.13705 \pm 1.54332$$

즉, (26.59373, 29.68037)로 주어진다. 그리고 θ_2 에 대한 95% 신뢰구간은

$$\theta_2 = 12.57445 \pm (2.120)(0.76305) = 12.57445 \pm 1.61767$$

즉, (10.95678, 14.19212)로 주어진다.



(그림 10.2) 식물의 성장속도예제에서의 공동신뢰영역과 신뢰구간 (그림에서 +기호는 점추정치 값을 나타낸다.)


이들 신뢰구간과 식 (10.15)을 이용하여 계산한 95% 공동신뢰영역은 (그림 10.2)에 주어져 있다.

(2) 가설 $H_0 : \theta_1 = 30$ 에 대한 t -검정통계량의 값은

$$t = \frac{28.13705 - 30.0}{0.72798} = -2.559$$

로 주어지며 이 값의 절대값은 $t_{0.025}(16) = 2.120$ 보다 크므로 유의수준 0.05 하에서 귀무가설을 기각한다.

(3) (그림 10.3)에는 표준화잔차의 예측치와 설명변수에 대한 산점도와 정규확률도가 주어져 있다. 각 그래프에서 특이한 점이 발견되지 않으므로 오차항에 대한 가정은 타당하다고 결론지을 수 있다. □



(그림 10.3) 잔차의 그래프 : (a) 잔차 대 예측치, (b) 잔차 대 설명변수, (c) 정규확률도

연습문제 (10)

[응용 문제]

10.1 다음에 주어진 비선형회귀식들에서 나타나는 각 모수의 초기치를 구하는 방법을 설명하라.

$$(1) f(X, \theta) = \theta_1 + \theta_2 e^{-\theta_3 X}$$

$$(2) f(X, \theta) = \frac{\theta_1}{1 + \theta_2 e^{-\theta_3 X}}$$

$$(3) f(x, \theta) = \exp[-\theta_1 X_1 \exp(-\theta_2 / X_2)]$$

10.2 다음은 본문에서 설명된 화학 반응에 관한 자료이다. 이 실험에서는 각 시간대에 A와 B의 농도를 모두 관측하였다.

시간	0.5	0.5	1	1	2	2	4	4	8	8
A의 농도	0.907	0.915	0.801	0.825	0.649	0.675	0.446	0.468	0.233	0.187
B의 농도	0.127	0.064	0.134	0.2	0.274	0.375	0.57	0.535	0.792	0.803

(1) A의 농도에 대해 비선형회귀식 $f_A(X, \theta) = e^{-\theta X}$ 을 적합시켜 모수 θ 의 추정치를 구하고 잔차분석을 하라.

(2) B의 농도에 대해 비선형회귀식 $f_B(X, \theta) = 1 - e^{-\theta X}$ 을 적합시키고자 한다. 가우스-뉴튼방법을 사용하기 위한 θ 의 초기치를 구하라. 그리고 θ 의 추정치를 구한 다음 잔차분석을 하라.

(3) (1)과 (2)의 결과를 비교하라.

10.3 6장의 [예 6.4]에 주어진 자료에는 비선형회귀분석을 적용하는 것이 타당하다. 이 자료에 대해 회귀식 (10.3)을 이용한 비선형회귀분석을 하고, [예 6.4]의 결과와 비교하라.

제 11 장

비모수회귀모형

11.1 서론

11.2 커널 추정법

11.3 급수 추정법

11.4 스플라인 추정법

11.5 예제

11.6 비모수 중회귀모형

} Covariate /

연속형 반응변수 Y 와 이를 설명해주는 한 개의 설명변수 X 의 관계가 회귀함수 f 에 의해 주어지는

$$Y_i = f(X_i) + \varepsilon_i$$

의 회귀모형으로 설정된다고 하자. 오차항 ε_i 는 평균이 0이고 분산이 σ^2 이라 가정한다. 지금까지 다루어 왔던 고전적 선형회귀모형, 일반화 선형모형, 비선형회귀모형 등에서는 회귀함수 f 의 형태가 사전에 주어졌었다. 다시 말해서, 단순선형회귀에서는 $f(x) = \beta_0 + \beta_1 x$ 로, 우리의 관심은 β_0 와 β_1 을 추정하고, 또한, $\beta_0 + \beta_1 x$ 라고 가정한 것이 타당한가를 알아보기 위해 잔차를 검토하거나 적합도 검정을 하였다. 일반화 선형모형도 마찬가지다. $g(\mu) = \beta_0 + \beta_1 x$ (단, g 는 연계함수이고 $\mu = E(Y)$)라는 모형을 미리 설정하고 회귀모형을 적합시켰다. 즉, 연계함수 g 가 주어지면 회귀함수 f 는 자동적으로 정해진다. 비선형 회귀모형도 설명변수와 회귀계수가 비선형으로 결합된 형태의 함수 f 가 미리 주어진다. 예를 들면, $f(x) = \beta_0 + \beta_1 e^{-\beta_2 x}$ 이 비선형 회귀모형이다. 이처럼, 회귀함수 f 의 형태가 미리 주어져 있는 상황에서, 회귀계수의 추정에 관심이 있는 경우를 모수 회귀모형(parametric regression model)이라 부른다.

한편, 회귀함수 f 에 대한 형태를 미리 설정하지 않고 단지 함수 f 는 어떤 요건을 만족시키는 함수군에 속한다고 가정하는 것이 비모수 회귀모형(nonparametric regression model)이다. 함수 f 가 만족시켜야 되는 요건은, 예를 들면 두 번 미분 가능하고 f^2 이 적분 가능하다는 등이 될 수 있다. 따라서 함수 f 는 무수히 많은 원소를 갖는 함수군에 속한다.

모수 회귀분석에서는 f 의 형태가 주어져 있으므로 회귀계수의 추정이 f 의 추정에 해당되지만, 비모수 회귀분석에서는 무수히 많은 원소 중의 하나를 선택하는 것이 f 의 추정이다. 따라서, 모형의 추정이란 관점에서 보면 비모수 회귀추정이 모수 회귀추정보다 더욱 힘들 것이다. 반면에, 많은 원소 중에서 선택하는 것이므로 비모수 회귀추정이 모수 회귀추정보다 여러 가지 좋은 성질을 가질 것이라고 기대된다. 그러나 무수히 많은 f 중에서 가장 좋은 것을 선택할 때 “가장 좋다”는 기준이 어떠한 것이며, 이러한 기준을 어떠한 관점에서 해석해야 하는가 등의 어려운 점도 예상된다.

11.1절에서는 평활의 개념을 설명하고, 비모수 회귀모형의 추정법으로 가장 널리 사용되는 커널추정(kernel estimator), 급수추정(series estimator), 평활 스플라인 추정(smoothing spline estimator)은 11.2절부터 11.4절까지 소개된다. 11.5절에는 실제자료에 근거하여 커널추정, 급수추정, 평활 스플라인 추정 및 회귀진단이 어떻게 이루어지는가를 공부한다.

11.1 서론

11.1.1 비모수회귀모형

회귀모형

$$y = f(x) + \varepsilon$$

에서 회귀함수 $f(x) = E(Y|X = x)$ 의 형태가 주어진 것이 모수 회귀모형임에 반해 비모수 회귀모형은 회귀함수의 형태를 가정하지 않는다. 따라서, 회귀함수 f 가 속하는 함수집합 $\mathcal{F}$ 의 차원은 무한대가 될 것이다. 그렇다면 n 개의 관측치 $(X_1, Y_1), \dots, (X_n, Y_n)$ 를 이용하여 차원이 무한대인 함수집합에 속하는 회귀함수 f 를 어떻게 추정할 수 있을까 하는 의문에 부딪힌다. 이를 해결하기 위한 방법으로 함수집합의 차원을 축소하는 것이다. 즉, 함수집합의 차원이 $k (< n)$ 인 $\mathcal{F}_k$ 로 축소시키고 회귀함수도 $f \in \mathcal{F}$ 로 부터 $f_k \in \mathcal{F}_k$ 로 축소시키는 것이다. 이 경우 $k \rightarrow \infty$ 로 감에 따라 $f_k \rightarrow f$ 가 될 수 있도록 함수집합을 선택해야 하며 이런 함수집합을 어떻게 선택하는가에 따라 여러 형태의 비모수 회귀모형이 생겨나게 되며 대표적인 비모수 회귀모형의 추정법으로 커널 추정법, 급수 추정법, 스플라인 추정법 등이 있다.

논의의 편의상 X 의 지지구간(support)을 $[0, 1]$ 이라 하고 추정하고자 하는 점을 x 라 하자. 커널 추정법은 기본적으로 점 x 에서의 추정치를 계산하기 위해 반응변수의 가중평균을 사용한다. 모수 회귀에서도 점 x 에서의 추정치가 반응변수들의 가중평균으로 나타나지만 근본적인 차이점은 모수회귀의 경우 모든 관측치가 이용되지만 커널 추정법은 x 주변의 관측치들만 사용한다는 것이다. 이런 측면에서 모수 회귀를 전체적 접근법(global approach)이라 부르고 커널 추정법을 국소적 접근법(local approach)라 부른다. 커널 추정법에서 x 근처의 관측치를 정하는 규칙은 커널 함수와 평활 모수(smoothing parameter, 다음 절에서 논의)에 의해 결정된다. 커널 추정법의 대표적인 국소다항회귀는 말 그대로 다항회귀의 개념을 이용하되 x 근처의 관측치들을 커널이란 가중치를 부여하여 구하는 방법이다.

함수공간(function space)이 정해지면 그 공간에 속하는 함수가 기저(basis)의 선형결합으로 표현된다. 즉, $f \in \mathcal{F}$ 이면 $f(x) = \sum_{j=1}^{\infty} \theta_j g_j(x)$ 로 표현되는데 여기서 θ_j 는 실수이고 $\{g_j(x), j = 1, 2, \dots\}$ 는 기저집합이다. 여기서 $\mathcal{F}_k = \{\sum_{j=1}^k \theta_j g_j : \theta_j \in \mathbb{R}, j =$

$1, \dots, k$ 으로 놓고 회귀함수 f 를 $\hat{f}(x) = \sum_{j=1}^k \hat{\theta}_j g_j(x)$ 으로 추정하는데 $(\hat{\theta}_1, \dots, \hat{\theta}_k)$ 는 $\sum_{i=1}^n \{Y_i - \sum_{j=1}^k \theta_j b_j(X_i)\}^2$ 을 최소화하는 값이며 이런 과정을 통해 추정되는 방법이 급수 추정법이다. 따라서, 어떤 기저를 선택하는가에 따라서 급수 추정치는 달라지게 되는데 푸리에(Fourier) 급수 추정법, 웨이블릿(wavelet) 급수 추정법 등이 있다.


스플라인 추정법은 크게 회귀 스플라인과 평활 스플라인 등의 두 가지로 구분할 수 있다. 회귀 스플라인은 X 의 지지구간을 몇 개의 구간으로 나누어 각 구간에서 적절한 차수의 다항식으로 추정하는 법이다. 한편, 평활 스플라인은 회귀함수를 소볼레프 공간(Sobolev space, 11.3.1 절 참조)으로 축소시킨 다음 회귀함수의 적합도(goodness-of-fit)와 회귀함수의 평활성(smoothness)을 적절하게 조화시킨 추정치를 구하는 방법이다.

11.1.2 바람직한 회귀함수

모수 회귀분석에서는 f 의 형태가 주어져 있으므로 회귀계수의 추정이 f 에 대한 추정에 해당되지만, 비모수 회귀분석에서는 무수히 많은 원소 중의 하나를 선택하는 것이 f 의 추정이다. 따라서 모형의 추정이란 관점에서 보면 비모수 회귀추정이 모수 회귀추정보다 더욱 힘들 것이다. 반면에, 많은 원소 중에서 선택하는 것이므로 비모수 회귀추정이 모수 회귀 추정보다 여러 가지 좋은 성질을 가질 것이라고 기대된다. 그러나 무수히 많은 f 중에서 가장 좋은 것을 선택할 때 “가장 좋다”는 기준이 어떠한 것이며, 이러한 기준을 어떠한 관점에서 해석해야 하는가 등의 어려운 점이 있다.

주어진 자료에 대해서 좋은 회귀함수를 선택할 때, “좋다”는 기준은 어떤 것이 있을까? 잔차가 작으면 좋은 것이라고 할 수 있을까? 우선, 가상적 자료를 바탕으로 잔차가 모든 관측치에서 0인 회귀함수를 생각해보자. (그림 11.1)(a)는 인접한 점들을 직선으로 연결시킨 것이고, (그림 11.1)(b)는 두번 미분한 것이 연속인 함수이다. 그림에서 보여주듯이, 이들은 증감의 정도(up-down; fluctuation)가 너무 심하게(wiggly) 나타난다. 이것은 주어진 자료를 회귀함수로 요약한다는 근본 취지에 어긋나는 것이다. 자료란 본래의 신호(signal; trend)에 얼마만큼의 잡음(noise)이 합해져서 생성된 것이다. 회귀분석을 한다는 것은 신호를 찾아내는 것이 목적이지만, 신호에 잡음이 합해져서 나온 자료를 그대로 연결시켜서 잔차가 0이 되게 하는 것이 아니다. n 개의 자료는 $n-1$ 차 다항식에 의해 항상 잔차가 0이 되게 할 수 있으나, 회귀분석은 자료축약(data reduction)이란 점에서 n 차 다항식이 의미하는 바는 전혀 없다.

한편, (그림 11.3)(c)는 가장 간단한 함수인 1차 다항식(직선식: $\beta_0 + \beta_1 x$)에 적합시킨



(그림 11.1) 가상자료에 대한 (a) 보간법으로 인접한 점끼리 직선으로 연결한 것, (b) 보간법으로 두 번 미분한 것이 연속이 되는 함수, (c) 단순선형회귀의 적합

것으로 잔차가 매우 커짐을 알 수 있다. 즉, 자료를 단순한 함수에 적합 시키면 자료축약과 추정된 회귀식의 해석은 쉬워지지만 잔차가 너무 커지고, 복잡한 함수에 적합 시키면 잔차는 작아지지만 자료축약을 이룰 수 없고 회귀식의 해석도 힘들어진다.

따라서, 바람직한 회귀함수란 잔차의 크기는 어느 정도 줄이면서, 함수의 단순성도 이루어야 하므로 이를 선택하는 적절한 방법이 필요하다.

11.1.3 평활의 개념

바람직한 회귀모형은 결코 잔차를 작게 해주는 것만이 아님을 앞절에서 언급하였다. 회귀모형의 역할은 잡음(noise)을 제거하고 신호(signal)를 포착하는데 있으며, 일반적으로 신호는 진동이 큰 들쭉날쭉한 모양이 아닌 매끄러운(smooth) 모양을 하고 있다.

우선, 가장 바람직한 회귀함수를 잔차제곱합이 작으면서 비교적 매끄러운 곡선이라고 하자. 여기서 매끄러운 정도(평활량:smoothness)는 여러 가지로 표현될 수 있으나, 다항식으로 한정시켜 얘기하면, 가장 매끄러운 곡선은 1차 다항식이고, 그 반대는 n 차 다항식이다. 따라서, 여기서는 매끄러운 정도를 2차 미분 값에 근거해 보자. 즉, 바람직한 회귀함수란

$$(1) \sum \{y_j - f(x_j)\}^2 : \text{적합도(goodness-of-fit)}$$

$$(2) \int_a^b f''(x)^2 dx : \text{매끄러운 정도(smoothness 또는 roughness)}$$

를 동시에 작게 해주는 것이다. 그러나 이것은 불가능하다. 왜냐하면, 잔차제곱합을 작게 하기 위해서는 차수가 높은 다항식이 필요한데 이럴 경우 (2)의 값이 커지게 되고, (2)의


값을 작게 하기 위해서는 차수가 낮은 다항식이 필요하지만 잔차제곱합이 커지게 된다. 따라서 (1)과 (2)를 균형 있게 조정하는 값이 필요하다. 즉, 우리가 찾고자 하는 회귀함수는, 적당한 가중치 $q(0 < q < 1)$ 에 대해서,

$$(1-q) \sum_{j=1}^n \{y_j - f(x_j)\}^2 + q \int_a^b \{f''(x)\}^2 dx \quad (11.1)$$


를 최소로 하는 f 이다. 여기서, $\lambda = q/(1-q)$ 라고 두면,

$$S(\lambda) = \sum_{j=1}^n \{y_j - f(x_j)\}^2 + \lambda \int_a^b \{f''(x)\}^2 dx \quad (11.2)$$

를 최소로 하는 f 를 찾는 것과 마찬가지다. 여기서, λ 는 잔차제곱합과 매끄러운 정도의 균형을 나타내는 값으로, 이를 **평활 모수(smoothing parameter, bandwidth)**라고 부른다. λ 의 값이 매우 작을 경우, $S(\lambda)$ 를 최소로 하는 것은 잔차제곱합을 최소로 하는 것과 거의 같고, 이는 각 점들을 연결시켜 주는 결과를 낳게 된다. 즉, 거의 n 차 다항식에 가까울 정도로 (그림 11.1)(b)처럼 들쭉날쭉한 모양이 된다. 반대로, λ 의 값이 매우 클 경우는 두 번 미분한 함수의 제곱을 구간 $[a, b]$ 에서 적분한 값을 최소로 해야 하므로 $f(x)$ 는 직선식에 가깝게 된다. (그림 11.2)는 λ 의 값이 작은 경우와 큰 경우의 f_λ 를 그린 것이다. 비모수회귀 모형에서는 어떤 값의 λ 가 가장 최적(optimal)인가 하는 문제가 매우 중요하다. λ 의 추정에 대한 문제는 11.4절에서 자세히 소개된다.



(a) λ 가 작은 경우



(b) λ 가 큰 경우

(그림 11.2) 가상자료에 대한 평활 추정치로 평활 모수가 작은 경우와 큰 경우

11.2 커널 추정법

11.2.1 커널 추정치

커널 추정법이란 회귀함수 f 의 추정치 $\hat{f}$ 이 $\mathbf{y} = (Y_1, Y_2, \dots, Y_n)'$ 의 선형결합으로 표현된다는 전제하에서 출발한다. 즉, $\hat{f}(x) = \sum w_i Y_i$ 으로 추정하고 싶은데, 가중치 w_i 를 어떻게 정해주는냐가 커널 추정법의 핵심적인 면이다. 다시 말해서 커널(kernel)이란 가중치로 이해하면 된다.

(1) 구간 평균법과 구간 직선법

커널 추정법을 가장 쉽게 이해 할 수 있는 방법 중에서 구간 평균법(running mean)과 구간 직선법(running line)을 소개한다. 구간 평균법을 설명하기 위해 우선

$$N_k(x) = \{i : x \text{의 양쪽으로 가장 가까이 있는 } k \text{개씩의 } x_i\}$$

을 정의하자. 즉, $N_k(x)$ 란 x 의 오른쪽에 가장 가까이 있는 k 개의 x_i 와 x 의 왼쪽에 가장 가까이 있는 k 개의 x_i 의 첨자 i 에 대한 집합으로 모두 $2k$ 개 만큼의 원소를 가진 집합이다. 논의의 편의상 x 가 정의된 구간을 $[0, 1]$ 이라고 하자. 만약 x 가 0 보다 조금 크거나 1 보다 조금 작은 값이면 $N_k(x)$ 는 $2k$ 개의 원소보다 작아질 수 있다. 극단적으로 x 가 0에 매우 가까워지면 $N_k(x)$ 는 k 개의 원소만 가지고, 1에 매우 가까워져도 같은 현상이 생긴다. 일반적으로 $N_k(x)$ 의 원소의 개수를 λ 라고 하면, λ 는 k 와 $2k$ 사이의 정수 값을 갖게 된다. 구간 평균법은 x 에서의 f 에 대한 추정치로

$$\hat{f}_\lambda(x) = \frac{1}{\lambda} \sum_{i \in N_k(x)} Y_i \quad (11.3)$$

을 사용한다. 즉, $\hat{f}_\lambda(x)$ 란 $N_k(x)$ 에 속하는 x_i 들에서 관측된 y_i 들의 산술평균이다. 따라서 $\hat{f}_\lambda(x)$ 는 $\mathbf{y}$ 의 선형결합으로 표현되며 가중치는

$$w_i = \begin{cases} \frac{1}{\lambda}, & i \in N_k(x) \\ 0, & i \notin N_k(x) \end{cases} \quad (11.4)$$

으로 표현된다. 만약, k 를 n 에 비해 작게 잡으면 $\hat{f}_\lambda(x)$ 는 x 주변에 있는 적은 개수의 관측치로 $\hat{f}_\lambda(x)$ 가 결정되므로, x 주변의 값들이 상대적으로 $\hat{f}_\lambda(x)$ 에 큰 영향을 주게 된다. 반