


대로, k 를 크게 잡으면 $\hat{f}_\lambda(x)$ 는 x 를 중심으로 많은 개수의 Y 값들에 의해 결정되므로 이들 Y 값의 영향은 상대적으로 작아진다. 따라서 k 를 작게 하면 $\hat{f}_\lambda$ 이 들쭉날쭉해지고 k 를 크게 하면 매끄러운 모양이 된다. 즉, k 가 평활 모수의 역할을 하게된다.

좀 더 구체적으로 설명하기 위해 $Y_i = \sin(X_i) + \varepsilon_i$ 라는 모형에서 생성한 $n = 50$ 개의 가상의 자료 (X_i, Y_i) 를 생각하자. 즉, 이 경우 $f(x) = \sin(x)$ 이고, $X_i \sim U(-2, 2)$, $\varepsilon_i \sim N(0, \frac{1}{9})$ 이다. (그림 11.3)은 생성한 자료의 산점도와 sine곡선, 그리고 k 를 1과 10으로 했을 때의 $\hat{f}$ 을 보여준다.

한편 구간 직선법은 $N_k(x)$ 에 속하는 (x_i, y_i) 들을 사용하여 단순선형회귀를 한 다음 x 에서의 적합치를 $f(x)$ 의 추정치로 사용한다. 즉,

$$\hat{f}_\lambda(x) = \hat{\beta}_0 + \hat{\beta}_1 x \quad (11.5)$$

인데 $\hat{\beta}_0$ 와 $\hat{\beta}_1$ 은 회귀직선의 최소 제곱추정치이다. 이 경우도, k 의 값이 커지면 $\hat{f}_\lambda$ 은 매끄러운 곡선이 되고, 작아지면 들쭉날쭉한 곡선이 됨을 쉽게 알 수 있다. (그림 11.3)은 k 를 1과 10으로 했을 때의 $\hat{f}$ 을 나타낸 것이다.



(그림 11.3) 가상자료에 대한 (a) 구간평균법, (b) 구간직선법

다음으로 구간 평균법 또는 구간 직선법과 매우 유사한 추정치를 소개하기 위해

$$J_k(x) = \{ i : x \text{에 가장 가까이 있는 } k \text{개의 } x_i \}$$

라 정의하고, 이를 k -최근접 주변(k -nearest neighbor)이라 부른다. 구간평균법 및 구간

직선법에서 $N_k(x)$ 대신 $J_k(x)$ 를 이용한 구간 추정치를 k -최근접 주변 추정치(k -nearest neighbor estimator)라 부른다. k 가 작으면 들쭉날쭉한 곡선이 되고 k 가 크면 매끄러운 곡선이 되므로 k 가 평활모수의 역할을 함을 알 수 있다.

(2) 커널 추정법

앞에서 논의했던 구간 평균법은 $N_k(x)$ 에 속하는 y_i 들이 똑같은 가중치를 가진 경우이다. 그러나 x 에서의 추정치를 정하는데 x 근처의 관측치들이 x 에서 멀리 떨어져 있는 관측치보다 y_i 에 더 많은 가중치를 가지는 것이 더 타당할 것이다. 즉, x 에서의 추정치를 결정할 때 x 에서 멀리 떨어질수록 가중치를 줄여나가는 것이다. 일반적으로, 커널 추정치는

$$\hat{f}_\lambda(x) = \frac{1}{n\lambda} \sum_{i=1}^n K\left(\frac{x - X_i}{\lambda}\right) Y_i = \frac{1}{n} \sum_{i=1}^n K_\lambda(x - X_i) Y_i \quad (11.6)$$

$K_\lambda(t) = \frac{1}{\lambda} K\left(\frac{t}{\lambda}\right)$

로 표현되는데, 여기서 λ 는 평활 모수이고 K 는 커널(kernel)이라 부르는 함수이다. 흔히 커널 K 는

$$\int K(t)dt = 1, \quad \int tK(t)dt = 0, \quad \int t^2K(t)dt < \infty$$

등의 조건을 만족하는데, K 를 표준정규분포 등의 확률밀도함수라고 생각하면 쉽다. 예를 들어, K 를 표준정규분포의 확률밀도함수라 하면

$$\hat{f}_\lambda(x) = \frac{1}{n\lambda} \sum_{i=1}^n \frac{1}{\sqrt{2\pi}} \exp\left[-\frac{(x - X_i)^2}{2\lambda^2}\right] Y_i$$


인데, X_i 가 x 에 가까이 있으면 K 가 큰 값을 가지고 X_i 가 x 에서 멀어질수록 K 는 작은 값을 가진다. 또한, 같은 X_i 에 대해서 λ 의 값이 커지면 K 가 작아지고, λ 의 값이 작아지면 K 의 값은 커진다. 즉, λ 의 값이 커지면 $\hat{f}_\lambda(x)$ 는 매끄러운 곡선이 되고 λ 의 값이 작아지면 들쭉날쭉한 추정치가 된다. 즉, 커널 추정치의 평활모수 λ 는 앞에서 정의했던 구간 평균법과 구간 직선법의 λ 와 같은 역할을 한다. 커널은 사용자가 임의로 부여해야 되는데 널리 사용되는 커널은 다음의 것들이 있다.

(1) 일양(uniform) 커널 : $K(t) = \frac{1}{2} I(|t| \leq 1)$

(2) 삼각(triangular) 커널 : $K(t) = (1 - |t|) I(|t| \leq 1)$


(3) 에파네chnikov(Epanechnikov) 커널 : $K(t) = \frac{3}{4}(1 - t^2) I(|t| \leq 1)$

(4) 정규(normal) 커널 : $K(t) = \frac{1}{\sqrt{2\pi}} e^{-t^2/2}$



그런데 커널 추정법에서 커널의 선택은 그리 중요한 문제가 아님이 밝혀져 있다. 중요한 것은 평활모수 λ 의 선택인데 이 문제는 11.4절에서 자세히 논의되며, 커널 추정법에 대한 더 자세한 내용은 해들(Härdle, 1991), 완드와 존스(Wand & Jones, 1995)를 참조하면 된다.

(그림 11.4)는 앞에서 사용했던 가상적 자료에 각각 정규커널과 에파네크니코프 커널을 쓰고 λ 를 각각 0.1 와 0.5 로 했을 때의 커널 추정치를 나타낸 것이다. λ 의 크기에 따라 추정된 모형의 평활정도가 매우 다름을 알 수 있다.



(그림 11.4) 가상자료에 대한 커널 추정치


(3) 나다라야왓슨 추정법

커널 추정치와 매우 유사한 형태를 가지는 몇 가지의 추정법이 있는데 그 중에서도 나다라야왓슨 (Nadaraya-Watson) 추정치를 소개한다. 이 추정치는

$$\hat{f}_\lambda(x) = \frac{\sum_j K\left(\frac{x - X_j}{\lambda}\right) Y_j}{\sum_j K\left(\frac{x - X_j}{\lambda}\right)} \quad (11.7)$$

로 주어지는데 식 (11.6)과의 차이는 분모의 $n\lambda$ 대신 $\sum K\{(x - X_j) / \lambda\}$ 가 사용된 점이다. 즉, y_j 에 대한 가중치의 합이 1이 되게 하였다. 왜냐하면, 식 (11.5)에서 $w_j = K\{(x - X_j) / \lambda\}$ 라 두면, $\hat{f}_\lambda(x) = \sum_j \left\{ \frac{w_j}{\sum_i w_i} y_j \right\} = \sum_j w_j^* y_j$ 인데, 여기서 $w_j^* = w_j / \sum_i w_i$ 이고 $\sum w_j^* = 1$ 이 된다.

(그림 11.5)는 앞에서 사용했던 가상적 자료에 각각 정규커널과 에파네크니코프 커널을 사용하여 λ 를 각각 0.15 와 0.5 으로 했을 때의 나다라야-왓슨 추정치를 나타낸 것이다



(a) 정규커널 사용

(b) 에파네크니코프 커널 사용

(그림 11.5) 가상자료에 대한 나다라야-왓슨 추정치

11.2.2 국소 다항회귀

local constant
(Nadaraya-Watson)
local linear
local quadratic

앞에서 잠깐 언급한 대로 국소다항회귀란 다항회귀를 국소적으로 커널 가중치를 적용하는 것이다. 즉, 점 x 에서의 추정치를 구하기 위해 전체 관측치를 모두 사용하는 대신 x 주변의 관측치만 사용하는 것이 근본적인 차이점이다. 국소다항회귀의 개념을 이해하기 위해 모수회귀모형(제1부에서 다루었던 고전적 회귀모형) 중에서 다항회귀를 다시 한 번 다른 각도에서 살펴보자.

우선 모수회귀모형중 가장 간단한 다항식이 상수이므로 상수모형인 경우부터 살펴 보자. 즉, $f(x) = \beta_0$ 라 가정하고 이 모형에 대한 최소제곱 추정치를 구하면

$$\hat{\beta}_0 = \underset{\alpha}{\operatorname{argmin}} \sum_{i=1}^n (Y_i - \alpha)^2 = \bar{Y}$$

이 되므로 추정하고자 하는 모든 점 x 에서 추정치는 $\hat{f}(x) = \bar{Y}$ 가 된다.

이제 차수를 하나 증가시켜 회귀함수가 일차인 경우를 보자. 즉, $f(x) = \beta_0 + \beta_1 x$ 이라

형 $f(z) = \beta_0 + \beta_1(z - x)$ 에 적합시켜 $\hat{\beta}_0$ 을 구하면 된다. 여기서 한 가지 흥미로운 사실은 모형 $f(z) = \beta_0 + \beta_1(z - x)$ 를 z 에 대해 한 번 미분한 함수의 x 값, 즉 $f'(x)$ 는 β_1 이 되며 이에 대한 추정치 $\hat{f}'(x)$ 는 다름 아닌 $\hat{\beta}_1$ 이 된다.

이러한 결과를 일반적인 차원의 다항식으로 확대해 보자. 다항회귀모형

$$f(x) = \beta_0 + \beta_1 x + \cdots + \beta_p x^p$$

에서 최소제곱 추정치는

$$(\hat{\beta}_0, \cdots, \hat{\beta}_p) = \underset{\beta_0, \cdots, \beta_p}{\operatorname{argmin}} \sum_{i=1}^n (Y_i - \beta_0 - \beta_1 X_i - \cdots - \beta_p X_i^p)^2$$

으로 주어지며 점 x 에서의 추정치는 $\hat{f}(x) = \hat{\beta}_0 + \hat{\beta}_1 x + \cdots + \hat{\beta}_p x^p$ 이 된다. 이는 모형

$$f(z) = \beta_0 + \beta_1 X_1(z - x) + \cdots + \beta_p (z - x)^p$$

에서

$$\sum_{i=1}^n \{Y_i - \beta_0 - \beta_1(X_i - x) - \cdots - \beta_p(X_i - x)^p\}^2$$

을 최소화하는 $\hat{\beta}_j, j = 0, 1, \cdots, p$ 을 구하면 $\hat{\beta}_0$ 은 점 x 에서의 추정치 $\hat{f}(x)$ 이 된다. 또한, $f(z)$ 를 z 에 대해 j 번 미분한 $f^{(j)}(z)$ 에 z 대신 x 를 대입하면 $j!\beta_j$ 가 되므로 $f^{(j)}(x)$ 에 대한 추정치는 $j!\hat{\beta}_j$ 가 된다.

이제 국소다항회귀중 가장 간단한 형태인 국소상수회귀(local constant regression)부터 살펴보자. 국소상수회귀는 상수모형에 적합시키되 추정하고자 하는 점 x 주변의 관측치만 이용한다. 이제 중심이 x 이고 길이가 λ 인 구간에 속하는 관측치, 즉 $\{i : |X_i - x| \leq \lambda/2\}$ 에 속하는 관측치만 이용하여 국소상수회귀에 적합시키면 $\hat{f}(x) = \hat{\beta}_0$ 이 되는데 여기서 $\hat{\beta}_0$ 은

$$\begin{aligned} \hat{\beta}_0 &= \underset{\beta_0}{\operatorname{argmin}} \sum_{i=1}^n (Y_i - \beta_0)^2 I_{(-\frac{\lambda}{2}, \frac{\lambda}{2})}(X_i - x) \\ &= \underset{\beta_0}{\operatorname{argmin}} \sum_{i=1}^n (Y_i - \beta_0)^2 I_{(-\frac{1}{2}, \frac{1}{2})}\left(\frac{X_i - x}{\lambda}\right) \end{aligned}$$

을 만족하는 값이다. 이는 바로 가중최소제곱법과 같은 형태를 가진다. 여기서 지시함수

$I_{(-\frac{1}{2}, \frac{1}{2})}$ 대신 보다 일반적인 가중치인 커널함수를 사용하면

$$\hat{\beta}_0 = \underset{\beta_0}{\operatorname{argmin}} \sum_{i=1}^n (Y_i - \beta_0)^2 K\left(\frac{X_i - x}{\lambda}\right) = \frac{\sum_{i=1}^n K\left(\frac{X_i - x}{\lambda}\right) Y_i}{\sum_{i=1}^n K\left(\frac{X_i - x}{\lambda}\right)}$$

이 되는데 이 추정치는 앞 절에서 다루었던 나다라야-왓슨(Nadaraya-Watson) 추정치이다. 즉, 국소상수회귀는 바로 나다라야-왓슨 추정치와 같다.

위의 과정을 일반적인 차수의 다항식으로 확장하면

$$f(z) \simeq \beta_0 + \beta_1(z - x) + \cdots + \beta_p(z - x)^p$$

이 되며 국소다항회귀 추정치는 $\hat{f}(x) = \hat{\beta}_0$ 으로 주어지는데 여기서 $\hat{\beta}_0$ 은

$$(\hat{\beta}_0, \dots, \hat{\beta}_p) = \underset{\beta_0, \dots, \beta_p}{\operatorname{argmin}} \sum_{i=1}^n \{Y_i - \beta_0 - \beta_1(X_i - x) - \cdots - \beta_p(X_i - x)^p\}^2 K\left(\frac{X_i - x}{\lambda}\right)$$

으로 부터 얻게 된다. 위 식을 행렬로 표현하면 $(y - X\beta)'W(y - X\beta)$ 이 되는데 여기서,

$$y = (Y_1, \dots, Y_n)'$$

$$X = \begin{pmatrix} (X_1 - x)^0 & \cdots & (X_1 - x)^p \\ \vdots & \ddots & \vdots \\ (X_n - x)^0 & \cdots & (X_n - x)^p \end{pmatrix},$$

$n \times (p+1)$

$$W = \operatorname{diag}\left(K\left(\frac{X_1 - x}{\lambda}\right), \dots, K\left(\frac{X_n - x}{\lambda}\right)\right)$$

이다. 이를 β 에 대해 편미분하여 0으로 놓으면

$$\hat{\beta} = (X'WX)^{-1}X'Wy$$

이 된다. 이제 1_j 을 j 번째 원소만 1이고 나머지 원소들은 전부 0인 $(p+1)$ -벡터라 하면 국소선형회귀의 추정치는

$$\hat{f}(x) = 1'_0 \underbrace{(X'WX)^{-1}X'Wy}_{\hat{\beta}} = \begin{pmatrix} 1 & 0 & \cdots & 0 \end{pmatrix} \begin{pmatrix} \hat{\beta}_0 \\ \vdots \\ \hat{\beta}_p \end{pmatrix} = \hat{\beta}_0$$

으로 주어진다. 또한, 회귀함수를 j 번 미분한 $\hat{f}^{(j)}(x)$ 의 추정치는

$$\hat{f}^{(j)}(x) = j! \hat{\beta}_j = j! \mathbf{1}'_j (\mathbf{X}' \mathbf{W} \mathbf{X})^{-1} \mathbf{X}' \mathbf{W} \mathbf{y}$$


으로 주어짐을 쉽게 알 수 있다.

국소 다항회귀를 이용하여 $f^{(j)}(x_0)$ 를 추정할 때 차수 p 의 선택이 매우 중요하다. 추정치의 평균오차제곱(mean squared error), 즉

$$E[(\hat{f}_\lambda^{(j)}(x_0) - f^{(j)}(x_0))^2]$$

에 근거한 결과로는 $p - j$ 가 홀수가 되는 것이 바람직하다는 연구결과가 있다. 예를 들어, $f(x_0)$ 를 추정할 때는($j = 0$ 인 경우) p 가 홀수가 되어야 하는데 일반적으로 $p = 1$ 인 경우를 많이 사용한다. 실제로, 국소 상수회귀($p = 0$ 인 경우)인 나다라야왓슨 추정치의 편이가 국소 선형회귀($p = 1$ 인 경우) 추정치의 편이보다 더 크다는 사실을 보일 수 있다. 또한, 회귀함수 $f(x)$ 의 추정시에 커널형태의 여러 추정치 중에서 국소 선형회귀가 가장 바람직하다는 연구결과가 있으며, 앞에서도 언급했듯이 회귀함수 f 를 j 번 미분한 $f^{(j)}(x)$ 에 대한 추정치도 쉽게 구할 수 있는 것이 큰 장점이다. 국소 다항회귀에 대한 더 자세한 내용은 팬과 기벨스(Fan & Gijbels, 1996)를 참고하기 바란다.

(그림 11.6)은 가상자료에 대한 국소선형추정치들 두 가지 (커널) 함수에 대해 각각 두 가지 평활모수를 사용하여 그린 것인데 (커널) 함수에 따라 큰 차이가 없음을 알 수 있다.



(그림 11.6) 가상자료에 대한 국소선형추정치

11.3 급수 추정법

11.3.1 함수공간이론

급수추정(series estimator)을 소개하기 위해 기본적인 함수공간(function space) 이론이 필요하며 이를 위해 몇 가지 기호와 정의를 소개한다.

구간 $[a, b]$ 에서 정의된 함수들 중에서 제곱의 적분값이 유한한 함수들의 집합을 $L_2[a, b]$ 로 나타낸다. 즉,

$$L_2[a, b] = \left\{ g : \int_a^b g(x)^2 dx < \infty \right\} \quad (11.9)$$

$L_2[a, b]$ 공간에 속하는 두 함수 g_1, g_2 에 대하여 함수의 크기 또는 놈(norm)을

$$\|g_1\| = \left\{ \int_a^b g_1(x)^2 dx \right\}^{1/2}$$

으로 정의하고, 내적(inner product)은

$$\langle g_1, g_2 \rangle = \int_a^b g_1(x)g_2(x)dx$$

로 정의한다. 따라서 내적은 코오시-슈바르츠 부등식(Cauchy-Schwarz inequality)

$$|\langle g_1, g_2 \rangle|^2 \leq \|g_1\|^2 \cdot \|g_2\|^2$$

에 의해 항상 정의될 수 있음을 알 수 있다.

$L_2[a, b]$ 공간은 너무 넓기 때문에 $L_2[a, b]$ 공간의 부분 공간을 고려할 필요가 있다. 그 중의 하나는

$$C^m[a, b] = \{g : g^{(j)} \text{는 연속, } j = 0, 1, \dots, m\} \quad (11.10)$$

인데, 여기서 $g^{(j)}$ 는 g 를 j 번 미분한 것이다. 즉, $C^m[a, b]$ 공간은 m 차까지의 미분이 연속인 함수들의 집합인데 $L_2[a, b] \supset C^0[a, b] \supset C^1[a, b] \supset \dots$ 임을 알 수 있다.

또 다른 $L_2[a, b]$ 공간의 부분공간으로 소볼레프 공간(Sobolev space)이 있다. m 차 소볼

레프 공간은

$$W_2^m[a, b] = \{g : g^{(j)}, j = 0, 1, \dots, m-1 \text{ 는 절대적으로 연속(absolutely continuous)이며 } g^{(m)} \in L_2[a, b]\} \quad (11.11)$$

으로 정의된다. 즉, $C^m[a, b]$ 공간에서 $f^{(m)}$ 이 연속이라는 조건이 완화된 것으로 $W_2^m[a, b] \supset C^m[a, b]$ 임을 알 수 있고 $W_2^0[a, b] = L_2[a, b]$ 가 된다.

$L_2[a, b]$ 공간에 속하는 두 함수 g_1, g_2 가 $\langle g_1, g_2 \rangle = 0$ 을 만족하면 g_1, g_2 는 직교(orthogonal)한다고 정의한다. 함수열 $\{g_j(x)\}$ 가 모든 $i \neq j$ 에 대해 $\langle g_i, g_j \rangle = 0$ 이고 모든 i 에 대해 $\|g_i\| = 1$ 을 만족하면 정규직교(orthonormal)라 정의한다. 또한, 정규직교인 함수열 $\{g_j(x)\}$ 에서 모든 j 에 대해 $\langle g, g_j \rangle = 0$ 이면 반드시 $g = 0$ 이 성립할 때 함수열 $\{g_j(x)\}$ 를 완비정규직교계(complete orthonormal system : CONS)라 부른다.

완비정규직교계의 중요성은 완비정규기저(complete orthogonal basis)가 된다는 점이다. 즉, $\{g_j(x)\}$ 가 완비정규직교계이면 임의의 함수 $f \in L_2[a, b]$ 는

$$f(x) = \sum_j \theta_j g_j(x)$$

로 표현되고, 여기서

$$\theta_j = \int g_j(x) f(x) dx$$

임을 쉽게 보일 수 있다(연습문제 11.7). 다시 말해서, 함수열 $\{g_j(x)\}$ 가 완비정규직교계가 되면 $L_2[a, b]$ 공간에 속하는 임의의 함수 f 는 완비정규직교계 $\{g_j(x)\}$ 의 선형결합으로 표현되고 그 때의 계수 θ_j 는 f 와 g_j 에 의해 결정된다.

가장 많이 사용되는 $L_2[a, b]$ 공간의 완비정규기저로는 푸리에 기저(Fourier basis)가 있는데 이는 다음과 같이 정의된다.

$$\begin{aligned} g_1(x) &= 1 \\ g_{2j}(x) &= \sqrt{2} \cos(2\pi j x / (b-a)), \quad j = 1, 2, \dots \\ g_{2j+1}(x) &= \sqrt{2} \sin(2\pi j x / (b-a)), \quad j = 1, 2, \dots \end{aligned} \quad (11.12)$$

이 푸리에 기저는 완비정규직교계가 됨을 쉽게 보일 수 있다(연습문제 11.8). 이 외에도 여러 형태의 비정규기저가 있는데 11.3.3에서 더 자세히 다루게 된다.

11.3.2 급수추정치

회귀모형 $y_i = f(x_i) + \varepsilon_i$, $i = 1, \dots, n$ 에서 회귀함수 $f(x)$ 는 $f \in L_2[a, b]$ 라 하자. 또한, 함수열 $\{g_j(x)\}$ 를 $L_2[a, b]$ 에 대한 완비정규기저라 하자. 즉,

$$f(x) = \sum_{j=1}^{\infty} \theta_j g_j(x) \quad (11.13)$$

이고, $\theta_j = \int g_j(x)f(x)dx$ 가 된다. 여기서 $f(x)$ 가 알려져 있지 않으므로 θ_j 는 추정되어야 할 모수인데, θ_j 의 자연스러운 추정치로

$$\hat{\theta}_j = \frac{1}{n} \sum_{i=1}^n g_j(x_i) Y_i, \quad j = 1, 2, \dots \quad (11.14)$$

를 생각할 수 있다. 따라서 회귀함수 f 의 추정치는

$$\hat{f}(x) = \sum_{j=1}^{\infty} \hat{\theta}_j g_j(x)$$

로 표현된다. 그러나, 이 추정치는 현실적으로 의미가 없다. 왜냐하면 $\hat{\theta}_j$ 를 모든 $j = 1, 2, \dots$ 에 대해 계산해야 하며, 이는 불가능한 것이다. 그러므로 사용가능한 추정치는 적당한 양의 정수 λ 에 대하여

$$\hat{f}_\lambda(x) = \sum_{j=1}^{\lambda} \hat{\theta}_j g_j(x) \quad (11.15)$$

으로 표현할 수 있으며, 이를 급수추정치(series estimator)라 부른다. 여기서, λ 는 평활모수의 역할을 하는데 λ 가 작으면 매우 매끄러운 곡선이 되고 λ 가 커지면 들쭉날쭉한 곡선이 됨을 쉽게 생각할 수 있다. 극단적으로, $\lambda = 1$ 이고 푸리에 기저를 사용하면 $\hat{f}_1(x) = \bar{Y}$ 가 됨을 알 수 있다(연습문제 11.9). λ 에 대한 추정은 11.5절에서 논하게 된다.

급수추정치는 식 (11.14)와 (11.15)로부터

$$\hat{f}_\lambda(x) = \sum_{j=1}^{\lambda} \left(\frac{1}{n} \sum_{i=1}^n g_j(x_i) Y_i \right) g_j(x) = \frac{1}{n} \sum_{i=1}^n \left\{ \sum_{j=1}^{\lambda} g_j(x_i) g_j(x) \right\} Y_i = \frac{1}{n} \sum_{i=1}^n K_\lambda(x, x_i) Y_i$$

으로 쓸 수 있다. 단, $K_\lambda(x, x_i) = \sum_{j=1}^{\lambda} g_j(x_i) g_j(x)$ 이다. 따라서, 급수추정치는 커널 추정치의 형태로 쓸 수 있다.


일반적으로 j 가 커지면 $|\theta_j|$ 가 작아지므로 급수추정치는 다음과 같이 크게 두 가지 형태로 분류한다. 하나는 강절단 추정치(hard-thresholding estimator)라 불리우며

$$\hat{f}_H(x) = \sum_{j=1}^{\infty} \hat{\theta}_j I_{\{|\hat{\theta}_j| > \delta\}} \cdot g_j(x)$$

으로 주어지는데 여기서 δ 는 절단모수(thresholding parameter)로서 평활모수의 역할을 한다. 다음으로 약절단 추정치(soft-thresholding estimator)라 불리우며

$$\hat{f}_S(x) = \sum_{j=1}^{\infty} \text{sign}(\hat{\theta}_j) \cdot (|\hat{\theta}_j| - \delta)_+ \cdot g_j(x)$$

으로 주어지며 마찬가지로 δ 는 절단모수이다. 강절단 함수와 약절단 함수는 (그림 11.7)에 주어져 있다.



(그림 11.7) 강절단 함수와 약절단 함수 ($\delta = 0.5$ 인 경우)

11.3.3 웨이브렛 추정치

결국 급수추정치는 어떤 완비정규기저를 사용하느냐에 달려있는데 지금까지는 푸리에 기저를 사용한 푸리에 급수추정치(Fourier series estimator)를 가장 많이 사용해 왔다. 최근에는 푸리에 기저의 단점을 보완한 웨이브렛 기저(wavelet basis)를 사용한 추정치가 많이 사용된다. 웨이브렛 기저의 종류에는 하 기저(Haar basis), 도베쉬 기저(Daubechies basis)등 많은 종류가 있으며, 이 중에서도 특히 도베쉬 기저가 널리 사용된다. 웨이브렛

분석에 대한 참고문헌으로 도베쉬(Daubechies, 1992), 츠이(Chui, 1992)등이 있다. 웨이브렛 추정에 대한 내용은 위낙 방대하므로 여기서는 기본 개념만 간략하게 소개한다.

$L_2(R)$ 공간에서 다음 성질을 만족하는 것을 다분해 해석(MRA : MultiResolution Analysis)이라 부른다.

(1)

$$\overline{\bigcup_{k \in Z} V_k} = L^2(R), \quad \bigcap_{k \in Z} V_k = \{0\}$$

을 만족하는 폐 부분공간(closed subspace) $\cdots \subset V_{-1} \subset V_0 \subset V_1 \cdots$ 이 존재한다.

(2) $f(\cdot) \in V_k \Leftrightarrow f(2^{-k}\cdot) \in V_0$

(3) $\{\phi(x-l) : l \in Z\}$ 이 V_0 의 정규직교기저가 되는 척도함수(scale function) 또는 부웨이브렛(father wavelet) $\phi \in V_0$ 가 존재한다.

(4) 공간 V_k 는 $\{2^{k/2} \phi(2^k x - l), l \in Z\}$.

(5) $\{2^{k/2} \phi(2^k x - l), l \in Z, k \in Z\}$ 는 $L_2(R)$ 의 정규직교기저가 된다.

MRA의 정의로 부터

$$\phi(x) = \sum_l c_l \phi(2x - l)$$

으로 표현할 수 있는데 여기서 c_l 은

$$\sum_l c_l c_{l-2m} = 2\delta_{0m}, \quad \forall m \in Z$$

을 만족하는 상수이다. 좀 더 구체적으로 살펴보기 위해 먼저 하 기저(Haar basis)의 경우를 보자. 하 기저는

$$\phi(x) = I(0 < x \leq 1)$$

으로 주어지는데 위의 두 식을 만족해야하므로 $c_0 = 1, c_1 = 1, c_l = 0, l \neq 0, 1$ 이 됨을 알 수 있다((그림 11.8) 참조).

한편, 계수 $\{c_j\}$ 가 주어지면 이에 해당되는 척도함수 ϕ 가 유일하게 결정되는데 이는 다음 정리로부터 알 수 있다.

[정리 11.1] $\hat{\phi}$ 를 ϕ 의 푸리에 변환이라 하면

$$\hat{\phi}(t) = m_0(t/2)\hat{\phi}(t/2)$$

이 성립하며 여기서 $m_0(t) = \sum_l c_l \exp\{ilt/2\}$ 이다.

따라서

$$\hat{\phi}(t) = \prod_{k=1}^{\infty} m_0(t/2^k)\hat{\phi}(0)$$

이 성립함을 쉽게 보일 수 있다.

하 기저는 단순하고 간단하지만 웨이브렛 추정치의 기저로서 효율성이 떨어진다. 현재 웨이브렛 추정치의 기저로 가장 효율성이 높은 것은 도베쉬 기저로 알려져 있다. 도베쉬 기저는 계수 $\{c_j\}$ 가

$$\sum_l c_l = 2, \quad \sum_l (-1)^l l^j c_l = 0, \quad 0 < j < N-1, \quad \sum_l l^{2N} c_l^2 < \infty$$

을 만족하는 것인데 여기서 N 은 주어진 상수이다 ((그림 11.8) 참조). 이러한 계수의 성질은 측도함수 ϕ 를 유일하게 결정한다는 사실이 위의 정리에서 밝혀졌고 이로 부터 측도함수는 다음과 같은 성질을 만족하게 된다.

$$\int x^j \phi(x) dx = \delta_{0j}, \quad j = 0, \dots, N-1 \quad \& \quad \int |x^N \phi(x)| dx < \infty$$

측도함수의 이러한 성질을 $N-1$ 차 적률소멸($N-1$ vanishing moments)이라 부른다.

이제 다분해 분석의 정의로 부터

$$\psi(x) = \sum_l (-1)^l c_{1-l} \phi(2x-l)$$

로 정의된 함수가 존재하는데 이는 다음과 같은 성질을 만족함을 보일 수 있다.

- (1) $\{2^{k/2} \psi(2^k x - l), \quad l \in Z\}$ 는 W_k 의 정규직교기저가 되는데 여기서 W_k 는 $V_{k+1} = V_k \oplus W_k$ 을 만족하는 공간이다.
- (2) $\{2^{k/2} \psi(2^k x - l), \quad l \in Z, k \in Z\}$ 는 $L_2(R)$ 의 정규직교기저가 된다.
- (3) $\int x^j \psi(x) dx = 0, \quad j = 0, \dots, N-1 \quad \& \quad \int |x^N \psi(x)| dx < \infty$

따라서,

$$L_2(R) = \overline{\bigcup_{k \in Z} V_k} = V_0 \oplus W_0 \oplus W_1 \oplus \cdots,$$

임을 알 수 있고 이 사실로 부터

$$\{\phi(x-l), 2^{k/2} \psi(2^k x - l), l \in Z, k \in Z^+\}$$

이 $L_2(R)$ 의 정규직교기저가 됨을 알 수 있다. $\phi(x)$ 를 부 웨이브렛(father wavelet)이라 불렀는데 이에 대응하여 $\psi(x)$ 를 모 웨이브렛(mother wavelet)이라 부른다. 즉, 부 웨이브렛과 모 웨이브렛을 이용하여 $L_2(R)$ 의 정규직교기저를 구성할 수 있음을 알 수 있다. $L_2(R)$ 의 정규직교기저를 또 다른 방법으로도 표현할 수 있는데 이를 위해 $p_k = p 2^k$ 라 하자. 여기서, $p > 0$ 는 원시 해상도(level of primary resolution)이다. 이제

$$\phi_l(x) = \sqrt{p} \phi(px - l), \quad \psi_{kl}(x) = \sqrt{p_k} \psi(p_k x - l)$$

라 정의하면

$$\{\phi_l(x), \psi_{kl}(x), l \in Z, k \in Z^+\}$$

이 $L^2(R)$ 이 정규직교기저가 됨을 알 수 있다.

앞에서 부 웨이브렛 $\phi(x)$ 와 모 웨이브렛 $\psi(x)$ 가 $L_2(R)$ 의 정규직교기저를 구성한다는 사실을 밝혔다. 따라서, 함수 $f \in L^2(R)$ 는 이들의 선형결합으로 표현될 수 있다. 즉,

$$f(x) = \sum_l \theta_l \phi_l(x) + \sum_{k=0}^{\infty} \sum_l \theta_{kl} \psi_{kl}(x)$$

으로 표현할 수 있는데 여기서

$$\theta_l = \int f(x) \phi_l(x) dx, \quad \theta_{kl} = \int f(x) \psi_{kl}(x) dx$$

이다. 따라서, 이에 대한 불편 추정치는

$$\hat{\theta}_l = \frac{1}{n} \sum_i \phi_l(x_i) Y_i, \quad \hat{\theta}_{kl} = \frac{1}{n} \sum_i \psi_{kl}(x_i) Y_i$$


이 된다. 이를 대입하면 함수 $f(x)$ 의 추정치를 구할 수 있으나 k 의 값이 커지면 p_k 가 커지

고(이를 고해상도라 함) 이 경우 $\hat{\theta}_{kl}$ 은 거의 잡음 수준이어서 고려할 필요가 없다. 따라서 최적의 해상도를 위해 다음과 같은 강절단추정치와 약절단 추정치를 주로 사용한다.

$$\hat{m}_H(x) = \sum_l \hat{\theta}_l \phi_l(x) + \sum_{k=0}^q \sum_l \hat{\theta}_{kl} I(|\hat{\theta}_{kl}| > \delta) \cdot \psi_{kl}(x)$$

$$\hat{m}_S(x) = \sum_l \hat{\theta}_l \phi_l(x) + \sum_{k=0}^q \sum_l \text{sign}(\hat{\theta}_{kl})(|\hat{\theta}_{kl}| - \delta)_+ \cdot \psi_{kl}(x)$$

여기서 $(x)_+ = xI(x > 0)$, q 는 수준 (level)을 나타내며 δ 는 절단모수이다. 한편, 절단모수의 추정치로 도노호와 잔스톤(Donoho & Johnstone, 1994)은 $\delta = \sqrt{2 \log(n\sigma)}$ 을 제안한 바 있다.



(그림 11.8) 웨이브렛 함수. (a) 하 웨이브렛 (부); (b) 하 웨이브렛 (모); (c) 도베쉬 모 웨이브렛 (1차 소멸 적률인 극상(extremal phase) 웨이브렛); (d) 도베쉬 모 웨이브렛 (7차 소멸 적률인 최소 비대칭(least asymmetric) 웨이브렛).

11.4 스플라인 추정법

11.4.1 회귀 스플라인

중선형모형으로는 주어진 자료를 제대로 설명하기 어려운 경우가 많다. 다항회귀모형을 사용하더라도 자료의 어떤 영역은 직선형태고 어떤 영역은 2차다항식이 적절하게 나타난다. 앞에서 언급했듯이 모수회귀모형은 단순함과 해석의 용이함에도 불구하고 이런 한계와 단점을 지닌다. 이를 극복하기 위한 방법중의 하나로 회귀 스플라인(regression spline)을 고려한다. 이를 위해 먼저 p 개의 설명변수를 M 개의 변수로 변환하는 함수 $h_m(X) : R^p \rightarrow R, m = 1, \dots, M$ 을 고려하자. 여기서 $X = (X_1, \dots, X_p)$ 으로 p 개의 설명변수를 나타내는 벡터이다. 이제 회귀모형은


$$f(X) = \sum_{m=1}^M \beta_m h_m(X)$$

으로 표현할 수 있는데 이를 흔히 선형기저표기(linear basis expansion)라 부른다. 즉, 회귀함수 $f(X)$ 를 기저함수 $h_m(X)$ 들의 선형결합으로 표현한 것이다. 이런 표현의 가장 큰 장점은 마치 $h_m(X)$ 를 설명변수로 취급하여 중선형회귀모형인 선형모형으로 표현한다는 것이다. 실제로 $h_m(X) = X_m, m = 1, \dots, p$ 이라 두면 중선형회귀가 되고 $h_m(X) = X_j^2$ 이라 두면 2차항을 추가하는 효과가 있고 $h_m(X) = X_j X_k$ 라 두면 교차항을 추가하는 셈이다. 이와 같이 선형기저표기는 매우 다양한 모형을 포함하고 있다.

먼저, 논의의 편의상 1개의 설명변수만 있는 경우를 고려하자. (그림 11.9(a))에 나타난 것 처럼 X 의 정의구역을 두 개의 매듭(knot) ξ_1, ξ_2 를 이용하여 세 부분 $(-\infty, \xi_1), [\xi_1, \xi_2), [\xi_2, \infty)$ 으로 나누었다고 하자. 처음 고려하는 회귀 스플라인은 구간별 상수(piecewise constant)기저인데 이는 다음과 같이 표현된다.

$$h_1(X) = I(X < \xi_1), h_2(X) = I(\xi_1 \leq X < \xi_2), h_3(X) = I(\xi_2 \leq X)$$

주어진 자료를 구간별 상수 기저를 이용한 모형 $f(X) = \sum_{m=1}^3 \beta_m h_m(X)$ 에 적합시키면 각 구간의 반응변수의 평균인 $\hat{\beta}_m = \bar{Y}_m$ 으로 주어진다. (그림 11.9(b))는 구간별 직선(piecewise linear)기저를 이용한 것인데 이를 위해 3개의 기저 함수 $h_{m+3}(X) = h_m(X)X$ 가 추가적으로 필요하여 전부 6개의 기저함수가 필요하다. 그런데 이 보다 더 바람직한 것은 각 매듭 ξ_1, ξ_2 에서 연속인 것이 바람직하다((그림 11.9(c)) 참조). 즉,




(그림 11.9) 곡선은 참함수(true function)이고, 이로부터 생성된 자료는 $\circ$ 로 표현되어 있다. ((a) 구간별 상수기저, (b) 구간별 직선기저, (c) 매듭에서 연속인 직선기저, (d) $(X - \xi_1)_+$ 함수)(출처: 해스티, 티브쉬라니와 프리드만(Hastie, Tibshirani & Friedman, 2001, p. 118))

$\beta_1 + \xi_1\beta_4 = \beta_2 + \xi_1\beta_5$ 와 $\beta_2 + \xi_2\beta_5 = \beta_3 + \xi_2\beta_6$ 의 두 가지 조건을 주면 오히려 2개의 모수가 줄어들게 되어 4개의 기저함수만 있으면 된다. 이 경우 기저함수는

$$h_1(X) = 1, h_2(X) = X, h_3(X) = (X - \xi_1)_+, h_4(X) = (X - \xi_2)_+$$

으로 표현 할 수 있다. 여기서 $u_+ = uI(u > 0)$ 이다. (그림 11.9(d))는 $h_3(X) = (X - \xi_1)_+$ 를 나타낸다.

그런데 (그림 11.9)에 나타난 것 처럼 직선만으로는 자료의 패턴을 제대로 나타내기 어렵기 때문에 차수를 올릴 필요가 있다. (그림 11.10)은 구간별 3차 다항식(piecewise cubic polynomials)을 나타낸 것인데 위의 두 그림은 각 매듭에서 연속이 아니고 아래의 두 그림은 연속이다. 특히, (그림 11.10(d))는 매듭에서 첫번째와 두번째 미분이 모두 연속인 경우인데 이를 특히 3차 스플라인(cubic spline)이라 부른다. 매듭이 ξ_1, ξ_2 인 경우 3차 스플라



(그림 11.10) 구간별 3차 스플라인 기저 ((a) 매듭에서 연속인 3차 기저, (b) 매듭에서 1차 미분이 연속인 3차 기저, (c) 매듭에서 2차 미분이 연속인 3차 기저)(출처: 해스티, 티브쉬라니와 프리드만(Hastie, Tibshirani & Friedman, 2001, p. 119))

인의 기저함수는 다음과 같은 6개의 함수로 나타낼 수 있다.

$$\begin{aligned} h_1(X) &= 1, \quad h_3(X) = X^2, \quad h_5(X) = (X - \xi_1)_+^3, \\ h_2(X) &= X, \quad h_4(X) = X^3, \quad h_6(X) = (X - \xi_2)_+^3 \end{aligned}$$

3차 스플라인이 6개의 기저함수로 이루어짐은 다음과 같이 설명할 수 있다. 먼저 각 영역에 4개의 모수($\beta_1, \dots, \beta_4$)가 필요하므로 전 영역에 $3 \times 4 = 12$ 개의 모수가 필요한데 각 매듭에서 3개의 제약조건 (연속, 한 번 미분한 것이 연속, 두 번 미분한 것이 연속)으로 인해 $2 \times 3 = 6$ 개의 모수가 사라지므로 최종적으로 $12 - 6 = 6$ 개의 모수만 있으면 된다.

일반적으로 K 개의 매듭 $\xi_j, j = 1, \dots, K$ 을 가진 도수 M (차수 $M - 1$)인 구간별 다항식(piecewise polynomial)을 도수 M (차수 $M - 1$)인 스플라인이라 부르고 이는 $M - 2$ 차

미분까지 연속인 함수이다. 이는

$$h_j(X) = X^{j-1}, j = 1, \dots, M,$$

$$h_{M+l}(X) = (X - \xi_l)_+^{M-1}, l = 1, \dots, K$$

으로 표현 할 수 있다. 앞에서 보았던 3차 스플라인은 $M = 4$ 임을 알 수 있다. 흔히 3차 스플라인이 가장 많이 사용되는데 3차 스플라인은 매듭에서 두 번 미분한 것 까지는 연속이지만 3번 미분하면 불연속이다. 사람의 눈으로 3번 미분한 것이 불연속인 사실은 거의 간파하기 어렵다고 하며, 3차 스플라인이 매듭에서 3번 미분한 것이 불연속인 것을 거의 눈치채지 못하는 가장 낮은 차수의 스플라인으로 알려져 있다.

(참고) 다항식 $a_0 + a_1x + a_2x^2 + a_3x^3$ 을 우리는 3차 다항식이라 부른다. 그런데 영어로는 이를 도수 4 (order 4) 또는 차수 3 (degree 3)인 다항식이라 부른다. 따라서, 영어로 된 교재나 논문을 읽을 때 order와 degree를 혼동하지 말기 바란다. 왜냐하면 order를 흔히 차수로 번역하기도 하기 때문이다. 본 교재에서는 order를 도수, degree를 차수로 사용한다. 왜냐하면 앞에서 주어진 다항식을 3차 다항식이라 부르지 4도 다항식이라 부르지 않기 때문이다.

3차 스플라인에서 경계 매듭 바깥쪽은 3차가 아닌 1차(선형)라고 가정하는 것이 자연 3차 스플라인(natural cubic spline)이다. 이 경우 4개의 모수(양쪽으로 2개씩)를 줄일 수 있으며 매듭 양쪽을 선형으로 가정한 자연 3차 스플라인을 이용하면 비록 편의는 커지지만 분산은 줄어드는 효과가 있다. 일반적으로 차수 $2M - 1$ 인 스플라인에서 경계 매듭(boundary knots) ξ_1, ξ_K 바깥쪽을 $M - 1$ 차 다항식으로 가정한 것을 $2M - 1$ 차 자연 스플라인(natural spline of degree $2M - 1$)이라 부른다. 실제로 $M = 2$ 인 3차 자연 스플라인이 가장 많이 사용되는데 매듭이 K 개인 경우 자연 3차 스플라인은 다음과 같은 K 개의 기저함수로 나타난다.

$$N_1(X) = 1, N_2(X) = X, N_{i+2} = d_i(X) - d_{K-1}(X), i = 1, \dots, K - 2$$

단, 여기서

$$d_i(X) = \frac{(X - \xi_i)_+^3 - (X - \xi_K)_+^3}{\xi_K - \xi_i}.$$

11.4.2 B - 스플라인

회귀 스플라인, 특히 자주 사용되는 3차 회귀 스플라인인 경우 계산상 심각한 문제점을 내포하고 있다. 예를 들어, $h_6(X) = (X - \xi_2)_+^3$ 을 계산할 때 ξ_2 의 오른쪽에 있는 관측치들의 경우 매우 큰 값을 갖게 되어 “나쁜 상태(ill-conditioning)”를 유발시킨다. 이는 특히, 역행렬의 계산시에 심각한 문제를 발생시키므로 회귀 스플라인에 주어져 있는 기저함수를 사용하는 대신 드 보아(de Boor, 1978)가 제안한 B-스플라인을 주로 사용한다.

B-스플라인을 정의하기 위해 먼저 두 개의 매듭 $\xi_0 (< \xi_1)$ 와 $\xi_{K+1} (> \xi_K)$ 을 추가로 정의한다. 또한, M 개의 매듭을 ξ_0 의 왼쪽에, 또 다른 M 개의 매듭을 ξ_{K+1} 의 오른쪽에 추가로 정의하여 전부 $K + 2M + 2$ 개의 매듭 τ 를 다음과 같이 정의한다.

$$\begin{aligned}\tau_1 &\leq \tau_2 \leq \cdots \leq \tau_M \leq \xi_0; \\ \tau_{j+M} &= \xi_j, j = 1, \cdots, K; \\ \xi_{K+1} &\leq \tau_{K+M+1} \leq \tau_{K+M+2} \leq \cdots \leq \tau_{K+2M}\end{aligned}$$

그러나 실제 계산에서는 경계 매듭을 넘어서는 매듭을 모두 경계 매듭과 같게 놓은 보다 간편화된 매듭 τ 를 다음과 같이 정의하여 사용한다.

$$\begin{aligned}\tau_1 &= \tau_2 = \cdots = \tau_M = \xi_0; \\ \tau_{j+M} &= \xi_j, j = 1, \cdots, K; \\ \xi_{K+1} &= \tau_{K+M+1} = \tau_{K+M+2} = \cdots = \tau_{K+2M}\end{aligned}$$

이를 바탕으로 매듭 τ 를 가진 도수 $m(m \leq M)$ 인 j 번째 B-스플라인 기저함수 $B_{j,m}$ 를 다음과 같이 귀납적인 식으로 정의한다. 먼저, $j = 1, \cdots, K + 2M - 1$ 에 대하여

$$B_{j,1}(x) = \begin{cases} 1, & \tau_j \leq x \leq \tau_{j+1} \text{ 일 때} \\ 0, & \text{otherwise} \end{cases}$$

으로 정의한다. 이는 흔히 하 기저(Haar basis)함수로 불리운다. 다음으로, $j = 1, \cdots, K + 2M - m$ 에 대하여

$$B_{j,m}(x) = \frac{x - \tau_j}{\tau_{j+m-1} - \tau_j} B_{j,m-1}(x) + \frac{\tau_{j+m} - x}{\tau_{j+m} - \tau_{j+1}} B_{j+1,m-1}(x)$$


으로 정의한다. 주어진 m 에 대하여 도수 m 인 구간별 다항식은 위에서 정의한 기저함수들

의 선형결합으로 표현 될 수 있음이 알려져 있다. 즉, 어떤 γ_j 에 대하여


$$s(x) = \sum_{j=1}^{K+m} \gamma_j B_{j,m}(x)$$

으로 표현할 수 있다.


(그림 11.11)은 구간 $(0, 1)$ 을 0.1씩 같은 길이로 나누어서 매듭을 정했을 때 상수부터 3차 B-스플라인을 나타낸 것이다.




(a) 상수 B-스플라인



(b) 1차 B-스플라인



(c) 2차 B-스플라인



(d) 3차 B-스플라인

(그림 11.11) 구간 $(0, 1)$ 을 0.1씩 같은 길이로 나누어서 매듭을 정했을 때 상수부터 3차 B-스플라인

회귀 스플라인에서 가장 중요한 문제 중의 하나는 매듭의 개수와 위치를 정하는 문제다. 매듭의 개수에 대한 선택은 마치 회귀모형에서 설명변수의 선택과 비슷한 개념이며 평활모수의 추정과도 비슷한 개념이다. 이에 대한 여러 가지 제안이 있는데 그 중에서도 가장 쉬운 방법 중의 하나는 월트(Wold, 1974)의 제안이다. 우선 매듭의 위치는 관측치 값이어야

하고 매듭의 개수는 작을 수록 좋은데 매듭 사이에는 적어도 4 ~ 5개의 관측치가 있어야 한다는 것이다.

11.4.3 평활 스플라인

여기서는 매듭의 위치와 개수를 정하는 문제를 걱정할 필요없이 관측치 각각을 매듭으로 사용하는 스플라인을 소개한다.

평활 스플라인 추정법이란, f 가 소볼레프 공간, 즉 $f \in W_2^m[a, b]$ 인 함수들 중에서

$$\sum_{i=1}^n \{y_i - f(x_i)\}^2 + \lambda \int_a^b \{f^{(m)}(t)\}^2 dt \quad (11.16)$$

를 최소로 하는 f_λ 를 찾는 것으로, 이 때의 f_λ 를 f 의 $(2m - 1)$ 차 평활 스플라인 추정치라고 부른다. 식 (11.16)의 형태는 이미 11.1.2절에서 소개되었던 것의 일반적인 형태다. 또한, λ 는 평활 모수로 잔차제곱합의 양과 평활량의 비중을 나타내는 값이다. 즉, λ 가 크면 평활량에 비중을 많이 두게 되어 추정치가 매우 매끄러운 곡선이 되고 반대로 λ 가 작으면 적합도에 많은 비중을 두므로 들쭉날쭉한 곡선이 된다.

일반적으로, $(2m - 1)$ 차 평활 스플라인 중에서 $m = 2$ 인 3차 평활 스플라인(cubic smoothing spline)이 가장 널리 사용되고, 앞으로는 3차 평활 스플라인에 대해서만 논의하겠다.

3차 평활 스플라인은, $f \in W_2^2[a, b]$ 인 함수들 중에서

$$S(f) = \sum_{i=1}^n \{y_i - f(x_i)\}^2 + \lambda \int_a^b \{f''(t)\}^2 dt \quad (11.17)$$

를 최소로 하는 f_λ 를 찾는 것인데 이를 최소로 하는 f_λ 는 n 개의 매듭 $X_1, \dots, X_n$ 을 갖는 자연 3차 스플라인이라는 사실이 증명되었다. 따라서, n 개의 기저함수가 존재하게 되는데 앞에서 언급했듯이 이들은

$$N_1(X) = 1, N_2(X) = X, N_{i+2} = d_i(X) - d_{n-1}(X), i = 1, \dots, n - 2$$

이 되고, 여기서

$$d_i(X) = \frac{(X - X_i)_+^3 - (X - X_n)_+^3}{X_n - X_i}$$

이다. 이제 $n \times n$ 행렬 $M = (M_{ij})$ 과 $N = (N_{ij})$ 을 다음과 같이 정의하자.

$$N_{ij} = N_j(X_i), \quad M_{ij} = \int N_i''(x)N_j''(x) dx$$

이제 $f = \sum_{j=1}^n \theta_j N_j$ 이므로

$$S(f) = (y - N\theta)'(y - N\theta) + \lambda \theta' M \theta$$

으로 표현할 수 있다. 따라서, 3차 평활 스플라인 추정치는

$$\hat{f}(x) = \sum_{j=1}^n \hat{\theta}_j N_j(x)$$

인데 여기서

$$\hat{\theta} \equiv (\hat{\theta}_1, \dots, \hat{\theta}_n) = (N'N + \lambda M)^{-1} N'y$$

이다. 따라서,

$$H_\lambda = N(N'N + \lambda M)^{-1} N'$$

라 두면

$$\hat{y} = H_\lambda y$$

으로 표현됨을 알 수 있다. 평활 모수 λ 가 어떤 값으로 주어져 있을 때 $f(x)$ 의 추정치를 $\hat{f}_\lambda(x)$ 라 하자. 앞에서 소개하였던 커널 추정치나 평활 스플라인 추정치는 Y_j 들의 선형결합으로 표현할 수 있다. 즉, $f(x) = (f(x_1), \dots, f(x_n))'$ 이라 하면

$$\hat{f}_\lambda(x) = H_\lambda y \quad (11.18)$$

으로 표현되는 $n \times n$ 행렬 H_λ 가 존재한다. 이 행렬은 고전적 선형회귀모형 $y = X\beta + \varepsilon$ 에서 $\hat{y} = Hy$ 가 되는 모자행렬 H 와 흡사하다. H 와 H_λ 는 모두 대칭이지만, H 가 멱등행렬임에 비해 H_λ 는 그렇지 않다.

11.4.4 평활모수의 추정

$\hat{f}_\lambda(x)$ 가 진정한 추정치 $f(x)$ 가 되기 위해서는 λ 의 추정치를 구해야만 한다. λ 의 추정 방법으로 가장 널리 사용되는 것이 교차확인(Cross Validation : CV) 또는 일반화 교차확인(Generalized Cross Validation : GCV)을 최소화하는 것이다.

이를 위해 우선 몇 가지 기호를 소개하자. n 개의 관측치 중에서 j 번째 관측치를 제외한 후, $(n-1)$ 개의 관측치로 추정된 f 의 $x = x_j$ 에서의 추정치를 $\hat{f}_{\lambda(j)}(x_j)$ 라 하자. 이 때, 교차확인은

$$CV(\lambda) = \frac{1}{n} \sum_{j=1}^n \{y_j - \hat{f}_{\lambda(j)}(x_j)\}^2 \quad (11.19)$$

으로 정의된다. 그런데 크레번과 와바(Craven & Wahba, 1979)의 한 점 소거정리(delete-one lemma)

$$\hat{f}_{\lambda(j)}(x_j) = \hat{f}_\lambda(x_j) - h_{jj}(y_j - \hat{f}_\lambda(x_j)) / (1 - h_{jj}) \quad (11.20)$$

을 이용하면

$$CV(\lambda) = \frac{1}{n} \sum_{j=1}^n \left\{ \frac{y_j - \hat{f}_\lambda(x_j)}{1 - h_{jj}} \right\}^2 \quad (11.21)$$

임을 쉽게 증명할 수 있다. 여기서 h_{ij} 는 H_λ 의 (i, j) 번째 원소이다. 식 (11.20)은 식 (11.19)보다 훨씬 편리함을 알 수 있다. 왜냐하면, 식 (11.19)는 한 개의 관측치를 소거하여 구하는 작업이 n 번 수행되어야 하지만 식 (11.20)은 f_λ 와 H_λ 만 알면 쉽게 계산된다. 교차확인의 논리는, $x = x_j$ 에서 반복측정이 있을 때 적합도 검정이 가능하다는 것을 모방한 것이라 볼 수 있다. 즉, 반복측정이 없을 경우에 추정에는 $n-1$ 개의 관측치만 쓰고, 1개의 관측치로 확인(validation)을 해 보자는 것이다. λ 의 선택 기준으로, 교차확인과 같은 류에 속하는 크레번과 와바(Craven & Wahba, 1979)의 일반화 교차확인(Generalized Cross Validation : GCV)

$$GCV(\lambda) = \frac{1}{n} \sum_{j=1}^n \left\{ \frac{y_j - \hat{f}_\lambda(x_j)}{1 - \text{tr}(\mathbf{H}_\lambda)/n} \right\}^2 \quad (11.22)$$

가 있다. 이것은 $CV(\lambda)$ 의 분모에 있는 h_{jj} 대신 $\text{tr}(\mathbf{H}_\lambda)/n$ 으로 대체한 형태이다. 따라서 $GCV(\lambda)$ 는 $CV(\lambda)$ 보다 계산이 더 편리하다. 왜냐하면, h_{jj} , $j = 1, \dots, n$ 를 계산할 필

요 없이 $\text{tr}(\mathbf{H}_\lambda)$ 만 계산하면 되기 때문이다. 실제로, $GCV(\lambda)$ 가 가장 널리 사용되는 기준치이며, 여러 가지 좋은 성질들이 밝혀져 있다. 그러나 $CV(\lambda)$ 나 $GCV(\lambda)$ 를 최소로 하는 λ 는 간편식으로 주어지지 않고, λ 가 속하는 양의 실수 구간에서 여러 가지 값을 대입하여 최소값을 찾는 격자 탐색(grid search)법을 이용해야 한다. 이것은 이미 박스-박스 변환모형에서 변환모수를 추정할 때 이용했던 방법이다. $GCV(\lambda)$ 를 최소로 하는 λ 를 구하는 프로그램이 몇 가지 개발되어 있으며 그 중에서도 GCVPACK, RKPACK 등의 포트란 부프로그램이 자주 이용된다. 그 외에 평활 스플라인에 대한 문제는 유뱅크(Eubank, 1988)를 참고하기 바란다.

11.4.5 비모수 회귀진단

우리는 4장에서 고전적 회귀모형에 대한 회귀진단을 논한 바 있는데 그 중에서도 소수 개의 관측치가 추정치에 심각한 영향을 미치는 경우를 살펴보았다. 비모수 회귀모형에서는 추정하고자 하는 점 x 근처의 자료만 사용하므로 고전적 회귀모형보다 비모수회귀 추정치가 소수개의 관측치에 대해 심각한 영향을 더 받을 수 있다. 여기서는 소수 개의 관측치가 비모수 회귀 추정치와 평활모수 추정치에 어떤 영향을 미치며 이를 탐색하기 위한 측도를 제시한다.

앞절에서 CV 또는 GCV 를 이용하여 구한 λ 의 추정치를 $\hat{\lambda}$ 이라 하면, $\mathbf{f}_\lambda$ 에 $\hat{\lambda}$ 을 대입한 것이 $\hat{\mathbf{f}}$ 이 된다. 또한, $\mathbf{H}_\lambda$ 에 $\lambda = \hat{\lambda}$ 을 대입한 것을 $\hat{\mathbf{H}}$ 이라 하자. 식 (11.18)로 부터 잔차 벡터는

$$\mathbf{e} = \mathbf{y} - \hat{\mathbf{f}} = (\mathbf{I} - \hat{\mathbf{H}})\mathbf{y} \quad (11.23)$$

로 표현되고 i 번째 관측치의 잔차는

$$e_i = y_i - \hat{f}(x_i)$$

이다. 또한, 오차항의 분산 σ^2 의 추정치로는

$$\hat{\sigma}^2 = \sum_{i=1}^n \{y_i - \hat{f}(x_i)\}^2 / \{n - \text{tr}(\hat{\mathbf{H}})\} \quad (11.24)$$

가 가장 널리 사용되며, 이것은 고전적 회귀모형에서 σ^2 의 추정치인 $s^2 = \sum e_i^2 / (n - 2)$ 와 매우 흡사한데 분모에 $n - 2$ 대신 $n - \text{tr}(\hat{\mathbf{H}})$ 가 사용된 것이 차이점이다. $\hat{\sigma}^2$ 을 이용하여 표

준화 잔차도 정의할 수 있다. $Cov(e) = (I - \hat{H})^2 \sigma^2$ 이므로

$$\frac{y_i - \hat{f}(x_i)}{\hat{\sigma}(1 - h_{ii})}$$

를 표준화 잔차로 정의할 수 있는데 일반적으로 $(I - \hat{H})^2$ 대신 $(I - \hat{H})$ 를 사용한

$$r_i = \frac{y_i - \hat{f}(x_i)}{\hat{\sigma}\sqrt{1 - h_{ii}}} \quad (11.25)$$

를 표준화 잔차로 사용한다(고전적 회귀모형에서는 $(I - H)^2 = (I - H)$ 임을 상기하라).

고전적 회귀모형에서 쿽 통계량 C_i 는 i 번째 관측치가 회귀계수의 추정치 $\hat{\beta}$ 에 미치는 영향을 나타내는 것으로

$$C_i = (\hat{\beta} - \hat{\beta}_{(i)})' Cov(\hat{\beta})^{-1} (\hat{\beta} - \hat{\beta}_{(i)}) / p$$

으로 정의되었다. 그렇다면 비모수 회귀모형에서 쿽 통계량 D_i 를 i 번째 관측치가 $\mathbf{f}$ 의 추정치 $\hat{\mathbf{f}}$ 에 미치는 영향을 나타내는 것으로 정의해 보면

$$D_i = (\hat{\mathbf{f}} - \hat{\mathbf{f}}_{(i)})' Cov(\hat{\mathbf{f}})^{-1} (\hat{\mathbf{f}} - \hat{\mathbf{f}}_{(i)}) / \text{tr}(\hat{H})$$

으로 표현할 수 있다. 여기서, $\hat{\mathbf{f}}_{(i)}$ 란 i 번째 관측치가 소거되었을 때 $(n-1)$ 개의 관측치로 계산한 $\mathbf{f}$ 의 추정치이다. 또한, p 대신 $\text{tr}(\hat{H})$ 를 사용하는 이유는 이미 11.5 절에서 밝힌 바 있다. 기호의 편의상 $H \equiv \hat{H}$ 라 두자. 이제 D_i 를 잔차 e_i 와 지렛값 h_{ii} 로 표현해 보자. 식 (11.20)의 한 점 소거정리

$$\hat{f}_{(i)}(x_j) = \hat{f}(x_j) - \frac{e_i}{1 - h_{ii}} h_{ij}$$

와 H 가 대칭이라는 사실을 이용하고, n 차원 벡터 $\mathbf{u}_i = (0, \dots, 0, 1, 0, \dots, 0)'$ 를 i 번째 원소만 모두 1 이고 나머지는 전부 0인 벡터라고 하면,

$$\begin{aligned} \hat{\mathbf{f}} - \hat{\mathbf{f}}_{(i)} &\equiv (\hat{f}(x_1) - \hat{f}_{(i)}(x_1), \dots, \hat{f}(x_n) - \hat{f}_{(i)}(x_n))' \\ &= \frac{e_i}{1 - h_{ii}} (h_{i1}, h_{i2}, \dots, h_{in})' \\ &= \frac{e_i}{1 - h_{ii}} H \mathbf{u}_i \end{aligned}$$

로 표현된다. 또한,

$$\text{Cov}(\hat{\mathbf{f}}) = \text{Cov}(\mathbf{H}\mathbf{y}) = \mathbf{H}^2\sigma^2$$

인데 많은 경우에 $\mathbf{H}^2 \simeq \mathbf{H}$ 이 되므로 이를 가정하면

$$\begin{aligned} D_i &= \left(\frac{e_i}{1-h_{ii}} \mathbf{H}\mathbf{u}_i \right)' (\mathbf{H}\sigma^2)^{-1} \left(\frac{e_i}{1-h_{ii}} \mathbf{H}\mathbf{u}_i \right) / \text{tr}(\mathbf{H}) \\ &= \frac{1}{\sigma^2 \text{tr}(\mathbf{H})} \frac{e_i^2 h_{ii}}{(1-h_{ii})^2} \end{aligned}$$

으로 표현될 수 있다. 이 형태는 고전적 회귀모형에서의 쿡 통계량 C_i 와 동일하다.

이제 $K = \{i_1, \dots, i_k\}$ 에 속하는 k 개의 관측치가 $\hat{\mathbf{f}}$ 에 미치는 영향을 알기 위해 k 개의 관측치에 대한 쿡 통계량을 정의해 보자.

$$D_K = (\hat{\mathbf{f}} - \hat{\mathbf{f}}_{(K)})' \text{Cov}(\hat{\mathbf{f}})^{-1} (\hat{\mathbf{f}} - \hat{\mathbf{f}}_{(K)}) / \text{tr}(\mathbf{H})$$

여기서 $\hat{\mathbf{f}}_{(K)}$ 란 집합 K 에 속하는 k 개의 관측치를 제거시킨 후 $(n-k)$ 개의 관측치로 추정된 것이다. 이 또한, 잔차와 지렛값으로 표현하기 위해 김(Kim, 1996)의 여러 점 소거정리(multiple cases deletion lemma)를 이용하면

$$D_K = \mathbf{e}_K' (\mathbf{I} - \mathbf{H}_K)^{-1} \mathbf{H}_K (\mathbf{I} - \mathbf{H}_K)^{-1} \mathbf{e}_K / \sigma^2 \text{tr}(\mathbf{H})$$

임을 보일 수 있다. 단, 여기서 $\mathbf{e}_K = (e_{i_1}, \dots, e_{i_k})'$ 이고 $\mathbf{H}_K$ 는 $k \times k$ 행렬로서 (h_{ij}) , $i, j \in K$ 의 원소를 포함하고 있다. 평활 스플라인에 대한 진단에 대한 더 자세한 내용은 유뱅크(Eubank, 1985)와 김(Kim, 1996)을 참고하기 바란다.

하나 또는 소수개의 관측치가 $\hat{\mathbf{f}}$ 뿐만 아니라 평활 모수의 추정치 $\hat{\lambda}$ 에도 심각한 영향을 미칠 수 있다. 여기서 $\hat{\lambda}$ 은 $CV(\lambda)$ 를 최소화시키는 값이라고 하자. 11.5 절에서 언급한 것처럼 $CV(\lambda)$ 또는 $GCV(\lambda)$ 를 최소화시키는 과정은 격자 탐색법이 이용되며, 상당한 계산 과정을 요구한다. i 번째 관측치가 $\hat{\lambda}$ 에 미치는 영향을 알기 위해서 가장 직접적인 방법은 $\hat{\lambda}$ 과 $\hat{\lambda}_{(i)}$ 의 차이, 즉,

$$\delta_i = \hat{\lambda} - \hat{\lambda}_{(i)}$$

를 구하는 것이다. 물론 $\hat{\lambda}_{(i)}$ 는 i 번째 관측치가 제거된 후 $(n-1)$ 개의 관측치로 계산된 λ 의 추정치이다. 그러나 δ_i 를 모든 i 에 대해 계산하는 것은 매우 힘들다. 따라서 δ_i 의 계산량을

줄여주는 방법이 필요하다. 이를 위해 i 번째 관측치가 제거된 $CV_{(i)}(\lambda)$ 를 정의해 보면

$$CV_{(i)}(\lambda) = \frac{1}{n-1} \sum_{j \neq i} \{y_j - \hat{f}_{\lambda(ij)}(x_j)\}^2$$

와 같이 표현할 수 있다. 여기에 여러 점 소거정리를 적용해 보면

$$\begin{aligned} CV_{(i)}(\lambda) &= \frac{1}{n-1} \sum_{j \neq i} \left[\{y_j - \hat{f}(x_j)\} + \{\hat{f}(x_j) - \hat{f}_{\lambda(ij)}(x_j)\} \right]^2 \\ &= \frac{1}{n-1} \sum_{j \neq i} \left\{ e_j + (h_{ij}h_{jj}) (I - \mathbf{H}_N)^{-1} \begin{pmatrix} h_{ij} \\ h_{jj} \end{pmatrix} \right\}^2 \end{aligned}$$

으로 쓸 수 있다. 단, $N = \{i, j\}$ 이다. 따라서 $CV_{(i)}(\lambda)$ 는 잔차와 지렛값으로 표현되고 이 값은 $\hat{\lambda}$ 을 구할 때 이미 구해진 값이므로, $\hat{\lambda}_{(i)}$ 를 계산하기 위해 $CV_{(i)}(\lambda)$ 를 최소화하는 과정이 매우 쉬워지고 계산량은 줄어들게 된다.

$K = \{i_1, \dots, i_k\}$ 에 속하는 k 개의 관측치가 $\hat{\lambda}$ 에 미치는 영향은 $\delta_K = \hat{\lambda} - \hat{\lambda}_{(K)}$ 를 계산하면 되는데 $\hat{\lambda}_{(K)}$ 는 $CV_{(K)}(\lambda)$ 를 최소화 해 주는 값이므로 $CV_{(K)}(\lambda)$ 를 잔차와 지렛값으로 표현한 식을 사용하면 계산량이 훨씬 줄어든다.

11.5 예제

11.5.1 성장곡선 자료


이 자료는 독일의 어린이들에 대한 키를 남녀별로 조사한 것으로 <표 11.1>에 나타나 있으며 단위는 밀리미터이다. 이 자료를 이용하여 남, 녀 각각에 대한 국소선형 추정치를 구해보자. 커널은 에파네크니코프 커널

$$K(t) = \frac{3}{4}(1 - t^2), \quad |t| \leq 1$$


을 이용하고, 평활모수는 $\lambda = 2$ 로 두고 구한 것이 (그림 11.14 (a))에 나타나 있다. 이제 키의 성장속도를 알기 위해 남,녀 각각에 대한 $f'(x)$ 의 국소선형추정치를 에파네크니코프 커널과 $\lambda = 4$ 로 놓고 그린 그림이 (그림 11.16 (b))에 주어져 있다. 생물학적으로 이미 알려진 사실이지만 여자는 12세 근처에서, 남자는 14세 근처에서 많이 자란다는 사실을 알 수 있다. 즉, 사춘기가 나타나는 연령에서 급성장함을 알 수 있다.

<표 11.1> 독일 어린이들의 남녀별 키 자료

나이	남	여	나이	남	여
1 개월	534	525	11.5 년	1540	1452
3 개월	601	584	12.0 년	1569	1493
6 개월	685	652	12.5 년	1599	1524
9 개월	729	696	13.0 년	1627	1552
1.0 년	762	736	13.5 년	1669	1584
1.5 년	822	798	14.0 년	1710	1600
2.0 년	885	843	14.5 년	1762	1607
3.0 년	984	930	15.0 년	1809	1620
4.0 년	1064	1014	15.5 년	1845	1626
5.0 년	1144	1085	16.0 년	1868	1631
6.0 년	1205	1135	16.5 년	1883	1632
7.0 년	1273	1200	17.0 년	1894	1636
8.0 년	1346	1266	17.5 년	1900	1639
9.0 년	1406	1316	18.0 년	1909	1639
9.5 년	-	1344	18.5 년	1913	-
10.0년	1461	1365	19.0 년	1913	1639
10.5년	-	1387	20.0 년	1915	1639
11.0년	1511	1423			



(a)



(b)

(그림 11.12) 독일 어린이의 연령에 대한 키. (a) 남녀별 국소선형추정치 (b) 1차 미분한 남녀별 국소선형추정치. 남자 키가 여자 키보다 전 연령에 걸쳐 항상 크지만 성장속도는 서로 다를 수 있다.

11.5.2 볼트하강 자료

미사일이 발사된 후 배터리 볼트의 변화하는 값이 시간대별로 <표 11.2>에 주어져 있다. 이 자료에 대한 푸리에 급수 추정치를 구해보자. 평활모수는 일반화 교차확인법 $GCV(\lambda)$ 를 최소로 하는 λ 를 구하기 위한 계산 결과가 <표 11.3>에 주어져 있다. 따라서 $\lambda = 6$ 을 선택하여

$$\hat{f}(x) = \sum_{j=1}^6 \hat{\theta}_j g_j(x)$$


가 되고, $\hat{\theta}_j = \frac{1}{n} \sum_{i=1}^n g_j(x_i) Y_i$ 이며 $g_j(x)$ 는 (11.17)에 주어진 푸리에기저이다. 이 자료에 대한 급수추정치의 모양이 (그림 11.13)에 주어져 있다.

<표 11.2> 볼트 하강 자료

시 간	볼트 하강	시 간	볼트 하강
0.0	8.33	10.5	14.92
0.5	8.23	11.0	14.37
1.0	7.17	11.5	14.63
1.5	7.14	12.0	15.18
2.0	7.31	12.5	14.51
2.5	7.60	13.0	14.34
3.0	7.94	13.5	13.81
3.5	8.30	14.0	13.79
4.0	8.76	14.5	13.05
4.5	8.71	15.0	13.04
5.0	9.71	15.5	12.06
5.5	10.26	16.0	12.05
6.0	10.91	16.5	11.15
6.5	11.67	17.0	11.15
7.0	11.76	17.5	10.14
7.5	12.81	18.0	10.08
8.0	13.30	18.5	9.78
8.5	13.88	19.0	9.80
9.0	14.59	19.5	9.95
9.5	14.05	20.0	9.51
10.0	14.48		

<표 11.3> 볼트 하강 자료에 대한 $GCV(\lambda)$


λ	0	1	2	3	4	5	6	7	8	9	10
$GCV(\lambda)$	6.731	0.235	0.149	0.139	0.122	0.103	0.090	0.097	0.114	0.127	0.154



(그림 11.13) 볼트 하강 자료에 대한 급수추정치

11.5.3 과통화팽창 자료

<표 11.4>의 자료는 1921년 2월부터 1923년 9월까지, 독일에서의 통화공급량과 외환율을 조사한 것이다. 실제로 y 는 통화공급량의 로그값이고, x 는 외환율의 로그값이다. (그림 11.14)에 나타난 것 처럼 이 자료를 고전적 회귀모형으로는 추정하기 어렵다는 것을 알 수 있다. 여기서는 이 자료를 3차 평활 스플라인으로 추정하였으며 평활 모수 λ 는 RK-PACK을 이용하여 $GCV(\lambda)$ 를 최소화시키는 값을 찾았다. 이때, $GCV(\lambda)$ 를 이용한 평활 모수의 추정치는 $\hat{\lambda} = 0.000228$ 였다. 또한, <표 11.4>에 표준화된 잔차 r_i 와 h_{ii} 가 주어져 있다. 잔차는 28, 29번째 관측치가 큰 값을 가지고 있으며, 지렛값은 31, 19, 30번째 관측치가 큰 값을 가지고 있음을 알 수 있다. 이 예제에서는 소수 개의 관측치가 추정치에 어떤 영향을 미치는지 살펴보기로 한다.



(그림 11.14) 과통화팽창 자료에 대한 3차 평활 스플라인 추정

<표 11.4> 과통화 팽창자료에서 잔차 및 쿡 통계량

case	y_i	x_i	h_{ii}	r_i^*	D_i
1	6.5605	-1.8202	.51732	.09392	.00091
2	6.5474	-1.7958	.47743	-.11140	.00110
3	6.5802	-1.1087	.50049	-.10077	.00098
4	6.5927	-.9927	.38820	.05562	.00019
5	6.5019	-.6832	.29274	-.84486	.02855
6	6.5896	-.6539	.28007	.25039	.00236
7	6.5414	-.3960	.15471	.58618	.00608
8	6.4580	-.3930	.15333	-.31193	.00170
9	6.5381	-.3653	.14284	.75434	.00917
10	6.4977	-.3271	.13533	.60819	.00559
11	6.4129	-.3093	.13423	-.16179	.00039
12	6.4225	-.1863	.14207	1.18761	.02257
13	6.2669	-.1839	.14236	-.48603	.00379
14	6.0839	-.0429	.16952	-.94474	.01761
15	6.1841	-.0837	.15800	-.27111	.00133
16	6.0578	.0000	.18820	-.81699	.01495
17	6.0774	.0999	.26242	.26116	.00234
18	5.9321	.3343	.58665	-.09331	.00119
19	5.7858	1.1845	.76177	.92114	.26218
20	5.5203	1.6369	.41275	.97721	.06486
21	5.2718	1.7630	.34842	-1.11170	.06386
22	5.2421	1.9243	.44030	-.65032	.03215
23	5.4116	2.4336	.30176	1.24463	.06469
24	5.1504	2.4774	.25723	-1.90649	.12164
25	5.4239	2.5908	.21998	1.22042	.04059
26	5.3290	2.6053	.22206	.14109	.00055
27	5.1921	2.7955	.28735	-.99290	.03841
28	5.4269	2.9565	.33620	2.88407	.40710
29	4.9010	3.1122	.46207	-2.35062	.45864
30	4.7712	3.6169	.61188	-.37074	.02094
31	4.7589	3.9176	.86066	.63474	.24048

위의 자료를 이용하여 $\hat{f}$ 과 $\hat{\lambda}$ 에 대한 영향력 있는 관측치들을 찾아보자. <표 11.5>는 $k = 1, 2, 3, 4$ 에 대해 가장 큰 쿡 통계량을 갖는 5개의 관측치들의 집합을 나타낸 것이다. $k = 1$ 일 때는 28, 29번째 관측치가 큰 값의 쿡 통계량을 갖는 반면, $k = 2$ 일 때는 (30, 31)이 월등히 큰 값을 갖는다. 즉, (30, 31)은 하나의 관측치에 대한 쿡 통계량으로는 찾아낼 수 없는 가면효과를 가지고 있다. 다시 말해서 30번째, 31번째 각각의 쿡 통계량은 작은 값이지만 이 둘을 동시에 고려하면 큰 값의 쿡 통계량을 갖는다. $k = 3$ 일 때는 (29, 30, 31)이 월등히 크다. $k = 4$ 일 때는 특별히 큰 값을 갖는 것이 없고 전부 (29, 30, 31)을 포함하고 있다. 따라서, $k = 4$ 일 때는 (29, 30, 31)에 의한 늑효과가 뚜렷하다.

<표 11.5> 과통화 팽창자료에서 $k = 1, 2, 3, 4$ 에 대한 D_K 통계량


k	sets	D_K
1	29	.459
	28	.407
	19	.262
	31	.240
	24	.122
2	30, 31	3.129
	19, 20	1.447
	29, 30	1.431
	29, 31	1.231
	27, 29	.864
3	29, 30, 31	15.060
	28, 30, 31	4.421
	27, 30, 31	4.358
	24, 30, 31	3.946
	19, 30, 31	3.376
4	25, 29, 30, 31	17.999
	23, 29, 30, 31	17.933
	27, 29, 30, 31	17.150
	26, 29, 30, 31	15.498
	19, 29, 30, 31	15.231

<표 11.6>은 $k = 1, 2, 3$ 에 대해 $|\hat{\lambda} - \hat{\lambda}_{(K)}|$ 가 큰 5개의 관측치들의 집합을 나타낸 것이다. $k = 1$ 일 때는 23, 24, 27번째 관측치들이 $\hat{\lambda}$ 에 큰 영향력을 미치고, $k = 2$ 일 때는 (19, 22)가 큰 영향을 미친다.

<표 11.6> 과통화팽창 자료에서 $k = 1, 2, 3$ 에 대한 평활 모수 추정치의 차

k	sets	$ \hat{\lambda}_{(K)} - \hat{\lambda} \times 10^4$
1	23	2.258
	24	2.253
	27	2.105
	28	0.879
	29	0.496
2	19, 22	6.154
	19, 20	4.096
	16, 19	3.671
	14, 19	3.273
	19, 31	2.409
3	16, 19, 22	11.839
	9, 19, 22	11.839
	7, 9, 19	11.597
	7, 19, 22	11.454
	10, 19, 22	11.126

(그림 11.15)는 각각 (29, 30, 31)을 제거 했을 때와 (19, 22)를 제거 했을 때의 3차 평활 스플라인 모형의 적합치를 나타낸 것이다.



(그림 11.15) 과통화 팽창자료를 3차 평활 스플라인으로 적합한 그림. 모든 관측치에 근거한 적합치(...). (a) 29, 30, 31을 제외한 적합치(—) (b) 19, 22를 제외한 적합치(—)

11.6 비모수 중회귀모형

앞에서 다루었던 비모수 회귀모형은 설명변수가 1개인 경우인데, 설명변수가 2개 이상인 경우의 비모수적 접근에 대해 몇 가지 방법을 소개한다.

11.6.1 가법모형과 일반화 가법모형

p 개의 설명변수 $X_1, \dots, X_p$ 가 있을 때 가법모형(additive model)은

$$Y = \alpha + \sum_{j=1}^p f_j(X_j) + \varepsilon \quad (11.26)$$

으로 정의된다. 여기서, ε 은 평균이 0, 분산이 σ^2 인 정규분포를 따르는 오차항이다. 또한, f_j 는 임의의 함수이며 $E[f_j(X_j)] = 0$ 이고, 따라서 $\alpha = E(Y)$ 이다. 가법모형은 각각의 설명변수 X_j 에 대해 f_j 라는 함수로 비모수 모형을 세운 다음 전부 합한 것으로 볼 수 있다.

설명변수가 1개일 때는 $\hat{f} = Hy$ 로 추정치는 y 의 선형결합으로 표현됨을 이미 논한 바 있다. 가법모형의 추정은 어떻게 이루어지는가? 이는 다음과 같은 조건부 기댓값

$$f_j(X_j) = E(Y - \alpha - \sum_{k \neq j} f_k(X_k) | X_j)$$

에 의해 아래에 기술된 반복 알고리즘을 제시한다.

후적합(backfitting) 알고리즘

- (1) 초기화단계 : $\alpha = \sum y_i/n, \quad f_j = f_j^0, \quad j = 1, \dots, p$
- (2) 적합단계 : $f_j = H_j(y - \alpha \mathbf{1} - \sum_{k \neq j} f_k | X_j), \quad j = 1, \dots, p$
- (3) 반복단계 : f_j 의 값이 수렴할 때까지 단계 (2)를 반복

위에서 H_j 는 j 번째 변수의 모자행렬로 어떤 비모수적 기법을 사용하느냐에 따라 달라진다.

가법모형은 반응변수가 지수족 분포를 따를 때도 쉽게 확장할 수 있다. 예를 들어, 반응변수가 이항분포를 따를 때 비모수적 방법은

$$\log \left(\frac{\pi}{1-\pi} \right) = \alpha + \sum_{j=1}^p f_j(X_j)$$

으로 모형을 세울 수 있다. 이러한 모형을 일반화 가법모형(generalized additive model)이라 부르고, 이에 대한 추정은 역시 후적합 알고리즘을 이용한다. 일반화 가법모형에 대한 자세한 연구는 해스티와 티브쉬라니(Hastie & Tibshirani, 1990)를 참고하기 바란다.

11.6.2 변수변환모형

고전적 선형회귀모형에서 반응변수의 정규성에 의심이 갈 때 박스-콕스 변환모형을 이용하였으며, 일반화 선형모형에서 뉴튼-랩슨 방법대신 최소제곱법을 사용할 때 분산 안정화변환을 했던 것처럼 비모수 중회귀모형에서도 이러한 변환이 필요한 경우가 있다.

가법모형에서 반응변수를 변환한 모형

$$\theta(Y) = \alpha + \sum_{j=1}^p f_j(X_j) + \varepsilon \quad (11.27)$$

을 생각하자. 여기서 θ 는 Y 의 변환을 의미하고 f_j 는 X_j 의 비모수함수이다. 이를 추정하기 위한 방법으로

$$E\{\theta(Y) - \sum_{j=1}^p f_j(X_j)\}^2$$

을 최소화하는 방법을 ACE(Alternating Conditional Expectation) 알고리즘이라 부르며, 구체적으로 다음과 같은 단계로 이루어진다.

ACE 알고리즘

- (1) 표준화 단계 : $\theta(Y) = \{Y - E(Y)\} / \{Var(Y)\}^{1/2}$
- (2) 가법모형 적합단계 : $\theta(Y)$ 를 $f_1(X_1), \dots, f_p(X_p)$ 에 적합
- (3) 조건부 기댓값 단계 : $\tilde{\theta}(Y) = E\{\sum_j f_j(X_j) | Y\}$ 와 $\theta(Y) = \tilde{\theta}(Y) / \{Var(\tilde{\theta}(Y))\}^{1/2}$ 를 계산
- (4) 반복단계 : $E\{\theta(Y) - \sum_j f_j(X_j)\}^2$ 이 작아질 때까지 단계 (2)와 (3)을 반복

ACE 알고리즘은 여러 가지 좋은 성질을 가지고 있다고 알려져 있으며, 다른 추정치들과의 관계도 규명되어있다.

이제 분산안정화변환의 경우를 생각해보자. 확률변수 W 의 평균이 μ , 분산이 $V(\mu)$ 일 때 분산안정화변환이

$$h(t) = \int_0^t \frac{1}{\sqrt{V(\mu)}} d\mu$$

로 주어진다. 이는 테일러 급수전개에 의해 쉽게 보일 수 있다. 반응변수 Y , 설명변수 $X_1, \dots, X_p$ 가 주어져 있을 때

$$E\{\theta(Y) | X_1, \dots, X_p\} = \sum_{j=1}^p f_j(X_j)$$

$$Var\{\theta(Y) | \sum_{j=1}^p f_j(X_j)\} = \text{상수}$$

을 만족하는 함수 θ 와 $f_1, \dots, f_p$ 를 찾는 알고리즘을 AVAS(Additivity and Variance Stabilization)라고 하며 다음과 같은 단계로 이루어진다.

AVAS 알고리즘

- (1) 초기화 단계 : $\theta(Y) = (Y - E(Y)) / \{Var(Y)\}^{1/2}$ 를 가법모형 $\sum_j f_j(X_j)$ 에 적합
- (2) 변환단계 : $V(u) = Var\{\theta(Y) | \sum_j f_j(X_j) = u\}$ 를 계산하고 $h(t) = \int_0^t 1/\sqrt{V(u)} du$ 를 구한다. 또한, $\theta(t)$ 대신 $h(\theta(t))$ 를 사용하여 다시 표준화한다. 즉

$$\theta(t) \leftarrow \frac{h(\theta(t)) - E[h(\theta(Y))]}{\sqrt{Var h(\theta(Y))}}$$

(3) 적합단계 : 단계 (2)에서 구한 $\theta(t)$ 를 가법모형 $\sum_j f_j(X_j)$ 에 적합

(4) 반복단계 : 단계 (2)와 (3)을 $E\{\theta(Y) - \sum_j f_j(X_j)\}^2$ 가 수렴할 때까지 반복

11.6.3 교호작용모형

지금까지 고려했던 가법모형과 이에 근거한 변환모형은 교호작용을 고려하지 않았다. 즉, 예를 들어, 2개의 설명변수 X_1, X_2 가 있을 때


$$Y = \alpha + f_1(X_1) + f_2(X_2) + \varepsilon$$

이 가법모형인데, 여기에 교호작용을 포함하면 다음과 같이 되는 것은 바람직하다.


$$Y = \alpha + f_1(X_1) + f_2(X_2) + f_{12}(X_1, X_2) + \varepsilon$$

여기서 $f_{12}(X_1, X_2)$ 의 추정을 위한 방법이 여러 가지 있으나 Y 를 X_1 과 X_2 에 대해 비모수 회귀시킨 다음 잔차를 구하여 이를 다시 $f_{12}(X_1, X_2)$ 에 회귀시키는 것이 바람직하다. 그러나 이러한 방법은 설명변수의 개수가 많아지면 매우 힘들게 된다. 여기서는 가장 간단한 방법중의 하나인 브라이만 등(Breiman, et al., 1984)에 의해 소개된 회귀나무(regression trees)를 소개한다.

우선 자료를 특정한 설명변수를 기준으로 두 부분으로 나눈다. 두 부분으로 나눌 때는 반응변수값이 각 그룹에서 분산이 최소화되도록 한다. 이렇게 나누어진 자료를, 이젠 다른 설명변수를 기준으로 다시 두 그룹으로 나누는데, 역시 각 그룹의 자료가 분산이 최소화 되도록 나눈다. 이러한 과정을 반복해 가는 것이 회귀나무이다. (그림 11.16)은 반응변수가 뉴욕시의 오존 양이고, 기온(temp)과 풍속(wind)이 설명변수로 주어져있을 때의 회귀나무를 그린 것이다. Y 의 전체평균은 -0.67이고, 자료를 두 부분으로 나눌 때 기온이 82.5 이상과 미만을 기준으로 나누면 각 그룹 내에서의 Y 의 분산이 최소로 되고 그때의 Y 의 평균은 각각 -1.03과 0.16이 된다. 기온이 82.5 미만일 때 풍속을 7.2를 기준으로 나누면 Y 의 평균은 각각 -0.24와 -1.14가 된다. 이런 식으로 계속해 나간 그림이 (그림 11.16)에 주어져 있다. 이를 3차원 그림으로 그린 것이 (그림 11.17)에 주어져 있으며 회귀나무를 쉽게 그려 주는 패키지로 CART(Classification and Regression Trees)가 있다.



(그림 11.16) 오존자료의 회귀나무그림. 기온(temp)과 풍속(wind)이 오존 양에 미치는 영향을 나타낸 것임.(출처: 해스티와 티브쉬라니(Hastie & Tibshirani, 1990, p. 272))



(그림 11.17) 오존자료를 회귀나무에 의해 분석한 것을 3차원 그래프로 나타내고(왼쪽), 2차원에서의 빈도를 나타낸 것임(오른쪽).(출처: 해스티와 티브쉬라니(Hastie & Tibshirani, 1990, p. 273))

연습문제 (11)

[이론 문제]

11.1 식 (11.2)에서 $\lambda = 0$ 일 때 $S(\lambda)$ 를 최소화하는 f 는 잔차가 0임을 증명하라. 또한, $\lambda = \infty$ 일 때 $S(\lambda)$ 를 최소화하는 f 는 직선임을 보여라.

11.2 $y_j = f(x_j) + \varepsilon_j$ 에서 평활 모수 λ 가 주어져 있을 때 $f(x)$ 의 추정치를 $\hat{f}_\lambda(x)$ 라 하면

$$L(\lambda) = \frac{1}{n} \sum_{j=1}^n \{f(x_j) - \hat{f}_\lambda(x_j)\}^2$$

을 손실함수(loss function)라 부르고,

$$R(\lambda) = E[L(\lambda)]$$

를 위험함수(risk function)라 한다. 또한, $y_j^* = f(x_j) + \varepsilon_j^*$, $j = 1, \dots, n$ 을 새로운 관측치라 하고 ε_j^* 는 ε_j 와 독립이라 가정할 때,

$$P(\lambda) = E \left[\frac{1}{n} \sum_{j=1}^n \{y_j^* - \hat{f}_\lambda(x_j)\}^2 \right]$$

를 예측위험함수(prediction risk function)이라 한다. 위에서 $P(\lambda) = \sigma^2 + R(\lambda)$ 임을 보여라. 또한, 평균오차제곱합

$$MSE(\lambda) = \frac{1}{n} \sum_{j=1}^n \{y_j - \hat{f}_\lambda(x_j)\}^2$$

은 $P(\lambda)$ 의 불편추정치가 아님을 보여라.

11.3 11.2.2절에 주어진 나다라야왓슨 추정치를 증명하라.

11.4 평활 모수 λ 가 매우 커지면 나다라야왓슨 추정치는 y_i 들의 산술평균으로 수렴함을 보여라.

11.5 커널 추정치의 모자행렬 H_λ 를 구하라.

11.6 구간평균법에서 각 관측치의 잔차가 0 이 되는 상황은 어떤 경우인가?

11.7 11.3.1절에서 $\theta_j = \int g_j(x)f(x)dx$ 임을 증명하라.

11.8 푸리에 기저가 완비정규직교계임을 보여라.

11.9 푸리에 급수추정치에서 $\lambda = 1$ 일 때 $\hat{f}_1(x) = \bar{Y}$ 임을 보여라.

[응용 문제]

11.1 <표 11.4>에 주어져 있는 과통화팽창 자료를 이용하여

- (1) $k = 5$ 와 $k = 20$ 일 때 구간평균법과 구간직선법을 이용한 추정치를 구하라.
- (2) $k = 10$ 과 $k = 20$ 일 때 k -최근접 주변 추정치를 구하라.
- (3) $\lambda = 0.0005$ 와 $\lambda = 0.001$ 일 때 삼각커널을 이용한 커널추정치를 구하라.
- (4) $\lambda = 6$ 일 때 푸리에 급수 추정치를 구하라.
- (5) $\lambda = 3$ 일 때 국소상수추정치 및 국소선형추정치를 구하라.
- (6) $\lambda = 5$ 일 때 한 번 미분한 회귀함수 $f'(x)$ 의 국소선형추정치를 구하라.

11.2 (x_i, y_i) , $i = 1, \dots, 20$ 가 $x_i = i - 10$, $y_i = |i - 10|$ 으로 주어져 있다. $\lambda = 2$ 일 때 $x = 0.5$ 에서 삼각 커널을 이용한 커널 추정치를 구하라.

11.3 <표 11.3>의 $GCV(\lambda)$ 값을 확인하라.

11.4 <표 11.1>의 성장곡선 자료에서 정규커널을 이용하고 $\lambda = 3$ 으로 두고 국소선형추정치를 구하라.

제 12 장

중도절단자료의 회귀모형

- 12.1 생존함수와 위험함수
- 12.2 중도절단 자료
- 12.3 생존함수의 추정
- 12.4 각스회귀모형
- 12.4 선형회귀모형

우리는 단순선형 회귀모형에서 비모수 회귀모형에 이르기까지 여러 형태의 회귀모형을 다루었다. 여기서는 중도절단자료에 대한 회귀모형을 소개한다. 중도절단자료의 대표적인 예로서 의학에서 주로 나타나는 생존시간이 완전하게 주어지지 않는 경우가 많다. 중도절단자료에 대한 회귀모형으로 콕스회귀모형, 가속수명모형, 선형모형 등을 소개한다.

12.1 생존함수와 위험함수

생존기간을 나타내는 확률변수를 T 라 하고, T 는 확률밀도함수 $f(t)$, 분포함수 $F(t)$ 를 가진다고 하자. 생존함수(survival function) $S(t)$ 는

$$S(t) = 1 - F(t) = P(T > t)$$

로 정의되며 위험율 또는 치사율(hazard rate) $\lambda(t)$ 는

$$\lambda(t) = f(t)/S(t)$$

로 정의된다. $\lambda(t)$ 의 의미는

$$\begin{aligned}\lambda(t) \cdot \Delta t &\simeq P(t < T < t + \Delta t \mid T > t) \\ &= P((t, t + \Delta t)\text{사이에서 사망} \mid t \text{까지 생존})\end{aligned}$$

이므로 t 시점까지 생존한 사람이 t 직후에 사망할 비율로 볼 수 있다. 예를 들어, 평균 λ 인 지수분포, 즉 $f(t) = \lambda e^{-\lambda t}$ 인 경우, 위험율 $\lambda(t) \equiv \lambda$ 임을 알 수 있다. 즉, 생존기간이 지수분포를 따르면 위험율은 시간에 관계없이 언제나 일정함을 알 수 있다.

$\lambda(t)$ 와 $S(t)$ 와의 관계는

$$\int_0^t \lambda(u) du = \int_0^t \frac{f(u)}{1 - F(u)} du = -\log(1 - F(t)) = -\log S(t)$$

로부터

$$S(t) = \exp\left(-\int_0^t \lambda(u) du\right)$$

가 됨을 알 수 있는데, 흔히

$$\Lambda(t) = \int_0^t \lambda(u) du$$

를 누적위험함수(cumulative hazard function)라 부른다. 따라서, $S(t) = \exp(-\Lambda(t))$ 로 표현됨을 알 수 있다.

12.2 중도절단 자료

통계학에서 다루는 자료는 완전자료(complete data)와 불완전자료(incomplete data)로 나눌 수 있다. 우리가 다루는 대부분의 자료는 완전자료로서 자료 그 자체가 원래의 의미를 제대로 반영하고 있는 경우이다. 예를 들어 어떤 사람의 몸무게가 $64kg$ 이라면 64라는 정보를 제대로 간직하고 있다. 물론 완전자료에는 측정오차(measurement error)가 발생되었거나 반올림 오류(round-off error) 등이 포함될 수 있어도 우리는 여전히 완전자료라고 부른다. 반면, 어떤 사람이 폐암에 걸린 나이는 65세와 69세 사이라고 할 때 이런 자료를 불완전 자료라고 부른다. 즉, 이 사람이 폐암에 걸린 나이를 정확히 알 수 없고 단지 구간만 알려져 있는 경우이다. 이런 형태의 불완전자료를 중도절단자료(censored data)라 부른다. 불완전자료의 또 다른 예로서, 어떤 사람이 신체검사에서 (키, 몸무게, 혈압) 세 가지를 측정해야 하는데 그 중에서 키와 몸무게만 측정하고 혈압 측정치는 없는 경우, 즉 자료의 일부가 없는 경우도 역시 불완전자료가 된다. 이런 형태의 불완전자료는 빠진자료(missing data)라 부른다.

12.2.1 우측중도절단자료

(I) 제1종 중도절단

실제 생존시간 $T_i, i = 1, \dots, n$ 에 대응하는 중도절단 변수 $C_i, i = 1, \dots, n$ 가 있을 때 제1종 중도절단은 $C_i, i = 1, \dots, n$ 를 변수로 취급하지 않고 미리 정해진 고정된 상수로 취급한 다음 우리는 $T_i, i = 1, \dots, n$ 대신

$$Y_i = \min(T_i, C_i),$$

$$\delta_i = I(T_i \leq C_i), \quad i = 1, \dots, n$$

를 관측하게 되는데 여기서 $\delta_i = I(T_i \leq C_i), i = 1, \dots, n$ 는 중도절단지수(censoring indicator)라 불리운다. 즉, 제1종 중도절단이란 생존시간이 미리 정해진 중도절단시간보다 작으면 관측되고, 크면 관측할 수 없게 되어 중도절단되어 버린다. 이 경우 우도함수를 구하기 위해

$$P(Y_i = C_i, \delta_i = 0) = P(T_i > C_i) = S(y_i)$$

$$P(Y_i = T_i, \delta_i = 1) = f(y_i)$$

을 이용하면

$$L(\theta) = \prod_{i=1}^n f(y_i)^{\delta_i} S(y_i)^{1-\delta_i}$$

이 된다. 여기서, θ 는 생존시간의 분포함수와 관련된 모수이다.

예제 12.1 $T_i, i = 1, \dots, n$ 는 서로 독립인 지수분포 $Exp(\lambda)$ 를 따른다고 하자. 즉, $f(t) = \lambda e^{-\lambda t}$ 라 하면 우도함수는

$$\begin{aligned} L(\lambda) &= \prod_{i=1}^n (\lambda e^{-\lambda y_i})^{\delta_i} (e^{-\lambda y_i})^{1-\delta_i} \\ &= \lambda^r e^{-\lambda \sum y_i} \end{aligned}$$

인데 여기서 $r = \sum \delta_i$ 이다. 로그우도함수 $l(\lambda) = r \log \lambda - \lambda \sum y_i$ 으로 부터 λ 의 최우추정치는 $\hat{\lambda} = r / \sum y_i$ 임을 알 수 있다. $\square$

(II) 제2종 중도절단

r 을 관측치 개수 n 보다 작은 양의 정수라 하고 $T_{(1)} < T_{(2)} < \dots < T_{(n)}$ 을 순서통계량이라 할 때, 생존기간을 $T_{(1)}$ 부터 $T_{(r)}$ 까지 관측하는 것을 제2종 중도절단(type II censoring)이라 한다. 즉, $T_{(r+1)}$ 부터 $T_{(n)}$ 까지는 $T_{(r)}$ 시점에서 중도절단되어 관측할 수 없는 값이다.

$T_{(1)}, \dots, T_{(r)}$ 에 대한 결합확률밀도함수는 순서통계량의 성질을 이용하면

$$\frac{n!}{(n-r)!} \left\{ \prod_{i=1}^r f(t_{(i)}) \right\} S(t_{(r)})^{n-r}$$

임을 어렵지 않게 보일 수 있다.

예제 12.2 생존시간이 예제 12.1과 같은 지수분포를 따르고 제2종 중도절단이 일어났다고 하면 로그우도함수는

$$l(\lambda) = r \log \lambda - \lambda \left\{ \sum_{i=1}^r t_{(i)} + (n-r)t_{(r)} \right\}$$

이 되므로 λ 의 최우추정치는 $\hat{\lambda} = r/W$ 인데 여기서 $W = \sum_{i=1}^r t_{(i)} + (n-r)t_{(r)}$ 이며 $2r\lambda/\hat{\lambda} \sim \chi^2(2r)$ 을 이용하여 λ 의 신뢰구간을 구할 수 있다. $\square$


(III) 임의 중도절단

$C_1, C_2, \dots, C_n$ 을 분포함수 G 를 갖는 서로 독립인 확률변수라 하자. 또한, C_i 는 T_i 에 관련된 중도절단시간이라 하자. 이때

$$Y_i = \min(T_i, C_i)$$

$$\delta_i = I(T_i \leq C_i) = \begin{cases} 1, & T_i \leq C_i \text{ 일때} \\ 0, & T_i > C_i \text{ 일때} \end{cases}$$

라 정의하면 중도절단된 자료는 $\delta_i = 0$ 이고 중도절단되지 않은 자료는 $\delta_i = 1$ 이다. 즉, δ_i 는 중도절단지수(censoring indicator)이다. 따라서 $T_i \leq C_i$ 이면 생존기간 T_i 를 관측할 수 있고 $T_i > C_i$ 이면 T_i 대신 C_i 만을 관측하게된다.



(그림 12.1) 임의 중도절단의 예

(그림 12.1)에서 환자 1은 중도절단 안 된 것으로 T_1 의 생존기간이 관측되었고, 환자 2는 연구종점까지 생존해 있으므로 T_2 는 관측할 수 없고 중도절단시간 C_2 만 관측되었다. 흔히, 이런 경우에 C_2 를 T_2^+ 로 표현한다. 환자 3은 연구종점 이전에 중도절단된 것인데 다른 병원으로 옮겨서 더 이상 추적(follow up)이 불가능하거나 연구대상이 아닌 다른 원인으로 사망한 경우이다.

이 경우 우도함수를 구하기 위해

$$P(Y_i = t, \delta_i = 0) = P(C_i = t, T_i > C_i) = g(t)S(t)$$

$$P(Y_i = t, \delta_i = 1) = P(T_i = t, T_i \leq C_i) = f(t)G(t)$$

을 이용하면

$$P(Y_i = t, \delta_i) = \{f(t)G(t)\}^{\delta_i} \{g(t)S(t)\}^{1-\delta_i}$$

으로 표현할 수 있는데 우도함수는 중도절단 변수의 분포함수나 밀도함수의 모수에 무관하므로

$$L(\theta) = \prod_{i=1}^n f(y_i)^{\delta_i} S(y_i)^{1-\delta_i}$$

이 된다. 단, 여기서 θ 는 생존시간의 분포함수 F 에 관련된 모수이다.

12.2.2 구간중도절단자료

의학, 치의학, 생물학 등에서 생존시간(survival time) 또는 사망시간(failure time) 등은 흔히 정확한 값을 알 수 없고 그 구간만 관측할 수 있는 구간중도절단자료(interval-censored data)의 형태를 띄게 된다. 따라서 생존시간 T 의 정확한 값을 알 수 없고 대신 T 가 속한 구간 $(L, R]$ 만 관측된다. 즉, $T \in (L, R]$, $L \leq R$ 으로 표현된다. 구간중도절단자료는 흔히 네 가지 경우로 구분한다. 첫째, 제1종 구간중도절단자료(case I interval-censored data)는 각 관측치가 $L = 0$ 또는 $R = \infty$ 로만 나타나는 경우로 실제 발생시간은 각 관측치의 전 또는 후를 나타내는 것으로 흔히 현상자료(current status data)라고도 불리운다. 즉, 폐암의 발생시점을 나타내는 현상자료에는 $(0, 59]$ 또는 $(66, \infty)$ 로 나타나며 이는 각각 56세 이전에 발병했거나 66세 이후에 발병했다는 사실만 알려줄 뿐이다. 둘째, 제2종 구간중도절단자료(case II interval-censored data)는 제1종 구간중도절단자료 처럼 $L = 0$ 또는 $R = \infty$ 로 나타나는 자료도 있지만 대부분의 자료가 L 과 R 이 모두 유한한 값으로 주어지는 경우이다. 좁은 의미의 구간중도절단자료는 흔히 제2종 구간중도절단자료를 의미한다. 제2종 구간중도절단자료에서 $R = \infty$ 이면 우측 중도절단자료(right-censored data)가 되고 $L = 0$ 이면 좌측 중도절단자료(left-censored data)에 해당된다. 즉, 제1종 구간중도절단, 우측중도절단, 좌측중도절단은 모두 제2종 구간중도절단의 특별한 경우라 할 수 있다. 세 번째는 이중중도절단자료(doubly censored data)로 두 가지의 생존시간이 모두 중도절단된 경우이다. 즉, L 과 R 모두 중도절단된 것이다. HIV(human immunodeficiency virus) 감염 후 AIDS(acquired immunodeficiency syndrome) 발병 때까지의 기간에 관심이 있다고 할 때 HIV 감염시기와 AIDS 발병시기 모두 구간중도절단자료이므로 이 경우 이중중도절단에 해당된다. 네 번째는 연석자료(panel data)로 어떤 사건이 여러