

변 발생할 때 (예를 들어, 종양의 발생이나 질환의 징조) 이에 대한 정확한 발생시기는 알 수 없고 단지 그 구간만 알 수 있는 경우로 흔히 오랜 기간의 임상시험(long-term clinical trial)이나 지속적인 생태학 연구(longitudinal sociological study)등에 나타난다. 여기서는 대표적 구간중도절단 형태인 제2종 구간중도절단자료를 간단히 구간중도절단자료라 정의 하겠다.

구간중도절단자료는

$$(L_i, R_i], i = 1, \dots, n$$

으로 표현할 수 있는데 이를 분석하기 위한 방법으로 여러 가지 분석법이 제안되었다. 그 중에서도 가장 간단한 방법은 평균대치법(mean imputation method)이란 것이 있는 이 방법은 R_i 가 유한인 경우 $(L_i, R_i]$ 를 평균값인 $Y_i = (L_i + R_i)/2$ 로 간주하고 중도절단되지 않은 것으로 (즉, $\delta_i = 1$) 가정한다. 한편, R_i 가 무한인 경우 (L_i, ∞) 를 좌측값인 $Y_i = L_i$ 로 간주하고 중도절단된 것으로 (즉, $\delta_i = 0$) 가정한다. 이렇게 두면 구간중도절단자료는 우측중도절단자료로 변환되므로 우측중도절단자료의 이론을 그대로 사용할 수 있다.

12.3 생존함수의 추정

12.3.1 모수적 추정

생존함수에 대한 모수적 추정은 위험율 함수나 생존함수를 특정함수로 가정하는 것이다. 따라서, 모수적 추정시에 가장 중요한 점은 가정한 함수가 자료의 성격을 제대로 반영하는 것인지 확인하는 것이다. 기본적으로 생존시간을 나타내는 확률변수는 언제나 양의 값을 가지므로 지수분포, 와이블 분포, 감마분포, 레일리 분포, 로그-정규분포 등이 많이 이용된다.

지수분포(exponential distribution)는 위험율 함수가 시간과 관계없이 언제나 일정한 상수로 가정한 것이다. 즉, $\lambda(t) = \lambda$ 로 가정한 것인데 이로 부터 $S(t) = e^{-\lambda t}$, $f(t) = \lambda e^{-\lambda t}$ 가 된다. 지수분포의 특징은 비기억성(memoryless property)을 갖는 것인데 이는

$$P(T > t + s | T > s) = P(T > t), 0 < s < t < \infty$$

을 의미한다. 지수분포는 모수적 추정에서 가장 단순한 분포이므로 현실성이 떨어지지만

기초이론 전개와 모의실험 등에 많이 사용된다.

지수분포의 현실적 한계를 극복하기 위해 모수 한 개를 더 추가시켜 확장한 분포가 감마 분포(gamma distribution)와 와이블 분포(Weibull distribution)이다. 감마분포의 확률밀도함수는

$$f(t) = \frac{\lambda^\alpha}{\Gamma(\alpha)} t^{\alpha-1} e^{-\lambda t}, \alpha > 0, \lambda > 0$$

으로 주어지는데 $\alpha = 1$ 인 경우가 바로 지수분포이다. 감마분포의 경우 위험율 함수 및 생존함수는 식으로 표현 할 수 없다(does not have closed form expressions).

한편, 와이블 분포의 생존함수는 $S(t) = \exp(-(\lambda t)^\alpha)$ 인데 이로 부터 $\lambda(t) = \alpha\lambda(\lambda t)^{\alpha-1}$ 임을 알 수 있다. 이 사실을 이용하면

$$f(t) = \alpha\lambda(\lambda t)^{\alpha-1} \exp(-(\lambda t)^\alpha)$$

으로 표현된다. 와이블 분포의 생존함수에 로그-로그 변환을 하면

$$\log[-\log S(t)] = \alpha(\log t + \log \lambda)$$

이므로 $\log[-\log \hat{S}(t)]$ 와 $\log t$ 의 관계가 선형으로 주어지면 와이블 분포의 가정이 옳음을 알 수 있다.

래일리 분포(Rayleigh distribution)는 상수 위험율(지수분포)을 선형 위험율로 확장한 것이다. 즉, 래일리 분포는 위험율 함수를

$$\lambda(t) = \lambda_0 + \lambda_1 t$$

으로 가정한 것인데 이로 부터 생존함수가

$$S(t) = \exp(-\lambda_0 t - \frac{1}{2}\lambda_1 t^2)$$

임을 쉽게 알 수 있고 이로 부터 확률밀도함수는

$$f(t) = (\lambda_0 + \lambda_1 t) \exp(-\lambda_0 t - \frac{1}{2}\lambda_1 t^2)$$

으로 표현된다.

한편, 로그-정규 분포(log-normal distribution)는 생존시간의 로그값인 $\log T$ 가 정규분포 $N(\mu, \sigma^2)$ 를 따른다고 가정한 것이다. 이로 부터 생존함수는

$$\begin{aligned} S(t) &= 1 - P(T \leq t) \\ &= 1 - P(\log T \leq \log t) \\ &= 1 - P\left(\frac{\log T - \mu}{\sigma} \leq \frac{\log t - \mu}{\sigma}\right) \\ &= 1 - \Phi\left(\frac{\log t - \mu}{\sigma}\right) \end{aligned}$$

이 된다. 로그-정규 분포는 생존시간을 로그 변환한 후 정규분포로 가정하므로 매우 편리하게 사용될 수 있는 분포이다.

12.3.2 비모수적 추정

(1) 카플란-마이어 추정치

우측 중도절단에서 임의 중도절단의 경우를 고려하자. 기호의 편의상 관측치 (Y_i, δ_i) , $i = 1, \dots, n$ 이 크기 순으로 나열되어 있다고 하자. 즉, $y_1 \leq y_2 \leq \dots \leq y_n$ 으로 가정하고 중도절단지수도 이와 대응되게 주어졌다고 가정하자. 이제 중도절단되지 않은 관측치(즉, 사망이 일어난 경우)들 중 서로 겹치지 않는 관측치들의 갯수가 k 개라 하고 이를

$$\tau_1 < \tau_2 < \dots < \tau_k$$

이라 하자(생존시간은 연속확률변수이므로 같은 값을 갖는 확률이 없지만 실제로는 생존시간을 반올림하여 기록하는 경우가 많아 같은 값을 갖는 경우가 흔히 발생됨). 또한,

$$d_j = \sum_{i=1}^n I(y_i = \tau_j, \delta_i = 1)$$

는 τ_j 시점에서 발생한 사망자 수를 나타내고

$$n_j = \sum_{i=1}^n I(y_i \geq \tau_j)$$

는 τ_j 직전까지 사망하지 않은 관측치들의 개수라 하자. τ_j 직전까지 사망하지 않은 관측치들의 집합을 흔히 τ_j 에서의 위험집합(risk set)이라 부른다. 생존함수에 대한 카플란-마

이러 추정치(Kaplan-Meier estimator, Kaplan & Meier, 1958)는 다음과 같은 식으로 부터 유도할 수 있다.

$$\begin{aligned} S(t) &= P(T > t) \\ &= P(T > t | T > \tau_{k-1}) P(T > \tau_{k-1}) \\ &= P(T > t | T > \tau_{k-1}) P(T > \tau_{k-1} | T > \tau_{k-2}) P(T > \tau_{k-2}) \\ &\vdots \\ &= P(T > t | T > \tau_{k-1}) P(T > \tau_{k-1} | T > \tau_{k-2}) \dots P(T > \tau_1 | T > \tau_0) P(T > \tau_0) \end{aligned}$$

여기서 $\tau_0 = 0$ 이므로 $P(T > \tau_0) = 1$ 이다. 이제,

$$p_j = P(T > \tau_j | T > \tau_{j-1}), \quad j = 1, \dots, k-1; \quad p_k = P(T > t | T > \tau_{k-1})$$

이라 두면

$$S(t) = \prod_{j=1}^k p_j$$

이다. 카플란-마이러 추정치는 p_j 를

$$\hat{p}_j = \hat{P}(T > \tau_j | T > \tau_{j-1}) = \hat{P}(T > \tau_j) / \hat{P}(T > \tau_{j-1}) = n_{j+1} / n_j = (n_j - d_j) / n_j$$

와 같이 추정하였다. 즉, 생존함수에 대한 카플란-마이러 추정치는

$$\hat{S}(t) = \prod_{j: \tau_j \leq t} (1 - \frac{d_j}{n_j})$$

으로 나타난다. 같은 논리로 누적위험함수에 대한 추정치를

$$\hat{\Lambda}(t) = \sum_{j: \tau_j \leq t} \frac{d_j}{n_j}$$

으로 표현할 수 있는데 이를 흔히 넬슨-알렌(Nelson-Aalen, 1969)추정치라 부른다.

특별한 경우로 같은 값을 갖는 관측치들이 하나도 없는 경우(no ties)를 고려해 보자. 이 때는 $y_1 < y_2 < \dots < y_n$ 이고 $\tau_j = y_j$ 라 두면 $d_j = \delta_j$, $n_j = n - j + 1$ 이 되므로 카플란-마

이러 추정치는

$$\hat{S}(t) = \prod_{j: y_j \leq t}^n \left(1 - \frac{\delta_j}{n - j + 1}\right) = \prod_{j: y_j \leq t}^n \left(1 - \frac{1}{n - j + 1}\right)^{\delta_j}$$

로 표현된다.

카플란-마이어 추정치는 여러 가지 좋은 성질을 가지고 있다. 첫째, 자기-일치성(self consistency)을 가지는데 이는 에프런(Efron, 1967)과 턴불(Turnbull, 1974)등에 의해 연구되었다. 둘째, 카플란-마이어 추정치는 일반화된 최우추정치(generalized MLE) 또는 비모수적 최우추정치(nonparametric MLE)가 된다. 셋째, 근사적 정규성을 가진다. 즉,

$$\hat{S}(t) \rightarrow N(S(t), \sigma_S^2(t))$$

인데 $\hat{S}(t)$ 의 분산에 대한 추정치로 흔히 그린우드 공식(Greenwood's formula)

$$\hat{\sigma}_S^2(t) \equiv \hat{Var}(\hat{S}(t)) = \hat{S}(t)^2 \sum_{j: \tau_j \leq t} \frac{d_j}{n_j(n_j - d_j)}$$

을 주로 사용한다. 같은 값을 갖는 관측치들이 하나도 없는 경우에는 그린우드 공식이

$$\hat{\sigma}_S^2(t) = \hat{S}(t)^2 \sum_{j: y_j \leq t} \frac{\delta_j}{(n - j)(n - j + 1)}$$

으로 표현된다. 이를 이용하여 분포함수에 대한 신뢰구간을 구할 수 있는데 $100 \times (1 - \alpha)\%$ 신뢰구간은

$$\hat{S}(t) \pm z_{\alpha/2} \hat{\sigma}_S(t)$$

로 주어진다. 여기서, 한 가지 주의해야 할 점은 t 가 0에 가까운 값이거나 매우 큰 값이면 신뢰구간이 (0, 1)을 벗어나는 값을 포함할 수 있다. 이를 피하기 위해 로짓변환이나 로그-로그 변환등이 있다.

(2) 커널 추정치

카플란-마이어 추정치는 앞에서 언급한대로 매우 좋은 성질들을 가지고 있으므로 생존함수의 추정치로 널리 이용되고 있다. 그러나, 카플란-마이어 추정치의 한 가지 단점은 계단함수(step function)로서 연속함수가 아니라는 점이다. 불연속함수는 역함수인 분위수

함수(quantile function)를 구하기 쉽지 않고 한 번 미분해서 밀도함수를 구하기도 쉽지 않다. 불연속점은 중도절단되지 않은 관측치에서 일어나는데 이러한 불연속 함수를 매끄러운 연속함수로 만들어주기 위해 커널 추정치가 주로 이용된다.

우선 중도절단 관측치가 전혀 없는 완전한 자료를 고려해 보자. 밀도함수 $f(t)$ 에 대한 커널 추정치는

$$\hat{f}(t) = \frac{1}{n} \sum_{i=1}^n K_h(t - Y_i)$$

로 주어진다. 여기서,

$$K_h(\cdot) = K(\cdot/h)/h$$

이고 $K(\cdot)$ 는 커널함수 (11장 참조)이며 h 는 추정되어야 할 평활모수이다. 이를 이용하면 분포함수 $F(t)$ 의 커널 추정치는

$$\hat{F}(t) = \int_{-\infty}^t \hat{f}(u) du = \frac{1}{n} \sum_{i=1}^n W\left(\frac{t - Y_i}{h}\right)$$

으로 표현할 수 있는데 여기서

$$W(t) = \int_{-\infty}^t K(u) du$$

이다. 이를 중도절단 자료에 적용해 보자. 완전 자료의 경우 커널 추정치의 가중치가 $1/n$ 으로 모두 같은 값인데 중도절단 자료의 경우 가중치를 카플란-마이어 추정치의 점프 크기로 대체하는 것이다. 즉, 밀도함수와 분포함수의 추정치는 각각

$$\begin{aligned}\hat{f}(t) &= \sum_{i=1}^n w_i K_h(t - Y_i) \\ \hat{F}(t) &= \sum_{i=1}^n w_i W\left(\frac{t - Y_i}{h}\right)\end{aligned}$$

으로 주어진다. 단, 여기서 w_i 는 카플란-마이어 추정치에 나타나는 Y_i 에서의 점프 크기를 나타낸다. 따라서 생존함수에 대한 커널 추정치는

$$\hat{S}(t) = 1 - \sum_{i=1}^n w_i W\left(\frac{t - Y_i}{h}\right)$$

이 된다.

예제 12.3 다음 자료는 백혈병 환자를 21명씩 나누어서 한 그룹은 6-MP(6-mercaptopurine) 처리를 하고 다른 그룹은 위약(placebo) 처리를 한 후 경감기간(lengths of remission)을 조사한 것이다(단위는 주를 나타냄).


6-MP	6 17+	6 19+	6 20+	6+ 22	7 23	9+ 25+	10 32+	10+ 32+	11+ 34+	13 35+	16
placebo	1 8	1 8	2 11	2 11	3 12	4 12	4 15	5 17	5 22	8 23	8

각 그룹에 대해 카플란-마이어 추정치를 구하고, $t = 15$ 일 때의 생존함수에 대한 추정치 및 95% 신뢰구간을 구해보자.

<풀이>

각 그룹에 대한 카플란-마이어 추정치는 다음과 같다.

6-MP 복용군					위약군				
t_j	n_j	d_j	$\hat{S}(t_j+)$	se	t_j	n_j	d_j	$\hat{S}(t_j+)$	se
6	21	3	0.857	0.076	1	21	2	0.905	0.064
7	17	1	0.807	0.087	2	19	2	0.810	0.086
10	15	1	0.753	0.096	3	17	1	0.762	0.093
13	12	1	0.690	0.107	4	16	2	0.667	0.103
16	11	1	0.627	0.114	5	14	2	0.571	0.108
22	7	1	0.538	0.128	8	12	4	0.381	0.106
23	6	1	0.448	0.135	11	8	2	0.286	0.099
					12	6	2	0.191	0.086
					15	4	1	0.143	0.076
					17	3	1	0.095	0.064
					22	2	1	0.048	0.047



(그림 12.2) 두 그룹의 생존분포 비교

6-MP그룹에서의 $\hat{S}(15) = 0.690$ 이고, 위약군은 $\hat{S}(15) = 0.143$ 임을 알 수 있다. 이제 그린우드 공식을 이용하여 각 그룹별로 $t = 15$ 일 때의 생존함수에 대한 95% 신뢰구간을 구해보자. 우선, 6-MP그룹에서 $t = 15$ 일 때의 분산은

$$\hat{Var}(\hat{S}(15)) = 0.690^2 \left(\frac{3}{21 \times 18} + \frac{1}{17 \times 16} + \frac{1}{15 \times 14} + \frac{1}{12 \times 11} \right) = 0.011403$$

이므로, $\hat{\sigma}_S(15) = 0.107$ 이다. 따라서, $t = 15$ 일 때의 생존함수에 대한 95% 신뢰구간은

$$0.690 \pm 1.96 \times 0.107 = (0.4803, 0.8997)$$

이 된다. 위약군도 마찬가지로 계산할 수 있다. □

12.4 콕스회귀모형

12.4.1 비례위험모형

중도절단자료에서 공변량(설명변수)이 생존시간(반응변수)에 미치는 영향을 알기 위한 회귀모형을 구축하는 방법에는 크게 두 가지가 있다. 첫째, 공변량과 반응시간과의 함수 관계를 바로 설정하는 방법이다. 이는 앞에서 다루었던 완전자료에 대한 모수적 회귀와 비모수적 회귀 모두 여기에 해당된다. 또한, 다음 절에서 소개하는 선형회귀모형도 이 방법에 의한 것이다. 둘째, 공변량이 위험을 함수에 미치는 영향을 가정하는 방법이다. 콕스(Cox, 1972)는 두 번째 방법으로 중도절단자료에서의 회귀모형을 다음과 같이 제안하였다.

생존기간 $T_1, T_2, \dots, T_n$ 이 임의중도절단에 의해 $(Y_1, \delta_1), \dots, (Y_n, \delta_n)$ 만 관측가능하고, p 개의 설명변수로 구성된 $\mathbf{x}_1, \dots, \mathbf{x}_n$ (즉, $\mathbf{x}_i = (X_{i1}, \dots, X_{ip})'$)이 있다고 하자. 편의상 $Y_1 < Y_2 < \dots < Y_n$ 이라 하고 이에 해당되는 중도절단지수를 $\delta_1, \delta_2, \dots, \delta_n$ 이라 하자. 이때 R_i 를 Y_i 직전까지 생존해 있는 환자의 집합을 나타낸다고 할 때 R_i 를 위험집합(risk set)이라 부른다. 또한, $\mathbf{x}$ 가 주어져 있을 때 시간 t 에서의 위험율을 $\lambda(t; \mathbf{x})$ 라 하고 $\mathbf{x} = 0$ 에서의 위험율, 즉, 기저 위험율(baseline hazard)을 $\lambda_0(t)$ 라 하자. 이때

$$\lambda(t; \mathbf{x}) = \exp(\mathbf{x}'\boldsymbol{\beta})\lambda_0(t)$$

로 가정한 모형을 비례위험모형(proportional hazard model) 또는 콕스회귀모형(Cox regression model)이라 한다. 콕스회귀모형은 반응변수와 설명변수간의 관계를 직접 나타낸

것이 아니고 위험함수를 이용한 회귀모형임을 알 수 있다.

[정의 12.1]: 어떤 양수 γ 와 임의의 분포함수 $F \in \mathfrak{F}$ 에 대하여 $1 - F = (1 - F_0)^\gamma$ 를 만족하는 $F_0 \in \mathfrak{F}$ 가 존재하면 분포함수군 $\mathfrak{F}$ 를 레만 대립군(family of Lehmann alternatives)이라 한다. (이를 분포함수 대신 생존함수로 표현하면 $S = S_0^\gamma$ 이 된다).

비례위험모형은 생존함수가 레만 대립군임을 알 수 있다. 왜냐하면

$$\begin{aligned} S(t : \mathbf{x}) &= \exp\left\{-\int_0^t \lambda(u : \mathbf{x}) du\right\} \\ &= \exp\left\{-\exp(\mathbf{x}'\boldsymbol{\beta}) \int_0^t \lambda_0(u) du\right\} \\ &= [\exp\left\{-\int_0^t \lambda_0(u) du\right\}]^{\exp(\mathbf{x}'\boldsymbol{\beta})} \\ &= [S_0(t)]^{\exp(\mathbf{x}'\boldsymbol{\beta})} \end{aligned}$$

인데 여기서

$$S_0(t) = \exp\left\{-\int_0^t \lambda_0(u) du\right\}$$

이다. 좀 더 간단한 경우로 공변량이 한 개만 ($p = 1$)있으며 공변량 $x_i, i = 1, \dots, n$ 는 두 집단을 나타낸다고 가정하자. 즉, i 번째 관측치가 첫번째 집단에 속하면 $x_i = 1$, 두번째 집단에 속하면 $x_i = 0$ 이라 가정하면, 첫번째 집단의 경우 $\exp(\beta x_i) = \exp(\beta) \equiv \gamma$ 이고 두번째 집단의 경우 $\exp(\beta x_i) = \exp(0) = 1$ 이므로

$$S_1(t) = S_2(t)^\gamma$$

가 성립되어 레만 대립군에 속함을 알 수 있다. 이 사실을 이용하면 비례위험모형의 가정이 올바른 것인지 확인할 수 있다. 위 식에 로그-로그를 취하면

$$\log[-\log S_1(t)] = \log \gamma + \log[-\log S_2(t)]$$

이 성립된다. 즉, 각 생존함수에 로그-로그를 취하면 시간에 관계없는 상수($\log \gamma$)만큼 차이가 나므로 각 집단의 생존함수를 추정한 그림이 시간에 관계없이 일정한 차이를 유지하는 형태를 보여야 비례위험모형의 가정이 옳다고 할 수 있다.

12.4.2 회귀계수의 추정

비례 위험모형하에서 중도절단되지 않은 Y_i 에 대한 위험 집합을 R_i 라 하면

$$\Pr([Y_i, Y_i + \Delta t] \text{에서 사망} \mid R_i) \simeq \sum_{j \in R_i} \exp(\mathbf{x}'_j \boldsymbol{\beta}) \lambda_0(y_j) \Delta t$$

이므로

$$\begin{aligned} \Pr(Y_i \text{ 시점에 환자 } i \text{가 사망} \mid Y_i \text{ 시점에 } R_i \text{에 속한 한 명이 사망}) \\ = \exp(\mathbf{x}'_i \boldsymbol{\beta}) / \sum_{j \in R_i} \exp(\mathbf{x}'_j \boldsymbol{\beta}) \end{aligned}$$

이 된다. 카스(Cox, 1972)는 이에 착안하여 $\boldsymbol{\beta}$ 의 추정을 위해 다음과 같은 우도함수를 제안하였다.

$$L(\boldsymbol{\beta}) = \prod_{i \in U} \left\{ \exp(\mathbf{x}'_i \boldsymbol{\beta}) / \sum_{j \in R_i} \exp(\mathbf{x}'_j \boldsymbol{\beta}) \right\}$$

이때 집합 U 는 중도절단되지 않은 환자들의 집합이다. 흔히 이 우도함수를 조건부 우도함수(conditional likelihood)라 부르는데 이는 조건부 확률을 이용하여 계산되었기 때문이다. 그런데, 이 우도함수는 엄밀한 의미에서 우도함수라 할 수 없다. 왜냐하면 반응변수에 해당되는 생존함수의 값 자체가 반영되지 않고 그 크기만 반영되었기 때문이다. 따라서 이 우도함수를 흔히 부분 우도함수(partial likelihood)라고도 한다. 카스는 비록 자료의 정보 중 일부분이 우도함수에 반영되지 않았지만 회귀계수의 추정에는 별 다른 문제가 없다고 주장하였다.

$\boldsymbol{\beta}$ 의 추정치 $\hat{\boldsymbol{\beta}}$ 을 구하기 위해 $\partial \log L(\boldsymbol{\beta}) / \partial \boldsymbol{\beta} = \mathbf{0}$ 을 계산한다. 그러나 이 식의 해는 뉴턴-랩슨 등의 반복법에 의해 구해야 한다. 이렇게 구한 $\hat{\boldsymbol{\beta}}$ 는 최우추정치의 근사적 정규성

$$\sqrt{n}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \xrightarrow{D} N_p(0, I^{-1}(\boldsymbol{\beta}))$$

이 만족됨을 증명할 수 있다. 여기서, $I^{-1}(\boldsymbol{\beta})$ 는 피셔정보행렬의 역행렬이다.

카스회귀모형에 대해서 많은 연구가 진행되었으며, 카스회귀모형 및 그 밖의 생존자료에 대한 회귀모형은 밀러(Miller, 1981), 카스와 옥스(Cox & Oakes, 1984), 칼브플라이쉬와 프렌티스(Kalbfleisch & Prentice, 1980) 등을 참고하기 바란다.

예제 12.4 (백혈병 환자 자료) 다음 자료는 42명의 백혈병 환자의 생존시간과 그에 영향을 미칠 것으로 생각되는 공변량들을 나타낸 것이다. 콕스회귀모형에 적합하고 그 결과를 해석하라.

x_1 : 성별 (1=남자, 0=여자)

x_2 : 백혈구수의 로그값 (WBC)

x_3 : 화학요법 (1=위약, 0=6-MP)

생존시간	성별	백혈구수	화학요법	생존시간	성별	백혈구수	화학요법
1	1	2.80	1	6	0	3.28	0
1	1	5.00	1	6	0	2.31	0
2	1	4.91	1	6	1	4.06	0
2	1	4.48	1	6+	0	3.20	0
3	1	4.01	1	7	0	4.43	0
4	1	2.42	1	9+	0	2.80	0
4	1	4.36	1	10	0	2.96	0
5	1	3.49	1	10+	0	2.70	0
5	0	3.97	1	11+	0	2.60	0
8	1	3.26	1	13	0	2.88	0
8	0	3.52	1	16	1	3.60	0
8	0	3.05	1	17+	0	2.16	0
8	0	2.32	1	19+	0	2.05	0
11	0	2.12	1	20+	1	2.01	0
11	0	3.49	1	22	1	2.32	0
12	0	1.50	1	23	1	2.57	0
12	0	3.06	1	25+	1	1.78	0
15	0	2.30	1	32+	1	2.20	0
17	0	2.95	1	32+	1	2.53	0
22	0	2.73	1	34+	1	1.47	0
23	1	1.97	1	35+	1	1.45	0

<풀이> 자료를 분석하기 위해 SAS의 “PHREG”(proportional hazard regression)를 이용하여 SAS output을 얻었다. 42명의 환자 중에서 12 명이 중도절단되어 중도절단율이 28.57%이다. 콕스 모형의 적합도는 우도비 검정의 χ^2 값이 43.752로서 $\chi^2(3)$ 과 비교한 결과 p-value가 .0001보다 작으므로 설명변수들의 설명력이 매우 뛰어남을 알 수 있다. SAS output의 마지막 부분에 각 설명변수에 대한 회귀계수 추정치와 표준오차가 주어져 있다. 여기서 Hazard Ratio(위험율 비)는 각 설명변수 값이 1단위 증가할 때 위험율의 증가값을 나타낸다. 예를 들어, WBC의 경우 Hazard Ratio가 4.921인데 이는 WBC 값이 1단위 증가하면 위험율이 약 5배 증가함을 의미한다. 또한,

$$\exp(\hat{\beta}_2) = \exp(1.59361) = 4.921$$

임을 쉽게 알 수 있다. 즉, 회귀계수 추정치가 0에 가까우면 Hazard Ratio는 1에 가까워진다. 회귀계수 추정치가 0에 가까우면 그에 해당되는 설명변수는 반응변수에 대한 설명력이 떨어지고 그로 인한 위험율의 변화도 거의 없게 된다.

□

The PHREG Procedure						
Number of Observations Read		42				
Number of Observations Used		42				
Summary of the Number of Event and Censored Values						
Total	Event	Censored	Percent Censored			
42	30	12	28.57			
Convergence Status						
Convergence criterion (GCONV=1E-8) satisfied.						
Model Fit Statistics						
Criterion	Without Covariates	With Covariates				
-2 LOG L	187.970	144.218				
AIC	187.970	150.218				
SBC	187.970	154.422				
Testing Global Null Hypothesis: BETA=0						
Test	Chi-Square	DF	Pr > ChiSq			
Likelihood Ratio	43.7520	3	<.0001			
Score	44.5708	3	<.0001			
Wald	31.7399	3	<.0001			
Analysis of Maximum Likelihood Estimates						
Variable	DF	Parameter Estimate	Standard Error	Chi-Square	Pr > ChiSq	Hazard Ratio
sex	1	0.26318	0.44943	0.3429	0.5582	1.301
WBC	1	1.59361	0.32999	23.3211	<.0001	4.921
trt	1	1.39087	0.45664	9.2772	0.0023	4.018

(그림 12.3) 백혈병환자 자료에 대한 SAS 출력결과물

12.4.3 생존함수의 추정

우리는 12.4.1절에서 $S(t; \mathbf{x}) = [S_0(t)]^{\exp(\mathbf{x}'\boldsymbol{\beta})}$, $S_0(t) = \exp\{-\int_0^t \lambda_0(u)du\}$ 임을 보였는데 생존함수 $S(t; \mathbf{x})$ 를 추정하기 위해 $\boldsymbol{\beta}$ 와 λ_0 또는 Λ_0 를 추정해야 하는데 $\boldsymbol{\beta}$ 는 앞에서 구한 $\hat{\boldsymbol{\beta}}$ 를 대입하면 되지만 λ_0 또는 Λ_0 를 추정해야 하는 문제가 남아 있다. 이를 위해 다음의 몇 가지 추정법을 소개한다.

우선 브레즐로우(Breslow, 1972)는

$$\hat{S}_0(t) = \prod_{i: y_i \leq t} \left(1 - \frac{\delta_i}{\sum_{j \in R_i} \exp(\mathbf{x}'_j \hat{\boldsymbol{\beta}})}\right)$$

을 제안하였는데 이는 카플란-마이어 추정치와 매우 흡사하다. 왜냐하면 위식에서 공변량들의 값이 모두 0이면 $\sum_{j \in R_i} 1 = n - i + 1$ 이므로 카플란-마이어 추정치와 같아짐을 알 수 있다. 그러나, 이 추정치는 $\hat{S}_0(t) \neq \exp\{-\hat{\Lambda}_0(t)\}$ 이며 $\hat{\Lambda}_0(t)$ 가 음수를 가질 수 있다는 약점이 있다.

이 약점을 보완하기 위해 치아티스(Tsiatis, 1978)는

$$\hat{S}_0(t) = \exp\{-\hat{\Lambda}_0(t)\}$$

를 제안하였으며 여기서

$$\hat{\Lambda}_0(t) = \sum_{i: y_i \leq t} \frac{\delta_i}{\sum_{j \in R_i} \exp(\mathbf{x}'_j \hat{\boldsymbol{\beta}})}$$

을 나타낸다. 이는 언제나 양수가 된다는 점이 보장되지만 공변량들의 값이 모두 0일 때 카플란-마이어 추정치가 되지 않는 점이 약점으로 지적되었다.

치아티스(Tsiatis, 1978)가 제안한 추정치 $\hat{\Lambda}_0(t)$ 는 계단함수이므로 링크(Link, 1979)는 이 계단함수를 선형으로 연결한 함수를 추정치로 제안하였다.

이상의 추정치들이 비례위험모형의 가정을 만족해야 하며 몇 가지의 단점을 가지고 있으므로 최근에는 국소선형회귀를 이용한 비모수적 방법들이 제안되었다. 스피어딕(Spierdijk, 2008)은 국소선형회귀를 이용하여 위험함수를 추정하였고 김 등(Kim, et al. 2010)은 국소선형회귀를 이용하되 카플란-마이어 추정치의 점프 크기를 가중치로 사용한 모형을 제안하였다.

12.5 선형회귀모형

중도절단자료인 경우에도 선형회귀모형

$$Y = \alpha + \mathbf{x}'\boldsymbol{\beta} + \epsilon$$

을 고려할 수 있다. 물론 완전자료와 같이 취급해서 기존의 결과를 그대로 사용할 수 없고 적절한 변환이 요구된다. 이 모형을 중도절단자료에 적합한 형태로 변환하는 방법에 따라 가속수명모형(AFT : accelerated failure time model), 밀러추정치(Miller estimator, 1976), 바클리-재임스 추정치(Buckley-James estimator, 1979)등이 있다. 가속수명모형은 로그-선형모형을 이용한 것이고 밀러 추정치와 바클리-재임스 추정치는 최소제곱추정치에 해당됨을 알게 될 것이다.

12.5.1 가속수명모형

T_0 는 생존시간을 나타내는 변수로서 위험율함수

$$\lambda_0(t) = f_0(t)/S_0(t)$$

를 가진다고 가정하자. 또한, 공변량 $\mathbf{x}$ 를 갖는 개인의 생존시간은 변량

$$T_{\mathbf{x}} = T_0 \exp(-\mathbf{x}'\boldsymbol{\beta})$$

와 같은 분포를 가진다고 가정하자. 여기서, 만약 $\mathbf{x}'\boldsymbol{\beta} > 0$ 이면 $T_{\mathbf{x}}$ 는 T_0 보다 작으므로 공변량 $\mathbf{x}$ 가 사망에 이르는 것을 가속화시킨다고 볼 수 있다. 따라서, 이런 가정하에 전개한 모형을 가속수명모형이라 부른다. 가속수명모형하에서

$$S(t : \mathbf{x}) = S_0(\exp(\mathbf{x}'\boldsymbol{\beta}))$$

임을 쉽게 알 수 있는데 이 사실로부터 $\mathbf{x}'\boldsymbol{\beta} < 0$ 이면 사망에 이르는 것을 가속화시킴을 알 수 있다. 또한, $T_{\mathbf{x}}$ 에 대한 위험율은

$$\begin{aligned} \lambda(t : \mathbf{x}) &= \frac{f(t : \mathbf{x})}{S(t : \mathbf{x})} \\ &= \frac{\exp(\mathbf{x}'\boldsymbol{\beta}) f_0(t \exp(\mathbf{x}'\boldsymbol{\beta}))}{S_0(t \exp(-\mathbf{x}'\boldsymbol{\beta}))} \\ &= \lambda_0(t \exp(\mathbf{x}'\boldsymbol{\beta})) \exp(\mathbf{x}'\boldsymbol{\beta}) \end{aligned}$$

이 된다. 한편, 카스회귀모형은 공변량 $\mathbf{x}$ 와 시간 t 에서의 위험율 함수 $\lambda(t : \mathbf{x})$ 와 공변량이 0인 경우의 기저위험율 함수 $\lambda_0(t)$ 와의 관계가

$$\lambda(t : \mathbf{x}) = \lambda_0(t) \exp(\mathbf{x}'\boldsymbol{\beta})$$

으로 가정하고 모형을 전개하였다. 가속수명모형과 카스회귀모형에서 위험함수가 각각 유사한 형태로 주어짐을 알 수 있다. 단지 차이점은 기저위험함수 $\lambda(\cdot)$ 에 공변량의 역할이 있고 없음의 차이이다. 이제

$$Y = \log T_{\mathbf{x}}$$

라 두면

$$E(Y) = E(\log T_0) + \mathbf{x}'\beta \equiv \alpha + \mathbf{x}'\beta$$

이 된다. 즉, 가속수명모형은 로그-선형모형이라 할 수 있다. 이는 생존시간이 언제나 양의 값을 갖는 확률변수이기 때문에 가능하다. 위의 식으로 부터

$$\begin{aligned} Y &= \alpha + \mathbf{x}'\beta + \epsilon \\ &\equiv E(\log T_0) + \mathbf{x}'\beta + \log T_0 - E(\log T_0) \end{aligned}$$

으로 표현할 수 있는데, 여기서 $\epsilon = \log T_0 - E(\log T_0)$ 이 되며 편의상 $\epsilon = \sigma W$ 라 둔다. 단, W 는 오차항으로서 특정 분포를 갖는 확률변수이다. 따라서,

$$Y \equiv \log T_{\mathbf{x}} = \alpha + \mathbf{x}'\beta + \sigma W$$

인데 W 의 분포에 따라 여러 가지 형태의 가속수명모형이 된다. 가속수명모형하에서 생존시간 $T \equiv T_{\mathbf{x}}$ 의 분포와 W 의 분포에 대한 관계를 살펴보기 위해 $\mu = \alpha + \mathbf{x}'\beta$ 라 두면

$$F_T(t) = P(\log T \leq \log t) = P\left(W \leq \frac{\log t - \mu}{\sigma}\right) = F_W\left(\frac{\log t - \mu}{\sigma}\right)$$

이므로

$$f_T(t) = \frac{1}{\sigma t} f_W\left(\frac{\log t - \mu}{\sigma}\right)$$

이 된다. 예를 들어, $W \sim N(0, 1)$ 이면 $\log T \sim N(\mu, \sigma^2)$, 즉 T 는 로그-정규분포가 된다. 또 다른 예로, W 의 분포가 극한값 분포, 즉 $f_W(w) = \exp(w - \exp(w))$ 이고 $\sigma = 1$ 일 때

$$\begin{aligned} f_T(t) &= \frac{1}{t} \exp(\log t - \mu - \exp(\log t - \mu)) \\ &= \lambda \exp(-\lambda t) \end{aligned}$$

인데 여기서, $\lambda \equiv \exp(-\mu)$ 이다. 즉, W 가 극한값분포이면 T 는 지수분포가 된다.

12.5.2 밀러 추정치

밀러 추정치를 설명하기 위해 편의상 공변량이 한 개인 단순선형회귀를 생각한다. 즉,

$$Y_i = \alpha + \beta X_i + \epsilon_i, \quad i = 1, 2, \dots, n$$

이고 여기서 $Y_i = \min(T_i, C_i)$ 는 우리가 관측하는 생존시간이다. 만약 중도절단된 관측치가 전혀 없다면 (즉, $T_i = Y_i, i = 1, 2, \dots, n$) 회귀계수 α 와 β 에 대한 최소제곱추정치는

$$\frac{1}{n} \sum_{i=1}^n \epsilon_i^2 = \frac{1}{n} \sum_{i=1}^n (y_i - \alpha - \beta x_i)^2$$

을 최소화하는 값으로 주어진다. 이제, $\epsilon_i = y_i - \alpha - \beta x_i, i = 1, 2, \dots, n$ 에 대한 경험분포 함수를

$$F_n(z) = \frac{1}{n} \sum_{i=1}^n I(\epsilon_i \leq z)$$

이라 두면

$$\frac{1}{n} \sum_{i=1}^n (y_i - \alpha - \beta x_i)^2 = \int z^2 dF_n(z)$$

임을 알 수 있다.

실제로 생존분석에서 우리가 관찰하는 관측치 $Y_i, i = 1, 2, \dots, n$ 는 중도절단된 관측치들이다. 만약 α 와 β 를 안다면 $(\epsilon_1, \delta_1), \dots, (\epsilon_n, \delta_n)$ 를 이용하여 분포함수 F 에 대한 카플란-마이어 추정치를 구할 수 있으며 이를 $\hat{F}$ 이라 하자. 밀러는 회귀계수에 대한 추정치로 다음 식을 최소화하는 방법을 제안하였다.

$$\int_{-\infty}^{\infty} z^2 d\hat{F}(z) = \sum_{i=1}^n \hat{w}_i(\beta) (y_i - \alpha - \beta x_i)^2$$

단, $\hat{w}_1(\beta), \dots, \hat{w}_n(\beta)$ 는 카플란-마이어 추정치에서 나타나는 각 관측치에서의 점프 크기(jump size)를 나타낸다. 즉, 중도절단이 없는 완전자료에서는 경험분포의 가중치 $1/n$ 사용하였으나 중도절단이 있는 경우에는 카플란-마이어 추정치의 점프 크기인 $\hat{w}_i(\beta)$ 을 가중치로 사용하는 것이다. 여기서 점프 크기인 $\hat{w}_i(\beta)$ 가 α 와는 무관하고 β 에만 의존하는 함수로 표현하였는데, 그 이유는 생존시간 T_i 에 상수인 α 만큼 더해지면 카플란-마이어 추정치는 α 만큼 이동할 뿐 점프 크기에는 변함이 없기 때문이다. 또한, $\delta_i = 0$ 이면

$\hat{w}_i(\beta) = 0$ 이 됨을 알 수 있고, 가장 큰 관측치가 중도절단되지 않았다면 $\sum_{i=1}^n \hat{w}_i(\beta) = 1$ 이 된다. 흔히 가장 큰 관측치는 중도절단 되더라도 중도절단 되지 않았다고 가정하고 이론을 전개하는데 이는 바로 $\sum_{i=1}^n \hat{w}_i(\beta) = 1$ 이 되게 하기 위해서다. 이제 $\hat{\alpha}$ 과 $\hat{\beta}$ 을 구하기 위해 먼저 α 에 대해 편미분하면

$$\hat{\alpha} = \sum_{i=1}^n \hat{w}_i(\beta) y_i - \beta \sum_{i=1}^n \hat{w}_i(\beta) x_i$$

이 되고 이를 원래의 식에 대입하면 β 만의 함수인

$$f(\beta) = \sum_{i=1}^n \hat{w}_i(\beta) (y_i - \hat{\alpha} - \beta x_i)^2$$

이 된다. 이 식을 β 에 대해 최소화시키고 이를 이용하여 α 의 값을 수정하는 과정을 반복한다. 실제로 $f(\beta)$ 는 연속함수가 아니므로 최소값을 찾는 것이 쉽지 않기 때문에 엄청난 계산량을 요구할 뿐더러 반복이 계속되더라도 수렴한다는 보장이 없는 것이 큰 단점으로 지적되었다. 그러나, 카플란-마이ер 추정치의 점프 크기(jump size)를 이용한 밀러 추정치의 아이디어는 여러 분야에서 널리 사용되고 있다.

12.5.3 바클리-재임스 추정치

만약 생존시간의 참 값인 T_i , $i = 1, 2, \dots, n$ 를 관측할 수 있다면 다음과 같은 모형을 세울 수 있다.

$$E(T_i) = \alpha + \beta x_i$$

그러나, T_i , $i = 1, 2, \dots, n$ 를 관측할 수 없고 대신 $Y_i = \min(T_i, C_i)$, $i = 1, 2, \dots, n$ 를 관측할 수 있지만 문제는

$$E(Y_i) \neq \alpha + \beta x_i$$

이다. 바클리와 재임스(Buckley & James, 1979)는 $\alpha + \beta x_i$ 에 대한 불편추정치로

$$Y_i^* = Y_i \delta_i + E(T_i | T_i > Y_i)(1 - \delta_i)$$

을 고려하였으며 불편성은 다음과 같이 증명할 수 있다.

$$\begin{aligned}
 E(Y_i^*) &= \int_0^\infty u(1 - G_i(u))dF_i(u) + \int_0^\infty \left[\frac{s dF_i(s)}{1 - F_i(u)} \right] (1 - F_i(u))dG_i(u) \\
 &= \int_0^\infty u(1 - G_i(u))dF_i(u) + \int_0^\infty \left[\int_0^s dG_i(u) \right] s dF_i(s) \\
 &= \int_0^\infty u(1 - G_i(u))dF_i(u) + \int_0^\infty G_i(s)s dF_i(s) \\
 &= \int_0^\infty u dF_i(u) \\
 &= \alpha + \beta x_i
 \end{aligned}$$

따라서 $y_i^*, \dots, y_n^*$ 을 관측할 수 있다면 회귀계수를 다음과 같이 추정할 수 있을 것이다.

$$\begin{aligned}
 \hat{\alpha} &= \bar{y}^* - \hat{\beta}\bar{x} \\
 \hat{\beta} &= \frac{\sum_{i=1}^n (x_i - \bar{x})y_i^*}{\sum_{i=1}^n (x_i - \bar{x})^2}
 \end{aligned} \tag{12.1}$$

하지만 $y_i^*, \dots, y_n^*$ 을 관측할 수 없으므로 이를 다시 추정해야 한다. 이제

$$\hat{E}(T_i | T_i > y_i) = \hat{\beta}x_i + \frac{\sum_{\hat{z}_k > \hat{z}_i} \hat{w}_k(\hat{\beta})\hat{z}_k}{1 - \hat{F}(\hat{z}_i)}$$

을 추정치로 사용하는데 여기서, $\hat{z}_i = y_i - \hat{\beta}x_i$ 이고, $\hat{F}$ 는 $(\hat{z}_1, \delta_1), \dots, (\hat{z}_n, \delta_n)$ 을 이용한 카플란-마이어 추정치이고 이 추정치의 점프 크기가 $\hat{w}_1(\hat{\beta}), \dots, \hat{w}_n(\hat{\beta})$ 이다. 최종적으로 y_i^* 의 추정치를

$$\hat{y}_i^* = y_i\delta_i + \left[\hat{\beta}x_i + \frac{\sum_{\hat{z}_k > \hat{z}_i} \hat{w}_k(\hat{\beta})\hat{z}_k}{1 - \hat{F}(\hat{z}_i)} \right] (1 - \delta_i) \tag{12.2}$$

으로 사용하는데 이 식은 $\hat{\beta}$ 을 포함하고 있으므로 식 (12.1)와 식 (12.2)이 수렴할 때까지 서로 반복되어야 최종적인 회귀계수를 추정할 수 있다. 이렇게 추정된 회귀계수를 바클

리-재임스 추정치라 부른다. 한편, 추정치의 분산에 대한 추정치로

$$\hat{Var}(\hat{\beta}) = \frac{\hat{\sigma}_u^2}{\sum_{i:\delta_i=1} (x_i - \bar{x}_u)^2}$$

을 제안하였는데 여기서 $n_u = \sum \delta_i$, $\bar{x}_u = \frac{1}{n_u} \sum_{i:\delta_i=1} x_i$ 이고

$$\hat{\sigma}_u^2 = \frac{1}{n_u - 2} \sum_{i:\delta_i=1} \{y_i - \bar{y}_u - \hat{\beta}(x_i - \bar{x}_u)\}^2$$

이다.

한편, 카울 등(Koul, Suarla & Van Ryzin, 1979)은

$$Y_i^* = Y_i \delta_i / (1 - G(Y_i))$$

로 두고 $E(Y_i^*) = E(T_i)$ (연습문제 12.4)을 이용하여 선형모형을 추정하였다. 이 경우에도 Y_i^* 는 G 가 알려져 있지 않으므로 관측할 수 없다. 따라서, 카울 등은

$$\hat{Y}_i^* = Y_i \delta_i / (1 - \hat{G}(Y_i))$$

를 제안하였으며 여기서 $\hat{G}$ 은 G 의 카플란-마이어 추정치이다. G 의 카플란-마이어 추정치는 F 에 대한 카플란-마이어 추정치를 구하는 방법을 정반대로 사용하면 된다. 즉, $Z_i = \max(T_i, C_i)$ 라 두면 $(Z_i, 1 - \delta_i)$, $i = 1, \dots, n$ 을 이용하여 카플란-마이어 추정치를 구하면 $\hat{G}$ 이 된다.

연습문제 (12)

[이론 문제]

12.1 생존시간변수 T 와 중도절단변수 C 의 분포함수를 각각 F 와 G 라고 하자. 확률변수 $Y = \min(T, C)$ 의 분포함수를 H 라고 하면 $H = 1 - (1 - F)(1 - G)$ 임을 증명하라. 단, T 와 C 는 독립이다.

12.2 중도절단율(censoring percentage)은 $P(T > C)$ 로 정의한다. 단, T 는 생존시간변수, C 는 중도절단변수를 나타낸다. $T \sim \text{Exp}(1)$, $C \sim \text{Exp}(\lambda)$ 일 때 10%, 30%, 50%중

도절단율에 해당되는 λ 는 각각 $1/9, 3/7, 1$ 임을 보여라.

12.3 우측중도절단하에서 생존시간이 와이불분포를 따른다고 하자.

- (1) 로그우도함수를 유도하라.
- (2) 모수에 대한 최우추정치를 구하라.
- (3) 피서정보행렬을 구하라.

12.4 생존시간을 나타내는 임의표본 $T_1, \dots, T_n$ 은 분포함수 F 를 따르고, 중도절단시간을 나타내는 임의표본 $C_1, \dots, C_n$ 은 분포함수 G 를 따르며, T 와 C 는 서로 독립이라 하자. 또한, $Y_i = \min(T_i, C_i)$, $\delta_i = I(T_i \leq C_i)$, $i = 1, \dots, n$ 라 하자. 이때

$$E[\delta_i Y_i / (1 - G(Y_i))] = E(T_i)$$

임을 증명하라.

[응용 문제]

12.1 다음 자료는 처리군과 대조군의 생존시간(단위: 주)을 나타낸 것이다.

처리군	9	13	13+	18	23	28+	31	34	45+	48	161+	
대조군	5	5	8	8	12	16+	23	27	30	33	43	45

- (1) 각 그룹에 대해 카플란-마이어 추정치를 구하라.
- (2) $t = 15$ 일 때의 생존함수값을 추정하고, 그린우드 공식을 이용하여 $t = 15$ 일 때의 생존함수에 대한 95% 신뢰구간을 구하라.

12.2 다음 자료는 40명의 폐암환자들의 생존시간을 조사한 것이다. 40명의 환자 중 21명은 처리 1(standard)에, 나머지 19명은 2(test)에 할당되었으며, 생존시간에 영향을 미칠 것으로 생각되는 공변량들은 다음과 같다. 이를 이용하여 콕스회귀모형에 적합하고 그 결과를 해석하라.

x_1 : 진단시의 환자상태(Performance Status : 0 ~ 100점)

x_2 : 환자의 나이 (단위: 년)

x_3 : 진단 후 연구참여시까지의 시간 (단위: 월)

x_4 : 종양의 유형 (squamous=1, small=2, adeno=3, large=4)

처리군 = 1					처리군 = 2				
생존시간	x_1	x_2	x_3	x_4	생존시간	x_1	x_2	x_3	x_4
411	70	64	5	1	999	90	54	12	1
126	60	63	9	1	231+	50	52	8	1
118	70	65	11	1	991	70	50	7	1
82	40	69	10	1	1	20	65	21	1
8	40	63	58	1	201	80	52	28	1
25+	70	48	9	1	44	60	70	13	1
11	70	48	11	1	15	50	40	13	1
54	80	63	4	2	103+	70	36	22	2
153	60	63	14	2	2	40	44	36	2
16	30	53	4	2	20	30	54	9	2
56	80	43	12	2	51	30	59	87	2
21	40	55	2	2	18	40	69	5	3
287	60	66	25	2	90	60	50	22	3
10	40	67	23	2	84	80	62	4	3
8	20	61	19	3	164	70	68	15	4
12	50	63	4	3	19	30	39	4	4
177	50	66	16	4	43	60	49	11	4
12	40	68	12	4	340	80	64	10	4
200	80	41	12	4	231	70	67	18	4
250	70	53	8	4					
100	60	37	13	4					

(출처 : Prentice, 1973)

부록 A

행렬이론

- A.1 기본적 이론
- A.2 역행렬
- A.3 분할된 행렬
- A.4 고유치와 고유벡터
- A.5 이차형식과 양정치행렬
- A.6 정사영과 행렬의 분해
- A.7 행렬의 기타 논제

A.1 기본적 이론

A.1.1 여러 형태의 행렬

$m \times n$ 행렬 A 의 ij 번째 원소를 a_{ij} 라고 하면 행렬 A 는

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

으로 표현되고, 간단히 $A = (a_{ij})$ 로 쓰기도 한다. A 의 i 번째 행(row)인 $(a_{i1} \ a_{i2} \ \cdots \ a_{in})$ 을 i 번째 행벡터(row vector)라 하고 j 번째 열(column)인

$$\begin{bmatrix} a_{1j} \\ a_{2j} \\ \vdots \\ a_{mj} \end{bmatrix}$$

를 j 번째 열벡터(column vector)라 한다. $m = n$ 일 때를 정방행렬(square matrix)이라 부르며, 정방행렬 중에서 대각원소 a_{ii} , $i = 1, \dots, n$ 를 제외한 비대각원소 a_{ij} , $i \neq j$, 들이 전부 0일 때를 대각행렬(diagonal matrix)이라 하고 흔히

$$A = \text{diag}(a_1, \dots, a_n)$$

으로 표시한다. 대각행렬 중에서 특히 $a_{ii} = 1$, $i = 1, \dots, n$ 인 행렬을 단위행렬(unit matrix) 또는 항등행렬(identity matrix)이라 하며 흔히 I 또는 I_n 으로 나타낸다. A 의 ij 번째 원소를 ji 번째로 바꾼 행렬을 A 의 전치(transpose)라 부르며 A' 으로 나타낸다. 그리고 $m \times n$ 행렬 A 의 전치행렬은 $n \times m$ 행렬이 된다. 만약 B 가 $n \times p$ 행렬일 때 두 행렬의 곱 AB 의 전치는 $B'A'$ 가 됨은 명백하다. 또한, 정방행렬 A 가

$$A^2 = A$$

를 만족하면 A 를 멱등행렬(idempotent matrix)이라 부른다.

A.1.2 행렬의 트레이스

정방행렬 A 의 대각원소의 합을 행렬 A 의 트레이스(trace)라 부르고, 흔히 $\text{tr}(A)$ 로 표현한다. 즉,

$$\text{tr}(A) = \sum a_{ii}$$

으로 정의된다. 트레이스에 관련된 정리들은 다음과 같다.

$$\begin{aligned}\text{tr}(A \pm B) &= \text{tr}(A) \pm \text{tr}(B) \\ \text{tr}(kA) &= k\text{tr}(A), \quad k \text{는 상수} \\ \text{tr}(AB) &= \text{tr}(BA)\end{aligned}\tag{A.1}$$

단, AB 와 BA 가 정의 될 경우라 가정한다.

A.1.3 행렬식

행렬식은 정방행렬에 대해 정의되며 $\det(A)$ 또는 $|A|$ 로 표시한다. $n \times n$ 행렬 $A = (a_{ij})$ 의 행렬식은 임의의 i ($i = 1, \dots, n$)에 대해

$$\det(A) = \sum_{j=1}^n a_{ij} c_{ij}$$

으로 정의되는데 여기서

$$c_{ij} = (-1)^{i+j} d_{ij}$$

는 a_{ij} 의 여인수(cofactor)라 하고, d_{ij} 는 행렬 A 의 i 번째 행과 j 번째 열을 제거시킨 $(n-1) \times (n-1)$ 행렬의 행렬식이다. $n=1$ 일 경우는 $|A| = a_{11}$, 즉 원소 그 자체의 값이고, $n=2$ 일 경우는

$$\begin{aligned}|A| &= \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix} = a_{11}a_{22} - a_{12}a_{21}, \quad i=1 \text{을 택했을 때} \\ &= -a_{21}a_{12} + a_{22}a_{11}, \quad i=2 \text{을 택했을 때}\end{aligned}$$

로 주어진다. 즉, i 를 1부터 n 까지 어떤 값을 택하더라도 행렬식은 같게되므로 계산이 편리하게되는 i 를 택하는 것이 바람직하다. $n = 3$ 인 경우는

$$\begin{aligned}
 |A| &= \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = a_{11}c_{11} + a_{12}c_{12} + a_{13}c_{13} \\
 &= a_{11} \begin{vmatrix} a_{22} & a_{23} \\ a_{32} & a_{33} \end{vmatrix} - a_{12} \begin{vmatrix} a_{21} & a_{23} \\ a_{31} & a_{33} \end{vmatrix} + a_{13} \begin{vmatrix} a_{21} & a_{22} \\ a_{31} & a_{32} \end{vmatrix} \\
 &= a_{11}a_{22}a_{33} - a_{11}a_{32}a_{23} - a_{12}a_{21}a_{33} + a_{12}a_{31}a_{23} \\
 &\quad + a_{13}a_{21}a_{32} - a_{13}a_{31}a_{22}
 \end{aligned}$$

으로 정의할 수 있다. 행렬식에 대하여 다음과 같은 성질들이 성립함을 쉽게 보일 수 있다.

$$\begin{aligned}
 |AB| &= |BA| = |A||B|, \quad A \text{와 } B \text{는 } n \times n \text{ 정방행렬} \\
 |A| &= |A'| \\
 |kA| &= k^n |A|, \quad k \text{는 상수}
 \end{aligned} \tag{A.2}$$

또한, $|A| \neq 0$ 인 정방행렬 A 를 정칙행렬(nonsingular matrix), $|A| = 0$ 인 경우를 비정칙행렬(singular matrix)라 한다.

A.2 역행렬

A.2.1 선형독립과 선형종속

n 차원 벡터 $v_1, \dots, v_k$ 와 상수 $c_1, \dots, c_k$ 의 선형결합(linear combination)이 0 일 때, 즉

$$c_1 v_1 + \dots + c_k v_k = 0$$

을 만족하는 c_i 들 중에서 적어도 하나의 c_i 가 0 이 아니면 $v_1, \dots, v_k$ 는 선형종속(linearly dependent)이라 하고, 위의 식을 만족하는 c_i 가 전부 0 이 되어야 하면 $v_1, \dots, v_k$ 는 선형독립(linearly independent)이라 한다.

예를 들어, 두 벡터 $(1, 1)$ 과 $(-3, 2)$ 는 선형독립이다. 왜냐하면

$$c_1 \begin{pmatrix} 1 \\ 1 \end{pmatrix} + c_2 \begin{pmatrix} -3 \\ 2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

에서 $c_1 - 3c_2 = 0$, $c_1 + 2c_2 = 0$ 을 만족하는 c_1, c_2 는 $c_1 = 0, c_2 = 0$ 이기 때문이다.

$v_1, \dots, v_k$ 가 선형독립이 아니라면 $c_1 v_1 + \dots + c_k v_k = \mathbf{0}$ 에서 0 아닌 c_i 가 존재한다. 만약 $c_j \neq 0$ 이라고 하면

$$v_j = -\frac{1}{c_j}(c_1 v_1 + \dots + c_{j-1} v_{j-1} + c_{j+1} v_{j+1} + \dots + c_k v_k)$$

이 된다. 즉, $v_1, \dots, v_k$ 가 선형종속을 이루면 이들 중 어떤 벡터가 다른 벡터들의 선형결합으로 표현됨을 알 수 있다.

A.2.2 행렬의 계수

$m \times n$ 행렬 A 는 m 개의 행벡터와 n 개의 열벡터로 구성되어있다. m 개의 행벡터들 중에서 선형독립을 이루는 벡터들의 최대갯수를 m^* 라 하고, n 개의 열벡터들 중에서 선형독립을 이루는 벡터들의 최대갯수를 n^* 라 하면, 항상 $m^* = n^*$ 이 되며 이를 행렬 A 의 계수(rank)라 하고 흔히 $r(A)$ 로 표시한다. 따라서 $r(A)$ 는 언제나 m 과 n 의 최소값보다는 작거나 같다.

다음과 같은 5×4 행렬 A 의 계수를 구해보자.

$$A = \begin{bmatrix} 1 & 2 & 0 & 1 \\ 1 & -1 & 3 & 2 \\ 3 & 0 & 6 & 5 \\ 2 & 1 & 3 & 3 \\ 6 & 0 & 12 & 10 \end{bmatrix}$$

우선 $r(A) \leq 4$ 이어야 한다. 행벡터를 중심으로 선형독립의 여부를 살펴보면 1행과 2행은 선형독립이고, 3, 4, 5행은 각각 1행과 2행의 선형결합으로 표현된다. 예를 들어, 3행은 $(1, 2, 0, 1) + 2(1, -1, 3, 2)$ 으로 표현되고, 4행은 1행과 2행의 합이다. 따라서 $r(A) = 2$ 임을 알 수 있다.

계수에 관련된 성질들을 요약하면 다음과 같다.

$$(I) \quad r(AB) \leq \min(r(A), r(B))$$

즉, 두 행렬의 곱에 대한 계수는 각 행렬의 계수의 최소값보다는 작거나 같다.

$$(II) \quad n \times n \text{ 행렬 } A \text{가 정칙행렬이면 } r(A) = n \text{이고, 비정칙행렬이면 } r(A) < n \text{이다.}$$

(III) 주어진 행렬에 정칙행렬을 곱해도 계수는 변하지 않는다.

$$(IV) \quad AGA = A \text{이면 } r(A) = r(GA) \text{이다.}$$

(V) $r(A:B) \leq r(A) + r(B)$ 이다. 단, A 는 $m \times n_1$ 이고 B 는 $m \times n_2$ 일 때 $A:B$ 는 A 행렬의 오른쪽에 B 행렬을 덧붙인 것으로 $m \times (n_1 + n_2)$ 인 추가행렬(augmented matrix)을 의미한다. 예를 들어,

$$A = \begin{pmatrix} 1 & 3 & 5 \\ 2 & 4 & 6 \end{pmatrix}, \quad B = \begin{pmatrix} 7 & 9 \\ 8 & 10 \end{pmatrix}$$

일 때

$$A:B = \begin{pmatrix} 1 & 3 & 5 & 7 & 9 \\ 2 & 4 & 6 & 8 & 10 \end{pmatrix}$$

$$(VI) \quad r(A+B) \leq r(A:B) \leq r(A) + r(B)$$

$$(VII) \quad n \times n \text{ 행렬 } A \text{에 대하여 } r(AB) \geq r(A) + r(B) - n \text{이 성립한다.}$$

$$(VIII) \quad n \times n \text{ 멱등행렬 } A \text{에 대하여 } r(I - A) = n - r(A) \text{이다.}$$

$$(IX) \quad r(A) = r(A') = r(A'A) = r(AA')$$

A.2.3 역행렬

방정식 $ax = b$ 에서 x 에 대한 해를 구하기 위해 양변에 a 의 역수인 $1/a$ 을 곱하여 x 를 구한다. 즉,

$$ax = b \Rightarrow \frac{1}{a} ax = \frac{1}{a} b \Rightarrow x = \frac{b}{a}$$

a ≠ 0

그런데 이러한 계산을 하기 위해서는 반드시 $a \neq 0$ 이어야 한다. 왜냐하면 a 의 역수 $1/a$ 이 존재하기 위해서는 반드시 $a \neq 0$ 이어야 하기 때문이다.

이제 미지수가 n 개인 n 차 연립방정식을 생각해보자.

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n &= b_2 \\ \vdots & \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nn}x_n &= b_n \end{aligned}$$

$$\Rightarrow A \underline{x} = \underline{b}$$

여기서 $A = (a_{ij})$, $i = 1, \dots, n$; $j = 1, \dots, n$ 를 $n \times n$ 정방행렬, $x = (x_1 \ x_2 \ \cdots \ x_n)'$, $b = (b_1 \ b_2 \ \cdots \ b_n)'$ 라 두면 위의 방정식은 $Ax = b$ 로 표현된다. 이때 A^{-1} 가 $AA^{-1} = A^{-1}A = I$ 를 만족할 때 A 의 역행렬(inverse matrix)이라 부른다. a 의 역수가 존재하기 위해 $a \neq 0$ 이어야 되는 것처럼 A 의 역행렬이 존재하기 위해 $|A| \neq 0$ 이어야 한다. 즉, A 는 정칙행렬이어야 하고 따라서 계수가 n 인 행렬이어야 한다. 따라서 A 가 정칙행렬이면 위의 연립방정식의 해는 $A^{-1}Ax = A^{-1}b$ 로부터 $x = A^{-1}b$ 가 된다.

구체적으로 A^{-1} 를 계산하기 위한 식은

$$A^{-1} = \frac{1}{|A|} \begin{bmatrix} c_{11} & c_{21} & \cdots & c_{n1} \\ \vdots & \vdots & & \vdots \\ c_{1n} & c_{2n} & \cdots & c_{nn} \end{bmatrix}$$

← Transpose

인데 c_{ij} 는 A.1.3에 주어져 있는 a_{ij} 의 여인수를 나타낸다.

A 가 정방행렬이고 정칙행렬일 때 A^{-1} 가 존재하고 A^{-1} 는 다음과 같은 성질을 가진다.

- (I) A^{-1} 는 유일하다.
- (II) A^{-1} 는 정칙행렬이다.
- (III) $(A')^{-1} = (A^{-1})'$
- (IV) $(AB)^{-1} = B^{-1}A^{-1}$

정방행렬 A 가 $A'A = AA' = I$ 를 만족하면 A 는 직교행렬(orthogonal matrix)이라 불리우고 $A^{-1} = A'$ 를 만족한다. A 가 직교행렬이면 다음의 성질들이 만족된다.

- (I) $\text{tr}(A'BA) = \text{tr}(B)$
- (II) $|A'BA| = |B|$
- (III) $|A| = \pm 1$