

Regression Analysis

제 2 판

회귀분석

김충락 · 강근석 지음



최소제곱의 해

β_1



教友社

Regression Analysis

제 2 판

회귀분석

김충락 · 강근석 지음



教友社

제2판 서문

이 책이 출간된지 벌써 10년의 세월이 지났다. 빠른 시일내에 개정판을 내겠다고 약속했는데 저자의 게으름으로 이제서야 제2판을 출간하게 되었다. 제2판을 출간하는 목적은 크게 두 가지다. 첫째, 초판에 편집상의 오타와 내용의 오류 및 미숙한 점이 너무 많았다. 이는 개정판을 통해 어느 정도 해소되었으나 결코 만족할 만한 수준은 아니었다. 둘째, 지난 10년간 새로운 이론이 많이 소개되었는데 그 중에서도 학부 수준의 회귀모형과 관련된 부분도 간과할 수 없을 정도였다. 물론 제2판에서 추가된 내용중에는 오래전에 소개된 것들이 대부분이지만 보다 체계적인 논리 전개를 위해 꼭 필요한 부분들이 많이 추가되었다.

제2판에서 추가되고 변경된 내용은 다음과 같다. 1장에 테일러 급수전개, 델타법, 뉴턴-랩슨 반복등이 추가되었고, 특히 가설검정의 새로운 개념인 위발견율(false discovery rate)이 다중검정과 함께 소개되었다. 3장에 설명변수를 추가한 모형이 소개되었고 이를 4장의 평균변동 이상치 모형에 적용한 내용이 추가되었다. 5장에서 교차확인법, 예측오차의 개념, AIC, 젠센 부등식, 칼백-라이블러 거리 등의 개념이 새롭게 추가되었다. 6장에서 편의추정 부분을 따로 독립시켜 7장으로 개편하면서 LASSO, 슈타인 축소 추정치, 부분최소제곱법 등을 소개하였다. 7, 8, 9장을 묶어서 8, 9장으로 개편하였고 11장의 비모수회귀는 대폭 수정되었다. 국소선형회귀를 보다 자세히 소개하였고 회귀 스플라인과 B-스플라인이 추가 되었으며 평활 스플라인도 보완되었다. 아울러, 웨이블릿도 추가되었다. 마지막으로 12장에서 중도절단자료에서의 회귀모형을 자세히 소개하였다. 가속수명모형, 밀러 추정치, 바클리-재임스 추정치 등이 새롭게 소개되었고 각스회귀모형도 많이 보완되었다.

그 동안 여러 교수님들로 부터 학부에 사용하기에 좀 어려운 편이라는 지적을 받았는데 오랫동안 내는 개정판이라 욕심이 생기다 보니 추가된 내용에 어려운 부분이 많아 더 비판을 받게 될 것 같다. 물론 학교에 따라 정도의 차이는 있겠지만 2학기 동안 사용하기에 내용이 좀 많거나 어렵게 느껴지는 부분이 제법 있을 것 같다. 하지만 일부 내용을 건너뛰면 웬만큼 소화할 수 있으리라 믿는다. 회귀분석 과목이 한 학기만 편성되어 있는 학교에서는 부록의 행렬이론과 제1부(1장 - 6장)를 15주 동안 강의하면 좋을 것이고, 두 학기가 편성되어 있는 학교에서는 전체 내용을 30주 동안 강의하기 알맞다고 생각한다. 아울러 본 교재는 쉬운 부분을 건너뛰는 전제하에 석사과정에서 사용해도 무방하리라 본다. 또한, 타 과목의 부교재로도 사용할 수 있을 것이며 이 분야를 잘 모르는 연구자들의 참고도서

ii 머리말

로도 가치가 있다고 본다. 초판에서 발생되었던 편집상의 오타를 원천적으로 없애기 위해 제2판에서는 저자와 대학원생들이 직접 텍(TeX)으로 타이핑했으며 그림도 되도록 R을 이용하려고 노력하였다. 따라서, 모든 편집상의 오류는 출판사가 아닌 저자의 책임일 수 밖에 없다.

그간 이 책의 초판으로 강의하면서 여러 충고를 아끼지 않으신 교수님들께 매우 감사드리고 특히 여러 부분의 오류를 수 차례 지적해 주신 서울대학교 김우철 교수님께 깊이 감사드립니다. 또한, 텍 작업을 위시하여 모든 편집을 꼼꼼히 살펴준 부산대학교 통계학과 대학원 박사과정에 재학중인 김진미에게 무한한 감사를 표합니다. 아울러 텍 작업을 도와준 황현미, 오타를 검토해 준 양호진, 이정수의 노고도 치하드리며 물심양면으로 도와주신 교우사 오판근 사장님께 감사드립니다.

다른 사람이 쓴 책을 비판하기는 쉬워도 제대로 된 책을 쓰기란 매우 어렵다는 점을 자꾸 느낍니다. 제3판은 좀 더 제대로 된 책이 될 수 있도록 여러 교수님들과 학생들의 거침 없는 비판을 기꺼이 수용할 것을 약속드립니다. 마지막으로 사랑하는 가족들에게 무한한 사랑을 전합니다.

2010년 1월

저자 드림

제1판 서문

대학교재용 책을 준비하는 사람에게 던져지는 질문은 크게 두 가지라고 한다. "왜 쓰는가?"와 "기존의 책과 어떻게 다른가?"이다. 첫 번째 질문의 답은 대부분 "기존의 책이 마음에 들지 않아서"이지만 두 번째 질문의 답은 각양 각색이다.

현대과학에서 가장 많이 사용되는 통계분석방법으로 회귀분석을 생각할 수 있다. 1900년 초에 도입되었다고 할 수 있는 이 분석방법은 1960년도에 들어와 컴퓨터의 급속한 발달에 힘입어 그 적용 영역을 끊임없이 확장하여 현재는 사회과학, 공학, 의학 등 다양한 학문 분야에서 사용되고 있다. 또한 통계학 내에서도 단순히 여러 분석방법들 중의 하나로 그치지 않고 응용범위를 넓혀 이제 광범위한 의미의 회귀분석으로 자리 매김 되어 상관분석, 선형모형, 실험계획 등을 포함하며, 품질관리, 비모수분석 등 다른 통계분석방법을 위한 중요한 도구의 역할을 하고 있다. 이러한 회귀분석의 중요성으로 대부분의 통계학과에서는 두 학기에 걸쳐 회귀분석을 강의하고 있으며, 국내외적으로 많은 교재들이 개발되어 사용되고 있다. 기존의 좋은 교재들이 있는 상황에서 이 책을 발간하게 된 이유는 회귀분석과 관련된 최신 분석기법들을 소개하고, 이를 학부과정에서부터 사용할 필요성을 강조함으로써 통계학에서의 회귀분석의 역할을 한 단계 더 높이자는 것이다. 이를테면, 등분산성, 정규성, 선형성 등의 정형화된 가정 하에서 하던 분석에서 이제는 이 가정들이 만족되지 않는 경우에 대한 분석의 중요성이 대두되고, 따라서 다양한 형태의 회귀모형에 대한 분석방법들이 개발되어 사용 중에 있다. 대표적으로 최근에 회귀분석과 관련된 문제라 할 수 있는 일반화선형모형도 학부의 범주형자료분석에서 소개되어 사용되고 있다. 그러나, 국내외적으로 이렇게 다양한 내용을 한 권의 책에 체계적으로 소개하고 있는 교재가 없다는 것이다. 이에 저자들은 기존의 교재들이 주로 다루고 있는 고전적 회귀분석의 내용에 회귀진단, 일반화선형모형, 비모수회귀모형 등의 주제를 첨가할 필요성을 느껴왔고, 이를 위하여 본 교재를 개발하게 되었다.

이 책은 통계학 전공자를 위한 것이다. 회귀분석과목을 위한 강의교재로 뿐만 아니라 대부분의 전공자들을 위한 참고서적으로서의 역할을 할 수도 있을 것이다. 강의에 사용할 경우 두 학기 강의에 적당하도록 제1부 '고전적 선형회귀모형'과 제2부 '회귀모형의 확장'으로 나누어 두었다. 제1부에서는 회귀분석에 대한 전반적인 내용을 다루고 있다. 단순회귀분석과 중회귀분석에서 사용되는 통계적 방법들은 거의 동일하다고 할 수 있으나, 회귀분

석을 처음 접하는 독자들을 위하여 따로 분리하여 소개하였다. 단지 빠른 전개를 위하여 몇 가지 분석방법들은 중회귀분석에서 소개되는데, 예를 들면, 적합결여검정과 공동신뢰영역 등의 경우이다. 이와 같이 중회귀분석에서 처음 설명되지만 단순회귀분석에서도 사용되는 경우에는 단순회귀에 관한 예제도 함께 보여주었다.

회귀진단의 문제는 제1부의 여러 곳에서 설명되며, 일반화 선형모형과 비모수회귀문제는 제2부에서 소개된다. 이 두 가지 주제를 학부과정에 소개하는 것이 경우에 따라서는 무리일 수도 있을 것이다. 그러나, 앞에서 언급한 것처럼 이 두 가지 통계분석방법의 타당성이 계속 입증되고 있으며, 또한 통계소프트웨어를 활용하면 이 방법들을 쉽게 적용할 수 있다는 측면에서 이 두 방법들의 사용을 보편화시키고자하는 시도가 있어야 한다는 것이 저자들의 생각이다. 또한, 강의하시는 분은 내용의 난이도, 수강생의 수준 및 타 교과목의 형평을 고려하여 내용을 침삭할 수 있도록 표시해 두었다. 이 책은 한 학기 강의용으로도 사용할 수 있는데 이 경우 4,6,10,12장 등을 제외하는 것이바람직하다.

이 책에서는 단순한 이론의 설명보다는 이론을 활용한 실제 자료의 분석에 비중을 많이 두고자 하였다. 본문의 예제들은 이러한 목적으로 본문 내용의 단순한 반복이 아닌 추가적인 설명이 포함되고, 특히 자료분석을 할 때 주의할 점들이 많이 설명되어 있으므로 참조하면 좋을 것이다. 이 책에서는 또한 그림을 많이 삽입하려고 노력하였다. 그림은 모든 통계분석방법에서 기초적이면서 필수적인 도구가 되어야 한다는 것이 저자들의 의견이다. 그러므로, 기계적으로 분석방법을 적용하기보다는 최소한 분석 전에 자료의 산점도 등을 활용한 사전분석을 하고 분석의 매 단계마다 그림을 함께 활용하는 것을 강조하였다. 그리고, 자료분석에는 특정한 한가지 통계패키지만을 사용하지는 않았다. 현재 다양한 통계패키지가 사용되고 있고, 각각이 나름대로의 장점을 가지고 있으므로 각자의 환경에 알맞은 것을 선택하여 사용하면 될 것이다.

이 책은 부산대학교와 숭실대학교 통계학과에서 저자들이 다년간 회귀분석 및 기타 과목에서 사용한 강의노트를 중심으로 저술되었으며 출판되기까지 많은 분들께 신세를 졌다. 특히 내용의 결정적 오류를 지적하시고 수정까지 해 주신 서울대학교 김우철 교수님께 깊은 감사를 드린다. 그리고, 두 학교의 동료 교수님들의 협조와 격려를 잊을 수 없으며, 이 책의 내용에 여러 도움말을 주었던 충북대학교 조중재교수, 동아대학교 김성연교수, 인제대학교 배화수교수, 서울대학교 박병욱교수, 부산대학교 홍창곤교수, 부산대학교 정미선박사께 감사 드린다. 이 책을 만드는 과정에 여러 대학원생들의 도움도 컸었다. 편집과 교정은 부산대학교 대학원에 재학중인 김형순, 임지연, 황순영 양의 독수리 같은 눈과 섬세한 손이 없었으면 불가능했다. 3년 여 동안 가제본 형태로 불편한 가운데 사용하면서 여러 가지 조언을 해 준 수강생들, 이 책이 나오기까지 수년간 신경 써 주셨던 교우사 오판근사장

님과 편집부에게도 감사를 드린다. 가제본 형태의 교재를 매 학기 교정해 가면서 좋은 책이 되도록 최선을 다했으나 출판되는 이 시점에도 허전함과 불안감을 감출 수 없다. 이 책의 모든 내용과 형식의 오류는 저자들의 몫이며 많은 분들의 질책과 조언을 겸허하게 수용하여 개정판에 꼭 반영할 것을 약속 드린다.

1999년 8월

저자 드림

차례


제1부 고전적 선형회귀모형

제 1 장	기초통계이론	1
1.1	기본 용어	3
1.1.1	모집단과 표본	3
1.1.2	변수의 분류	3
1.2	자료의 기초적 분석	4
1.2.1	표와 그림을 이용한 자료분석	4
1.2.2	기본적 측도를 이용한 자료분석	7
1.3	확률변수와 확률표본	7
1.3.1	확률변수의 기댓값과 분산	8
1.3.2	결합확률분포	9
1.3.3	공분산과 상관계수	11
1.3.4	확률변수들의 선형결합	12
1.3.5	이산확률분포	13
1.3.6	정규분포	15
1.3.7	정규분포와 관련된 연속확률분포	18
1.3.8	확률벡터와 다변량정규분포	19
1.4	통계적 추정과 검정	22
1.4.1	추정량의 종류와 성질	22
1.4.2	최소제곱 추정치	24
1.4.3	최우 추정치	25
1.4.4	정규모집단에 대한 추론	26
1.5	테일러 근사법	30
1.5.1	테일러 급수전개	30
1.5.2	델타법	31
1.5.3	뉴턴-랩슨 반복	32
1.6	다중검정	33

1.6.1	다중검정의 예	33
1.6.2	제1종 오류	34
1.6.3	군 단위 오류율	35
1.6.4	위발견율	37
제 2 장	단순선행회귀모형	39
2.1	회귀분석의 기초개념	41
2.2	단순선행회귀모형	44
2.3	회귀계수의 추정	49
2.3.1	최소제곱법	49
2.3.2	최소제곱추정량의 성질	54
2.3.3	오차분산의 추정	56
2.3.4	최우추정법	57
2.4	회귀직선의 적합도	59
2.5	회귀의 분산분석	63
2.6	회귀분석에서의 추론	65
2.6.1	기울기 β_1 에 관한 추론	66
2.6.2	절편 β_0 에 관한 추론	68
2.6.3	Y 의 평균값에 관한 추론	70
2.7	잔차분석	74
2.8	원점을 지나는 회귀직선	81
2.9	상관분석	85
2.9.1	상관계수의 추정	86
2.9.2	상관계수의 검정	88
	연습문제	89
제 3 장	중선행회귀모형	97
3.1	중선행회귀모형	99
3.1.1	모집단 중회귀모형	99
3.1.2	선형모형과 비선형모형	101
3.1.3	행렬을 이용한 모형식	102
3.2	회귀계수의 추정	104

3.2.1	최소제곱법	104
3.2.2	최소제곱추정량의 성질	108
3.3	회귀직선의 적합도와 분산분석	110
3.4	이차형식과 제곱합의 분포	114
3.4.1	제곱합의 이차형식	114
3.4.2	제곱합의 분포	116
3.5	중회귀분석에서의 추론 I	120
3.5.1	회귀계수에 대한 추론	120
3.5.2	공동신뢰영역과 가설검정	123
3.5.3	동시신뢰구간	126
3.5.4	Y 의 평균에 대한 추론	129
3.5.5	잔차분석	131
3.6	중회귀분석에서의 추론 II	133
3.6.1	부분 F -검정	133
3.6.2	일반적 가설검정	138
3.6.3	설명변수의 추가	141
3.7	적합결여검정	144
3.8	기타 논제	148
3.8.1	회귀계수의 표준화	148
3.8.2	다중공선성	151
3.8.3	최소제곱법의 기하학적 의미	152
3.8.4	다변량 정규분포와의 관계	154
	연습문제	155
제 4 장	회귀진단	163
4.1	서론	165
4.2	잔차	166
4.2.1	내 표준화 잔차	167
4.2.2	외 표준화 잔차	168
4.3	지렛값	169
4.4	영향력 관측치	171
4.5	영향력 측도	173

4.5.1	소거법에 의한 측도	174
4.5.2	다른 방법에 의한 측도	179
4.6	이상치의 검정	184
4.7	다중공선성의 탐색	186
4.8	자기상관과 더빈-왓슨 검정	189
	연습문제	196
제 5 장	회귀모형의 선택	201
5.1	모형선택	203
5.1.1	모형선택의 필요성	203
5.1.2	예측오차	203
5.1.3	모형선택의 예	206
5.2	변수선택의 기준	207
5.2.1	R_p^2	211
5.2.2	R_{ap}^2 와 s_p^2	212
5.2.3	C_p	213
5.2.4	$PRESS_p$	215
5.3	변수선택의 방법	217
5.3.1	모든 가능한 회귀	217
5.3.2	앞으로부터의 단계적 회귀	218
5.3.3	앞으로 부터의 선택	220
5.3.4	뒤로 부터의 제거	221
5.4	모형의 확인	221
5.4.1	교차확인	221
5.4.2	훈련자료와 시험자료, 그리고 예측오차	222
5.5	변수선택의 진단	223
5.6	모형선택의 기타 논제	225
5.6.1	젠센 부등식과 칼백-라이블러 거리	225
5.6.2	AIC와 BIC	225
5.6.3	AIC의 정당성	227
5.6.4	선형모형에서 AIC의 응용	228
	연습문제	229

제 6 장	선형회귀모형의 변환 (dummy variable)	231
6.1	가변수를 이용한 회귀분석	233
6.1.1	하나의 가변수가 있는 경우	233
6.1.2	가변수 이용의 확장	237
6.1.3	회귀모형을 이용한 분산분석	240
6.2	다항회귀분석 (polynomial regression)	244
6.2.1	k차 다항회귀모형	244
6.2.2	반응표면분석 response analysis	247
6.3	가중 최소제곱법 (Weighted LSE) $\leftarrow \text{Var}(Y_i) = \sigma^2$	252
6.4	박스-콕스 변환 모형 $\leftarrow Y \sim N(X\beta, \sigma^2 I)$	257
6.5	로버스트 회귀	260
6.5.1	M - 추정량	261
6.5.2	영향력 함수	263
6.6	역회귀	266
연습문제		270
제2부 회귀모형의 확장		

제 7 장	편의추정법 (Biased Estimation)	275
7.1	재임스-슈타인 축소법	277
7.2	능형회귀 Ridge $\hat{\beta}_R = (X^T X + \lambda I)^{-1} X^T Y$: biased	279
7.2.1	능형회귀의 정의와 추정	279
7.2.2	능형회귀 추정치의 성질	282
7.3	주성분회귀 $\leftarrow$ 설명변수가 많을 때	285
7.4	부분최소제곱법	286
7.5	LASSO	287
7.5.1	LASSO의 정의와 추정	287
7.5.2	LASSO의 성질	289
7.6	예제	291
7.7	편의 추정치와 베이스 추정치	295
7.7.1	베이스 추정치	295

7.7.2	슈타인 축소추정치와 경험적 베이스 추정치	296
7.7.3	베이스 추정치와 회귀계수 추정치	298
	연습문제	299
제 8 장	일반화 선형모형 I	301
8.1	자료와 통계적 모형의 분류	303
8.2	지수 분포군 <i>237, 238, 239</i>	304
8.3	일반화 선형모형의 구성	307
8.4	회귀계수의 추정	309
8.5	모형의 적합도 <i>(GOF)</i>	312
8.6	가설 검정과 잔차	315
8.7	분산분석 모형	317
	연습문제	326
제 9 장	일반화 선형모형 II	329
9.1	로지스틱 회귀 모형 <i>$Y \sim \text{Binomial}$</i>	331
9.1.1	이항분포와 이진자료 <i>$n \text{ Bernoulli}$</i>	331
9.1.2	로지스틱 회귀모형	332
9.1.3	중간값의 추정	337
9.1.4	최소제곱법의 이용	338
9.1.5	다항 분포와 다진 자료	340
9.2	로그선형모형 <i>$Y \sim P(\text{이항분포})$</i>	342
9.2.1	범주형 자료 <i>237, 238, 239</i>	342
9.2.2	포아송 분포와 다항분포 <i>237, 238, 239</i>	343
9.2.3	로그 선형모형	347
9.3	과산포 <i>237, 238, 239</i>	350
9.3.1	이항분포의 과산포	350
9.3.2	포아송분포의 과산포	353
9.4	로그 선형 모형과 로지스틱 모형과의 관계	354
	연습문제	355
제 10 장	비선형회귀모형	359
10.1	비선형회귀모형	361

regression { parametric (known) $f(x) = \beta_0 + \beta_1 x_1 + \dots + \beta_p x_p$
 (non-parametric (unknown)) $f(x) = \frac{e^{\beta_0 x_0}}{1 + e^{\beta_1 x_1}}$

차례 xiii

10.2	모수의 추정	363
10.2.1	최소제곱법	363
10.2.2	가우스-뉴턴 방법	364
10.2.3	초기치의 계산	366
10.3	비선형회귀분석에서의 추론	368
	연습문제	372
제 11 장	비모수회귀모형	373
11.1	서론	375
11.1.1	비모수회귀모형	375
11.1.2	바람직한 회귀함수	376
11.1.3	평활의 개념	377
11.2	커널 추정법	379
11.2.1	커널 추정치	379
11.2.2	국소 다항회귀	383
11.3	급수 추정법	388
11.3.1	함수공간이론	388
11.3.2	급수추정치	390
11.3.3	웨이브렛 추정치	391
11.4	스플라인 추정법	396
11.4.1	회귀 스플라인	396
11.4.2	B - 스플라인	400
11.4.3	평활 스플라인	402
11.4.4	평활모수의 추정	404
11.4.5	비모수 회귀진단	405
11.5	예제	408
11.5.1	성장곡선 자료	408
11.5.2	볼트하강 자료	410
11.5.3	과통화팽창 자료	411
11.6	비모수 중회귀모형	414
11.6.1	가법모형과 일반화 가법모형 (GAM)	414
11.6.2	변수변환모형	415

11.10.1

11.6.3 교호작용모형	417
연습문제	419
제 12 장 중도절단자료의 회귀모형	421
12.1 생존함수와 위험함수	423
12.2 중도절단 자료	424
12.2.1 우측중도절단자료	424
12.2.2 구간중도절단자료	427
12.3 생존함수의 추정	428
12.3.1 모수적 추정	428
12.3.2 비모수적 추정	430
12.4 콕스회귀모형	435
12.4.1 비례위험모형	435
12.4.2 회귀계수의 추정	437
12.4.3 생존함수의 추정	439
12.5 선형회귀모형	440
12.5.1 가속수명모형	441
12.5.2 밀러 추정치	443
12.5.3 바클리-재임스 추정치	444
연습문제	446

부록

부록 A 행렬이론	449
A.1 기본적인 이론	450
A.1.1 여러 형태의 행렬	450
A.1.2 행렬의 트레이스	451
A.1.3 행렬식	451
A.2 역행렬	452
A.2.1 선형독립과 선형종속	452
A.2.2 행렬의 계수	453
A.2.3 역행렬	454

A.2.4	특수한 행렬의 역행렬	456
A.2.5	일반화 역행렬	456
A.2.6	역행렬의 계산적 문제	459
A.3	분할된 행렬	460
A.4	고유치와 고유벡터	462
A.4.1	고유치의 정의	462
A.4.2	고유치의 성질	463
A.5	이차형식과 양정치행렬	464
A.5.1	이차형식	464
A.5.2	양정치행렬	465
A.6	정사영과 행렬의 분해	467
A.6.1	정사영	467
A.6.2	행렬의 분해	468
A.7	행렬의 기타 논제	470
A.7.1	합벡터와 중심화 행렬	470
A.7.2	행렬의 미분	471
A.7.3	크로네커 곱	471
A.7.4	벡	472
부록 B	통계분포표	473
표.1	표준정규분포표	474
표.2	χ^2 분포표	475
표.3	t 분포표	476
표.4	F 분포표	477
표.5	본페로니 동시신뢰구간을 위한 t 값	481
표.6	최대계수 t 동시신뢰구간을 위한 백분위수	482
표.7	더빈-왓슨 검정의 기각역	483
참고문헌		485
찾아보기		490